Analyse socio-économique et sanitaire des pays du monde

Diane ANATO et Patrice KOLIE

TABLE DE MATIÈRES

Introduction **2**
Présenter les données . . . 3

Présentation de la base de données **3**
Source des données . . . 3
Variables qualitatives . . . 3
Variables quantitatives . . . 4

Traitement initial et mise en forme des données **5**
Introduction des valeurs manquantes dans la base de données . . . 8

Analyse exploratoire des données **8**
Analyse descriptive univariée . . . 8
Qualitative . . . 11
Méthode d'imputationn par les données externes . . . 14
Traitement des NA pour la variable Région_géographique . . . 14
Variables quantitatives . . . 19
Méthode d'imputation par le solde commercial . . . 21

Troisième Imputations **22**
Tableau des Statistiques des données quantitatives . . . 26
Histogramme des variables quantatives . . . 27
Histogramme quanti et Niveau_développement . . . 36
Boxplot . . . 41
Boxplot des quanti avec le niveau de developpment . . . 41

Analyse descriptive bivariée **55**
Quali - Quali . . . 55

Quanti-quanti **58**
Matrice de correlation 58
Nuage de point 61
Méthode d'imputation par les MCO 74
Methode d'imputation par la moyenne 82

Imputation par l'ACP **85**
Méthode d'imputation par l'ACP 91

Imputation multiple (Mice) **101**
Resultat 107
Conclusion 109
Bibilographie 109

Introduction

Aujourd'hui, de plus en plus de fossés se creusent entre les pays développés et les pays en développement en termes de richesse. Les pays riches continuent de s'enrichir, tandis que les pays les plus pauvres demeurent dans la pauvreté. Cette situation peut s'expliquer par des politiques de développement inefficaces, un manque de volonté politique dans certains pays, ou encore par des rapports de force internationaux qui maintiennent certains États dans la précarité, à travers des pratiques de concurrence déloyale, des embargos, des conflits armés et une instabilité politique persistante.

Face à ces inégalités durables, plusieurs questions se posent : comment aider les pays les plus vulnérables et comment réduire ces écarts de richesse ? C'est donc dans cette perspective que nous nous poserons la question suivante : quels sont les principaux facteurs expliquant les disparités de développement entre les pays, et comment les données socio-économiques et sanitaires permettent-elles de les identifier ?
Dans un premier temps, nous présenterons la base de données ainsi que les indicateurs utilisés, tels que le PIB, la mortalité infantile, l'espérance de vie, les dépenses dans la santé etc… Dans un second temps, nous expliciterons les méthodes de traitement des données, notamment le nettoyage des données, l'analyse descriptive réalisée et, enfin, les méthodes de remplacement des valeurs manquantes.

L'objectif de cette étude est d'identifier les leviers prioritaires d'investissement susceptibles de favoriser le développement des pays les plus défavorisés. Dans cette perspective analytique, et en se plaçant dans le rôle d'un futur data analyst, nous mènerons cette analyse à partir d'une base de données qui reste néanmoins loin d'être exhaustive. En effet, la comparaison entre pays nécessite bien plus qu'un nombre limité de variables. Toutefois, nous ferons l'hypothèse que cette base de données est suffisamment représentative et qu'une interprétation rigoureuse des données permettra de répondre de manière pertinente à la problématique posée.

Présenter les données

Notre base de données provient de Kaggle et contient des indicateurs socio-économiques et de santé pour plusieurs pays. Elle comprend 10 colonnes et 167 observations, chaque observation correspondant à un pays. Les variables décrivent différents aspects du niveau de développement et de la situation géographique des pays. À première vue, cette base de données sur Kaggle avait été principalement conçue pour identifier les pays nécessitant une aide urgente. Cependant, notre problématique est différente : nous nous intéressons aux sources d'inégalités des ressources. La problématique originale est bien détaillée sur Kaggle, et afin d'éviter de simplement reproduire ou nous inspirer du travail des auteurs, il nous a semblé nécessaire d'aller au-delà de cette exploitation initiale. Pour approfondir l'analyse et apporter une réelle valeur ajoutée à notre travail, nous avons donc décidé d'enrichir la base de données. Dans cette optique, nous avons créé trois nouvelles variables : Niveau de développement , Zone géographique (qualitative) et la Balance commerciale (quantitative), Nous présentons à présent la description détaillée des variables.

Présentation de la base de données

Source des données

Variables qualitatives

Country (Pays)

La variable pays représente le nom des États. Notre base de données couvre environ 85 % des pays du monde, soit 167 sur 197. Cette variable sert d'index principal dans l'étude.

Region_geographique (Région géographique)

Cette variable, ajoutée à notre base de données par nous-même, regroupe les pays en fonction de leur situation géographique, en s'appuyant sur plusieurs sources fiables (Wikipédia, ONU, CIA World Factbook, EMIW, etc.). Les zones retenues sont : Afrique, Amérique, Asie, Europe, Océanie.

Niveau_de_développement

La variable Niveau_de_développement est une variable que nous avons créée afin d'adapter la base de données à notre problématique. Elle permet d'analyser les différences entre pays selon leur niveau de développement et constitue un élément central de notre étude. Les pays sont classés en quatre catégories principales : développé, en développement, émergent et sous-développé. Cette classification s'appuie sur plusieurs sources fiables, notamment le FMI, la

Banque mondiale, l'UNCTAD et des analyses économiques spécialisées (BNP Paribas), afin de refléter à la fois les critères économiques et les indicateurs de développement. Elle offre ainsi un cadre cohérent pour comparer les pays et évaluer leur position dans le contexte mondial.

Variables quantitatives

Child_mort (Mortalité infantile)

Cette variable mesure la mortalité infantile (le nombre d'enfants de moins de 5 ans décédés pour 1 000 naissances vivantes). En 2021, environ 5 millions d'enfants sont morts avant l'âge de 5 ans, et 1,9 million sont nés morts (DHS Program, 2015 ; UNICEF France, s.d.). Cet indicateur est essentiel pour évaluer le niveau de développement d'un pays, car il reflète la qualité des services de santé, de la nutrition et des conditions de vie. Il constitue également une composante de l'Indice de Développement Humain (IDH).

Exports (exportation)

La variable Exports mesure les exportations de biens et services par habitant, exprimées en pourcentage du PIB par habitant. Elle reflète la capacité d'un pays à vendre des biens et services à l'étranger (Douane Française, s.d.; CCI Paris IDF, s.d.).

Health (Dépenses de santé) :

La variable Health mesure les dépenses totales de santé par habitant, exprimées en pourcentage du PIB. Elle inclut la consommation de biens et services médicaux, tels que les soins curatifs, la réadaptation, la prévention et les services de santé publique. Ces dépenses sont financées par des régimes publics obligatoires et/ou des assurances privées (OCDE, s.d.; IRDES, s.d.).

Imports (Importations)

La variable Imports mesure les importations de biens et services par habitant, exprimées en pourcentage du PIB. Elle reflète l'entrée de biens et services achetés à l'étranger, ce qui permet aux pays d'accéder à des matières premières, des technologies et des savoir-faire, tout en générant des flux financiers (SumUp, s.d.; Eurofiscalis, s.d.).

Income (Revenu)

La variable Income mesure le revenu net par personne, reflétant le bien-être économique d'une population. Un revenu élevé favorise l'accès à l'alimentation, à l'éducation, aux soins de santé et au logement, et constitue un indicateur clé de la qualité de vie (AskFilo, s.d.).

Inflation

La variable Inflation mesure la hausse générale et durable des prix dans un pays, entraînant une perte du pouvoir d'achat. Lorsque les prix augmentent, une même somme d'argent permet d'acheter moins de biens et services (Wikipédia, s.d.). Bien que le lien avec le développement soit moins direct que pour d'autres indicateurs économiques, une inflation stable et faible est généralement caractéristique des pays développés, reflétant la stabilité économique et la capacité des autorités à réguler les marchés.

Life_expec (Espérance de vie)

La variable Life_expec mesure le nombre moyen d'années qu'un nouveau-né pourrait espérer vivre si les tendances actuelles en matière de mortalité restaient inchangées (Wikipédia, s.d.). Cet indicateur est largement utilisé pour évaluer le développement humain, car il reflète les conditions sanitaires, l'accès aux soins de santé, la nutrition et le niveau de vie.

Total_fer (Fécondité totale)

Cette variable mesure le nombre moyen d'enfants qu'une femme pourrait avoir si les taux de fécondité par âge restaient constants (Eurostat, s.d.). Cet indicateur est un élément clé de l'analyse démographique, permettant d'évaluer la reproduction et la croissance de la population.

GDPp (PIB par habitant):

La variable GDPp mesure le produit intérieur brut par habitant, calculé en divisant le PIB total d'un pays par sa population totale (FERDI, s.d.). Cet indicateur permet d'évaluer la richesse moyenne produite par habitant et sert à comparer le niveau économique entre pays.

Balance commercial

Cette variable a été crée par nous-même, elle mesure la différence entre la valeur des biens et services exportés et celle des biens et services importés par un pays sur une période donnée (Eurostat, s.d.; AvaTrade, s.d.). Elle indique si un pays vend davantage de produits à l'étranger qu'il n'en achète, reflétant ainsi sa capacité à générer des revenus grâce au commerce international.

Traitement initial et mise en forme des données

```r
##  Packages utilisés
rm(list = ls())

library(dplyr)
```

```
Attachement du package : 'dplyr'

Les objets suivants sont masqués depuis 'package:stats':

    filter, lag

Les objets suivants sont masqués depuis 'package:base':

    intersect, setdiff, setequal, union
```

```r
library(tidyverse)
```

```
-- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
v forcats   1.0.0     v readr     2.1.4
v ggplot2   3.4.2     v stringr   1.5.0
v lubridate 1.9.2     v tibble    3.2.1
v purrr     1.0.1     v tidyr     1.3.0

-- Conflicts ------------------------------------------ tidyverse_conflicts() --
x purrr::%||%()   masks base::%||%()
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to beco
```

```r
library(readxl)
```

```
Warning: le package 'readxl' a été compilé avec la version R 4.4.3
```

```r
library(readr)
library(naniar)
```

```
Warning: le package 'naniar' a été compilé avec la version R 4.4.3
```

```
library(gridExtra)
```

```
Attachement du package : 'gridExtra'

L'objet suivant est masqué depuis 'package:dplyr':

    combine
```

```
library(writexl)
```

```
Warning: le package 'writexl' a été compilé avec la version R 4.4.3
```

```
library(corrplot)
```

```
corrplot 0.92 loaded
```

```
library(missMDA)
```

```
Warning: le package 'missMDA' a été compilé avec la version R 4.4.3
```

Il s'agit ici de tous les packages qu'on a utilisé tout au longde ce projet

```
# Import de la base de l'ancienne donnée
library(readxl)
bdd_projet <- read_excel("bdd_projet.xlsx")
```

```
### conversion de types
bdd_projet[c(2,3)]=lapply(bdd_projet[,c(2,3)],as.factor)
```

```
### Changement de nom des variables
bdd_projet <- bdd_projet |>
  rename(
    Mortalité_infantile = child_mort,
    Exportation = exports,
    Dépenses_santé = health,
    Importation = imports,
    Revenu = income,
```

```
    Inflation = inflation,
    Espérance_vie = life_expec,
    Fécondité_totale = total_fer,
    PIB_par_habitant = gdpp
  )
```

Introduction des valeurs manquantes dans la base de données

```
#
# # reproductibilité
# set.seed(92)
#
# # Variables et nombre de NA à introduire
# vars_prend_na <- c("Région_géographique","Mortalité_infantile", "Exportation", "Dépenses_sa
#
# nb_na <- c(10, 6, 11, 9, 7, 10, 15, 14, 8, 13, 12)
#
# # Boucle
# for (i in seq_along(vars_prend_na)) {
#   indices_na <- sample(seq_len(nrow(bdd_projet)), size = nb_na[i], replace = FALSE)
#   bdd_projet[indices_na, vars_prend_na[i]] <- NA
# }
#
#
# # Sauvegarder en Excel
# writexl::write_xlsx(bdd_projet, "DIANE.xlsx")
```

```
#Charger depuis Excel
library(readxl)
DIANE_PATRICE <- read_excel("DIANE.xlsx")
```

Analyse exploratoire des données

Analyse descriptive univariée

```
### Vérification de la structure des données

str(DIANE_PATRICE)
```

```
tibble [167 x 13] (S3: tbl_df/tbl/data.frame)
 $ Pays                 : chr [1:167] "Afghanistan" "Afrique du Sud" "Albanie" "Algérie" ...
 $ Région_géographique  : chr [1:167] "Asie" "Afrique" "Europe" "Afrique" ...
 $ Niveau_développement: chr [1:167] "Sous-développé" "Émergent" "En développement" "En déve
 $ Mortalité_infantile : num [1:167] 90.2 53.7 16.6 27.3 4.2 119 10.3 15.7 14.5 18.1 ...
 $ Exportation          : num [1:167] 10 28.6 28 38.4 42.3 62.3 45.5 49.6 18.9 20.8 ...
 $ Dépenses_santé       : num [1:167] 7.58 8.94 6.55 4.17 11.6 2.85 6.03 4.29 8.1 4.4 ...
 $ Importation          : num [1:167] 44.9 27.4 48.6 31.4 37.1 42.9 58.9 NA 16 45.3 ...
 $ Revenu               : num [1:167] 1610 12000 9930 12900 40400 5900 19100 45400 18700 6700
 $ Inflation            : num [1:167] 9.44 6.35 4.49 16.1 0.758 NA 1.44 17.2 20.9 7.77 ...
 $ Espérance_vie        : num [1:167] 56.2 54.3 76.3 76.5 80.1 60.1 76.8 NA 75.8 73.3 ...
 $ Fécondité_totale     : num [1:167] 5.82 2.59 1.65 2.89 1.39 6.16 2.13 2.96 NA 1.69 ...
 $ PIB_par_habitant     : num [1:167] 553 7280 NA 4460 41800 NA 12200 19300 10300 3220 ...
 $ Balance_commerciale : num [1:167] -34.9 NA -20.6 7 5.2 19.4 -13.4 16.6 2.9 -24.5 ...
```

```
dim(DIANE_PATRICE)
```

```
[1] 167  13
```

```
summary(DIANE_PATRICE)
```

```
     Pays           Région_géographique Niveau_développement
 Length:167         Length:167          Length:167
 Class :character   Class :character    Class :character
 Mode  :character   Mode  :character    Mode  :character



 Mortalité_infantile  Exportation      Dépenses_santé    Importation
 Min.   :  2.60       Min.   :  0.109   Min.   : 1.810   Min.   :  0.0659
 1st Qu.:  7.80       1st Qu.: 22.800   1st Qu.: 4.973   1st Qu.: 29.8250
 Median : 19.30       Median : 35.000   Median : 6.570   Median : 43.2500
 Mean   : 38.14       Mean   : 40.605   Mean   : 6.924   Mean   : 46.2685
 3rd Qu.: 62.00       3rd Qu.: 50.825   3rd Qu.: 8.710   3rd Qu.: 58.9000
 Max.   :208.00       Max.   :200.000   Max.   :17.900   Max.   :154.0000
 NA's   :6            NA's   :11        NA's   :9        NA's   :7
     Revenu         Inflation       Espérance_vie   Fécondité_totale
 Min.   :   609   Min.   : -4.210   Min.   :32.10   Min.   :1.150
 1st Qu.:  3720   1st Qu.:  1.830   1st Qu.:65.50   1st Qu.:1.785
 Median : 10400   Median :  5.415   Median :73.10   Median :2.410
```

```
 Mean   : 17280   Mean   :  7.890   Mean   :70.74   Mean   :2.962
 3rd Qu.: 22700   3rd Qu.: 10.675   3rd Qu.:76.80   3rd Qu.:3.995
 Max.   :125000   Max.   :104.000   Max.   :82.80   Max.   :7.490
 NA's   :10       NA's   :15        NA's   :14      NA's   :8
 PIB_par_habitant Balance_commerciale
 Min.   :   231   Min.   :-73.500
 1st Qu.:  1310   1st Qu.:-14.850
 Median :  4670   Median : -5.100
 Mean   : 12657   Mean   : -5.516
 3rd Qu.: 13400   3rd Qu.:  4.500
 Max.   :105000   Max.   : 39.400
 NA's   :13       NA's   :12
```

```r
# conversion de Région_géographique en factor
DIANE_PATRICE[c(2,3)]=lapply(DIANE_PATRICE[,c(2,3)],as.factor)
```

Avant de procéder à l'analyse des données et au traitement des valeurs manquantes, un travail de préparation a été réalisé afin de rendre la base exploitable sous R. Les données ont été importées depuis un fichier excel.

Une première vérification de la structure des données a été effectuée afin d'identifier le type des variables et la dimension de la base. Certaines variables ont été converties dans un format approprié (variables qualitatives en facteurs et variables quantitatives en numériques).

```r
plot(DIANE_PATRICE)
```

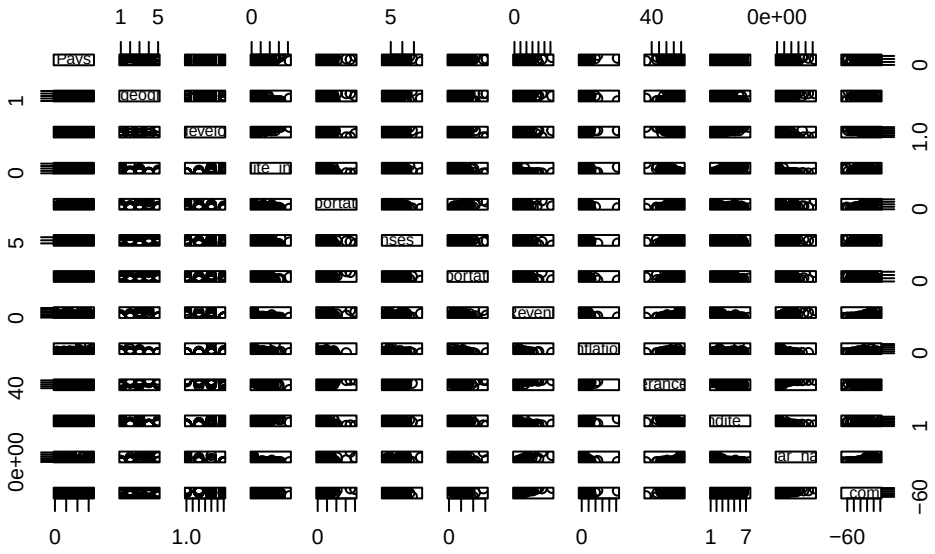


Figure 1: Répartition en diagramme en barre selon le région géographique

NOus avons fait avec plot() la visualisation des relations entre toutes les paires de variables d'un seul coup d'œil.

```
### vecteur couleur

vecteur_couleur <-c(
  "Développé" ="darkturquoise",
  "Émergent" = "darkorange",
  "En développement"="darkviolet",
  "Sous-développé"="darkgray",
  "Afrique"="lightblue",
  "Amérique"="lightpink",
  "Asie"="darkkhaki",
  "Europe"="darkgoldenrod",
  "Océanie"="brown")
```

Qualitative

```r
# Répartition des pays selon le niveau de développement

DIANE_PATRICE |>
  count(Niveau_développement) |>
  knitr::kable(
    caption = "Répartition des pays selon le niveau de développement")
```

Table 1: Répartition des pays selon le niveau de développement

Niveau_développement	n
Développé	30
Émergent	27
En développement	71
Sous-développé	39

Dans notre base de donnée nous avons 71 pays en développement contre 27 pays émergents, 30 pays développé contre 39 pays sous-développé.

```r
# Répartition des pays selon la région géographique

DIANE_PATRICE |>
  count( Région_géographique) |>
  knitr::kable(
    caption = "Répartition des pays selon la région géographique")
```

Table 2: Répartition des pays selon la région géographique

Région_géographique	n
Afrique	44
Amérique	26
Asie	41
Europe	38
Océanie	8
NA	10

Présence de 10 valeurs manquantes. Très faibles représentation des pays de l'océanie.

```r
# Répartition des pays selon le niveau de développement et la région géographique
DIANE_PATRICE |>
  count(Niveau_développement, Région_géographique) |>
  knitr::kable(
    caption = "Répartition des pays selon le niveau de développement et la région géographiqu
  )
```

Table 3: Répartition des pays selon le niveau de développement et la région géographique

Niveau_développement	Région_géographique	n
Développé	Amérique	2
Développé	Asie	2
Développé	Europe	23
Développé	Océanie	1
Développé	NA	2
Émergent	Afrique	3
Émergent	Amérique	4
Émergent	Asie	12
Émergent	Europe	6
Émergent	NA	2
En développement	Afrique	15
En développement	Amérique	19
En développement	Asie	20
En développement	Europe	9
En développement	Océanie	5
En développement	NA	3
Sous-développé	Afrique	26
Sous-développé	Amérique	1
Sous-développé	Asie	7
Sous-développé	Océanie	2
Sous-développé	NA	3

Il s'agit d'un tableau de contingence, qui met en évidence les combinaisons possibles des pays en fonction de leur Niveau de développement et leur région géographique. Pas de valeurs manquantes dans la distribution de la variable Niveau_développement, mais il y en 10 dans la variable Région_géographique.

Méthode d'imputationn par les données externes

Traitement des NA pour la variable Région_géographique

```
#Afficher les lignes où "Région_géographique" est manquante
indices_région <- which(is.na(DIANE_PATRICE$Région_géographique))

# le nom des pays correspondants à ces lignes
DIANE_PATRICE$Pays[indices_région]
```

```
 [1] "Angola"           "Arménie"          "Azerbaïdjan"      "Cambodge"
 [5] "Finlande"         "Libye"            "Nouvelle-Zélande" "Pérou"
 [9] "Slovaquie"        "Tanzanie"
```

```
# connaissant le continent, un Vecteur a été créé
continent_manquant <- c("Afrique", "Europe", "Europe", "Asie", "Europe",
           "Afrique", "Océanie", "Amérique", "Europe", "Afrique")

# Remplacer les continent par pays
DIANE_PATRICE$Région_géographique[indices_région] <- continent_manquant

# Vérification
summary(DIANE_PATRICE$Région_géographique)
```

```
 Afrique Amérique     Asie   Europe  Océanie
      47       27       42       42        9
```

```
# verication de toute la base de donnée
summary(DIANE_PATRICE)
```

```
     Pays           Région_géographique       Niveau_développement
 Length:167         Afrique :47         Développé       :30
 Class :character   Amérique:27         Émergent        :27
 Mode  :character   Asie    :42         En développement:71
                    Europe  :42         Sous-développé  :39
                    Océanie : 9

 Mortalité_infantile  Exportation      Dépenses_santé    Importation
```

```
 Min.   :  2.60      Min.   :  0.109   Min.   : 1.810   Min.   :  0.0659
 1st Qu.:  7.80      1st Qu.: 22.800   1st Qu.: 4.973   1st Qu.: 29.8250
 Median : 19.30      Median : 35.000   Median : 6.570   Median : 43.2500
 Mean   : 38.14      Mean   : 40.605   Mean   : 6.924   Mean   : 46.2685
 3rd Qu.: 62.00      3rd Qu.: 50.825   3rd Qu.: 8.710   3rd Qu.: 58.9000
 Max.   :208.00      Max.   :200.000   Max.   :17.900   Max.   :154.0000
 NA's   :6           NA's   :11        NA's   :9        NA's   :7
    Revenu         Inflation       Espérance_vie   Fécondité_totale
 Min.   :   609   Min.   : -4.210   Min.   :32.10   Min.   :1.150
 1st Qu.:  3720   1st Qu.:  1.830   1st Qu.:65.50   1st Qu.:1.785
 Median : 10400   Median :  5.415   Median :73.10   Median :2.410
 Mean   : 17280   Mean   :  7.890   Mean   :70.74   Mean   :2.962
 3rd Qu.: 22700   3rd Qu.: 10.675   3rd Qu.:76.80   3rd Qu.:3.995
 Max.   :125000   Max.   :104.000   Max.   :82.80   Max.   :7.490
 NA's   :10       NA's   :15        NA's   :14      NA's   :8
 PIB_par_habitant Balance_commerciale
 Min.   :   231   Min.   :-73.500
 1st Qu.:  1310   1st Qu.:-14.850
 Median :  4670   Median : -5.100
 Mean   : 12657   Mean   : -5.516
 3rd Qu.: 13400   3rd Qu.:  4.500
 Max.   :105000   Max.   : 39.400
 NA's   :13       NA's   :12
```

Nous avons remplacé les valeurs manquantes de la variable région_géographique par une méthode d'imputation simple. Celle-ci consiste à identifier la région correspondante à chaque pays à partir des continents déjà connus. Pour ce faire, nous nous sommes appuyés sur des recherches effectuées sur Internet, en mobilisant différentes sources fiables. Ainsi, les données manquantes de cette variable ont pu être complétées.

```
library(dplyr)

vars_quanti <-DIANE_PATRICE|>
  select(where(is.numeric)) |>
  names()

vars_quanti
```

```
 [1] "Mortalité_infantile" "Exportation"         "Dépenses_santé"
 [4] "Importation"         "Revenu"              "Inflation"
 [7] "Espérance_vie"       "Fécondité_totale"    "PIB_par_habitant"
[10] "Balance_commerciale"
```

```r
DIANE_PATRICE |>
  count(Région_géographique, name = "effectif") |>
  mutate(
    pourcentage = effectif / sum(effectif) * 100,
    label = paste0(round(pourcentage, 1), " %")
  ) |>
  ggplot(aes(x = "", y = effectif, fill = Région_géographique)) +
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y") +
  geom_text(
    aes(label = label),
    position = position_stack(vjust = 0.5),
    size = 4
  ) +
  scale_fill_manual(values = vecteur_couleur) +
  theme_void()
```

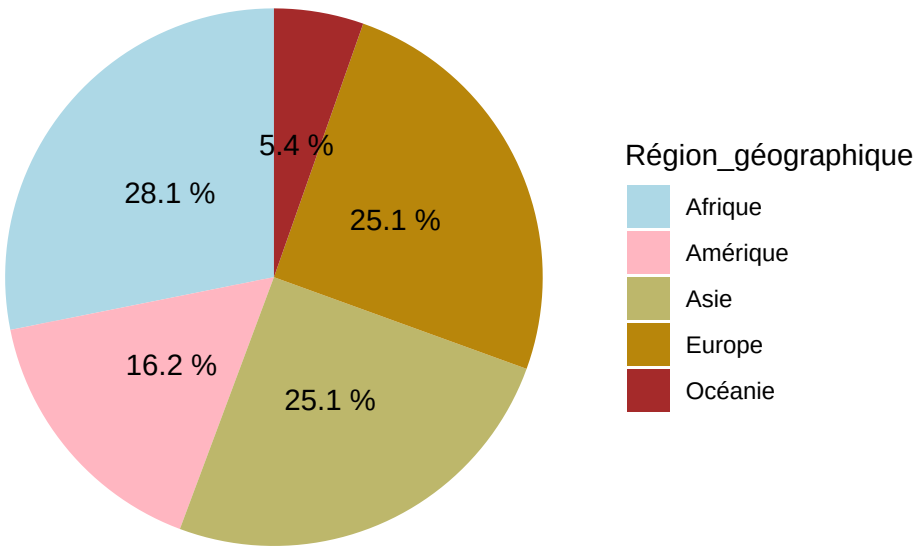


Figure 2: Répartition en diagramme circulaire selon la Région géographique

Chaque portion du cercle correspond à une région géographique, et la taille de la portion indique la part (en pourcentage) de cette région dans l'ensemble des données.

La distribution montre que les données sont principalement concentrées en Afrique, en Asie et en Europe, qui totalisent ensemble plus de 78 % des observations. À l'inverse, l'Océanie est faiblement représentée, ce qui peut s'expliquer par le nombre limité de pays dans cette région ou par la structure du jeu de données.

```
DIANE_PATRICE |>
  count(Niveau_développement) |>
  mutate(
    pourcentage = n / sum(n) * 100,
    label = paste0(round(pourcentage, 1), " %")
  ) |>
  ggplot(aes(x = "", y = n, fill = Niveau_développement)) +
  geom_bar(stat = "identity", width = 1) +
  coord_polar("y") +
  geom_text(
    aes(label = label),
    position = position_stack(vjust = 0.5),
    size = 4
  ) +
    scale_fill_manual(values = vecteur_couleur) +
  theme_void()
```

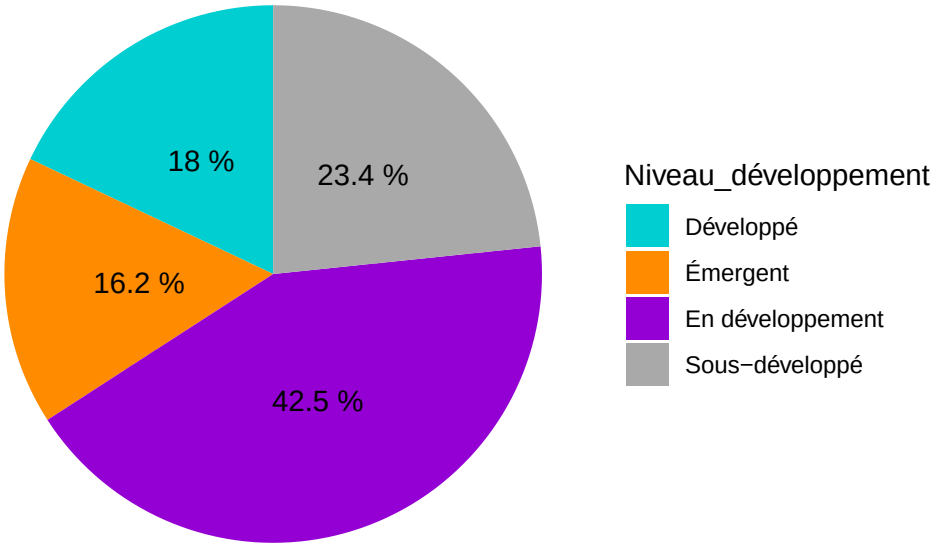


Figure 3: Répartition en diagramme circulaire selon le niveau de développement

Ce graphique représente la répartition des pays selon leur niveau de développement. Les pourcentages indiquent la proportion de pays dans chaque catégorie. La majorité des pays dans ce graphique (42,5 %) sont encore en développement, tandis qu'une minorité seulement (18 %) sont développés. Cela montre un déséquilibre global dans le niveau de développement à travers le monde.

```
DIANE_PATRICE |>
  ggplot() +
  aes(x = Niveau_développement, fill = Niveau_développement) +
  geom_bar() +
  scale_fill_manual(values = vecteur_couleur) +
  theme_classic()
```

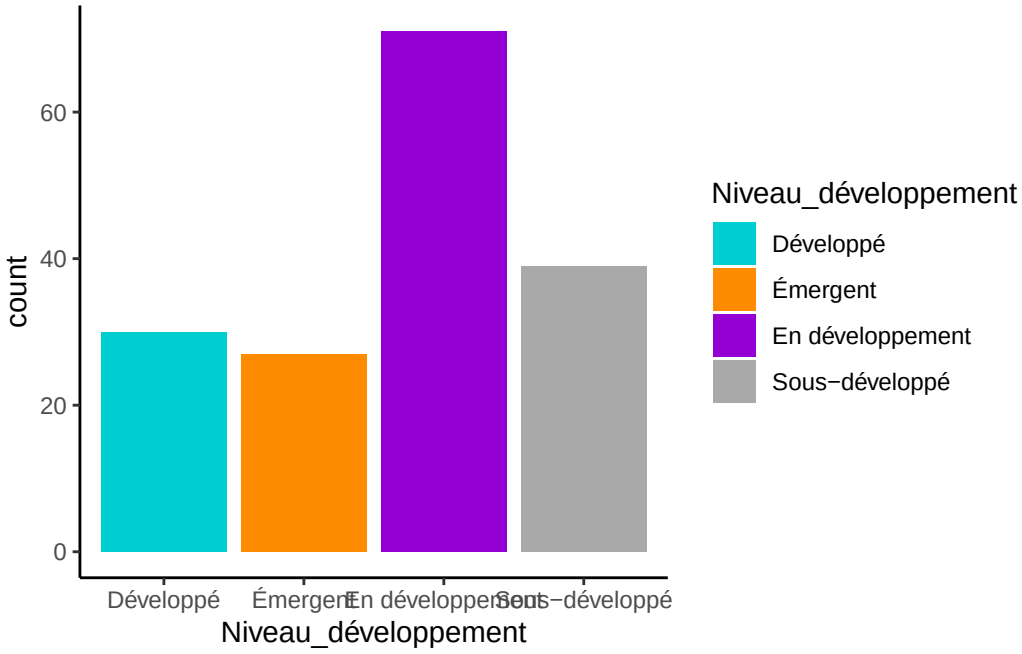


Figure 4: Répartition en diagramme en barre selon le niveau de développement

La majorité des pays sont encore en développement, ce qui confirme ce qu'on voyait dans le camembert.

```
DIANE_PATRICE |>
  ggplot() +
  aes(x = Région_géographique, fill = Région_géographique) +
  geom_bar() +
```

```
  scale_fill_manual(values = vecteur_couleur) +
  theme_classic()
```

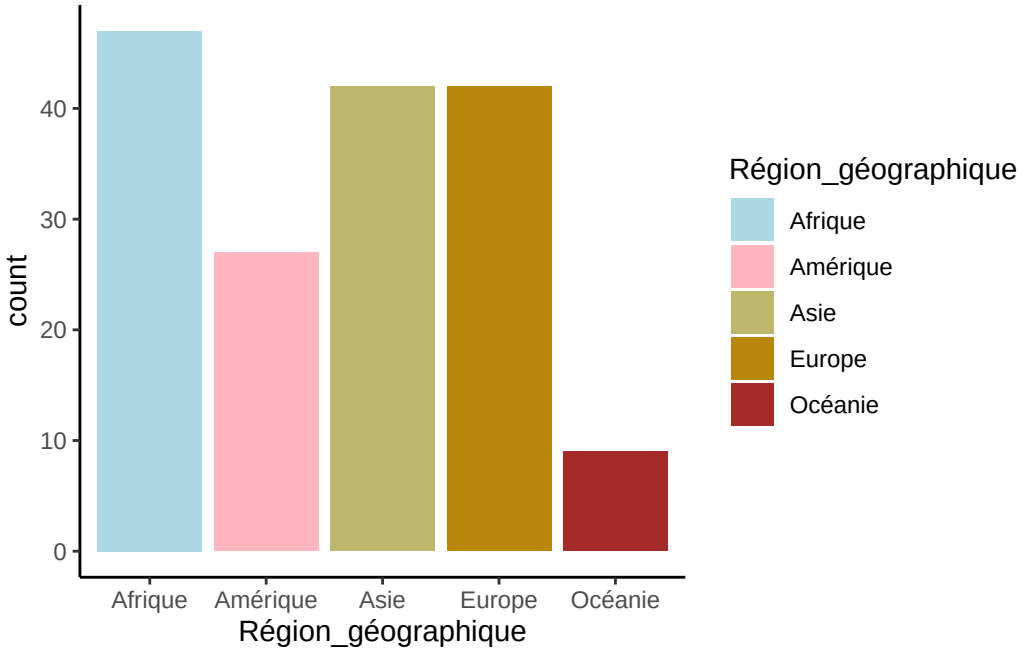
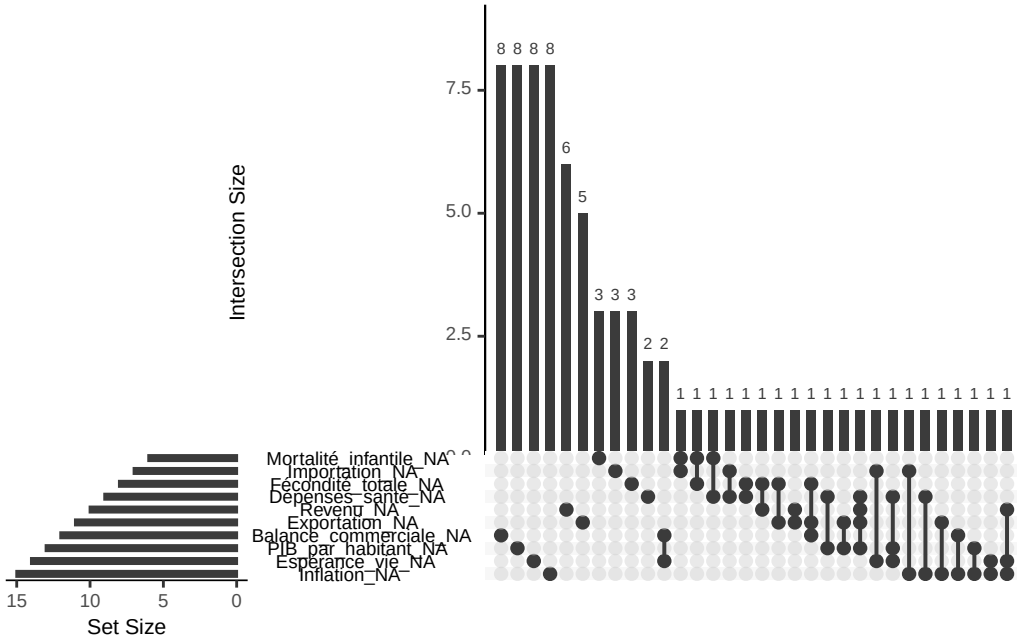


Figure 5: Répartition en diagramme en barre selon le région géographique

Ce graphique montre la distribution des données selon les régions géographiques, avec l'Afrique, l'Asie et l'Europe en tête, et l'Océanie.

Variables quantitatives

```
# Visualisation des valeurs manquantes
gg_miss_upset(DIANE_PATRICE, nset=12)
```




```
miss_var_summary(DIANE_PATRICE)
```

```
# A tibble: 13 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 Inflation                15     8.98
 2 Espérance_vie            14     8.38
 3 PIB_par_habitant         13     7.78
 4 Balance_commerciale      12     7.19
 5 Exportation              11     6.59
 6 Revenu                   10     5.99
 7 Dépenses_santé            9     5.39
 8 Fécondité_totale          8     4.79
 9 Importation               7     4.19
10 Mortalité_infantile       6     3.59
11 Pays                      0     0
12 Région_géographique       0     0
13 Niveau_développement      0     0
```

Méthode d'imputation par le solde commercial

```
# Code pour affecter les valeurs manquantes des importation , exportation et balance_commerci

DIANE_complete <- DIANE_PATRICE |>
  mutate(
    # Imputation de Balance_commerciale si elle est NA
    Balance_commerciale = if_else(
      is.na(Balance_commerciale) & !is.na(Exportation) & !is.na(Importation),
      Exportation - Importation,
      Balance_commerciale
    ),
    # Imputation d'Importation si elle est NA
    Importation = if_else(
      is.na(Importation) & !is.na(Exportation) & !is.na(Balance_commerciale),
      Exportation - Balance_commerciale,
      Importation
    ),
    # Imputation d'Exportation si elle est NA
    Exportation = if_else(
      is.na(Exportation) & !is.na(Balance_commerciale) & !is.na(Importation),
      Balance_commerciale + Importation,
      Exportation
    )
  )
```

Dans un premier temps, l'analyse descriptive et l'exploration graphique ont mis en évidence la présence de valeurs manquantes au niveau des variables exportations, importations et balance commerciale. Or, ces trois variables sont liées par une relation comptable simple : la balance commerciale correspond à la différence entre les exportations et les importations. Cette relation a constitué la base méthodologique de notre stratégie de traitement des valeurs manquantes.

Lorsque une seule variable était manquante parmi les trois, et que les deux autres étaient disponibles, nous avons imputé la valeur manquante en utilisant directement cette relation comptable. Ainsi, la balance commerciale a été recalculée comme la différence entre les exportations et les importations, les importations ont été obtenues comme la différence entre les exportations et la balance commerciale, et les exportations comme la somme de la balance commerciale et des importations. Cette approche permet de conserver une cohérence économique entre les variables et repose sur une identité comptable vérifiée.

```
# Verification
miss_var_summary(DIANE_complete, nset= 10)
```

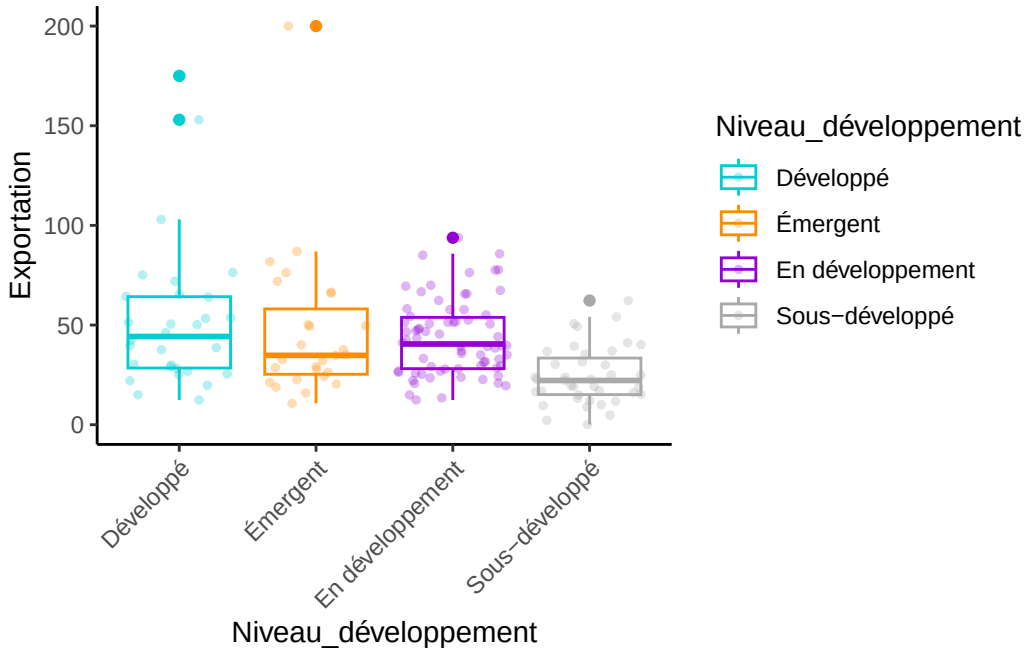
```
# A tibble: 13 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 Inflation                15    8.98
 2 Espérance_vie            14    8.38
 3 PIB_par_habitant         13    7.78
 4 Revenu                   10    5.99
 5 Dépenses_santé            9    5.39
 6 Fécondité_totale          8    4.79
 7 Mortalité_infantile       6    3.59
 8 Exportation               1    0.599
 9 Balance_commerciale       1    0.599
10 Pays                      0    0
11 Région_géographique       0    0
12 Niveau_développement      0    0
13 Importation               0    0
```

Nous remarquons bien que les NA des importations sont désormais égaux à 0 et les celles des exportations et balance sont égaux à 1. Nous allons donc resoudre ce probmleme en les imputant par la moyenne.

Troisième Imputations

```
#Boxplot Exportations vs Niveau de développement
DIANE_complete |>
    ggplot(aes(
      x = Niveau_développement,
      y = Exportation,
      color = Niveau_développement
    )) +
    geom_boxplot(na.rm = TRUE) +
    geom_jitter(size = 1, alpha = 0.3, na.rm = TRUE) +
    scale_color_manual(values = vecteur_couleur) +

    theme_classic() +
    theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




```
moyenne_dev <- DIANE_complete |>
  filter(Niveau_développement == "En développement") |>
  pull(Exportation) |>
  mean(na.rm = TRUE) |>
  round()

moyenne_dev
```

```
[1] 44
```

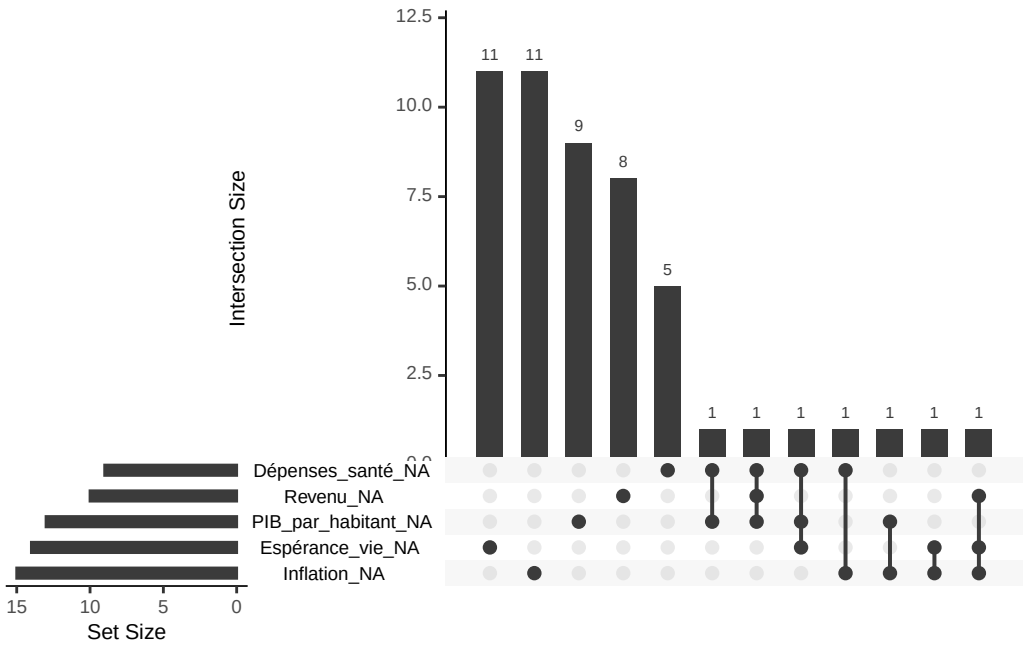
```
#Affiche les lignes où "Exportation" est manquante
indices_export <- which(is.na(DIANE_complete$Exportation))

# le nom des pays correspondants à ces lignes
DIANE_complete$Exportation[indices_export]  = moyenne_dev

# Les verifications
DIANE_complete$Exportation[indices_export]
```

```
[1] 44
```

```
gg_miss_upset(DIANE_complete)
```




```
miss_var_summary(DIANE_complete)
```

```
# A tibble: 13 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 Inflation                15    8.98
 2 Espérance_vie            14    8.38
 3 PIB_par_habitant         13    7.78
 4 Revenu                   10    5.99
 5 Dépenses_santé            9    5.39
 6 Fécondité_totale          8    4.79
 7 Mortalité_infantile       6    3.59
 8 Balance_commerciale       1    0.599
 9 Pays                      0    0
10 Région_géographique       0    0
11 Niveau_développement      0    0
12 Exportation               0    0
13 Importation               0    0
```

```r
summary(DIANE_complete)
```

```
    Pays           Région_géographique       Niveau_développement
 Length:167         Afrique :47         Développé       :30
 Class :character   Amérique:27         Émergent        :27
 Mode  :character   Asie    :42         En développement:71
                    Europe  :42         Sous-développé  :39
                    Océanie : 9


 Mortalité_infantile  Exportation      Dépenses_santé    Importation
 Min.   :  2.60       Min.   :  0.109   Min.   : 1.810   Min.   :  0.0659
 1st Qu.:  7.80       1st Qu.: 23.800   1st Qu.: 4.973   1st Qu.: 30.2000
 Median : 19.30       Median : 35.400   Median : 6.570   Median : 43.3000
 Mean   : 38.14       Mean   : 41.177   Mean   : 6.924   Mean   : 46.8902
 3rd Qu.: 62.00       3rd Qu.: 51.350   3rd Qu.: 8.710   3rd Qu.: 58.7500
 Max.   :208.00       Max.   :200.000   Max.   :17.900   Max.   :174.0000
 NA's   :6                              NA's   :9
    Revenu         Inflation       Espérance_vie   Fécondité_totale
 Min.   :   609   Min.   : -4.210   Min.   :32.10   Min.   :1.150
 1st Qu.:  3720   1st Qu.:  1.830   1st Qu.:65.50   1st Qu.:1.785
 Median : 10400   Median :  5.415   Median :73.10   Median :2.410
 Mean   : 17280   Mean   :  7.890   Mean   :70.74   Mean   :2.962
 3rd Qu.: 22700   3rd Qu.: 10.675   3rd Qu.:76.80   3rd Qu.:3.995
 Max.   :125000   Max.   :104.000   Max.   :82.80   Max.   :7.490
 NA's   :10       NA's   :15        NA's   :14      NA's   :8
 PIB_par_habitant Balance_commerciale
 Min.   :   231   Min.   :-73.500
 1st Qu.:  1310   1st Qu.:-14.700
 Median :  4670   Median : -4.650
 Mean   : 12657   Mean   : -5.641
 3rd Qu.: 13400   3rd Qu.:  3.925
 Max.   :105000   Max.   : 39.400
 NA's   :13       NA's   :1
```

```r
# Imputation de la valeur dans la balance commerciale du capvert
DIANE_complete$Balance_commerciale[34] = DIANE_complete$Exportation[34] - DIANE_complete$Impo

# Verification
miss_var_summary(DIANE_complete)
```

```
# A tibble: 13 x 3
```

```
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 Inflation                15     8.98
 2 Espérance_vie            14     8.38
 3 PIB_par_habitant         13     7.78
 4 Revenu                   10     5.99
 5 Dépenses_santé            9     5.39
 6 Fécondité_totale          8     4.79
 7 Mortalité_infantile       6     3.59
 8 Pays                      0     0
 9 Région_géographique       0     0
10 Niveau_développement      0     0
11 Exportation               0     0
12 Importation               0     0
13 Balance_commerciale       0     0
```

Nous avons réussi a imputer ka valeur de la balance commerciale du pays Cap-vert en se basant sur le calcul des des imports et exports. lA verification nous le montre bien dans un tableau.

```
### Vecteur comportant nos variables quantitatives
vars_quanti <- c("Mortalité_infantile","Exportation","Dépenses_santé","Importation","Revenu"
```

Tableau des Statistiques des données quantitatives

```
stats_long <- DIANE_complete |>
  select(all_of(vars_quanti)) |>
  pivot_longer(cols = everything(),
               names_to = "Variable",
               values_to = "Valeur") |>
  group_by(Variable) |>
  summarise(
    N = sum(!is.na(Valeur)),
    Moyenne = mean(Valeur, na.rm = TRUE),
    Médiane = median(Valeur, na.rm = TRUE),
    Écart_type = sd(Valeur, na.rm = TRUE),
    Min = min(Valeur, na.rm = TRUE),
    Max = max(Valeur, na.rm = TRUE)
  )
stats_long |>   knitr::kable(
    caption = "Statistique des varuiables quantiatative")
```

Table 4: Statistique des varuiables quantiatative

Variable	N	Moyenne	Médiane	Écart_type	Min	Max
Balance_commerciale	167	-5.713574	-4.800	18.878854	-73.5000	3.94e+01
Dépenses_santé	158	6.924430	6.570	2.734295	1.8100	1.79e+01
Espérance_vie	153	70.739869	73.100	8.836857	32.1000	8.28e+01
Exportation	167	41.176641	35.400	27.405074	0.1090	2.00e+02
Fécondité_totale	159	2.961824	2.410	1.534728	1.1500	7.49e+00
Importation	167	46.890215	43.300	24.209589	0.0659	1.74e+02
Inflation	152	7.890092	5.415	10.848745	-4.2100	1.04e+02
Mortalité_infantile	161	38.137267	19.300	40.433360	2.6000	2.08e+02
PIB_par_habitant	154	12656.987013	4670.000	18410.443611	231.0000	1.05e+05
Revenu	157	17280.210191	10400.000	19483.651094	609.0000	1.25e+05

Histogramme des variables quantatives

```
# Crée un vecteur pour la variable qualitative Région_géographique, afin de l'utiliser dans l
var_region <- "Région_géographique"

for (v in vars_quanti) {
  p <- ggplot(DIANE_complete, aes(x = .data[[v]], fill = .data[[var_region]])) +
    geom_histogram(bins = 20) +
    scale_fill_manual(values = vecteur_couleur) +
    theme_classic() +
    ggtitle(paste("Distribution de", v, "par", var_region))

  print(p)
}
```

```
Warning: Removed 6 rows containing non-finite values (`stat_bin()`).
```

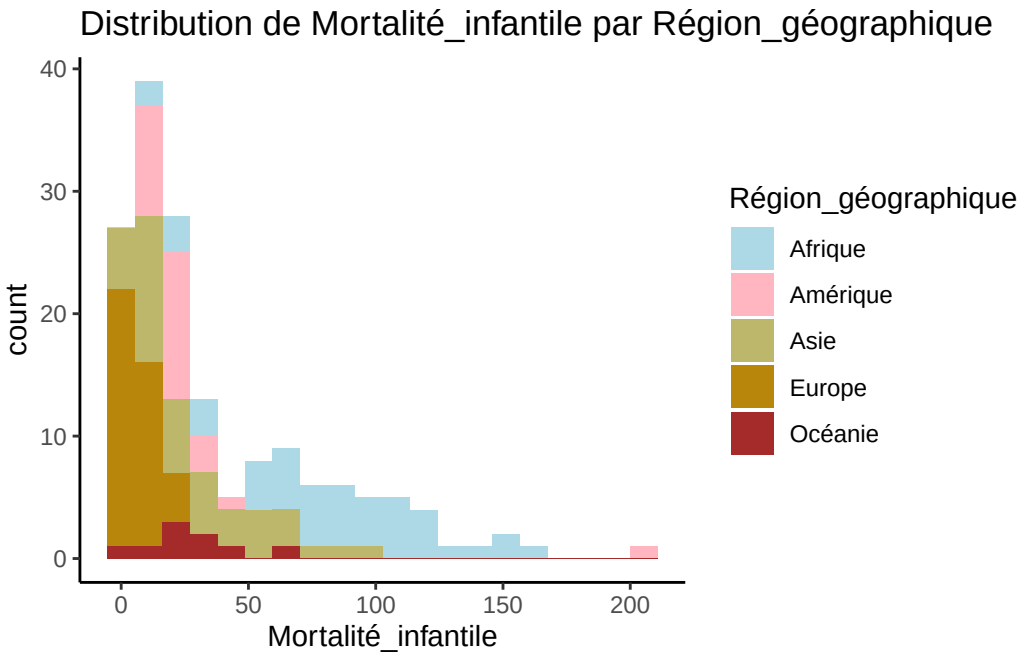


Figure 6: Répartition en histogramme des variables quantitatives selon la région géographique

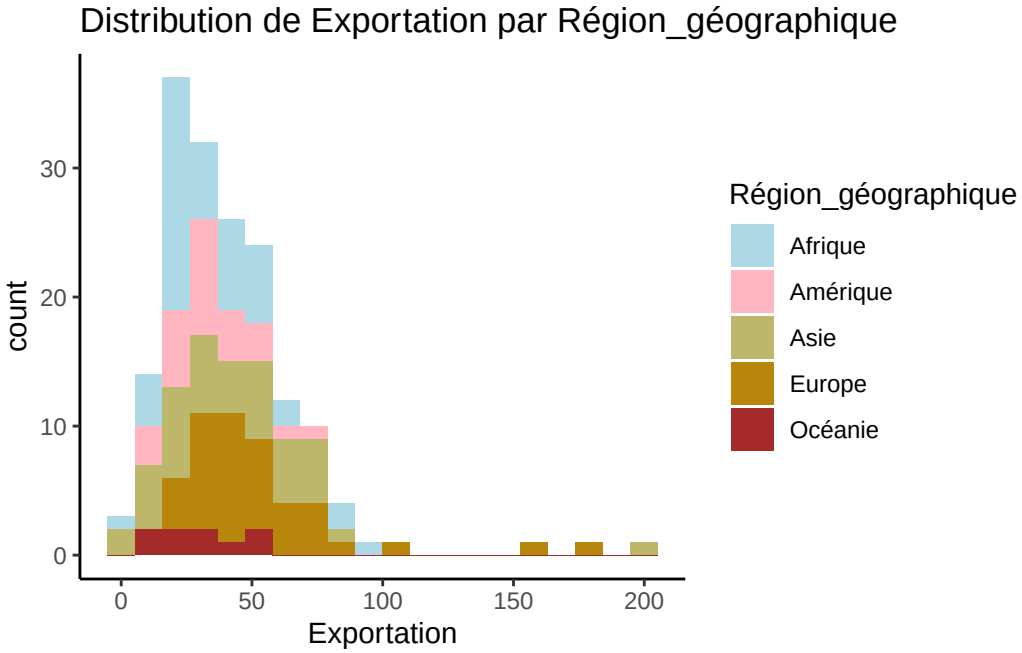


Figure 7: Répartition en histogramme des variables quantitatives selon la région géographique

```
Warning: Removed 9 rows containing non-finite values (`stat_bin()`).
```

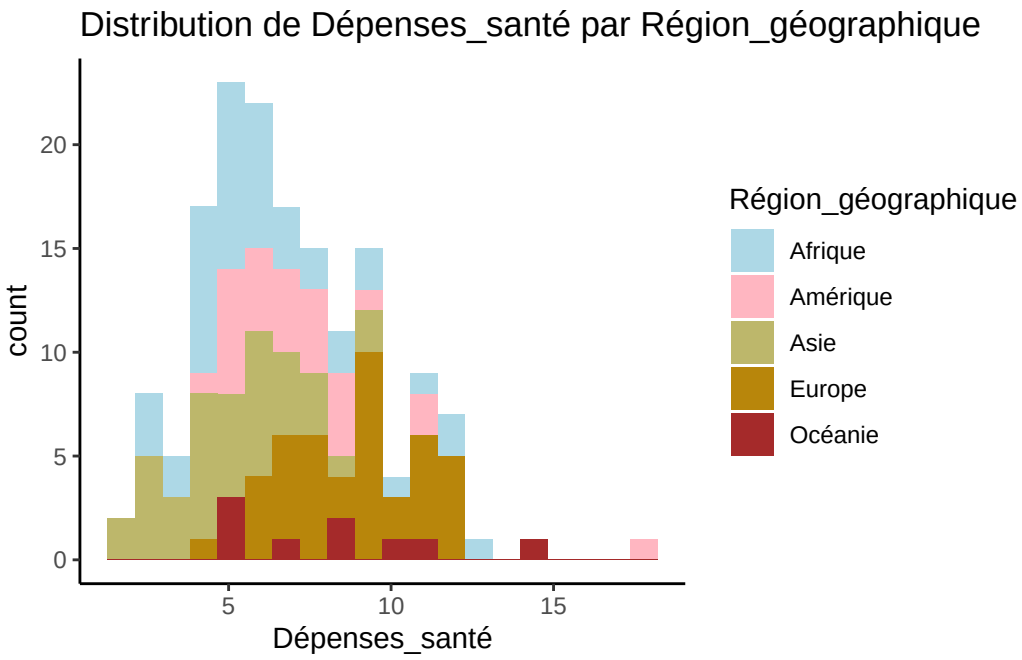


Figure 8: Répartition en histogramme des variables quantitatives selon la région géographique

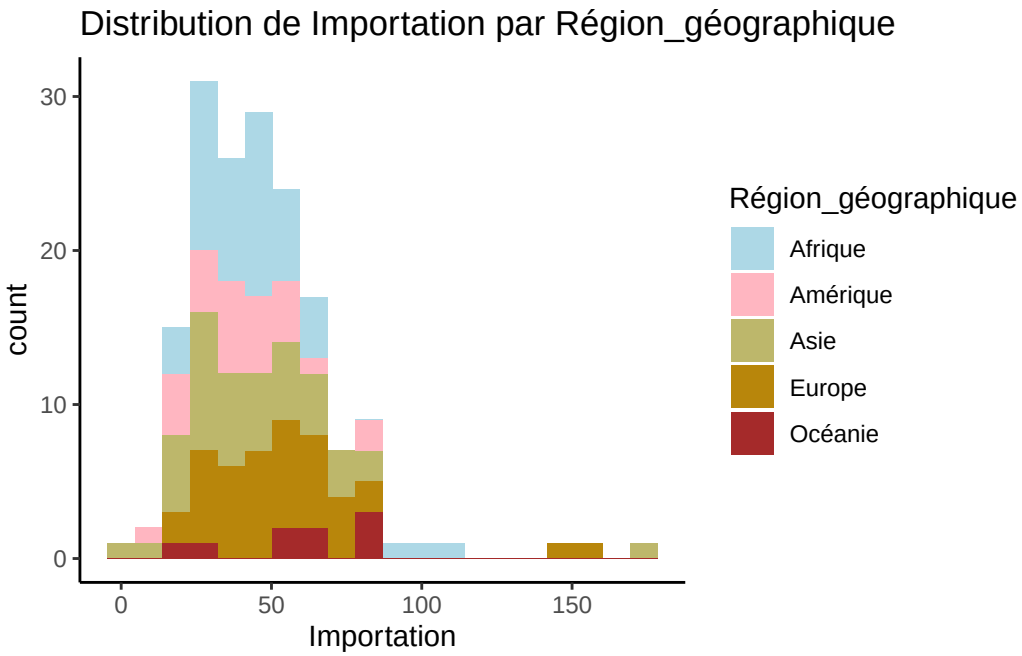


Figure 9: Répartition en histogramme des variables quantitatives selon la région géographique

```
Warning: Removed 10 rows containing non-finite values (`stat_bin()`).
```

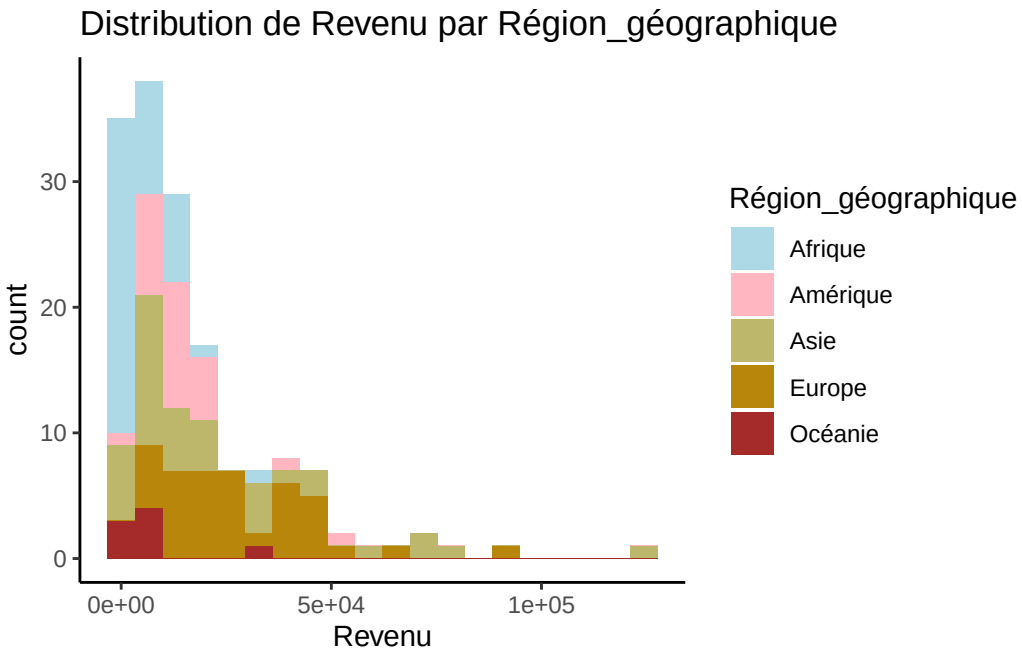


Figure 10: Répartition en histogramme des variables quantitatives selon la région géographique

```
Warning: Removed 15 rows containing non-finite values (`stat_bin()`).
```

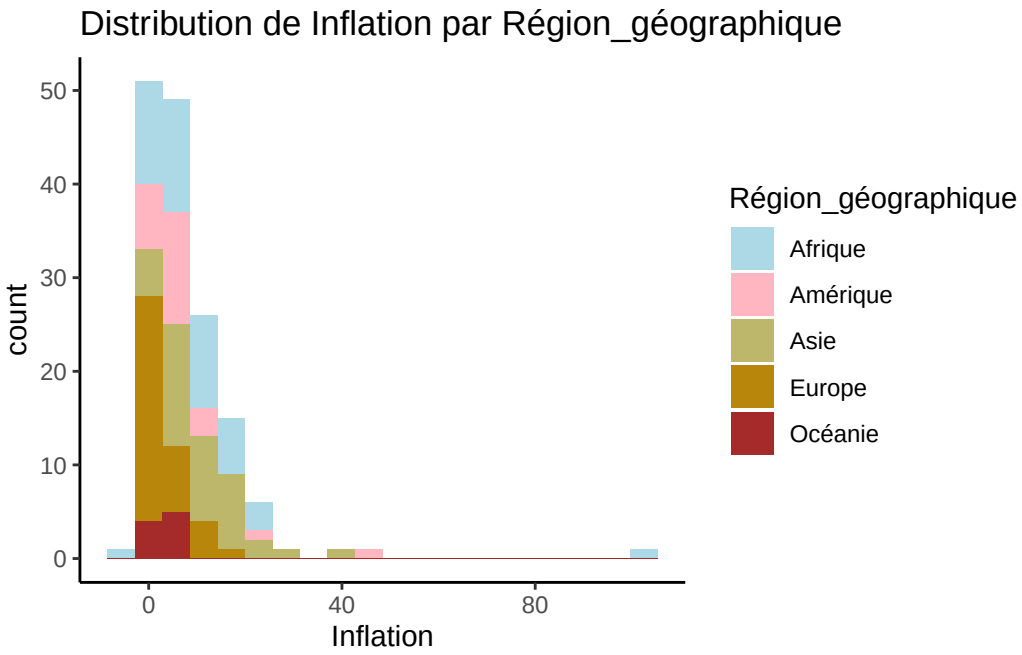


Figure 11: Répartition en histogramme des variables quantitatives selon la région géographique

```
Warning: Removed 14 rows containing non-finite values (`stat_bin()`).
```

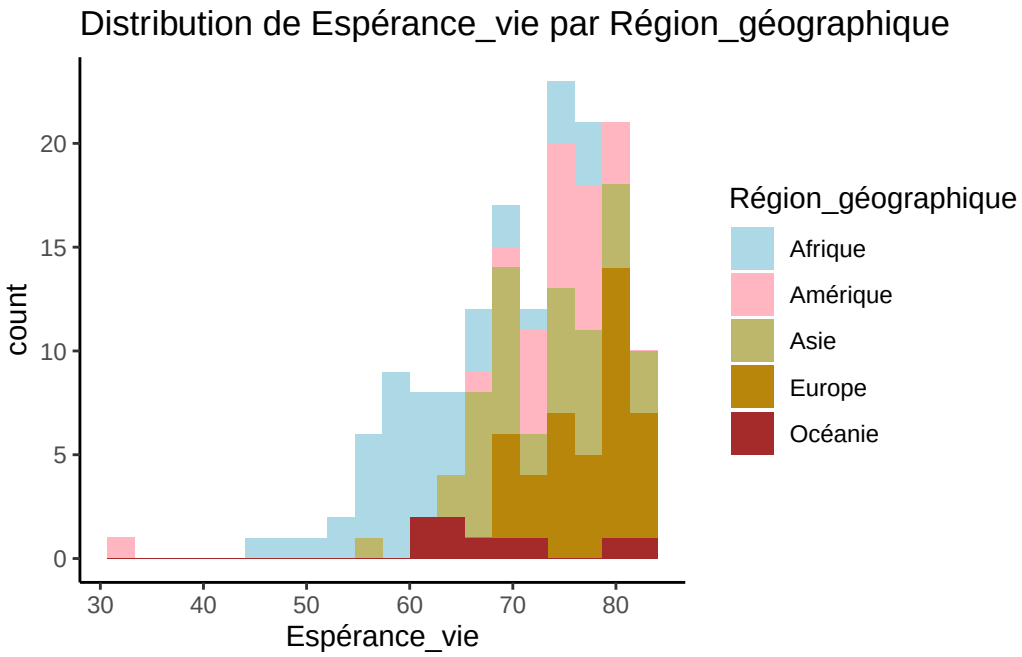


Figure 12: Répartition en histogramme des variables quantitatives selon la région géographique

```
Warning: Removed 8 rows containing non-finite values (`stat_bin()`).
```

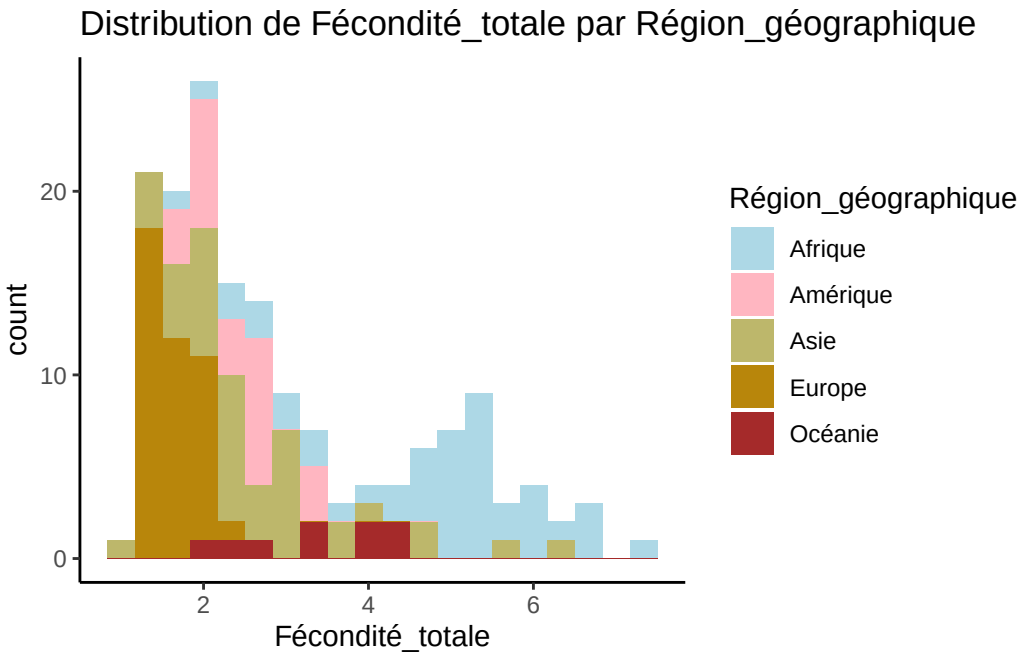


Figure 13: Répartition en histogramme des variables quantitatives selon la région géographique

```
Warning: Removed 13 rows containing non-finite values (`stat_bin()`).
```

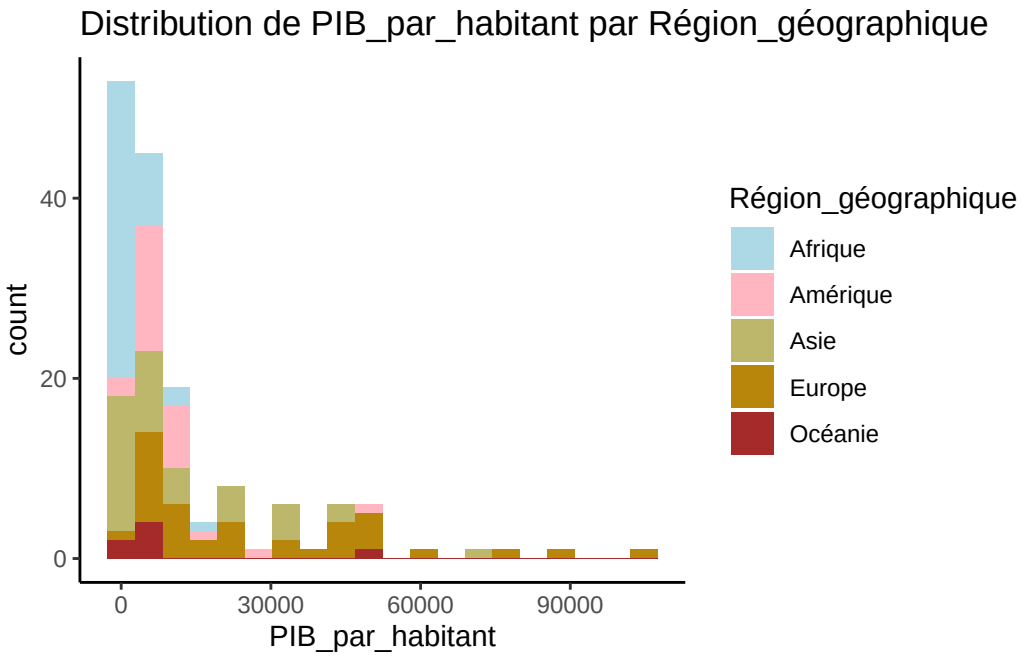


Figure 14: Répartition en histogramme des variables quantitatives selon la région géographique

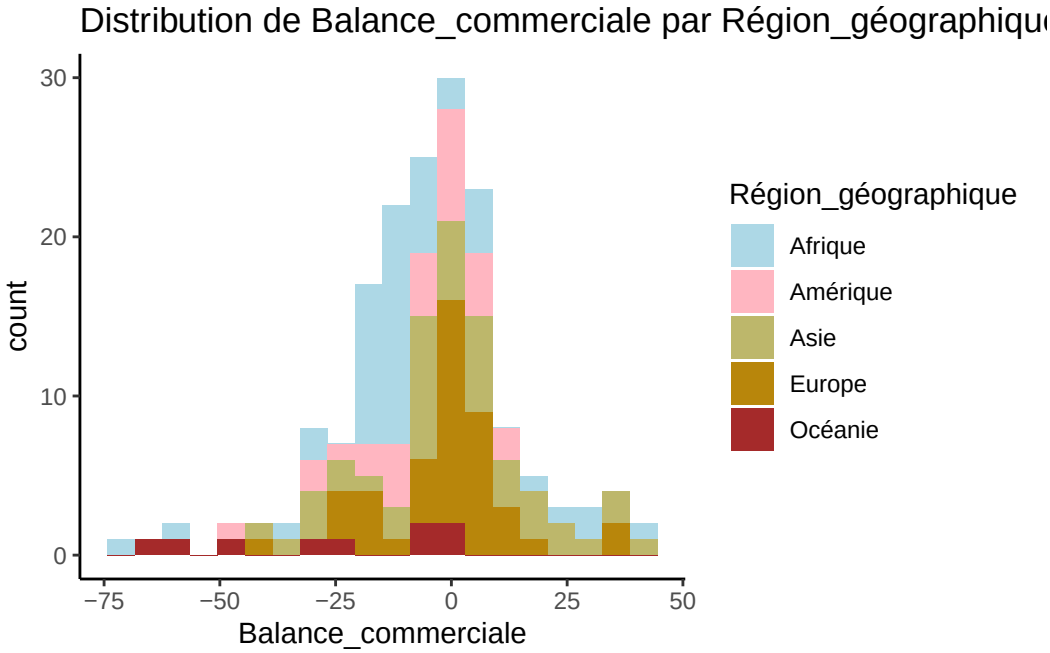


Figure 15: Répartition en histogramme des variables quantitatives selon la région géographique

Histogramme quanti et Niveau_développement

```
# Crée un vecteur pour la variable qualitative Niveau_développement, afin de l'utiliser dans
var_Niveau <- "Niveau_développement"

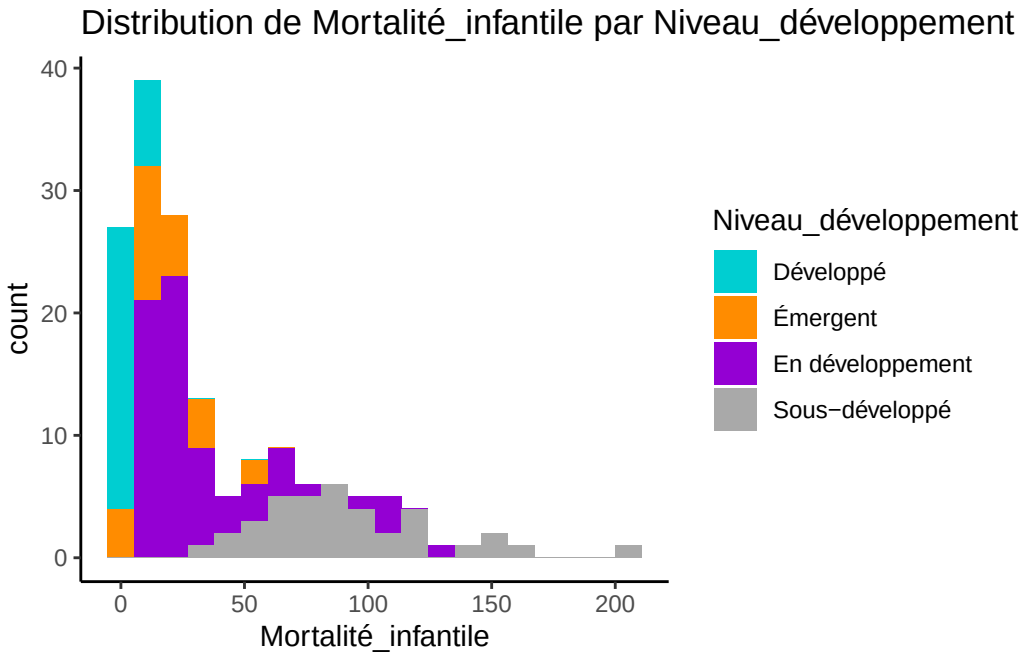
#| fig-cap: "Répartition en Histogramme des variables qua,titatives selon le région géographi

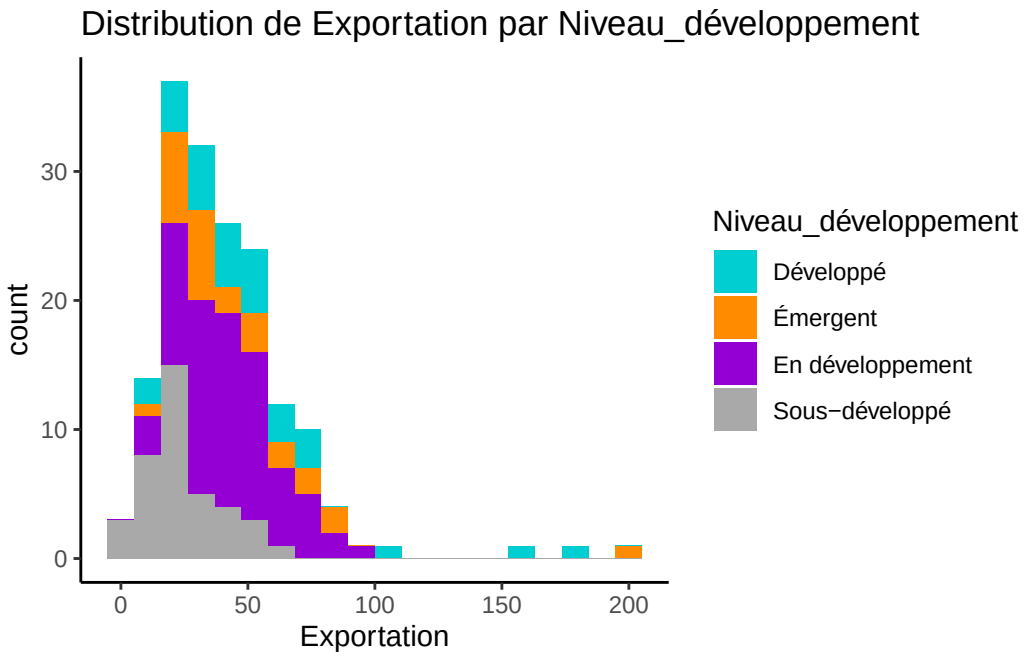
for (v in vars_quanti) {
  p <- ggplot(DIANE_complete, aes_string(x = v, fill = var_Niveau)) +
    geom_histogram(bins = 20) +
    scale_fill_manual(values = vecteur_couleur) +
    theme_classic() +
    ggtitle(paste("Distribution de", v, "par", var_Niveau))

  print(p)
}
```

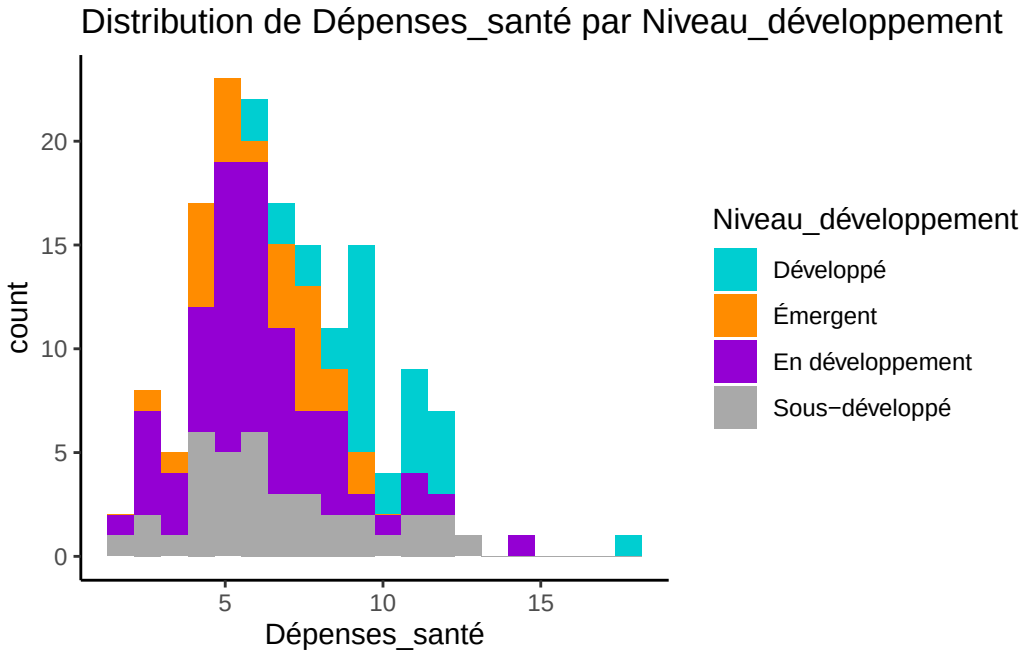
```
Warning: `aes_string()` was deprecated in ggplot2 3.0.0.
i Please use tidy evaluation idioms with `aes()`.
i See also `vignette("ggplot2-in-packages")` for more information.

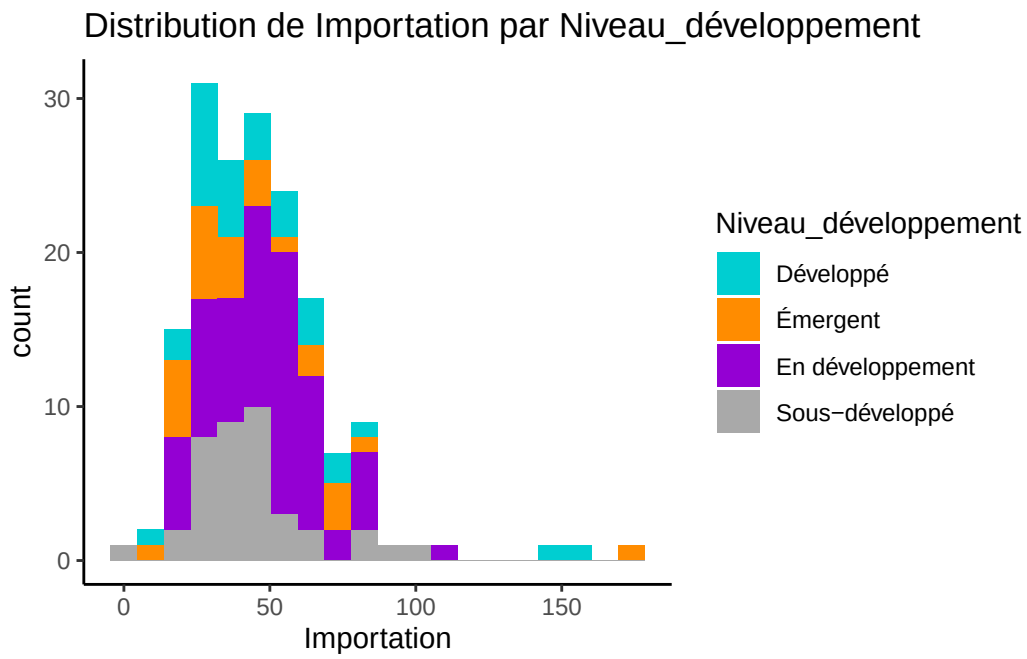
Warning: Removed 6 rows containing non-finite values (`stat_bin()`).
```



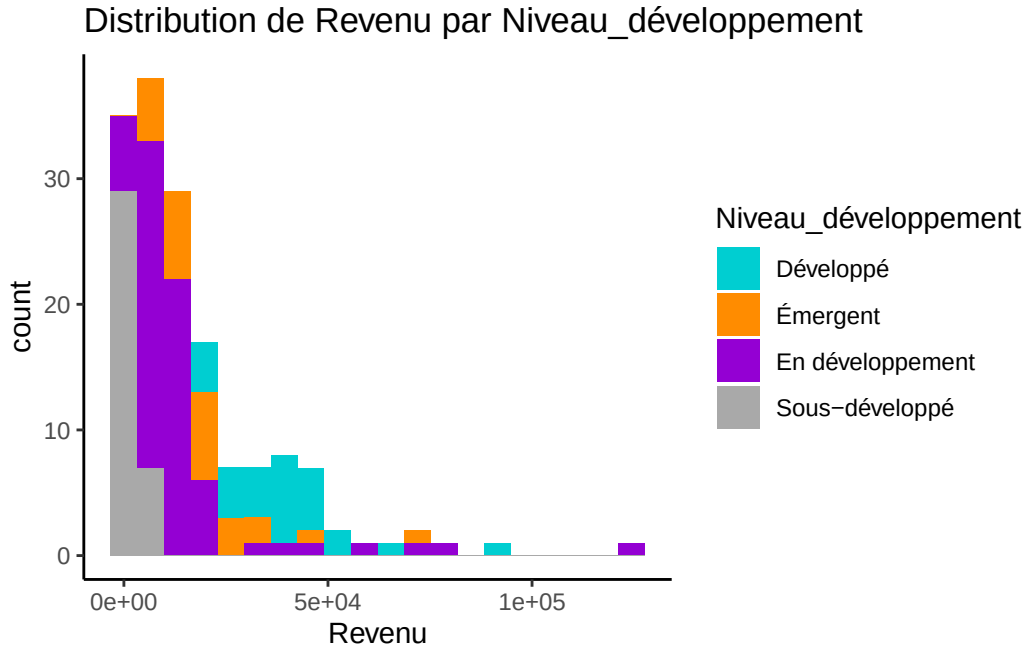



```
Warning: Removed 9 rows containing non-finite values (`stat_bin()`).
```

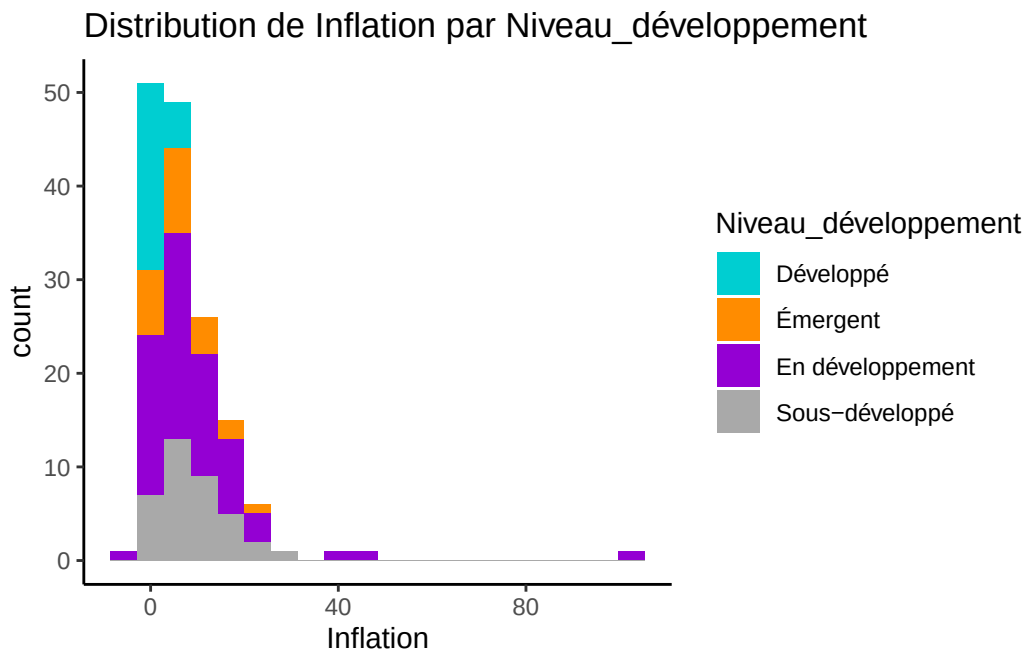




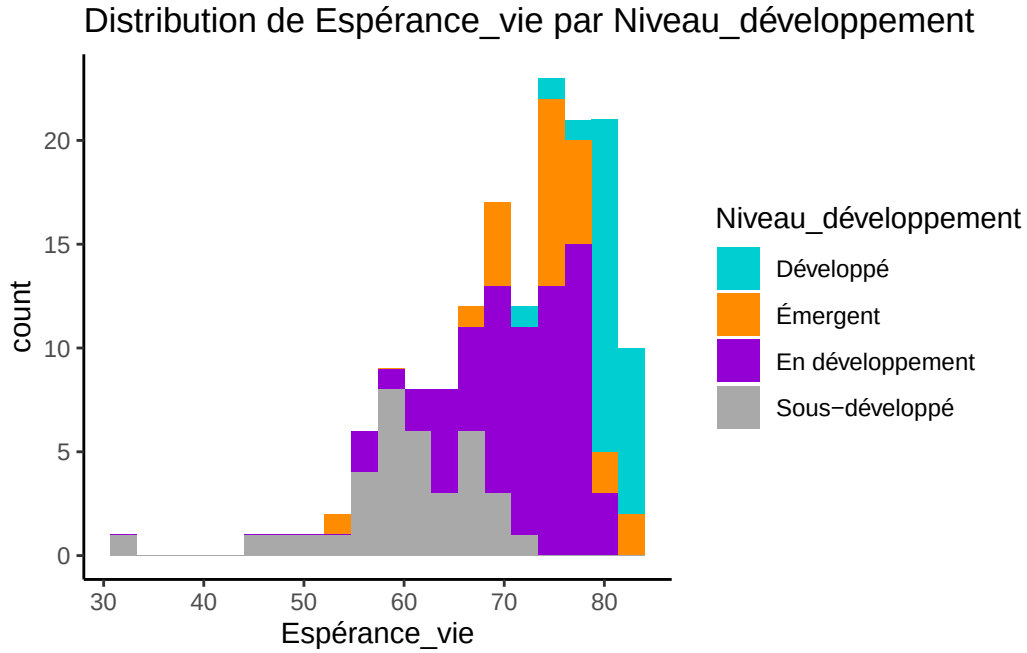

```
Warning: Removed 10 rows containing non-finite values (`stat_bin()`).
```



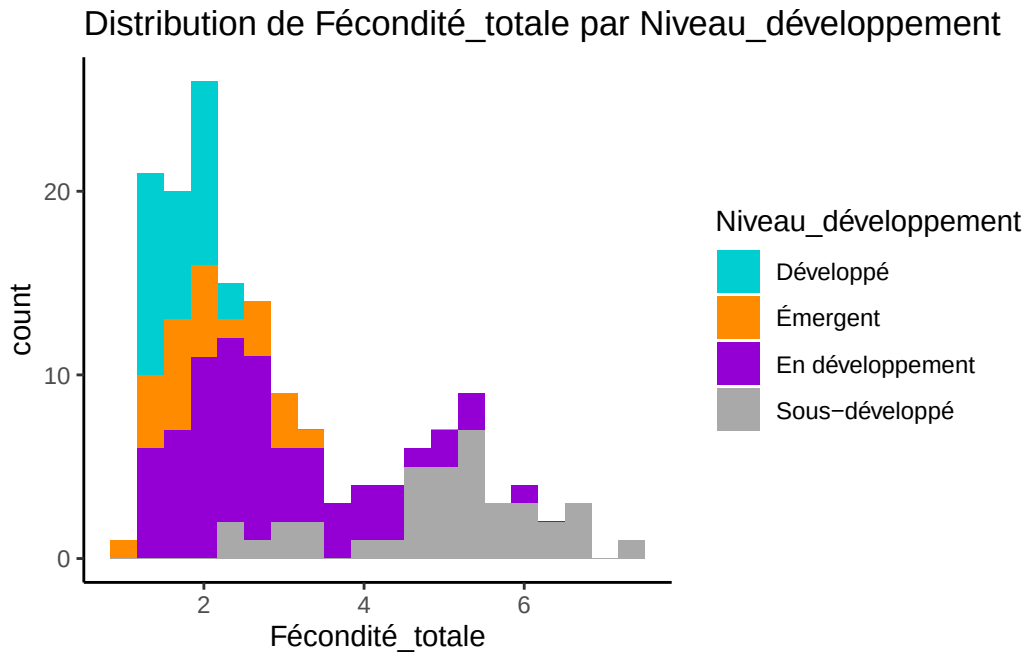

```
Warning: Removed 15 rows containing non-finite values (`stat_bin()`).
```



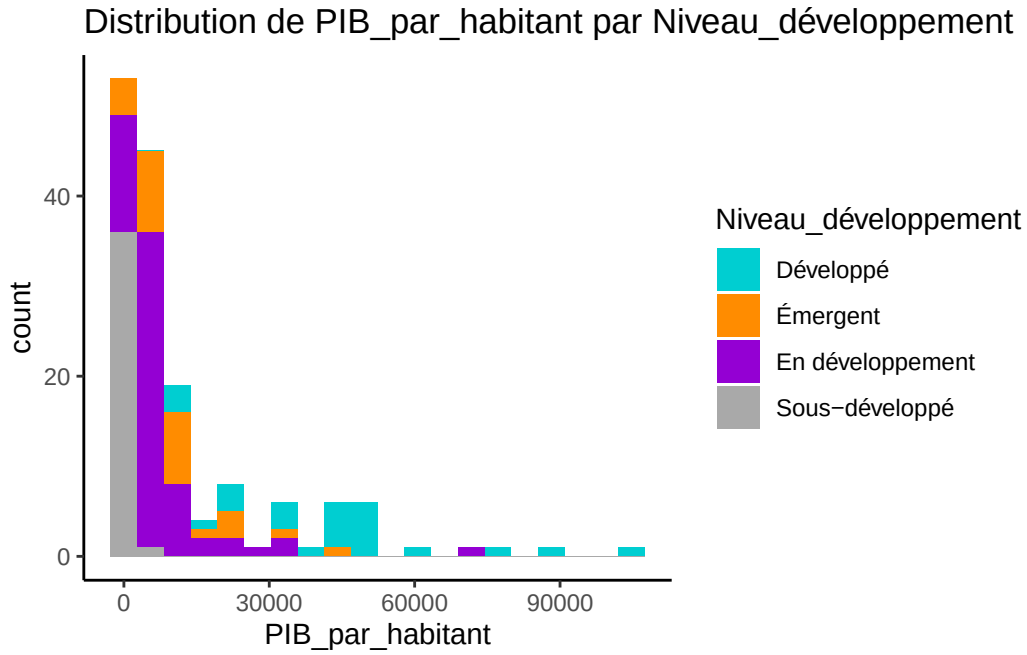

```
Warning: Removed 14 rows containing non-finite values (`stat_bin()`).
```

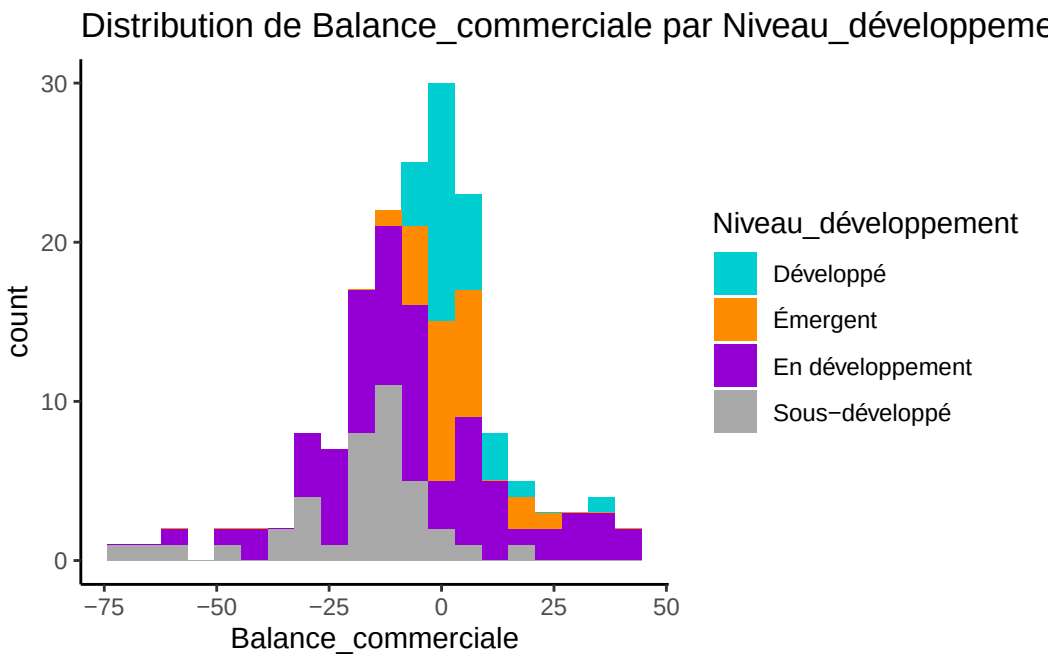



```
Warning: Removed 8 rows containing non-finite values (`stat_bin()`).
```




```
Warning: Removed 13 rows containing non-finite values (`stat_bin()`).
```



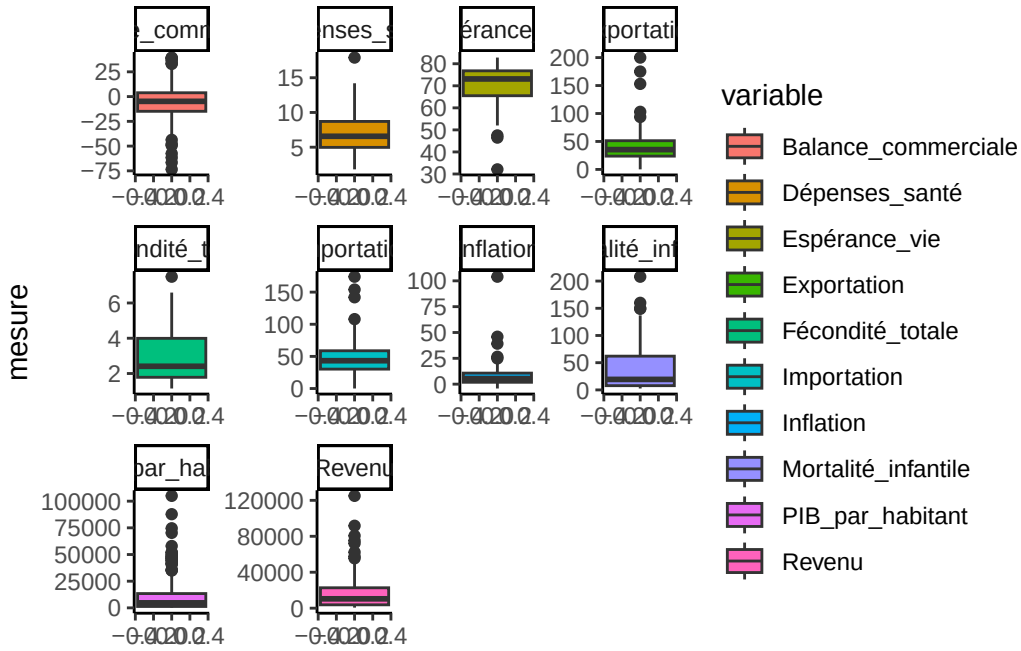


Boxplot

Boxplot des quanti avec le niveau de developpment

```
DIANE_complete |>
  pivot_longer(
    where(is.numeric),
    names_to = "variable",
    values_to = "mesure"
    ) |>
  ggplot() +
  aes(y = mesure , fill=  variable) +
  geom_boxplot() +
  facet_wrap(~ variable, scales = "free") +
  theme_classic()
```

```
Warning: Removed 75 rows containing non-finite values (`stat_boxplot()`).
```



L'analyse des boxplots montre que seule la distribution de la balance commerciale apparaît globalement symétrique. En revanche, les autres variables présentent des distributions asymétriques. Les variables économiques telles que le revenu et le PIB par habitant sont caractérisées par une asymétrie à droite, traduisant l'influence de quelques pays émergents ou à revenu élevé qui étirent la distribution. À l'inverse, l'espérance de vie présente une asymétrie à gauche, indiquant la présence de pays à espérance de vie plus faible qui tirent la distribution vers le bas. On observe également la présence de quelques valeurs extrêmes, reflétant l'hétérogénéité des situations économiques et sociales entre les pays.

```
library(EnvStats)
```

```
Warning: le package 'EnvStats' a été compilé avec la version R 4.4.3
```

```
Attachement du package : 'EnvStats'
```

```
Les objets suivants sont masqués depuis 'package:stats':
```

```
    predict, predict.lm
```

```
L'objet suivant est masqué depuis 'package:base':
```

```
    print.default
```

```r
for(i in vars_quanti){
  print(paste("Rosner test pour :", i))
  print(rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05))
}
```

```
[1] "Rosner test pour : Mortalité_infantile"
```

```
Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 6
observations with NA/NaN/Inf in 'x' removed.
```

```
Results of Outlier Test
-------------------------

Test Method:                     Rosner's Test for Outliers

Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Number NA/NaN/Inf's Removed:     6

Sample Size:                     161

Test Statistics:                 R.1  = 4.201054
                                 R.2  = 3.214287
                                 R.3  = 3.065573
                                 R.4  = 3.143861
                                 R.5  = 2.916108
                                 R.6  = 2.804173
                                 R.7  = 2.678165
                                 R.8  = 2.629745
                                 R.9  = 2.606815
                                 R.10 = 2.676230

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
                                 from the same Distribution.

Type I Error:                    5%
```

```
Number of Outliers Detected:     1

   i   Mean.i     SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 38.13727 40.43336   208      68 4.201054   3.539193    TRUE
2  1 37.07563 38.24313   160     142 3.214287   3.537251   FALSE
3  2 36.30252 37.08850   150     153 3.065573   3.535295   FALSE
4  3 35.58291 36.07573   149     129 3.143861   3.533324   FALSE
5  4 34.86051 35.02596   137     100 2.916108   3.531339   FALSE
6  5 34.20577 34.16131   130     114 2.804173   3.529338   FALSE
7  6 33.58774 33.38564   123     113 2.678165   3.527322   FALSE
8  7 33.00714 32.70007   119       6 2.629745   3.525291   FALSE
9  8 32.44510 32.05248   116      29 2.606815   3.523245   FALSE
10 9 31.89539 31.42653   116      41 2.676230   3.521183   FALSE


[1] "Rosner test pour : Exportation"

Results of Outlier Test
-------------------------

Test Method:                     Rosner's Test for Outliers

Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Sample Size:                     167

Test Statistics:                 R.1  = 5.795400
                                 R.2  = 5.494182
                                 R.3  = 5.110852
                                 R.4  = 3.146755
                                 R.5  = 2.794147
                                 R.6  = 2.518108
                                 R.7  = 2.519865
                                 R.8  = 2.542425
                                 R.9  = 2.425261
                                 R.10 = 2.253907

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
```

```
                                from the same Distribution.

Type I Error:                   5%

Number of Outliers Detected:    3

   i   Mean.i     SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 41.17664 27.40507 200.0     143 5.795400   3.550554    TRUE
2  1 40.21987 24.53143 175.0      94 5.494182   3.548694    TRUE
3  2 39.40302 22.22662 153.0     101 5.110852   3.546821    TRUE
4  3 38.71036 20.43045 103.0      75 3.146755   3.544935   FALSE
5  4 38.31594 19.85725  93.8     141 2.794147   3.543035   FALSE
6  5 37.97345 19.42988  86.9      97 2.518108   3.541121   FALSE
7  6 37.66956 19.10041  85.8      65 2.519865   3.539193   FALSE
8  7 37.36874 18.77391  85.1      40 2.542425   3.537251   FALSE
9  8 37.06855 18.44398  81.8      69 2.425261   3.535295   FALSE
10 9 36.78544 18.15273  77.7      48 2.253907   3.533324   FALSE


[1] "Rosner test pour : Dépenses_santé"

Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 9
observations with NA/NaN/Inf in 'x' removed.


Results of Outlier Test
-------------------------

Test Method:                    Rosner's Test for Outliers

Hypothesized Distribution:      Normal

Data:                           DIANE_complete[[i]]

Number NA/NaN/Inf's Removed:    9

Sample Size:                    158

Test Statistics:                R.1  = 4.014039
                                R.2  = 2.827867
                                R.3  = 2.479546
                                R.4  = 2.057645
```

```
                                  R.5  = 2.093439
                                  R.6  = 2.090189
                                  R.7  = 2.086566
                                  R.8  = 2.082549
                                  R.9  = 2.120521
                                  R.10 = 2.117729

Test Statistic Parameter:         k = 10

Alternative Hypothesis:           Up to 10 observations are not
                                  from the same Distribution.

Type I Error:                     5%

Number of Outliers Detected:      1

   i   Mean.i     SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 6.924430 2.734295  17.9      53 4.014039   3.533324    TRUE
2  1 6.854522 2.597533  14.2     105 2.827867   3.531339   FALSE
3  2 6.807436 2.537789  13.1     142 2.479546   3.529338   FALSE
4  3 6.766839 2.494678  11.9      56 2.057645   3.527322   FALSE
5  4 6.733506 2.467946  11.9     123 2.093439   3.525291   FALSE
6  5 6.699739 2.440096  11.8      91 2.090189   3.523245   FALSE
7  6 6.666184 2.412488  11.7     106 2.086566   3.521183   FALSE
8  7 6.632848 2.385131  11.6       5 2.082549   3.519104   FALSE
9  8 6.599733 2.358037  11.6      30 2.120521   3.517009   FALSE
10 9 6.566174 2.329772  11.5     149 2.117729   3.514898   FALSE


[1] "Rosner test pour : Importation"

Results of Outlier Test
-------------------------

Test Method:                      Rosner's Test for Outliers

Hypothesized Distribution:        Normal

Data:                             DIANE_complete[[i]]

Sample Size:                      167

Test Statistics:                  R.1  = 5.250390
```

```
                                  R.2  = 4.867630
                                  R.3  = 4.694789
                                  R.4  = 3.290997
                                  R.5  = 3.040546
                                  R.6  = 2.677249
                                  R.7  = 2.467329
                                  R.8  = 2.427998
                                  R.9  = 2.202936
                                  R.10 = 2.215348

Test Statistic Parameter:         k = 10

Alternative Hypothesis:           Up to 10 observations are not
                                  from the same Distribution.

Type I Error:                     5%

Number of Outliers Detected:      3

   i   Mean.i     SD.i    Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 46.89021 24.20959 174.0000     143 5.250390   3.550554    TRUE
2  1 46.12449 22.16181 154.0000     101 4.867630   3.548694    TRUE
3  2 45.47070 20.56095 142.0000      94 4.694789   3.546821    TRUE
4  3 44.88211 19.17896 108.0000     141 3.290997   3.544935   FALSE
5  4 44.49488 18.58387 101.0000      88 3.040546   3.543035   FALSE
6  5 44.14609 18.09839  92.6000      91 2.677249   3.541121   FALSE
7  6 43.84513 17.74357   0.0659     110 2.467329   3.539193   FALSE
8  7 44.11875 17.45522  86.5000      75 2.427998   3.537251   FALSE
9  8 43.85220 17.18061  81.7000      84 2.202936   3.535295   FALSE
10 9 43.61266 16.96679  81.2000      70 2.215348   3.533324   FALSE


[1] "Rosner test pour : Revenu"

Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 10
observations with NA/NaN/Inf in 'x' removed.


Results of Outlier Test
-------------------------

Test Method:                      Rosner's Test for Outliers
```

```
Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Number NA/NaN/Inf's Removed:     10

Sample Size:                     157

Test Statistics:                 R.1  = 5.528727
                                 R.2  = 4.288726
                                 R.3  = 3.911712
                                 R.4  = 3.792485
                                 R.5  = 3.791722
                                 R.6  = 3.313768
                                 R.7  = 3.113106
                                 R.8  = 3.073464
                                 R.9  = 2.718080
                                 R.10 = 2.507498

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
                                 from the same Distribution.

Type I Error:                    5%

Number of Outliers Detected:     5
```

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	17280.21	19483.65	125000	128	5.528727	3.531339	TRUE
2	1	16589.70	17513.43	91700	94	4.288726	3.529338	TRUE
3	2	16105.12	16487.64	80600	27	3.911712	3.527322	TRUE
4	3	15686.32	15692.53	75200	86	3.792485	3.525291	TRUE
5	4	15297.34	14980.70	72100	143	3.791722	3.523245	TRUE
6	5	14923.64	14296.83	62300	115	3.313768	3.521183	FALSE
7	6	14609.89	13809.39	57600	48	3.113106	3.519104	FALSE
8	7	14323.29	13397.49	55500	149	3.073464	3.517009	FALSE
9	8	14046.93	13006.63	49400	53	2.718080	3.514898	FALSE
10	9	13808.06	12718.63	45700	75	2.507498	3.512770	FALSE

```
[1] "Rosner test pour : Inflation"
```

```
Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 15
observations with NA/NaN/Inf in 'x' removed.


Results of Outlier Test
-------------------------

Test Method:                     Rosner's Test for Outliers

Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Number NA/NaN/Inf's Removed:     15

Sample Size:                     152

Test Statistics:                 R.1  = 8.859081
                                 R.2  = 5.141835
                                 R.3  = 4.708482
                                 R.4  = 3.116418
                                 R.5  = 2.974807
                                 R.6  = 2.861779
                                 R.7  = 2.818648
                                 R.8  = 2.574785
                                 R.9  = 2.627714
                                 R.10 = 2.684987

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
                                 from the same Distribution.

Type I Error:                    5%

Number of Outliers Detected:     3

   i   Mean.i      SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 7.890092 10.848745 104.0     114 8.859081   3.521183    TRUE
2  1 7.253603  7.516071  45.9     164 5.141835   3.519104    TRUE
3  2 6.995960  6.839580  39.2     107 4.708482   3.517009    TRUE
4  3 6.779826  6.327833  26.5     155 3.116418   3.514898   FALSE
```

```
5  4 6.646581  6.136001  24.9      65 2.974807   3.512770   FALSE
6  5 6.522408  5.967475  23.6     166 2.861779   3.510625   FALSE
7  6 6.405438  5.816462  22.8     147 2.818648   3.508462   FALSE
8  7 6.292372  5.673338  20.9       9 2.574785   3.506282   FALSE
9  8 6.190931  5.559613  20.8      41 2.627714   3.504084   FALSE
10 9 6.088769  5.441825  20.7      40 2.684987   3.501868   FALSE
```

```
[1] "Rosner test pour : Espérance_vie"
```

```
Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 14
observations with NA/NaN/Inf in 'x' removed.
```

```
Results of Outlier Test
-------------------------

Test Method:                     Rosner's Test for Outliers

Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Number NA/NaN/Inf's Removed:     14

Sample Size:                     153

Test Statistics:                 R.1  = 4.372580
                                 R.2  = 2.956152
                                 R.3  = 2.932264
                                 R.4  = 2.458002
                                 R.5  = 2.375653
                                 R.6  = 2.272781
                                 R.7  = 2.148265
                                 R.8  = 2.109541
                                 R.9  = 2.109156
                                 R.10 = 2.108533

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
                                 from the same Distribution.
```

```
Type I Error:                    5%

Number of Outliers Detected:     1

   i   Mean.i     SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 70.73987 8.836857  32.1      68 4.372580   3.523245    TRUE
2  1 70.99408 8.285799  46.5      88 2.956152   3.521183   FALSE
3  2 71.15629 8.067586  47.5     129 2.932264   3.519104   FALSE
4  3 71.31400 7.857600  52.0     167 2.458002   3.517009   FALSE
5  4 71.44362 7.721507  53.1      98 2.375653   3.514898   FALSE
6  5 71.56757 7.597549  54.3       2 2.272781   3.512770   FALSE
7  6 71.68503 7.487454  55.6      66 2.148265   3.510625   FALSE
8  7 71.79521 7.392702  56.2       1 2.109541   3.508462   FALSE
9  8 71.90276 7.302805  56.5     153 2.109156   3.506282   FALSE
10 9 72.00972 7.213413  56.8     118 2.108533   3.504084   FALSE


[1] "Rosner test pour : Fécondité_totale"

Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 8
observations with NA/NaN/Inf in 'x' removed.


Results of Outlier Test
-------------------------

Test Method:                     Rosner's Test for Outliers

Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Number NA/NaN/Inf's Removed:     8

Sample Size:                     159

Test Statistics:                 R.1  = 2.950474
                                 R.2  = 2.443890
                                 R.3  = 2.472760
                                 R.4  = 2.524137
                                 R.5  = 2.389335
```

```
                                  R.6  = 2.421604
                                  R.7  = 2.426872
                                  R.8  = 2.476322
                                  R.9  = 2.326410
                                  R.10 = 2.354789

Test Statistic Parameter:         k = 10

Alternative Hypothesis:           Up to 10 observations are not
                                  from the same Distribution.

Type I Error:                     5%

Number of Outliers Detected:      0

   i   Mean.i     SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1  0 2.961824 1.534728  7.49     113 2.950474   3.535295   FALSE
2  1 2.933165 1.496317  6.59     153 2.443890   3.533324   FALSE
3  2 2.909873 1.472091  6.55     100 2.472760   3.531339   FALSE
4  3 2.886538 1.447410  6.54      41 2.524137   3.529338   FALSE
5  4 2.862968 1.421748  6.26      30 2.389335   3.527322   FALSE
6  5 2.840909 1.399523  6.23     155 2.421604   3.525291   FALSE
7  6 2.818758 1.376769  6.16       6 2.426872   3.523245   FALSE
8  7 2.796776 1.354114  6.15     118 2.476322   3.521183   FALSE
9  8 2.774570 1.330561  5.87      29 2.326410   3.519104   FALSE
10 9 2.753933 1.310549  5.84     114 2.354789   3.517009   FALSE


[1] "Rosner test pour : PIB_par_habitant"

Warning in rosnerTest(DIANE_complete[[i]], k = 10, alpha = 0.05): 13
observations with NA/NaN/Inf in 'x' removed.


Results of Outlier Test
-------------------------

Test Method:                      Rosner's Test for Outliers

Hypothesized Distribution:        Normal

Data:                             DIANE_complete[[i]]
```

```
Number NA/NaN/Inf's Removed:     13

Sample Size:                     154

Test Statistics:                 R.1  = 5.015795
                                 R.2  = 4.489144
                                 R.3  = 4.000565
                                 R.4  = 3.958894
                                 R.5  = 3.331753
                                 R.6  = 3.044670
                                 R.7  = 3.140951
                                 R.8  = 3.139520
                                 R.9  = 3.134806
                                 R.10 = 3.233852

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
                                 from the same Distribution.

Type I Error:                    5%

Number of Outliers Detected:     4
```

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	12656.987	18410.44	105000	94	5.015795	3.525291	TRUE
2	1	12053.438	16873.28	87800	115	4.489144	3.523245	TRUE
3	2	11555.105	15759.00	74600	149	4.000565	3.521183	TRUE
4	3	11137.589	14944.18	70300	128	3.958894	3.519104	TRUE
5	4	10743.173	14183.77	58000	46	3.331753	3.517009	FALSE
6	5	10426.013	13687.52	52100	148	3.044670	3.514898	FALSE
7	6	10144.432	13293.93	51900	11	3.140951	3.512770	FALSE
8	7	9860.381	12880.83	50300	123	3.139520	3.510625	FALSE
9	8	9583.397	12478.16	48700	75	3.134806	3.508462	FALSE
10	9	9313.628	12086.63	48400	53	3.233852	3.506282	FALSE

```
[1] "Rosner test pour : Balance_commerciale"

Results of Outlier Test
-------------------------
```

```
Test Method:                     Rosner's Test for Outliers

Hypothesized Distribution:       Normal

Data:                            DIANE_complete[[i]]

Sample Size:                     167

Test Statistics:                 R.1  = 3.590601
                                 R.2  = 3.371333
                                 R.3  = 3.220907
                                 R.4  = 3.098541
                                 R.5  = 2.716823
                                 R.6  = 2.697697
                                 R.7  = 2.702313
                                 R.8  = 2.736784
                                 R.9  = 2.793199
                                 R.10 = 2.727309

Test Statistic Parameter:        k = 10

Alternative Hypothesis:          Up to 10 observations are not
                                 from the same Distribution.

Type I Error:                    5%

Number of Outliers Detected:     1
```

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	-5.713574	18.87885	-73.5	91	3.590601	3.550554	TRUE
2	1	-5.305222	18.18117	-66.6	85	3.371333	3.548694	FALSE
3	2	-4.933739	17.59326	-61.6	88	3.220907	3.546821	FALSE
4	3	-4.588213	17.07635	-57.5	105	3.098541	3.544935	FALSE
5	4	-4.263601	16.61367	-49.4	68	2.716823	3.543035	FALSE
6	5	-3.984981	16.27871	-47.9	157	2.697697	3.541121	FALSE
7	6	-3.712217	15.95382	39.4	27	2.702313	3.539193	FALSE
8	7	-3.981668	15.63209	38.8	57	2.736784	3.537251	FALSE
9	8	-4.250735	15.30530	38.5	128	2.793199	3.535295	FALSE
10	9	-4.521309	14.96762	36.3	86	2.727309	3.533324	FALSE

Après l'interprétation de notre boxplot, nous avons constaté que certaines valeurs se démarquaient nettement des autres. Nous avons alors envisagé qu'elles pouvaient être atypiques

ou aberrantes. Pour vérifier cette hypothèse, nous avons appliqué le Rosner test, qui permet d'identifier de manière précise ces valeurs atypiques dans nos variables quantitatives.

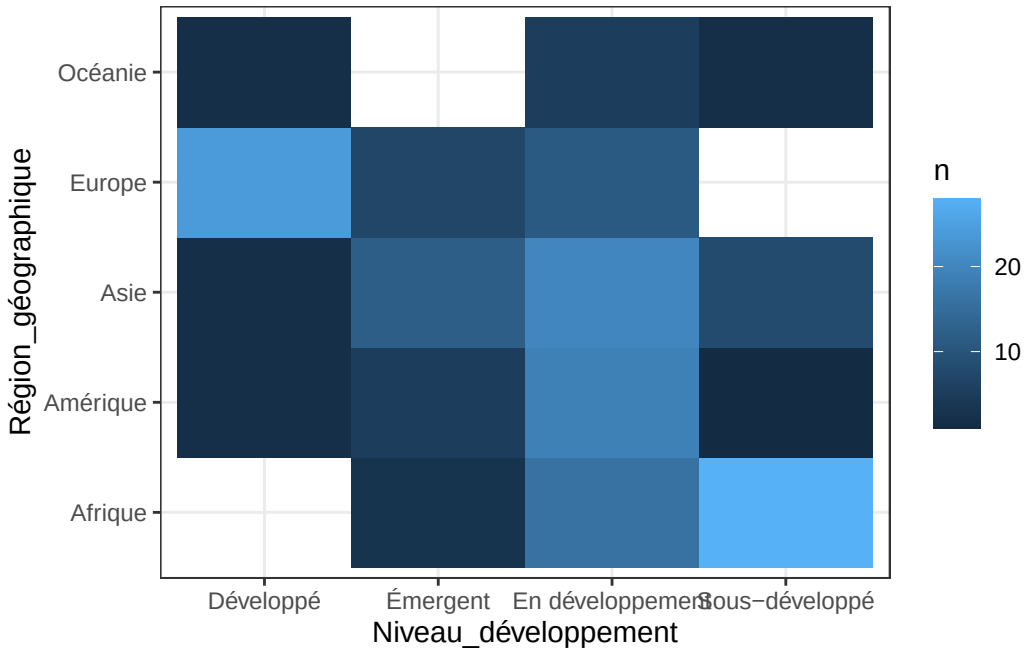
Les résultats du test ont montré la présence de valeurs atypique pour plusieurs variables. Pour la mortalité infantile, nous avons identifié une seule valeur aberrante. Pour les exportations, trois valeurs étaient considérées comme atypiques, tandis que la dépense en santé présentait une seule valeur aberrante. Les importations avaient deux valeurs atypiques, et le revenu en comptait cinq. Concernant l'inflation, trois valeurs étaient atypiques, l'espérance de vie avait une valeur aberrante, tandis que la fécondité n'en présentait aucune. Enfin, le PIB affichait quatre valeurs atypiques et la balance commerciale une seule.

Bien que ces valeurs atypiques soient connues, nous avons choisi de ne pas les supprimer pour nos analyses statistiques. En effet, notre base de données porte sur différents pays, et supprimer une observation correspondant à un pays reviendrait à supprimer un pays entier, ce qui pourrait avoir un impact négatif sur nos résultats et nos conclusions. Nous avons donc décidé de conserver ces valeurs afin de maintenir la représentativité et l'intégrité de notre base de données.

Analyse descriptive bivariée

Quali - Quali

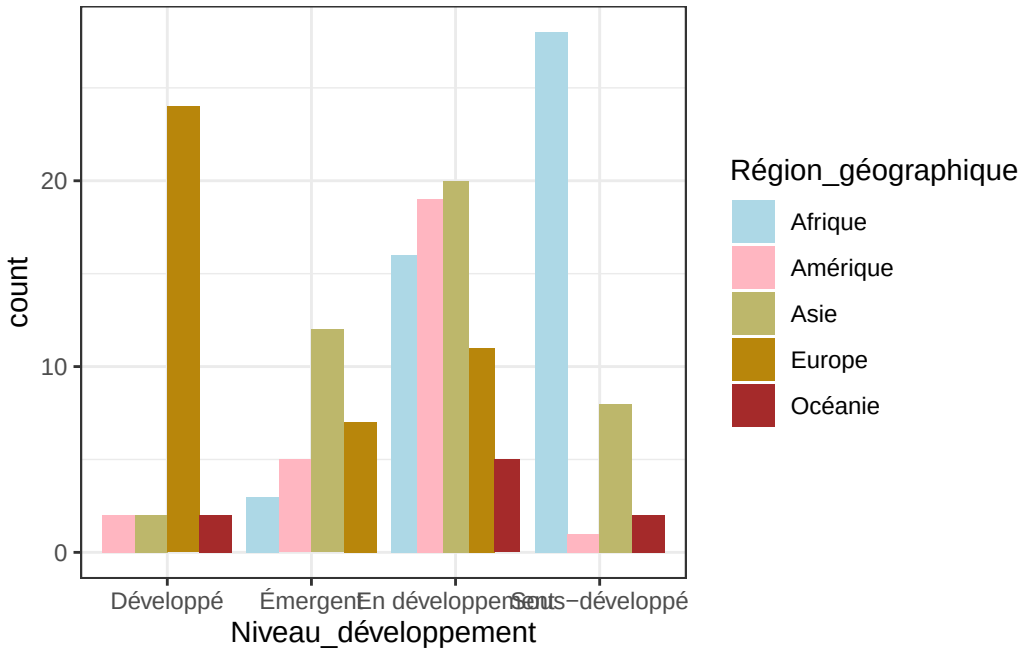
```
DIANE_complete |>
count(Niveau_développement,  Région_géographique) |>
ggplot() +
aes(x = Niveau_développement, y = Région_géographique, fill = n) +
geom_tile() +
theme_bw()
```



Cete graphique présente une heatmap (carte de chaleur) . Elle croise deux variables qualitatives : la Région géographique (en ordonnées) et le Niveau de développement (en abscisses).Voici l'analyse de ce que ce graphique nous apprend sur vos données : 1. Interprétation visuelle (L'intensité des couleurs)La légende à droite indique que plus le bleu est clair, plus l'effectif (n) est élevé. Plus le bleu est sombre, plus le nombre de pays dans cette catégorie est faible. Les zones blanches indiquent une absence totale de données (effectif de zéro). Les pôles de concentration : Afrique / Sous-développé : C'est la zone la plus claire du graphique, indiquant que la majorité des pays classés comme "Sous-développés" se trouvent en Afrique.Europe / Développé : On observe un bleu très clair ici aussi, montrant une forte concentration de pays développés en Europe.Les zones de transition :L'Asie et l'Amérique semblent avoir une répartition plus diffuse, touchant principalement les catégories "Émergent" et "En développement".L'Océanie est très peu représentée (couleurs sombres partout), ce qui est logique vu le faible nombre de pays dans cette région.

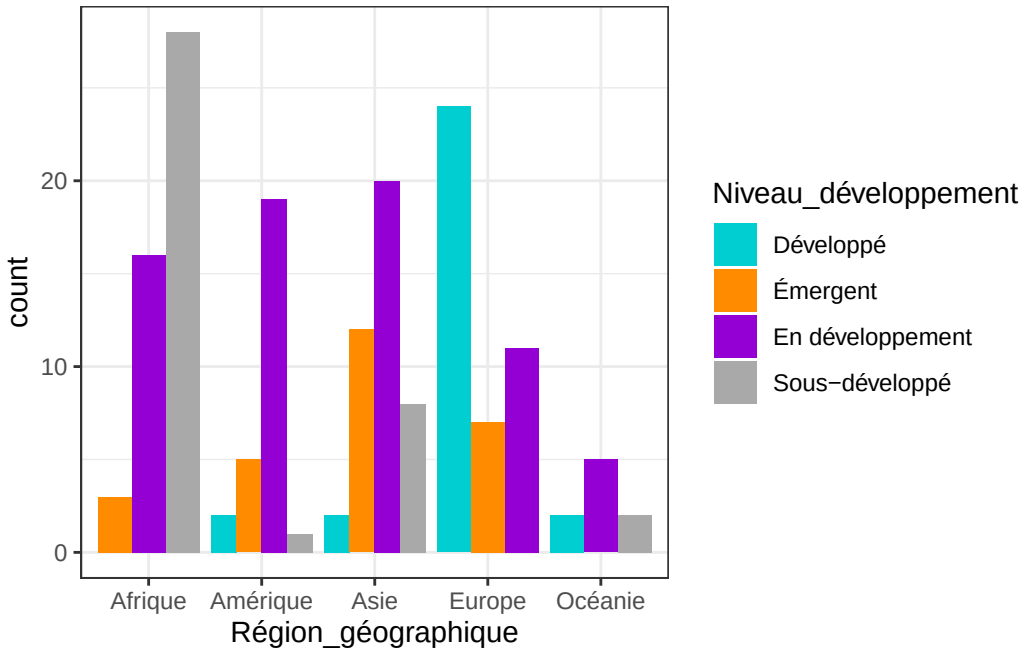
```
DIANE_complete |>
ggplot(aes(x = Niveau_développement, fill = Région_géographique)) +
geom_bar(position = "dodge") +   # barres côte à côte
scale_fill_manual(values = vecteur_couleur) +

theme_bw()
```



Il s'agit ici de la distribution du niveau de développement dans laquelle nous avons mis en évidence la région géographique .

```
DIANE_complete |>
ggplot(aes(x = Région_géographique, fill = Niveau_développement)) +
geom_bar(position = "dodge") +   # barres côte à côte
scale_fill_manual(values = vecteur_couleur) +
theme_bw()
```



Nous restons dans la même logique , pour cette fois, nous mettons en évidence le niveau de développement à partir de la distribution de la région géographique.

L'analyse des boxplots révèle que la plupart des variables quantitatives présentent des variations importantes selon le niveau de développement des pays. Cette tendance met en évidence les différences économiques et sociales entre pays développés, en développement et sous-développés. En revanche, les importations semblent relativement constantes, ce qui suggère que ce facteur est moins influencé par le niveau de développement.

Quanti-quanti

Matrice de correlation

```
# pearson

# Calculer la matrice de corrélation
mat_corr <- cor(DIANE_complete[vars_quanti], use = "complete.obs")
```

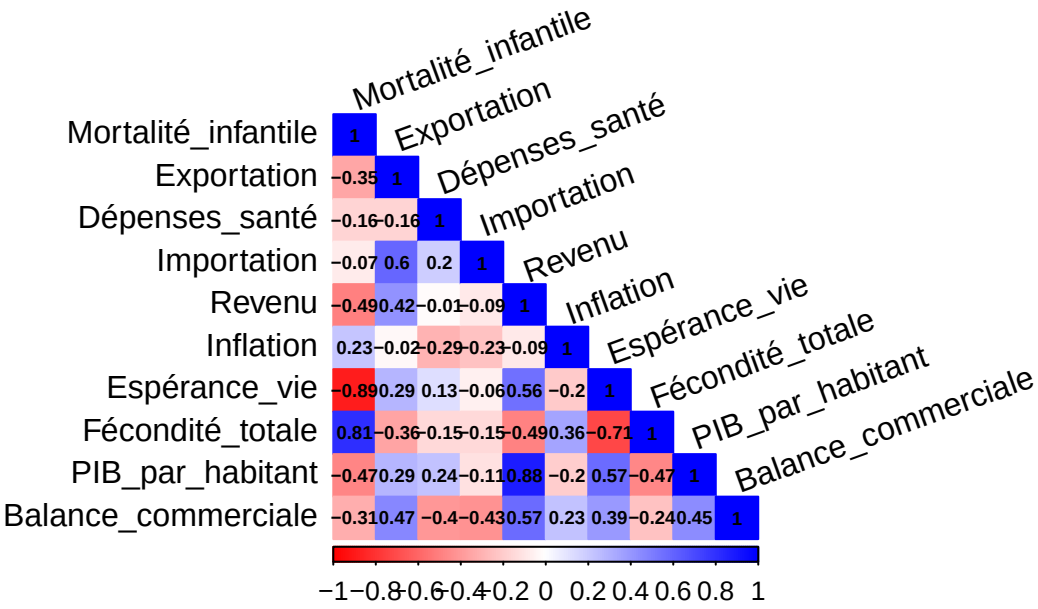
```r
# Afficher la matrice
mat_corr
```

```
                   Mortalité_infantile Exportation Dépenses_santé Importation
Mortalité_infantile          1.00000000 -0.34849346    -0.16472284 -0.07364833
Exportation                 -0.34849346  1.00000000    -0.16226804  0.59912180
Dépenses_santé              -0.16472284 -0.16226804     1.00000000  0.19749567
Importation                 -0.07364833  0.59912180     0.19749567  1.00000000
Revenu                      -0.49310665  0.42318214    -0.01085148 -0.08563142
Inflation                    0.22784243 -0.02082997    -0.29351156 -0.23323556
Espérance_vie               -0.88545705  0.28997336     0.12808214 -0.05935899
Fécondité_totale             0.81332980 -0.35537304    -0.14719654 -0.14696955
PIB_par_habitant            -0.47486758  0.28643863     0.23959446 -0.11277185
Balance_commerciale         -0.31207190  0.46728207    -0.40125617 -0.42790940
                         Revenu   Inflation Espérance_vie Fécondité_totale
Mortalité_infantile -0.49310665  0.22784243   -0.88545705        0.8133298
Exportation          0.42318214 -0.02082997    0.28997336       -0.3553730
Dépenses_santé      -0.01085148 -0.29351156    0.12808214       -0.1471965
Importation         -0.08563142 -0.23323556   -0.05935899       -0.1469696
Revenu               1.00000000 -0.08744725    0.55916901       -0.4888852
Inflation           -0.08744725  1.00000000   -0.20352855        0.3550582
Espérance_vie        0.55916901 -0.20352855    1.00000000       -0.7119571
Fécondité_totale    -0.48888518  0.35505815   -0.71195711        1.0000000
PIB_par_habitant     0.88244788 -0.19603784    0.57380792       -0.4662590
Balance_commerciale  0.57226516  0.23403118    0.39288187       -0.2388746
                    PIB_par_habitant Balance_commerciale
Mortalité_infantile       -0.4748676          -0.3120719
Exportation                0.2864386           0.4672821
Dépenses_santé             0.2395945          -0.4012562
Importation               -0.1127718          -0.4279094
Revenu                     0.8824479           0.5722652
Inflation                 -0.1960378           0.2340312
Espérance_vie              0.5738079           0.3928819
Fécondité_totale          -0.4662590          -0.2388746
PIB_par_habitant           1.0000000           0.4478716
Balance_commerciale        0.4478716           1.0000000
```

```r
# pearson

# Calcul de la matrice de corrélation
mat_corr <- cor(DIANE_complete[vars_quanti], use = "complete.obs")
```

```r
# Affichage avec couleurs et valeurs
corrplot(mat_corr, method = "color", type = "lower",
         addCoef.col = "black", # affiche les coefficients
         tl.col = "black", tl.srt = 20, # noms des variables
         number.cex = 0.6,
         col = colorRampPalette(c("red","white","blue"))(200))
```



Dynamiques de santé et indicateurs démographiques Le corrplot permet d'identifier des mécanismes sociaux profonds, notamment à travers ce que l'on peut appeler le "Triangle de la Santé". La corrélation négative extrêmement forte entre la mortalité infantile et l'espérance de vie (-0,89) montre que la survie des enfants reste le levier majeur de la longévité globale d'une population. Parallèlement, la forte corrélation positive entre la fécondité et la mortalité infantile (0,81) illustre un cycle démographique souvent observé dans les zones précaires : un taux de natalité élevé compense souvent une mortalité infantile importante, ces deux facteurs étant généralement alimentés par un accès limité aux soins et à l'éducation.

Corrélations économiques et variables structurelles Sur le plan économique, le graphique met en évidence un "Bloc Économique" où le Revenu et le PIB par habitant sont quasi indissociables (corrélation de 0,88), l'un agissant comme le moteur direct de l'autre. Cette prospérité semble également favoriser l'ouverture commerciale, puisque la balance commerciale est positivement liée au revenu (0,57), suggérant que les pays les plus riches génèrent des flux d'échanges plus massifs ou bénéficient d'excédents plus fréquents. À l'inverse, des variables comme l'inflation ou les dépenses de santé affichent des teintes très pâles, indiquant qu'elles n'exercent pas

d'influence linéaire prévisible sur les autres indicateurs dans ce contexte précis, leur impact étant probablement modulé par d'autres facteurs structurels non mesurés ici.

Nuage de point

```
library(gridExtra)

# Après ta boucle, tu as une liste de plots
plots <- list()

k <- 1
for (i in seq_along(vars_quanti)) {
  for (j in seq_along(vars_quanti)) {
    if (i < j) {
      xvar <- vars_quanti[i]
      yvar <- vars_quanti[j]

      plots[[k]] <- ggplot(DIANE_complete, aes_string(x = xvar, y = yvar)) +
        geom_point() +
        geom_smooth(method = "lm", se = FALSE) +
        theme_classic()
        # ggtitle(paste("Relation entre", xvar, "et", yvar))
      k <- k + 1
    }
  }
}

# Afficher plusieurs graphiques sur une seule page
grid.arrange(grobs = plots[1:4], nrow=2 ,ncol=2)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 6 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 6 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 14 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 14 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

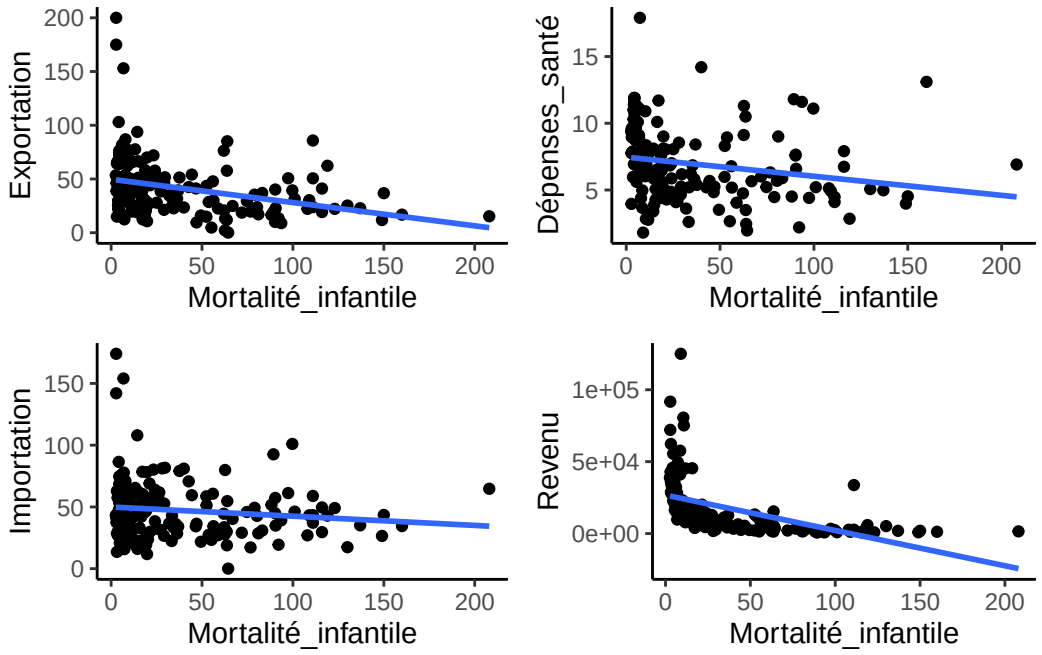
Warning: Removed 6 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 6 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 16 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 16 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[5:8], nrow=2 ,ncol=2)
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 21 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 21 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 20 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 20 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

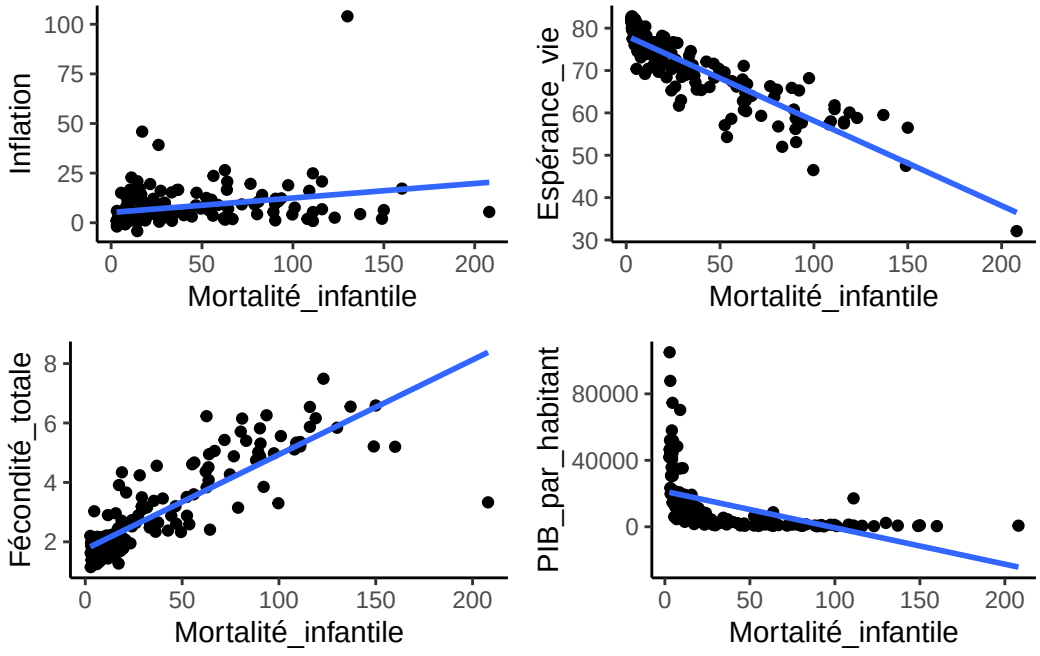
Warning: Removed 13 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 13 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 19 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 19 rows containing missing values (`geom_point()`).
```



```
grid.arrange(grobs = plots[9:12], nrow=2 ,ncol=2)# première page
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 6 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 6 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

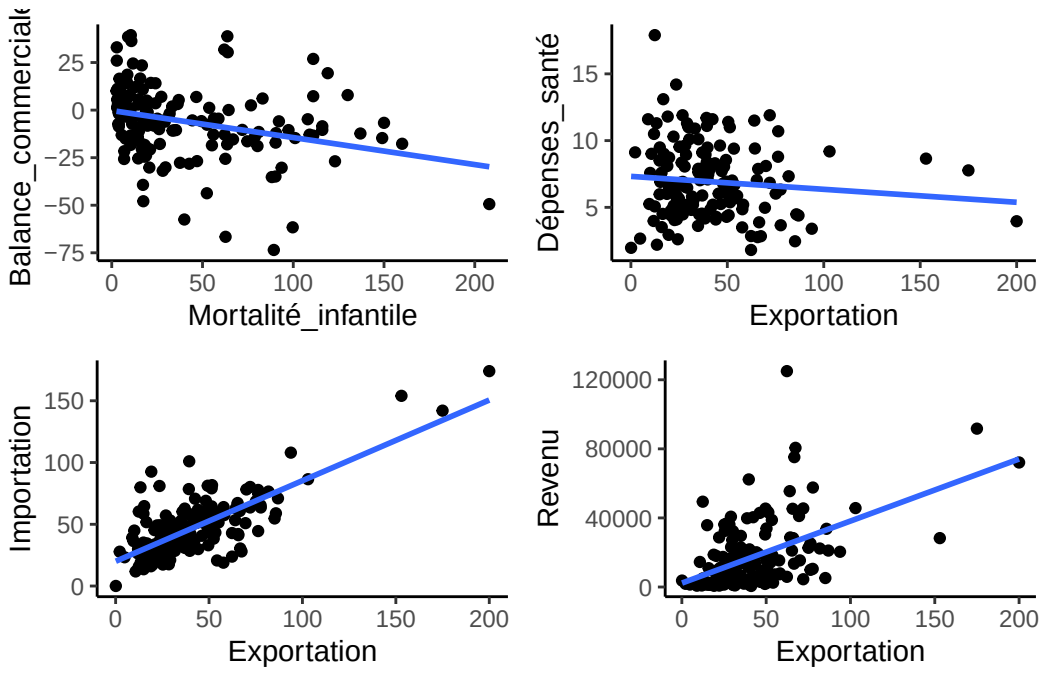
Warning: Removed 9 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 9 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 10 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 10 rows containing missing values (`geom_point()`).
```



```r
grid.arrange(grobs = plots[13:16], nrow=2 ,ncol=2)# première page
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 15 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 15 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 14 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 14 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

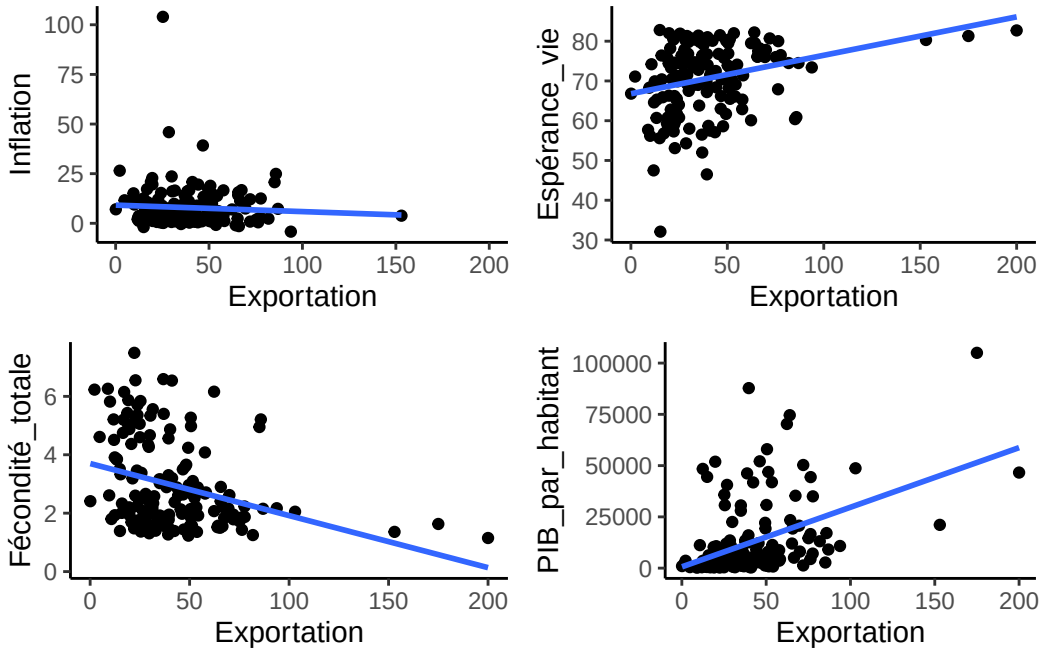
Warning: Removed 8 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 8 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 13 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 13 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[17:20], nrow=2 ,ncol=2)
```

```
`geom_smooth()` using formula = 'y ~ x'
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 9 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 9 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

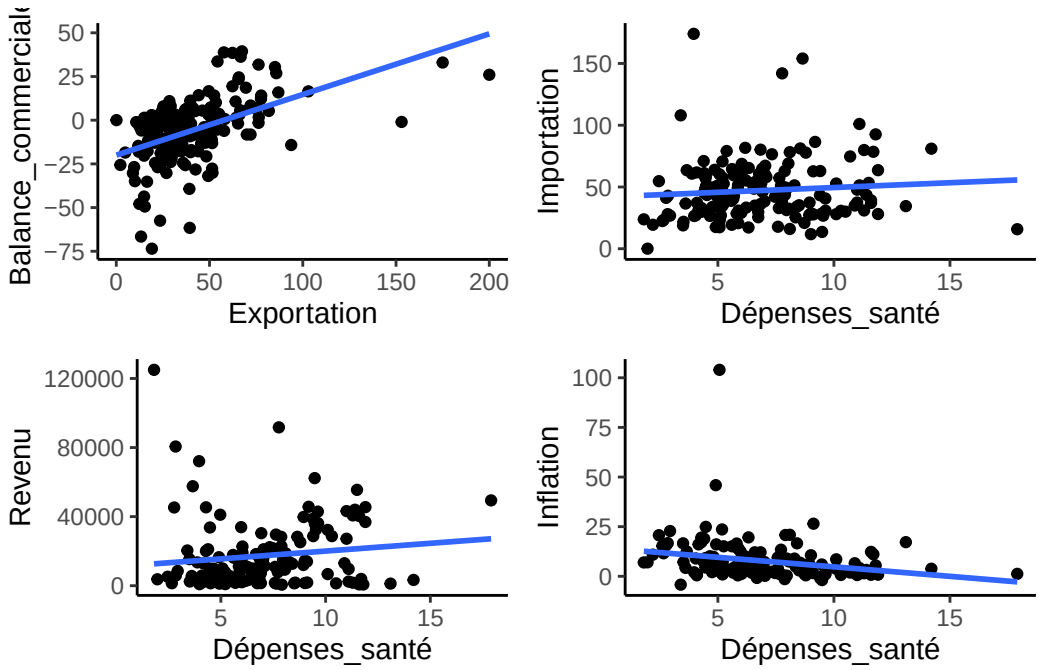
Warning: Removed 18 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 18 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 23 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 23 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[21:24], nrow=2 ,ncol=2)# deuxième page
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 22 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 22 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 16 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 16 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

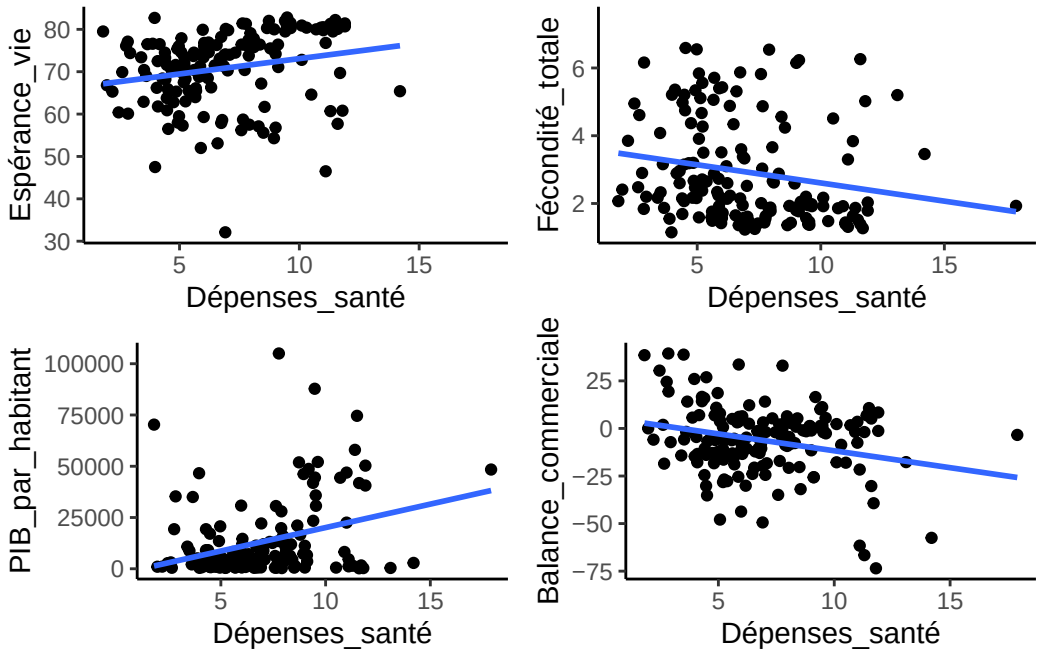
```
Warning: Removed 19 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 19 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 9 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 9 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[25:28], nrow=2 ,ncol=2)# deuxième page
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 10 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 10 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 15 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 15 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'

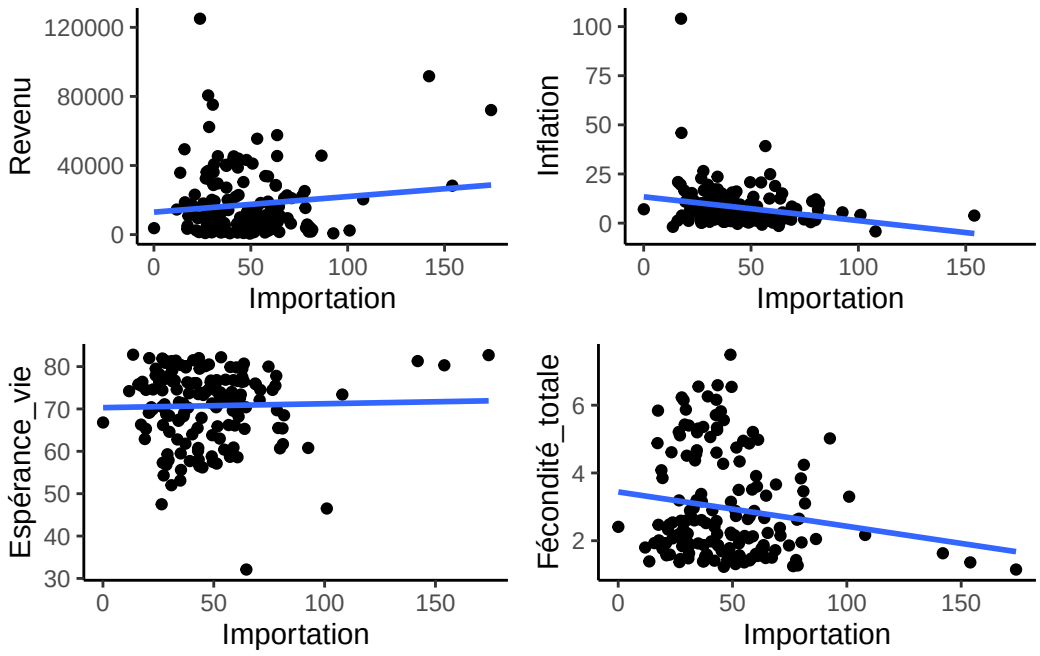
Warning: Removed 14 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 14 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 8 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 8 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[29:32], nrow=2 ,ncol=2)# deuxième page
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 13 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 13 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
`geom_smooth()` using formula = 'y ~ x'
```

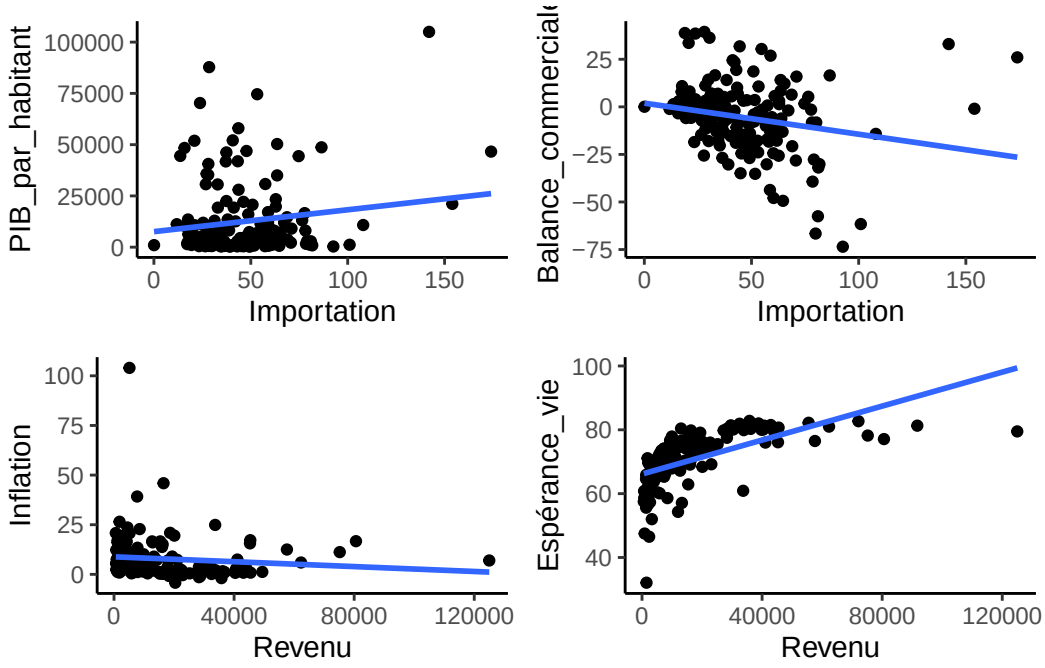
```
Warning: Removed 24 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 24 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 23 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 23 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[33:36], nrow=2 ,ncol=2)# deuxième page
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 17 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 17 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 22 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 22 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

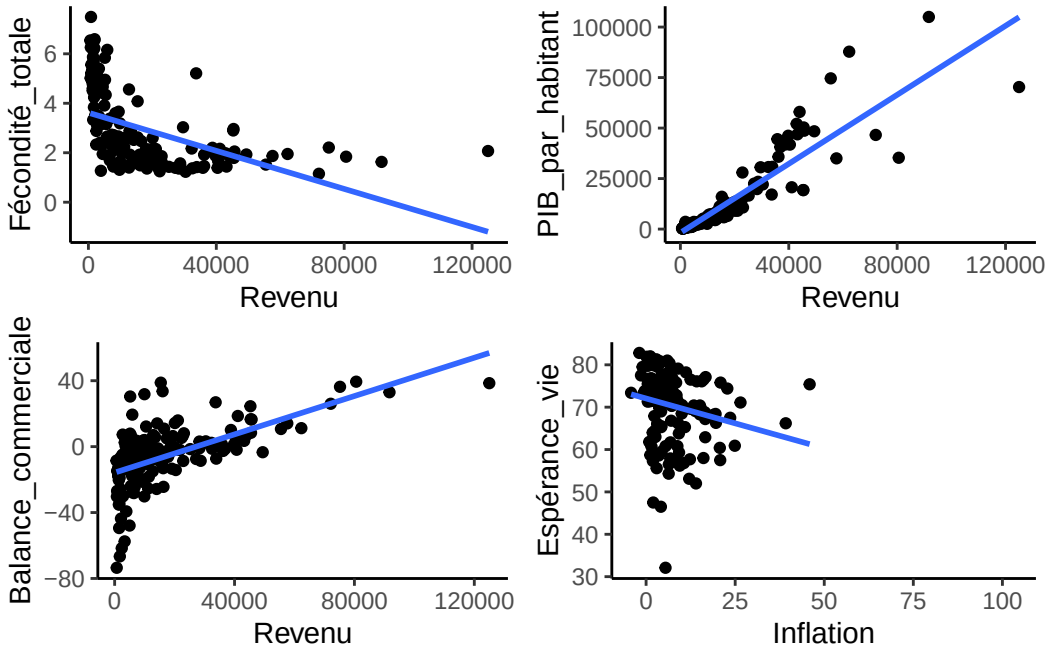
Warning: Removed 10 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 10 rows containing missing values (`geom_point()`).

`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 27 rows containing non-finite values (`stat_smooth()`).

Warning: Removed 27 rows containing missing values (`geom_point()`).
```



```
grid.arrange(grobs = plots[37:40], nrow=2 ,ncol=2)# deuxième page
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 23 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 23 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 27 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 27 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

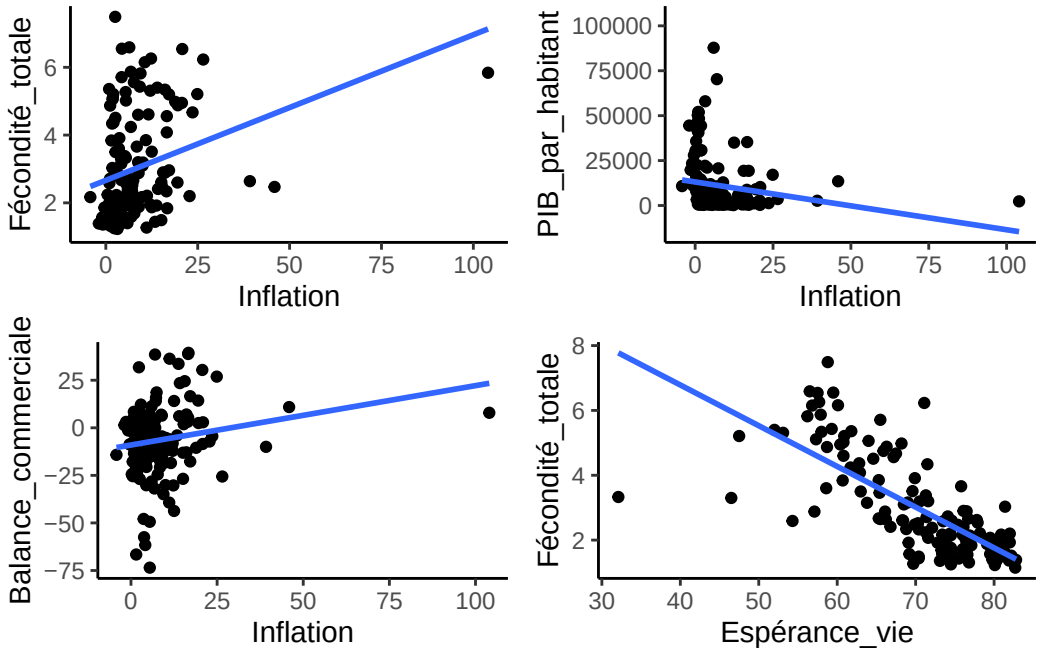
```
Warning: Removed 15 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 15 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 22 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 22 rows containing missing values (`geom_point()`).
```




```
grid.arrange(grobs = plots[41:44], nrow=2 ,ncol=2)# deuxième page
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 26 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 26 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 14 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 14 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

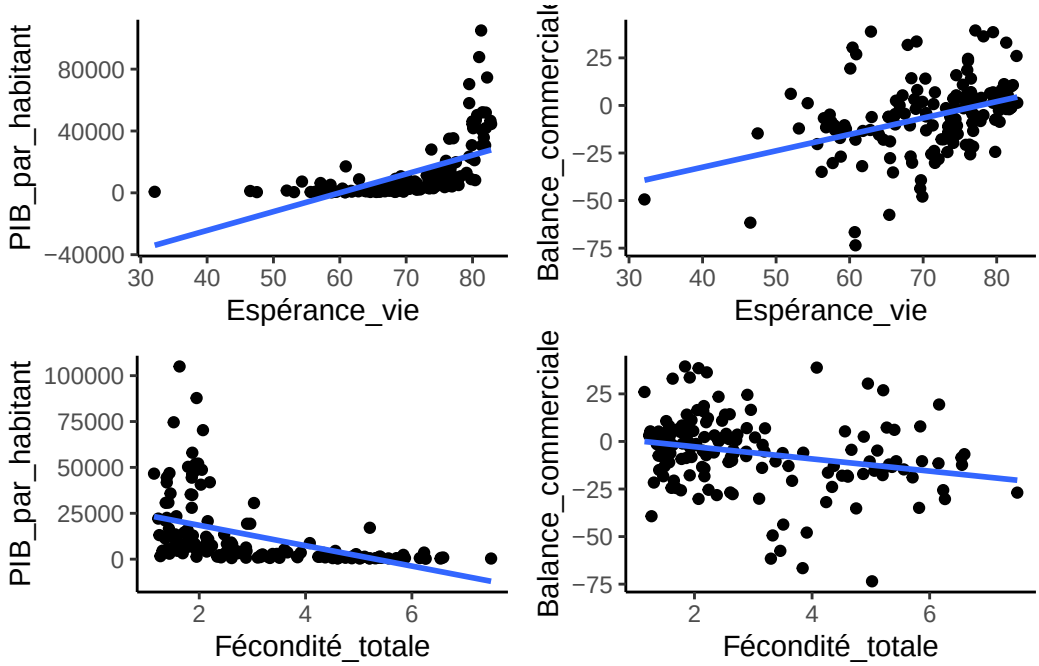
```
Warning: Removed 21 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 21 rows containing missing values (`geom_point()`).
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 8 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Removed 8 rows containing missing values (`geom_point()`).
```



Dans ces différents graphiques, nous avons obtenu plusieurs sorties représentant des paires de variables, à la fois quantitatives.

Dans notre cas, nous nous sommes particulièrement intéressés à la variable mortalité, car nous pensions qu'elle pouvait être corrélée, positivement ou négativement, avec d'autres variables. Nous nous sommes donc demandé pourquoi ne pas l'utiliser comme variable de référence afin de procéder à une imputation à l'aide des MCO.

C'est dans cette perspective que nous avons décidé de la retenir.

Ce qu'il faut principalement retenir de cette partie, c'est que, globalement, la relation entre la variable mortalité et les autres variables observées sur les graphiques tend à converger vers une relation de régression linéaire.

Méthode d'imputation par les MCO

```r
base_regression <- DIANE_complete[complete.cases(DIANE_complete), ]

lm(Mortalité_infantile~Revenu + Exportation +Dépenses_santé + Importation + Inflation + Espé

summary()
```

```
Call:
lm(formula = Mortalité_infantile ~ Revenu + Exportation + Dépenses_santé +
    Importation + Inflation + Espérance_vie + Fécondité_totale +
    PIB_par_habitant + Balance_commerciale, data = base_regression)

Residuals:
    Min      1Q  Median      3Q     Max
-41.783  -7.157   0.173   8.627  54.422

Coefficients: (1 not defined because of singularities)
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)          2.280e+02  2.247e+01  10.147  < 2e-16 ***
Revenu              -1.760e-04  2.144e-04  -0.821   0.4137
Exportation         -1.002e-01  1.234e-01  -0.812   0.4187
Dépenses_santé      -1.385e+00  8.010e-01  -1.729   0.0871 .
Importation         -8.275e-03  1.196e-01  -0.069   0.9450
Inflation           -2.026e-01  2.411e-01  -0.840   0.4028
Espérance_vie       -2.927e+00  2.630e-01 -11.127  < 2e-16 ***
Fécondité_totale     9.671e+00  1.560e+00   6.201 1.37e-08 ***
PIB_par_habitant     4.397e-04  2.483e-04   1.771   0.0798 .
Balance_commerciale         NA         NA      NA       NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.63 on 97 degrees of freedom
Multiple R-squared:  0.8647,    Adjusted R-squared:  0.8535
F-statistic: 77.48 on 8 and 97 DF,  p-value: < 2.2e-16
```

```r
library(leaps)
modele0<-lm(Mortalité_infantile~1,data=base_regression)
modele<-
lm(Mortalité_infantile~Revenu + Exportation +Dépenses_santé + Importation + Inflation + Espé

#Méthode ascendante
```

```r
step(modele0, scope=list(lower=modele0, upper=modele),data=base_regression,
direction="forward")
```

```
Start:  AIC=787.47
Mortalité_infantile ~ 1

                     Df Sum of Sq    RSS    AIC
+ Espérance_vie       1    137341  37831 627.01
+ Fécondité_totale    1    115877  59295 674.64
+ Revenu              1     42594 132578 759.94
+ PIB_par_habitant    1     39501 135671 762.38
+ Exportation         1     21274 153898 775.74
+ Balance_commerciale 1     17060 158112 778.61
+ Inflation           1      9094 166079 783.82
+ Dépenses_santé      1      4753 170419 786.55
<none>                            175172 787.47
+ Importation         1       950 174222 788.89

Step:  AIC=627.01
Mortalité_infantile ~ Espérance_vie

                     Df Sum of Sq   RSS    AIC
+ Fécondité_totale    1   11886.4 25945 589.03
+ Importation         1    2800.1 35031 620.86
+ Exportation         1    1609.4 36222 624.40
<none>                            37831 627.01
+ Dépenses_santé      1     468.9 37362 627.69
+ Inflation           1     414.5 37417 627.84
+ PIB_par_habitant    1     288.1 37543 628.20
+ Balance_commerciale 1     265.6 37566 628.26
+ Revenu              1       1.0 37830 629.01

Step:  AIC=589.03
Mortalité_infantile ~ Espérance_vie + Fécondité_totale

                     Df Sum of Sq   RSS    AIC
+ PIB_par_habitant    1    787.37 25158 587.76
+ Importation         1    594.89 25350 588.57
<none>                            25945 589.03
+ Revenu              1    332.70 25612 589.66
+ Exportation         1    267.82 25677 589.93
+ Inflation           1    185.44 25759 590.27
```

```
+ Dépenses_santé       1    167.14 25778 590.35
+ Balance_commerciale  1     88.76 25856 590.67

Step:  AIC=587.76
Mortalité_infantile ~ Espérance_vie + Fécondité_totale +
    PIB_par_habitant

                     Df Sum of Sq   RSS    AIC
<none>                             25158 587.76
+ Importation         1    438.95 24719 587.90
+ Exportation         1    413.62 24744 588.01
+ Dépenses_santé      1    355.68 24802 588.25
+ Inflation           1    135.23 25022 589.19
+ Revenu              1     76.31 25081 589.44
+ Balance_commerciale 1      0.88 25157 589.76



Call:
lm(formula = Mortalité_infantile ~ Espérance_vie + Fécondité_totale +
    PIB_par_habitant, data = base_regression)

Coefficients:
     (Intercept)     Espérance_vie  Fécondité_totale  PIB_par_habitant
       2.110e+02        -2.924e+00         1.012e+01         2.066e-04
```

```
#méthode descendante
step(modele, data=base_regression,direction="backward")
```

```
Start:  AIC=591.46
Mortalité_infantile ~ Revenu + Exportation + Dépenses_santé +
    Importation + Inflation + Espérance_vie + Fécondité_totale +
    PIB_par_habitant + Balance_commerciale


Step:  AIC=591.46
Mortalité_infantile ~ Revenu + Exportation + Dépenses_santé +
    Importation + Inflation + Espérance_vie + Fécondité_totale +
    PIB_par_habitant

                   Df Sum of Sq   RSS    AIC
- Importation       1       1.2 23706 589.46
- Exportation       1     161.2 23866 590.18
```

```
- Revenu            1     164.7 23870 590.19
- Inflation         1     172.6 23877 590.23
<none>                          23705 591.46
- Dépenses_santé    1     730.2 24435 592.68
- PIB_par_habitant  1     766.2 24471 592.83
- Fécondité_totale  1    9396.4 33101 624.85
- Espérance_vie     1   30258.4 53963 676.66

Step:  AIC=589.46
Mortalité_infantile ~ Revenu + Exportation + Dépenses_santé +
    Inflation + Espérance_vie + Fécondité_totale + PIB_par_habitant

                   Df Sum of Sq   RSS    AIC
- Revenu            1       164 23870 588.19
- Inflation         1       179 23885 588.26
<none>                          23706 589.46
- Exportation       1       457 24163 589.49
- PIB_par_habitant  1       807 24513 591.01
- Dépenses_santé    1       955 24661 591.65
- Fécondité_totale  1      9464 33170 623.07
- Espérance_vie     1     31724 55430 677.50

Step:  AIC=588.19
Mortalité_infantile ~ Exportation + Dépenses_santé + Inflation +
    Espérance_vie + Fécondité_totale + PIB_par_habitant

                   Df Sum of Sq   RSS    AIC
- Inflation         1       236 24106 587.24
<none>                          23870 588.19
- Exportation       1       643 24512 589.01
- Dépenses_santé    1       792 24661 589.65
- PIB_par_habitant  1      1237 25107 591.55
- Fécondité_totale  1     10147 34017 623.74
- Espérance_vie     1     31715 55585 675.80

Step:  AIC=587.24
Mortalité_infantile ~ Exportation + Dépenses_santé + Espérance_vie +
    Fécondité_totale + PIB_par_habitant

                   Df Sum of Sq   RSS    AIC
<none>                          24106 587.24
- Dépenses_santé    1       638 24744 588.01
- Exportation       1       696 24802 588.25
```

```
- PIB_par_habitant  1      1274 25380 590.70
- Fécondité_totale  1     10151 34257 622.49
- Espérance_vie     1     32462 56568 675.65


Call:
lm(formula = Mortalité_infantile ~ Exportation + Dépenses_santé +
    Espérance_vie + Fécondité_totale + PIB_par_habitant, data = base_regression)

Coefficients:
     (Intercept)       Exportation    Dépenses_santé     Espérance_vie
       2.258e+02        -1.275e-01        -1.016e+00        -2.945e+00
Fécondité_totale  PIB_par_habitant
       9.435e+00         2.731e-04
```

```r
#méthode dans les 2 sens
step(modele0, scope = list(upper=modele),data=base_regression,direction="both")
```

```
Start:  AIC=787.47
Mortalité_infantile ~ 1

                     Df Sum of Sq    RSS    AIC
+ Espérance_vie       1    137341  37831 627.01
+ Fécondité_totale    1    115877  59295 674.64
+ Revenu              1     42594 132578 759.94
+ PIB_par_habitant    1     39501 135671 762.38
+ Exportation         1     21274 153898 775.74
+ Balance_commerciale 1     17060 158112 778.61
+ Inflation           1      9094 166079 783.82
+ Dépenses_santé      1      4753 170419 786.55
<none>                            175172 787.47
+ Importation         1       950 174222 788.89

Step:  AIC=627.01
Mortalité_infantile ~ Espérance_vie

                     Df Sum of Sq    RSS    AIC
+ Fécondité_totale    1     11886  25945 589.03
+ Importation         1      2800  35031 620.86
+ Exportation         1      1609  36222 624.40
<none>                            37831 627.01
+ Dépenses_santé      1       469  37362 627.69
```

```
+ Inflation            1       415  37417 627.84
+ PIB_par_habitant     1       288  37543 628.20
+ Balance_commerciale  1       266  37566 628.26
+ Revenu               1         1  37830 629.01
- Espérance_vie        1    137341 175172 787.47

Step:  AIC=589.03
Mortalité_infantile ~ Espérance_vie + Fécondité_totale

                     Df Sum of Sq   RSS    AIC
+ PIB_par_habitant     1       787 25157 587.76
+ Importation          1       595 25350 588.57
<none>                             25945 589.03
+ Revenu               1       333 25612 589.66
+ Exportation          1       268 25677 589.93
+ Inflation            1       185 25759 590.27
+ Dépenses_santé       1       167 25778 590.35
+ Balance_commerciale  1        89 25856 590.67
- Fécondité_totale     1     11886 37831 627.01
- Espérance_vie        1     33350 59295 674.64

Step:  AIC=587.76
Mortalité_infantile ~ Espérance_vie + Fécondité_totale +
    PIB_par_habitant

                     Df Sum of Sq   RSS    AIC
<none>                             25157 587.76
+ Importation          1       439 24719 587.90
+ Exportation          1       414 24744 588.01
+ Dépenses_santé       1       356 24802 588.25
- PIB_par_habitant     1       787 25945 589.03
+ Inflation            1       135 25022 589.19
+ Revenu               1        76 25081 589.44
+ Balance_commerciale  1         1 25157 589.76
- Fécondité_totale     1     12386 37543 628.20
- Espérance_vie        1     32090 57247 672.92


Call:
lm(formula = Mortalité_infantile ~ Espérance_vie + Fécondité_totale +
    PIB_par_habitant, data = base_regression)
```

```
Coefficients:
     (Intercept)     Espérance_vie  Fécondité_totale  PIB_par_habitant
       2.110e+02        -2.924e+00         1.012e+01         2.066e-04
```

```r
DIANE_complete2 <- DIANE_complete

regr_mortalite <- lm(formula = Mortalité_infantile ~ Espérance_vie + Fécondité_totale +
    PIB_par_habitant, data = base_regression)

# Calculer les prédictions avec ton modèle
DIANE_complete2$pred_mortalite <- predict(regr_mortalite, newdata = DIANE_complete2)
# Remplacer les NA de salaire_min par les prédictions
DIANE_complete2$Mortalité_infantile <-
  ifelse(
    is.na(DIANE_complete2$Mortalité_infantile),
    DIANE_complete2$pred_mortalite,
    DIANE_complete2$Mortalité_infantile
  )

# vérification
miss_var_summary(DIANE_complete2)
```

```
# A tibble: 14 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 pred_mortalite           34   20.4
 2 Inflation                15    8.98
 3 Espérance_vie            14    8.38
 4 PIB_par_habitant         13    7.78
 5 Revenu                   10    5.99
 6 Dépenses_santé            9    5.39
 7 Fécondité_totale          8    4.79
 8 Mortalité_infantile       1    0.599
 9 Pays                      0    0
10 Région_géographique       0    0
11 Niveau_développement      0    0
12 Exportation               0    0
13 Importation               0    0
14 Balance_commerciale       0    0
```

Pour la variable mortalité infantile., l'idée est de la régresser sur l'ensemble des autres variables qualitatives de notre étude. Cette approche nous permettra de prédire les valeurs manquantes

de la variable de mortalité infantile.

Ensuite, nous utilisons la fonction stepwise, qui permet de ne conserver que les variables expliquant de manière significative la variable mortalité infantile., c'est-à-dire celles ayant un impact statistiquement significatif sur celle-ci.

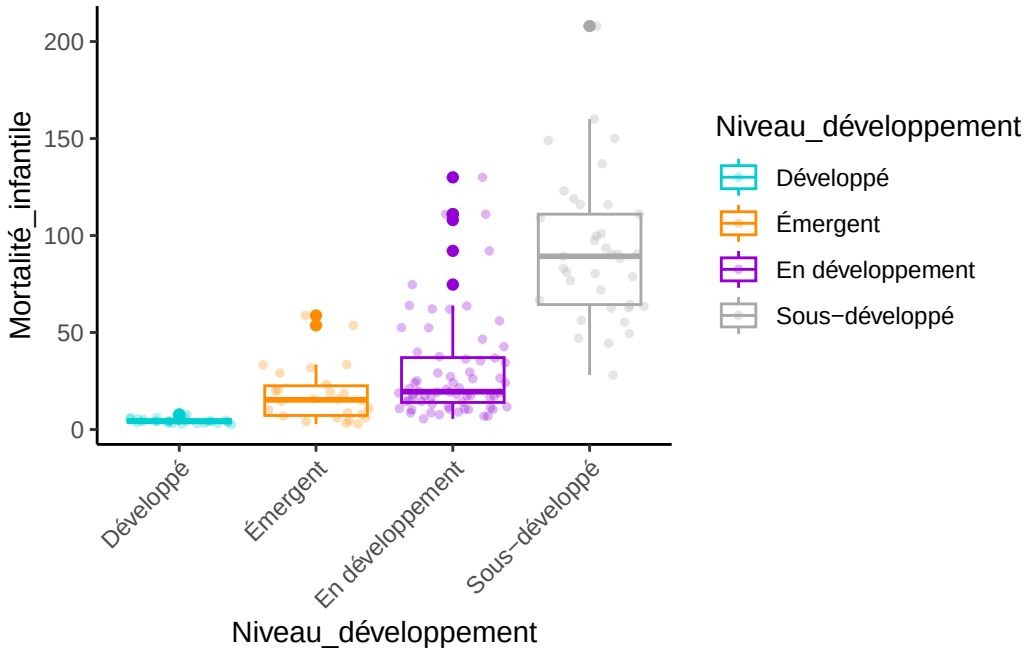
À partir du modèle sélectionné par la méthode stepwise, nous appliquons la fonction predict. Cette fonction nous permet de remplacer les valeurs manquantes de la variable mortalité par les valeurs prédites.

Grâce à cette méthode, plusieurs valeurs manquantes ont pu être imputées. Toutefois, une valeur n'a pas pu être remplacée. C'est pour cette raison que nous avons recours à une autre méthode d'imputation, à savoir l'imputation par la moyenne, appliquée uniquement à la variable mortalité infantile. qui n'a pas pu être imputée par la méthode des MCO.

Methode d'imputation par la moyenne

```
#Boxplot Exportations vs Niveau de développement
DIANE_complete |>
    ggplot(aes(
      x = Niveau_développement,
      y = Mortalité_infantile,
      color = Niveau_développement
    )) +
    geom_boxplot(na.rm = TRUE) +
    geom_jitter(size = 1, alpha = 0.3, na.rm = TRUE) +
    scale_color_manual(values = vecteur_couleur) +

    theme_classic() +
    theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




```
#lignes où "Région_géographique" est manquante
indices3 <- which(is.na(DIANE_complete2$Mortalité_infantile))

DIANE_complete2$Pays[indices3]
```

```
[1] "Guinée-Bissau"
```

```
DIANE_complete2$Niveau_développement[indices3]
```

```
[1] Sous-développé
Levels: Développé Émergent En développement Sous-développé
```

```
moyenne_Mort <- DIANE_complete2 |>
  filter(Niveau_développement == "Sous-développé") |>
  pull(Mortalité_infantile) |>
  mean(na.rm = TRUE) |>
  round()

moyenne_Mort
```

```
[1] 92
```

```
# le nom des pays correspondants à ces lignes

DIANE_complete2$Mortalité_infantile[indices3]  = moyenne_Mort

#Les Verifications
DIANE_complete2$Mortalité_infantile[indices3]
```

```
[1] 92
```

```
miss_var_summary(DIANE_complete2)
```

```
# A tibble: 14 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 pred_mortalite           34    20.4
 2 Inflation                15     8.98
 3 Espérance_vie            14     8.38
 4 PIB_par_habitant         13     7.78
 5 Revenu                   10     5.99
 6 Dépenses_santé            9     5.39
 7 Fécondité_totale          8     4.79
 8 Pays                      0     0
 9 Région_géographique       0     0
10 Niveau_développement      0     0
11 Mortalité_infantile       0     0
12 Exportation               0     0
13 Importation               0     0
14 Balance_commerciale       0     0
```

Nous avons donc pu remplacer la valeur manquante restante à l'aide d'une méthode d'imputation par la moyenne. Ainsi, le problème des quelques individus présentant une valeur manquante pour la mortalité infantile a été entièrement résolu.

```
# Suppression de la colonne pred_mortalite
DIANE_complete2 <- DIANE_complete2 |>  select(- pred_mortalite)

# Vérification
DIANE_complete2
```

```
# A tibble: 167 x 13
   Pays             Région_géographique Niveau_développement Mortalité_infantile
   <chr>            <fct>               <fct>                              <dbl>
 1 Afghanistan      Asie                Sous-développé                      90.2
 2 Afrique du Sud   Afrique             Émergent                            53.7
 3 Albanie          Europe              En développement                    16.6
 4 Algérie          Afrique             En développement                    27.3
 5 Allemagne        Europe              Développé                            4.2
 6 Angola           Afrique             Sous-développé                     119
 7 Antigua-et-Barb~ Amérique            En développement                    10.3
 8 Arabie saoudite  Asie                Émergent                            15.7
 9 Argentine        Amérique            Émergent                            14.5
10 Arménie          Europe              En développement                    18.1
# i 157 more rows
# i 9 more variables: Exportation <dbl>, Dépenses_santé <dbl>,
#   Importation <dbl>, Revenu <dbl>, Inflation <dbl>, Espérance_vie <dbl>,
#   Fécondité_totale <dbl>, PIB_par_habitant <dbl>, Balance_commerciale <dbl>
```

Après la résolution de l'imputation par les MCO des valeurs manquantes de la variable mortalité infantile, notre programme a généré une nouvelle colonne appelée pred_mortalite.

Dans ce contexte, nous avons demandé la suppression de cette nouvelle colonne, afin de conserver la base de données initiale, tout en intégrant la valeur manquante de la mortalité infantile qui a désormais été correctement remplacée.

Imputation par l'ACP

```
library(PerformanceAnalytics)
```

```
Warning: le package 'PerformanceAnalytics' a été compilé avec la version R
4.4.3
```

```
Le chargement a nécessité le package : xts
```

```
Le chargement a nécessité le package : zoo
```

```

Attachement du package : 'zoo'
```

```
Les objets suivants sont masqués depuis 'package:base':

    as.Date, as.Date.numeric


######################### Warning from 'xts' package ##########################
#                                                                             #
# The dplyr lag() function breaks how base R's lag() function is supposed to  #
# work, which breaks lag(my_xts). Calls to lag(my_xts) that you type or       #
# source() into this session won't work correctly.                            #
#                                                                             #
# Use stats::lag() to make sure you're not using dplyr::lag(), or you can add #
# conflictRules('dplyr', exclude = 'lag') to your .Rprofile to stop           #
# dplyr from breaking base R's lag() function.                                #
#                                                                             #
# Code in packages is not affected. It's protected by R's namespace mechanism #
# Set `options(xts.warn_dplyr_breaks_lag = FALSE)` to suppress this warning.  #
#                                                                             #
###############################################################################


Attachement du package : 'xts'

Les objets suivants sont masqués depuis 'package:dplyr':

    first, last


Attachement du package : 'PerformanceAnalytics'

Les objets suivants sont masqués depuis 'package:EnvStats':

    kurtosis, skewness

L'objet suivant est masqué depuis 'package:graphics':

    legend
```

```
chart.Correlation(DIANE_complete2[,vars_quanti], histogram=TRUE, pch=19,method = c("spearman"
```

```
Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos


Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos
```

```
Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
```

```
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

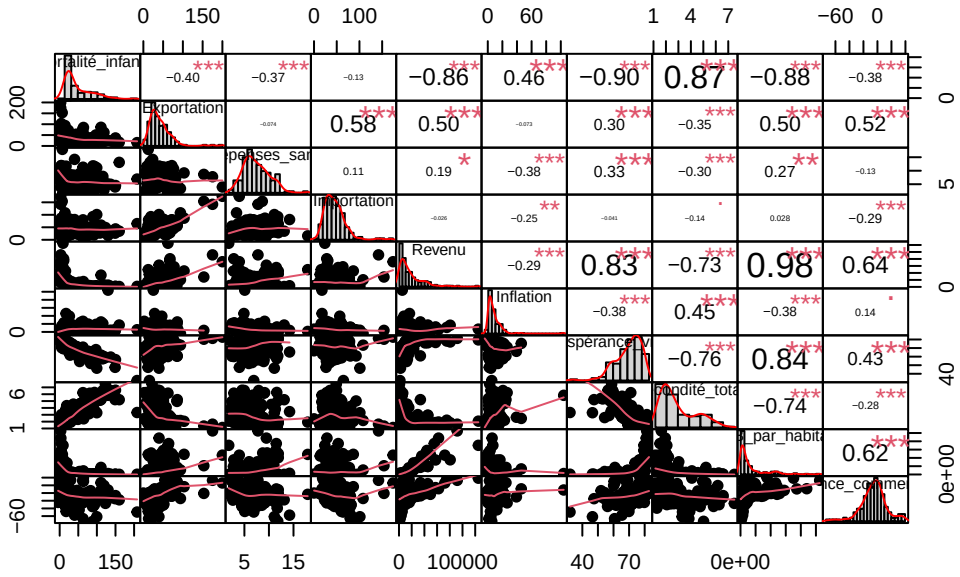
Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos
```

```
Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos

Warning in cor.test.default(as.numeric(x), as.numeric(y), method = method):
Impossible de calculer la p-value exacte avec des ex-aequos
```



La matrice de corrélation de Spearman met en évidence une structuration forte autour des variables de développement socio-économique. La mortalité infantile et la fécondité sont fortement et négativement corrélées à l'espérance de vie, au revenu et au PIB par habitant, tandis que ces dernières variables sont positivement liées entre elles. Ces relations traduisent une opposition nette entre pays moins développés et pays plus développés, confirmant l'existence d'une information commune favorable à la réalisation d'une ACP.

En revanche, les variables liées au commerce extérieur et à la stabilité macroéconomique présentent des corrélations plus modérées. Les importations semblent porter une information distincte, susceptible de structurer une dimension secondaire, tandis que les exportations, la balance commerciale, l'inflation et les dépenses de santé contribuent plus faiblement à la structuration des axes principaux, ce qui explique leur rôle secondaire dans l'analyse factorielle.

Méthode d'imputation par l'ACP

Avant la réalisation de l'analyse en composantes principales (ACP), une analyse de la matrice de corrélation de Spearman a été menée afin d'évaluer les relations entre les variables. Ce choix se justifie par le fait que certaines variables ne respectent pas l'hypothèse de normalité. Les variables présentant de fortes corrélations avec plusieurs autres ont été conservées, car elles contribuent davantage à la structuration de l'information commune. À l'inverse, les variables faiblement corrélées avec l'ensemble des autres, notamment les dépenses de santé et l'inflation, ont été écartées, car elles apportaient peu d'information partagée et risquaient d'affaiblir la qualité de la représentation factorielle. L'ACP a ensuite été réalisée sur le sous-ensemble de variables retenues.

```
# suppression des valeurs manquante pour preparer l'ACP
DIANE_sna <- DIANE_complete2 |>
  drop_na()
```

```
library(mice)
```

```
Warning: le package 'mice' a été compilé avec la version R 4.4.3
```

```
Attachement du package : 'mice'
```

```
L'objet suivant est masqué depuis 'package:stats':
```

```
    filter
```

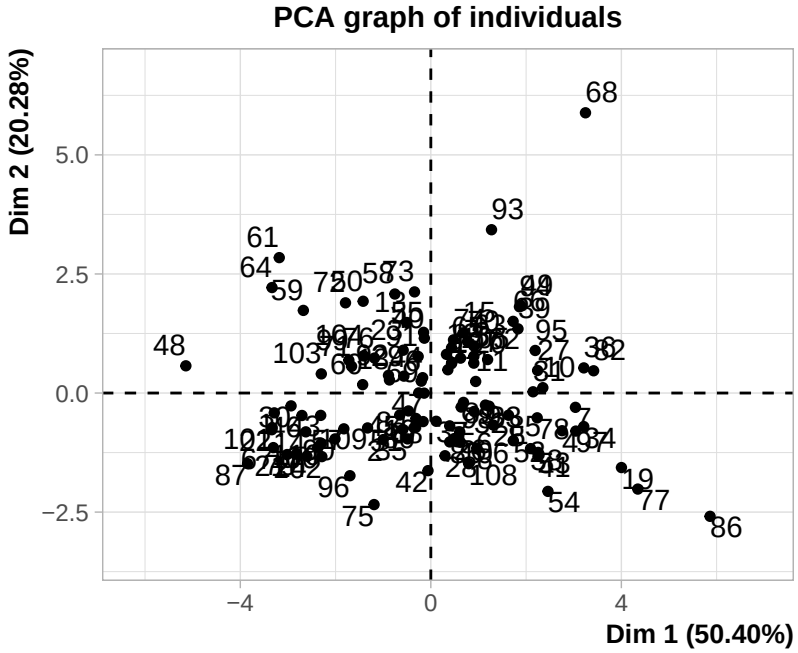
```
Les objets suivants sont masqués depuis 'package:base':
```

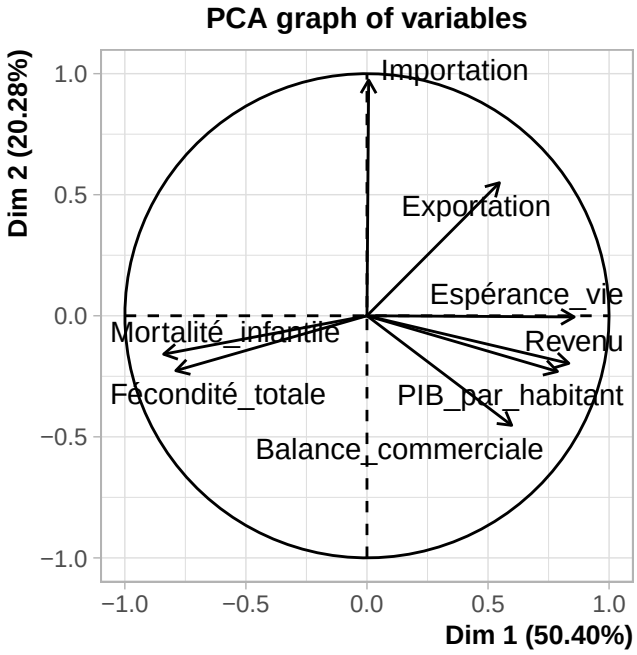
```
    cbind, rbind
```

```
library(missMDA)
library(FactoMineR)
```

```
Warning: le package 'FactoMineR' a été compilé avec la version R 4.4.3
```

```
acp_DIANE <- DIANE_sna |>
  select(-Pays,- Niveau_développement, -Région_géographique, -Inflation, -Dépenses_santé) |>
  PCA()
```





L'analyse du nuage des variables issu de l'ACP réalisée sur la base sans valeurs manquantes montre que les variables de fécondité, de mortalité infantile, d'espérance de vie, de revenu et de PIB par habitant sont fortement corrélées à la première dimension. Les importations apparaissent principalement associées à la deuxième dimension. En revanche, les variables

d'exportations et de balance commerciale présentent une faible corrélation avec les axes factoriels, comme l'indique leur position proche de l'angle de 45°, traduisant une contribution limitée à la structuration des dimensions retenues.

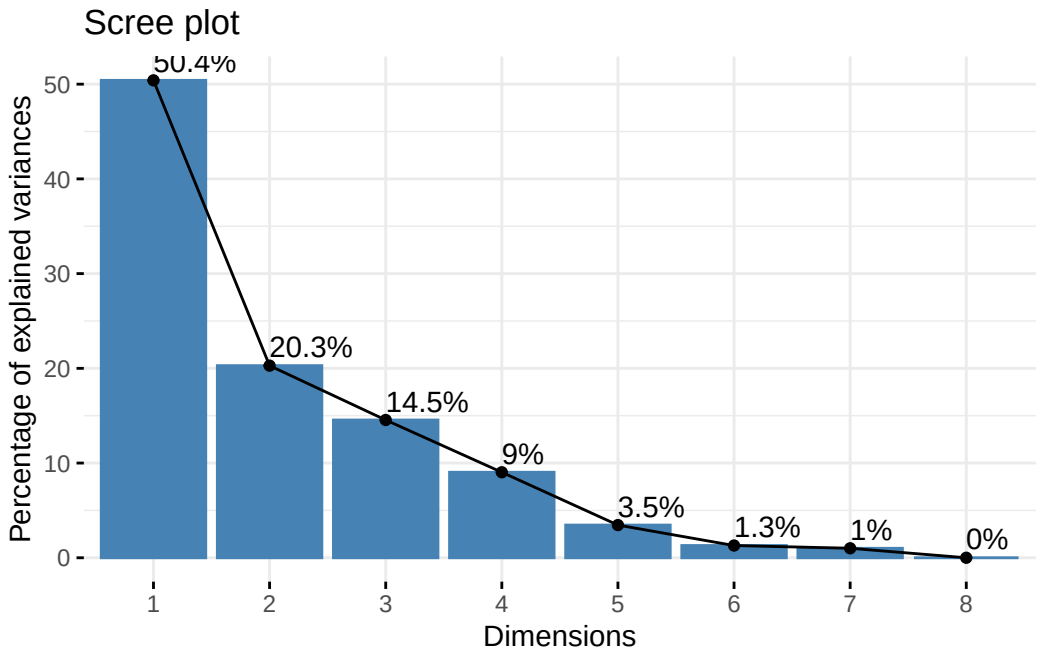
```
# Affichage des variances des composantes
round(acp_DIANE$eig,2)
```

```
       eigenvalue percentage of variance cumulative percentage of variance
comp 1       4.03                 50.40                               50.40
comp 2       1.62                 20.28                               70.69
comp 3       1.16                 14.54                               85.23
comp 4       0.72                  9.03                               94.26
comp 5       0.28                  3.45                               97.71
comp 6       0.10                  1.29                               99.00
comp 7       0.08                  1.00                              100.00
comp 8       0.00                  0.00                              100.00
```

```
# Graphique des niveaux de dimension
library(factoextra)
```

```
Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

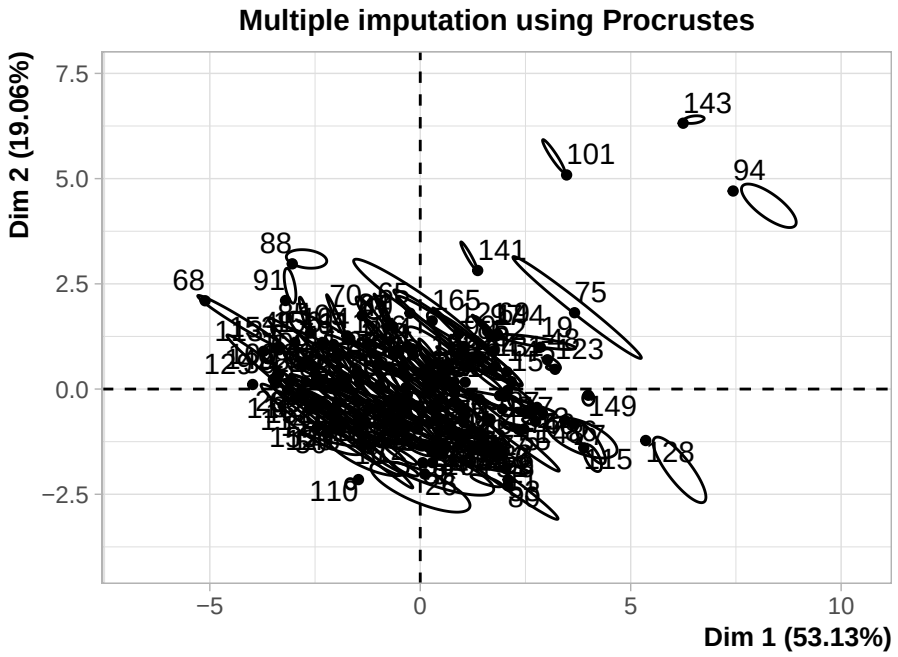
```
fviz_screeplot(acp_DIANE, addlabels = TRUE)
```

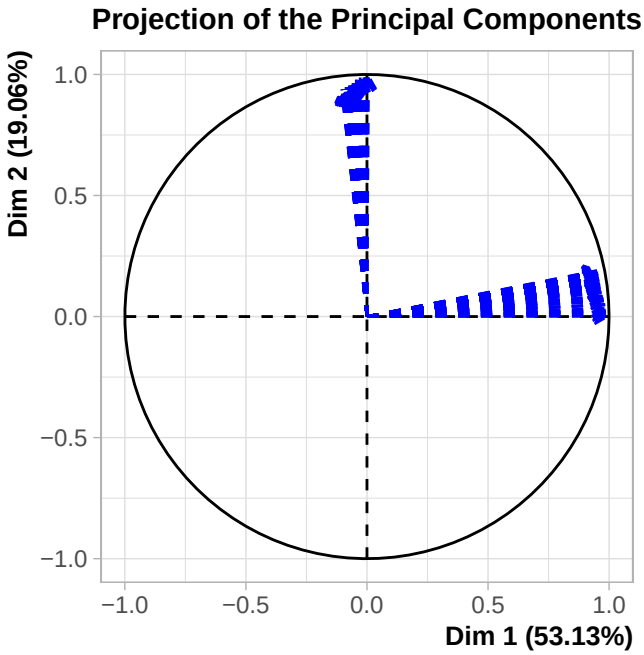


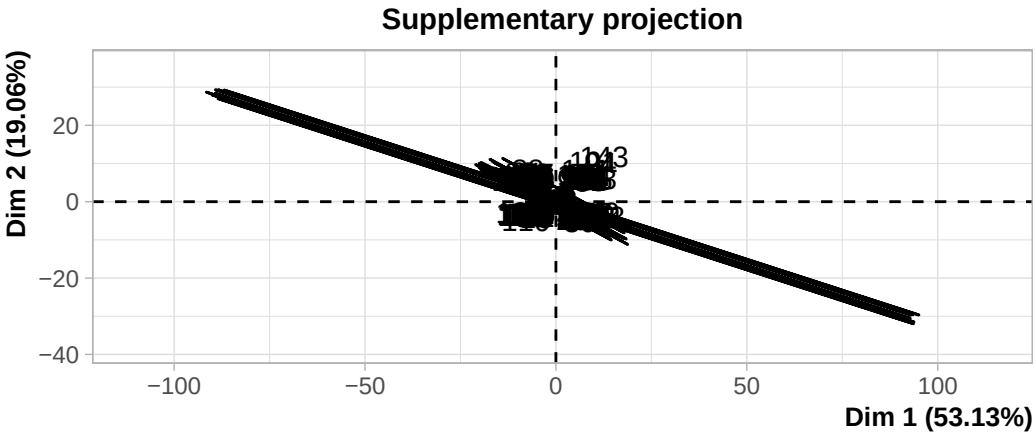
Nous retiendrons deux dimensions pour notre étude : la première explique 53,7 % de la variance et la deuxième 18,2 %, soit un total cumulé de 71,9 %.

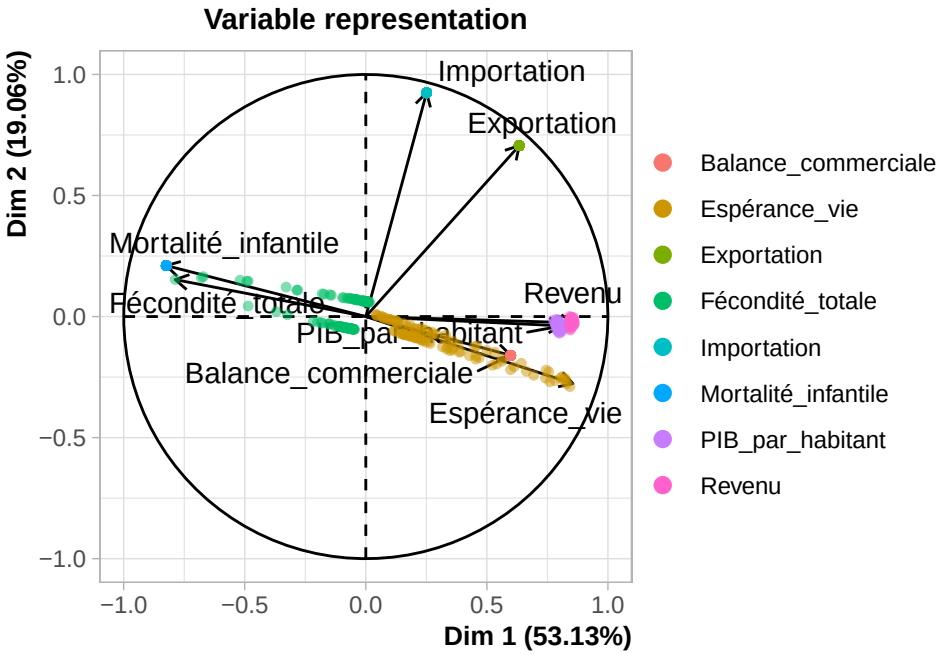
```
#Remplacement des NA par l'ACP

DIANE_complete3 <- MIPCA(DIANE_complete2 |> select(-Pays,- Niveau_développement, -Région_géog
plot.MIPCA(DIANE_complete3)
```

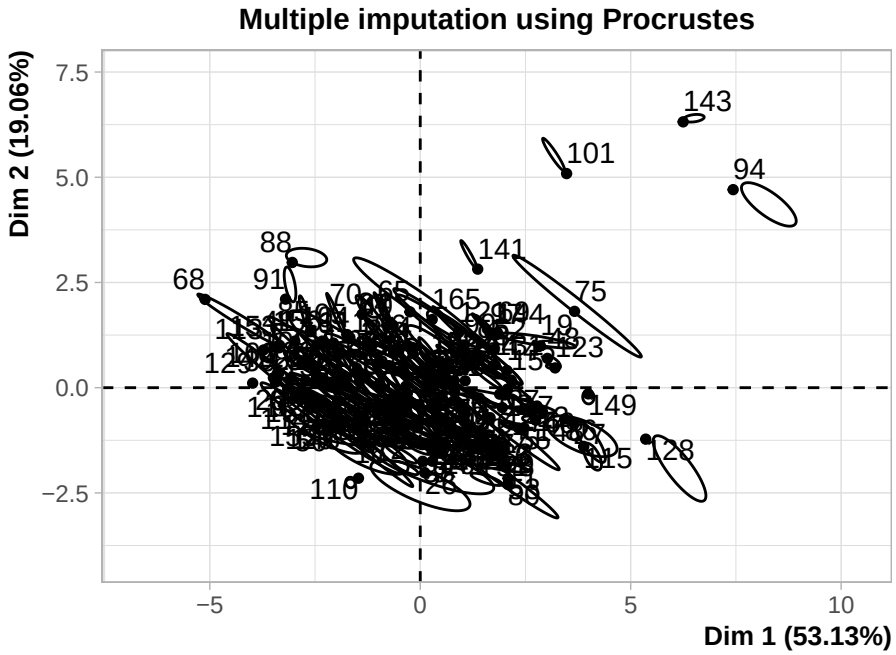



Projection of the Principal Components
Dim 2 (19.06%)
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0
Dim 1 (53.13%)

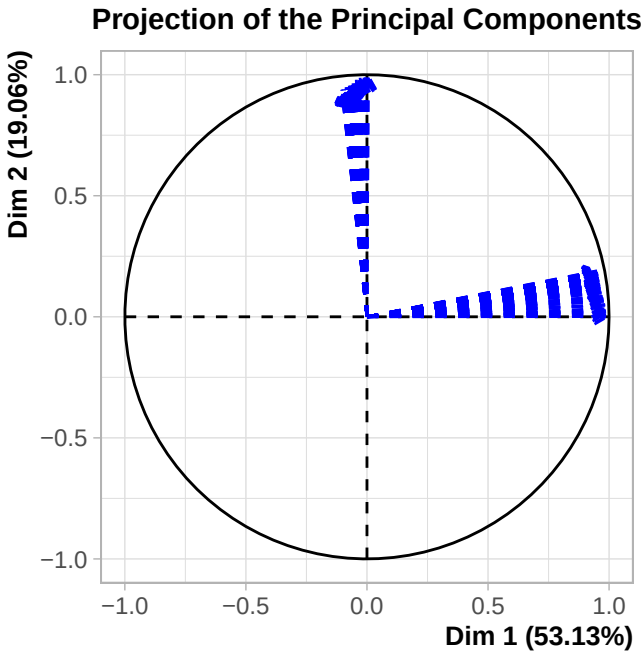

Supplementary projection
Dim 2 (19.06%)
20
0
−20
−40
−100
−50
0
50
100
Dim 1 (53.13%)



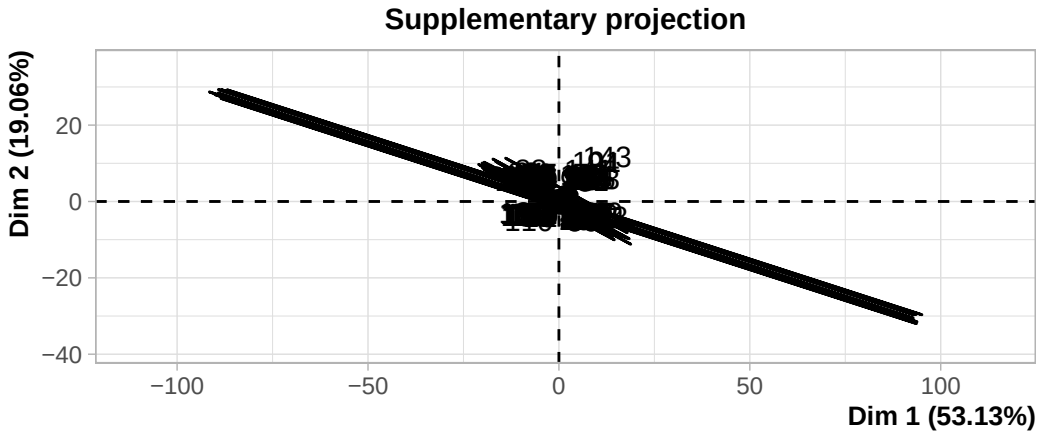
$PlotIndProc



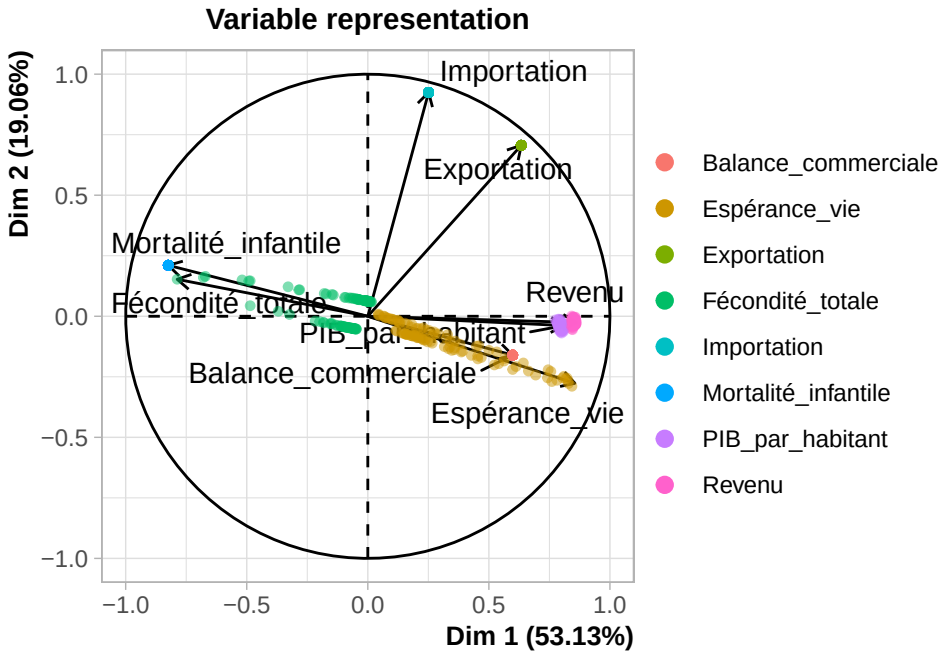
$PlotDim



$PlotIndSupp


Supplementary projection
Dim 2 (19.06%)
20
0
−20
−40
−100
−50
0
50
100
Dim 1 (53.13%)

```
$PlotVar
```


Variable representation
Dim 2 (19.06%)
1.0
0.5
0.0
−0.5
−1.0
Importation
Exportation
Mortalité_infantile
Fécondité_totale
Revenu
PIB_par_habitant
Balance_commerciale
Espérance_vie
−1.0
−0.5
0.0
0.5
1.0
Dim 1 (53.13%)
Balance_commerciale
Espérance_vie
Exportation
Fécondité_totale
Importation
Mortalité_infantile
PIB_par_habitant
Revenu

Après imputation des données manquantes et réalisation de l'ACP, l'analyse du nuage des variables met en évidence des liaisons marquées entre l'espérance de vie, la mortalité infantile, la fécondité, le PIB par habitant ainsi que la balance commerciale, qui sont fortement corrélées à la première dimension. Par ailleurs, les importations apparaissent davantage associées à la deuxième dimension que les exportations, traduisant une meilleure contribution à la structuration de cet axe.

```
#Ajout des autres variables
DIANE_complete3<- bind_cols(
  DIANE_complete2|> select(Pays, Niveau_développement, Région_géographique, Inflation, Dépens
  DIANE_complete3[["res.imputePCA"]] )

  summary(DIANE_complete3)
```

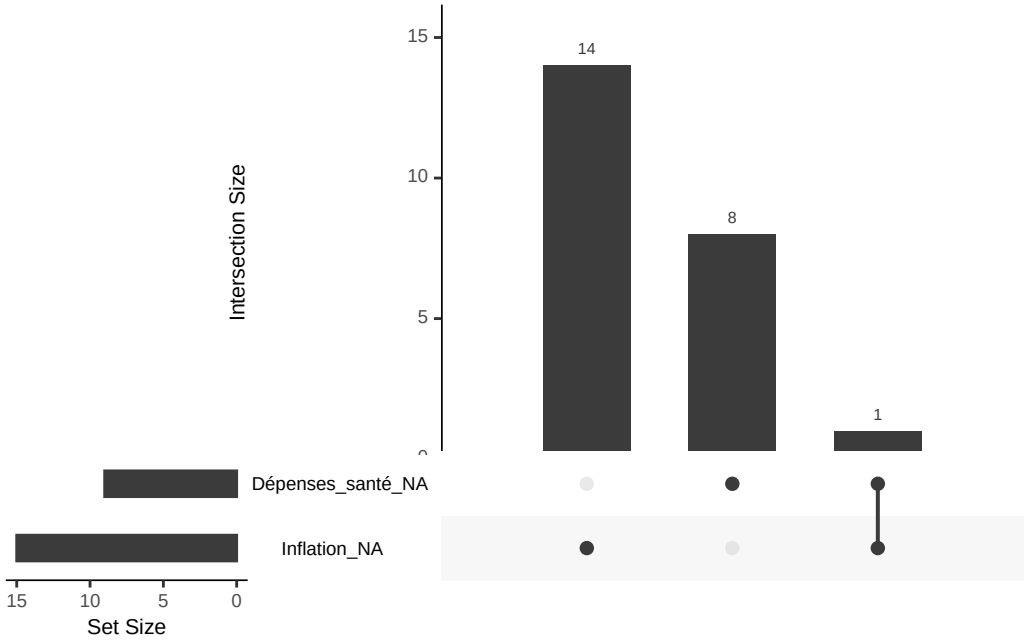
```
     Pays                Niveau_développement Région_géographique
 Length:167          Développé       :30      Afrique :47
 Class :character    Émergent        :27      Amérique:27
 Mode  :character    En développement:71      Asie    :42
                     Sous-développé  :39      Europe  :42
                                              Océanie : 9


   Inflation        Dépenses_santé   Mortalité_infantile  Exportation
 Min.   : -4.210   Min.   : 1.810   Min.   : -4.274     Min.   :  0.109
 1st Qu.:  1.830   1st Qu.: 4.973   1st Qu.:  7.850     1st Qu.: 23.800
 Median :  5.415   Median : 6.570   Median : 19.700     Median : 35.400
 Mean   :  7.890   Mean   : 6.924   Mean   : 38.144     Mean   : 41.177
 3rd Qu.: 10.675   3rd Qu.: 8.710   3rd Qu.: 62.100     3rd Qu.: 51.350
 Max.   :104.000   Max.   :17.900   Max.   :208.000     Max.   :200.000
 NA's   :15        NA's   :9
  Importation          Revenu       Espérance_vie   Fécondité_totale
 Min.   :  0.0659   Min.   : -5442   Min.   :32.10   Min.   :1.150
 1st Qu.: 30.2000   1st Qu.:  3448   1st Qu.:65.30   1st Qu.:1.820
 Median : 43.3000   Median : 10400   Median :72.54   Median :2.480
 Mean   : 46.8902   Mean   : 17132   Mean   :70.64   Mean   :2.967
 3rd Qu.: 58.7500   3rd Qu.: 22800   3rd Qu.:76.80   3rd Qu.:3.880
 Max.   :174.0000   Max.   :125000   Max.   :82.80   Max.   :7.490

 PIB_par_habitant   Balance_commerciale
 Min.   :  -700.1   Min.   :-73.500
 1st Qu.:  1330.0   1st Qu.:-14.850
 Median :  5410.0   Median : -4.800
```

```
 Mean   : 12943.8   Mean   : -5.714
 3rd Qu.: 15681.5   3rd Qu.:  3.850
 Max.   :105000.0   Max.   : 39.400
```

```
# verification
gg_miss_upset(DIANE_complete3, nset=12)
```



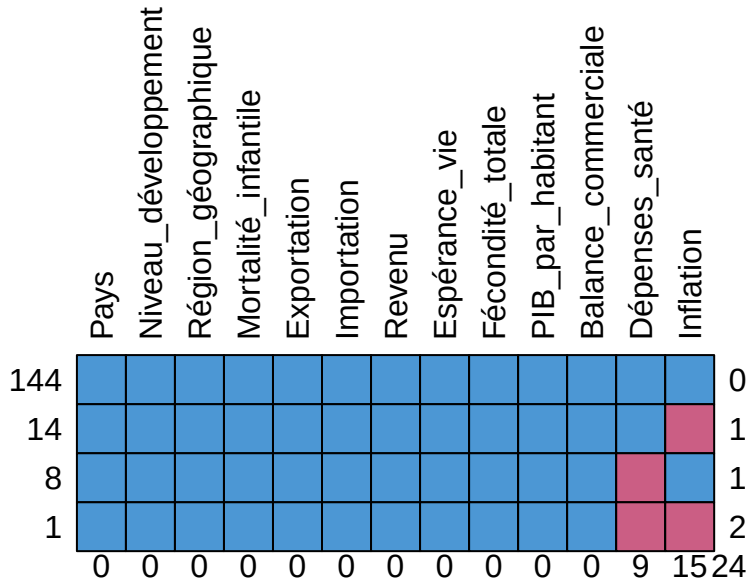

```
miss_var_summary(DIANE_complete3)
```

```
# A tibble: 13 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 Inflation                15     8.98
 2 Dépenses_santé            9     5.39
 3 Pays                      0     0
 4 Niveau_développement      0     0
 5 Région_géographique       0     0
 6 Mortalité_infantile       0     0
 7 Exportation               0     0
 8 Importation               0     0
 9 Revenu                    0     0
```

```
10 Espérance_vie             0     0
11 Fécondité_totale          0     0
12 PIB_par_habitant          0     0
13 Balance_commerciale       0     0
```

Imputation multiple (Mice)

```
# Imputation multiple
library(mice)
#Visualisation des NA par variable
md.pattern(DIANE_complete3,rotate.names=TRUE)
```




```
    Pays Niveau_développement Région_géographique Mortalité_infantile
144    1                    1                   1                   1
14     1                    1                   1                   1
8      1                    1                   1                   1
1      1                    1                   1                   1
       0                    0                   0                   0
    Exportation Importation Revenu Espérance_vie Fécondité_totale
144           1           1      1             1                 1
```

```
14              1           1      1             1                1
8               1           1      1             1                1
1               1           1      1             1                1
                0           0      0             0                0
    PIB_par_habitant Balance_commerciale Dépenses_santé Inflation
144                1                   1              1         1  0
14                 1                   1              1         0  1
8                  1                   1              0         1  1
1                  1                   1              0         0  2
                   0                   0              9        15 24
```

Après l'imputation des données manquantes par la méthode fondée sur l'ACP, deux variables présentent encore des valeurs manquantes. Celles-ci seront donc traitées à l'aide de la méthode d'imputation multiple par équations chaînées (Mice), afin de compléter les données tout en préservant la cohérence statistique des relations entre les variables.

```r
#Imputation mutiple avec 3 jeux de données
DIANE_PATRICE_impute<-mice(
DIANE_complete3,m=3)
```

```
 iter imp variable
  1   1  Inflation  Dépenses_santé
  1   2  Inflation  Dépenses_santé
  1   3  Inflation  Dépenses_santé
  2   1  Inflation  Dépenses_santé
  2   2  Inflation  Dépenses_santé
  2   3  Inflation  Dépenses_santé
  3   1  Inflation  Dépenses_santé
  3   2  Inflation  Dépenses_santé
  3   3  Inflation  Dépenses_santé
  4   1  Inflation  Dépenses_santé
  4   2  Inflation  Dépenses_santé
  4   3  Inflation  Dépenses_santé
  5   1  Inflation  Dépenses_santé
  5   2  Inflation  Dépenses_santé
  5   3  Inflation  Dépenses_santé

Warning: Number of logged events: 31
```

```r
#voir les imputations réalisées
DIANE_PATRICE_impute$imp
```

```
$Pays
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Niveau_développement
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Région_géographique
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Inflation
        1     2      3
6   11.20 20.80 13.800
26   1.40  4.30 12.100
39   9.20  8.55 13.400
55   4.44  2.33 -4.210
60   2.09 20.80  8.780
67   2.04 20.90 -0.393
74   9.44  9.44  2.880
75   2.01 -4.21  3.830
76   3.68  1.13  3.220
94   6.81 -4.21  4.150
121  1.85  4.44  3.120
134  3.12  1.18 18.900
143  1.22  4.15  3.830
149  1.16  1.52  1.520
154  7.64  8.79  5.440

$Dépenses_santé
       1    2     3
44  5.88 5.68  5.60
86  2.46 3.50  6.33
92  4.39 5.81  5.88
96  5.66 9.01  4.66
107 5.22 5.20  5.89
113 5.66 5.97  8.55
134 6.85 8.06 10.10
```

```
140 5.97 6.85  7.59
159 6.33 6.33  6.33

$Mortalité_infantile
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Exportation
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Importation
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Revenu
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Espérance_vie
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Fécondité_totale
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$PIB_par_habitant
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)

$Balance_commerciale
[1] 1 2 3
<0 lignes> (ou 'row.names' de longueur nulle)
```

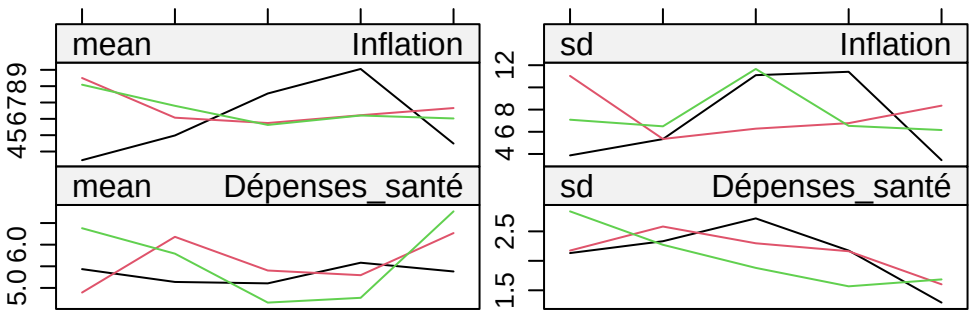
```
#méthode appliquées
DIANE_PATRICE_impute$method
```

```
                Pays Niveau_développement  Région_géographique
                  ""                    ""                   ""
           Inflation       Dépenses_santé  Mortalité_infantile
               "pmm"                "pmm"                   ""
```

```
        Exportation          Importation              Revenu
                 ""                   ""                  ""
      Espérance_vie     Fécondité_totale     PIB_par_habitant
                 ""                   ""                  ""
 Balance_commerciale
                 ""
```

```
DIANE_complete_miss <- mice::complete(DIANE_PATRICE_impute, 2)

plot(DIANE_PATRICE_impute)
```




```
summary(DIANE_complete_miss)
```

```
    Pays                Niveau_développement Région_géographique
 Length:167         Développé        :30     Afrique :47
 Class :character   Émergent         :27     Amérique:27
 Mode  :character   En développement:71      Asie    :42
                    Sous-développé   :39     Europe  :42
                                             Océanie : 9

   Inflation       Dépenses_santé   Mortalité_infantile  Exportation
 Min.   : -4.210   Min.   : 1.810   Min.   : -4.274     Min.   :  0.109
```

```
 1st Qu.:  1.755   1st Qu.: 5.025   1st Qu.:  7.850     1st Qu.: 23.800
 Median :  5.140   Median : 6.470   Median : 19.700     Median : 35.400
 Mean   :  7.780   Mean   : 6.889   Mean   : 38.144     Mean   : 41.177
 3rd Qu.: 10.350   3rd Qu.: 8.600   3rd Qu.: 62.100     3rd Qu.: 51.350
 Max.   :104.000   Max.   :17.900   Max.   :208.000     Max.   :200.000
  Importation          Revenu       Espérance_vie   Fécondité_totale
 Min.   :  0.0659   Min.   : -5442   Min.   :32.10   Min.   :1.150
 1st Qu.: 30.2000   1st Qu.:  3448   1st Qu.:65.30   1st Qu.:1.820
 Median : 43.3000   Median : 10400   Median :72.54   Median :2.480
 Mean   : 46.8902   Mean   : 17132   Mean   :70.64   Mean   :2.967
 3rd Qu.: 58.7500   3rd Qu.: 22800   3rd Qu.:76.80   3rd Qu.:3.880
 Max.   :174.0000   Max.   :125000   Max.   :82.80   Max.   :7.490
 PIB_par_habitant   Balance_commerciale
 Min.   :  -700.1   Min.   :-73.500
 1st Qu.:  1330.0   1st Qu.:-14.850
 Median :  5410.0   Median : -4.800
 Mean   : 12943.8   Mean   : -5.714
 3rd Qu.: 15681.5   3rd Qu.:  3.850
 Max.   :105000.0   Max.   : 39.400
```

```
miss_var_summary(DIANE_complete_miss)
```

```
# A tibble: 13 x 3
   variable             n_miss pct_miss
   <chr>                 <int>    <num>
 1 Pays                      0        0
 2 Niveau_développement      0        0
 3 Région_géographique       0        0
 4 Inflation                 0        0
 5 Dépenses_santé            0        0
 6 Mortalité_infantile       0        0
 7 Exportation               0        0
 8 Importation               0        0
 9 Revenu                    0        0
10 Espérance_vie             0        0
11 Fécondité_totale          0        0
12 PIB_par_habitant          0        0
13 Balance_commerciale       0        0
```

L'analyse des moyennes (mean) pour l'inflation et les dépenses de santé met en évidence des variations importantes selon le niveau de développement des pays. Pour l'inflation, on constate que certains groupes connaissent des niveaux moyens plus élevés que d'autres, mais cette

tendance n'est pas uniforme : les courbes se croisent, ce qui montre que l'inflation relative des pays peut varier selon les périodes ou les conditions économiques. Concernant les dépenses de santé, la moyenne est globalement plus stable, mais certains pays en développement affichent des valeurs ponctuellement plus élevées, suggérant que la politique de financement de la santé diffère fortement d'un pays à l'autre au sein de ce groupe.

L'analyse de l'écart-type (sd) complète cette observation en montrant l'hétérogénéité au sein de chaque groupe. Pour l'inflation, certains pays présentent un écart-type élevé, indiquant une forte variabilité et donc une instabilité économique plus marquée. À l'inverse, d'autres pays ont un écart-type plus faible, traduisant une inflation plus stable. Pour les dépenses de santé, certains groupes présentent également des écarts-types élevés, reflétant des disparités importantes dans le financement et l'accès aux soins, tandis que d'autres groupes montrent une homogénéité plus forte. Ces observations mettent en lumière la diversité des situations économiques et sociales des pays selon leur niveau de développement.

Resultat

```
stats_long_fin <- DIANE_complete_miss |>
  select(all_of(vars_quanti)) |>
  pivot_longer(cols = everything(),
               names_to = "Variable",
               values_to = "Valeur") |>
  group_by(Variable) |>
  summarise(
    N = sum(!is.na(Valeur)),
    Moyenne = mean(Valeur, na.rm = TRUE),
    Médiane = median(Valeur, na.rm = TRUE),
    Écart_type = sd(Valeur, na.rm = TRUE),
    Min = min(Valeur, na.rm = TRUE),
    Max = max(Valeur, na.rm = TRUE)
  )
stats_long_fin |>   knitr::kable(
    caption = "Statistique des varuiables quantiatative")
```

Table 5: Statistique des varuiables quantiatative

Variable	N	Moyenne	Médiane	Écart_type	Min	Max
Balance_commercial	167	-5.713574	-4.800000	18.878854	-73.500000	3.94e+01
Dépenses_santé	167	6.889042	6.470000	2.686402	1.810000	1.79e+01
Espérance_vie	167	70.635785	72.539679	8.698087	32.100000	8.28e+01
Exportation	167	41.176641	35.400000	27.405074	0.109000	2.00e+02

Variable	N	Moyenne	Médiane	Écart_type	Min	Max
Fécondité_totale	167	2.966991	2.479638	1.504960	1.150000	7.49e+00
Importation	167	46.890215	43.300000	24.209589	0.065900	1.74e+02
Inflation	167	7.779665	5.140000	10.633548	-4.210000	1.04e+02
Mortalité_infantile	167	38.144481	19.700000	40.258504	-4.274055	2.08e+02
PIB_par_habitant	167	12943.838638	5410.000000	17927.873064	-700.083761	1.05e+05
Revenu	167	17132.205331	10400.000000	19220.817280	-5442.491416	1.25e+05

```
stats_long_debut <- bdd_projet |>
  select(all_of(vars_quanti)) |>
  pivot_longer(cols = everything(),
               names_to = "Variable",
               values_to = "Valeur") |>
  group_by(Variable) |>
  summarise(
    N = sum(!is.na(Valeur)),
    Moyenne = mean(Valeur, na.rm = TRUE),
    Médiane = median(Valeur, na.rm = TRUE),
    Écart_type = sd(Valeur, na.rm = TRUE),
    Min = min(Valeur, na.rm = TRUE),
    Max = max(Valeur, na.rm = TRUE)
  )
stats_long_debut |>   knitr::kable(
    caption = "Statistique des varuiables quantiatative")
```

Table 6: Statistique des varuiables quantiatative

Variable	N	Moyenne	Médiane	Écart_type	Min	Max
Balance_commerciale	167	-5.781239	-4.80	18.942578	-73.5000	3.94e+01
Dépenses_santé	167	6.815689	6.32	2.746837	1.8100	1.79e+01
Espérance_vie	167	70.555689	73.10	8.893172	32.1000	8.28e+01
Exportation	167	41.108976	35.00	27.412010	0.1090	2.00e+02
Fécondité_totale	167	2.947964	2.41	1.513848	1.1500	7.49e+00
Importation	167	46.890215	43.30	24.209589	0.0659	1.74e+02
Inflation	167	7.781832	5.39	10.570704	-4.2100	1.04e+02
Mortalité_infantile	167	38.270060	19.30	40.328932	2.6000	2.08e+02
PIB_par_habitant	167	12964.155689	4660.00	18328.704809	231.0000	1.05e+05
Revenu	167	17144.688623	9960.00	19278.067698	609.0000	1.25e+05

L'analyse porte sur 167 observations (N=167) pour les deux tableaux.Impact sur la Mortalité Infantile : Dans le premier tableau (données imputées), la valeur minimale est de -4,27. Dans le second tableau (données réelles), la valeur minimale est de 2,60. Cette valeur négative dans le premier tableau est une erreur typique d'une méthode d'imputation mal calibrée (comme une régression linéaire simple sans contrainte), car un taux de mortalité ne peut être négatif. Ajustement du Revenu : On observe une correction significative du minimum pour le Revenu. Les données imputées affichaient un minimum aberrant de -6313,19, tandis que les données réelles présentent un minimum cohérent de 609,00. Stabilité des tendances centrales : Malgré ces corrections sur les valeurs extrêmes, les moyennes et médianes restent relativement stables entre les deux versions. Par exemple, l'Espérance de vie passe d'une moyenne de 70,60 à 70,55 ans. Cela indique que les valeurs manquantes n'étaient pas assez nombreuses ou biaisées pour masquer les tendances globales du jeu de données.

Conclusion

En conclusion, ce travail d'analyse sous R démontre que le niveau de développement d'un pays est un phénomène multidimensionnel où les indicateurs économiques et de santé publique s'influencent mutuellement de manière prévisible.

Si la richesse (Revenu) est un moteur essentiel, elle est indissociable des progrès sanitaires (baisse de la mortalité infantile) pour assurer une amélioration réelle de la qualité de vie (Espérance de vie). Pour les décideurs, ce projet suggère que les politiques de développement les plus efficaces sont celles qui ciblent simultanément la croissance économique et l'accès aux soins de base, particulièrement dans les régions identifiées comme "Sous-développées".

Bibilographie

Liste des pays du monde. (s.d.). : https://www.techno-science.net/glossaire-definition/Liste-des-pays-du-monde-par-continent.html

Wikipédia. Consulté le 15 décembre 2025 : https://fr.wikipedia.org/wiki/Liste_des_pays_du_monde

Moyen-Orient. (s.d.). Wikipédia. Consulté le 15 décembre 2025 : https://fr.wikipedia.org/wiki/Moyen-Orient

Eveiller mon enfant (15 déc. 2022) , Géographie || Les Pays d'Amérique : Amérique du Nord, Amérique centrale, Caraïbes et Amérique du Sud : https://www.youtube.com/watch?v=Vg71D84xqa4

United Nations Statistics Division. (s.d.). Methodology: M49 Standard. Consulté le 15 décembre 2025 : https://unstats.un.org/unsd/methodology/m49/

Liste de pays selon le schéma géographique des Nations unies. (s.d.). Wikipédia. Consulté le 15 décembre 2025 : https://fr.wikipedia.org/wiki/Liste_de_pays_selon_le_sch%C3%A9ma_g%C3%A9ographique_des_Nations_unies

List of countries and territories by the United Nations geoscheme. (s.d.). Wikipedia. Consulté le 15 décembre 2025 : https://fr.wikipedia.org/wiki/Liste_de_pays_selon_le_sch%C3%A9ma_g%C3%A9ographique_des_Nations_unies

Central Intelligence Agency. (2023). The World Factbook: Location (Archive). Consulté le 15 décembre 2025 : https://www.cia.gov/the-world-factbook/about/archives/2023/field/location/

International Monetary Fund (IMF). (2023). WEO database: Groups and aggregates. Consulté le 15 décembre 2025 : https://www.imf.org/en/publications/weo/weo-database/2023/april/groups-and-aggregates

United Nations Conference on Trade and Development (UNCTAD). (s.d.). Least developed countries: List. Consulté le 15 décembre 2025 : https://unctad.org/topic/least-developed-countries/list

World Bank. (s.d.). World Bank country and lending groups. Consulté le 15 décembre 2025 : https://datahelpdesk.worldbank.org/knowledgebase/articles/906519-world-bank-country-and-lending-groups

BNP Paribas Economic Research. (2025, 13 novembre). Pays émergents : croissance résiste, suffit de stabiliser l'endettement public. Consulté le 15 décembre 2025 : https://economic-research.bnpparibas.com/html/fr-FR/Editorial-Pays-emergents-croissance-resiste-suffit-stabiliser-endettement-public-13/11/2025,52989

BNP Paribas Economic Research. (2025, 13 novembre). Pays émergents : indicateurs économiques. Consulté le 15 décembre 2025 : https://economic-research.bnpparibas.com/html/fr-FR/Pays-emergents-Indicateurs-economiques-13/11/2025,52991

DHS Program. (2015). Chapitre 8 – Mortalité infantile et maternelle [PDF]. Consulté le 15 décembre 2025 : https://dhsprogram.com/pubs/pdf/FR133/08Chapitre8.pdf UNICEF France. (s.d.). Mortalité infantile. Consulté le 15 décembre 2025 : https://www.unicef.fr/convention-droits-enfants/sante/mortalite-infantile/

Douane Française. (s.d.). Exporté ou exportation. Consulté le 15 décembre 2025 : https://www.douane.gouv.fr/lexique/exporte-ou-exportation
Chambre de Commerce et d'Industrie Paris Île-de-France (CCI Paris IDF). (s.d.). Démarrer l'export. Consulté le 15 décembre 2025 : https://www.cci-paris-idf.fr/fr/entreprises/croissance/developpement-international/demarrer-export

Organisation de Coopération et de Développement Économiques (OCDE). (s.d.). Indicateurs des dépenses de santé. Consulté le 15 décembre 2025 : https://www.oecd.org/fr/data/indicators/health-spending.html

IRDES – Institut de recherche et documentation en économie de la santé. (s.d.). Dépenses de santé : définitions. Consulté le 15 décembre 2025 : https://www.irdes.fr/enseignement/chiffres-et-graphiques/depenses-de-sante/definitions-depenses-de-sante.html

SumUp. (s.d.). Importation. Consulté le 15 décembre 2025 : https://www.sumup.com/fr-fr/factures/termes-comptables/importation/
Eurofiscalis. (s.d.). Importation. Consulté le 15 décembre 2025 : https://www.eurofiscalis.com/lexiques/importation/

AskFilo. (s.d.). How is income an important factor in assessing development? Consulté le 15 décembre 2025 : https://askfilo.com/user-question-answers-smart-solutions/question-1-how-is-income-an-important-factor-in-assessing-3335393738323031

SumUp. (s.d.). Importation. Consulté le 15 décembre 2025 : https://www.sumup.com/fr-fr/factures/termes-comptables/importation/ Eurofiscalis. (s.d.). Importation. Consulté le 15 décembre 2025 : https://www.eurofiscalis.com/lexiques/importation/

Inflation. (s.d.). Wikipédia. Consulté le 15 décembre 2025 : https://fr.wikipedia.org/wiki/Inflation

Espérance de vie humaine. (s.d.). Wikipédia. Consulté le 15 décembre 2025 : https://fr.wikipedia.org/wiki/Esp%C3%A9rance_de_vie_humaine

Eurostat. (s.d.). Glossaire : Fécondité. Consulté le 15 décembre 2025 : https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Glossary:Fertility/fr

FERDI – Fondation pour les Études et Recherches sur le Développement International. (s.d.). PIB par habitant (US$ courants). Consulté le 15 décembre 2025 : https://competitivite.ferdi.fr/indicateurs/pib-par-habitant-us-courants

limitée à exporter des produits diversifiés et à forte valeur ajoutée. Eurostat. (s.d.). Glossaire : Balance commerciale. Consulté le 15 décembre 2025 : https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Glossary:Trade_balance/fr#:~:text=La%20balance%20commerciale%20est%20la,import%C3%A9s%20par%20le%20m%C3%AAme%20pays

AvaTrade. (s.d.). Balance of trade. Consulté le 15 décembre 2025, : https://www.avatrade.fr/education/economic-indicators/fundamental-indicators/balance-of-trade#:~:text=La%20balance%20commerciale%20montre%20si,cours%20de%20la%20p%C3%A9riode%20consid%C3%A9r%C3%A9e