Support 4

Patrice Kolié

Table of contents

1 Exercice 1 : 2
- 1.1 Chargement de packages et visualisation . . . 2
  - 1.1.1 Interprétation: . . . 3
- 1.2 Test de stationnarité . . . 4
  - 1.2.1 Interprétation : . . . 4

2 le modèle ARMA 4
- 2.1 ACF et PACF . . . 4
  - 2.1.1 Interprétation (ACF et PACF): . . . 6
- 2.2 Sélection automatique du modèle . . . 6
  - 2.2.1 Interprétation : . . . 7
- 2.3 Estimation de quelques modèles . . . 7
  - 2.3.1 Interprétation : . . . 8
- 2.4 Graphique de l'évolution de phi_5 et phi_3 . . . 9
  - 2.4.1 Interprétation: . . . 10
- 2.5 Évaluation des performances . . . 10
  - 2.5.1 Test de Mincer-Zarnowitz . . . 10
- 2.6 Test de Diebold-Mariano . . . 13
  - 2.6.1 Résultat et interprétation : . . . 14
- 2.7 Conclusion générale . . . 14
  - 2.7.1 Quel modèle est le plus performant ? . . . 14

3 Exercice 2 : Modèle HAR sur la volatilité réalisée (KOSPI 200) 15

4 Partie 1 : 15
- 4.1 Chargement des données et création des variables HAR . . . 15
- 4.2 Estimation du modèle HAR(1,5,22) . . . 16
  - 4.2.1 HAR sur RV (Realized Variance) . . . 16
  - 4.2.2 HAR sur MedRV (Median Realized Variance) . . . 17

4.3 Transformations (racine carrée et logarithme) 18
4.3.1 Interprétation : 20
4.4 Conclusions : 20
4.4.1 Détails du meilleur modèle 20

5 Partie 2 : Prévisions avec schéma récursif 21
5.1 ndefinedCode pour les prévisions récursives 21
5.2 Calcul de la perte QLIKE et test de Diebold-Mariano 25
5.3 Test de Diebold-Mariano 25
5.4 Tests de Diebold-Mariano (QLIKE) : 28
5.4.1 Synthèse et recommandations 28
5.4.2 Paradoxe modélisation vs prévision : 28
5.4.3 Recommandation finale : 28

1 Exercice 1 :

1.1 Chargement de packages et visualisation

```
library(readxl)
library(tseries)
```

```
Warning: le package 'tseries' a été compilé avec la version R 4.5.3
```

```
library(forecast)
```

```
Warning: le package 'forecast' a été compilé avec la version R 4.5.3
```

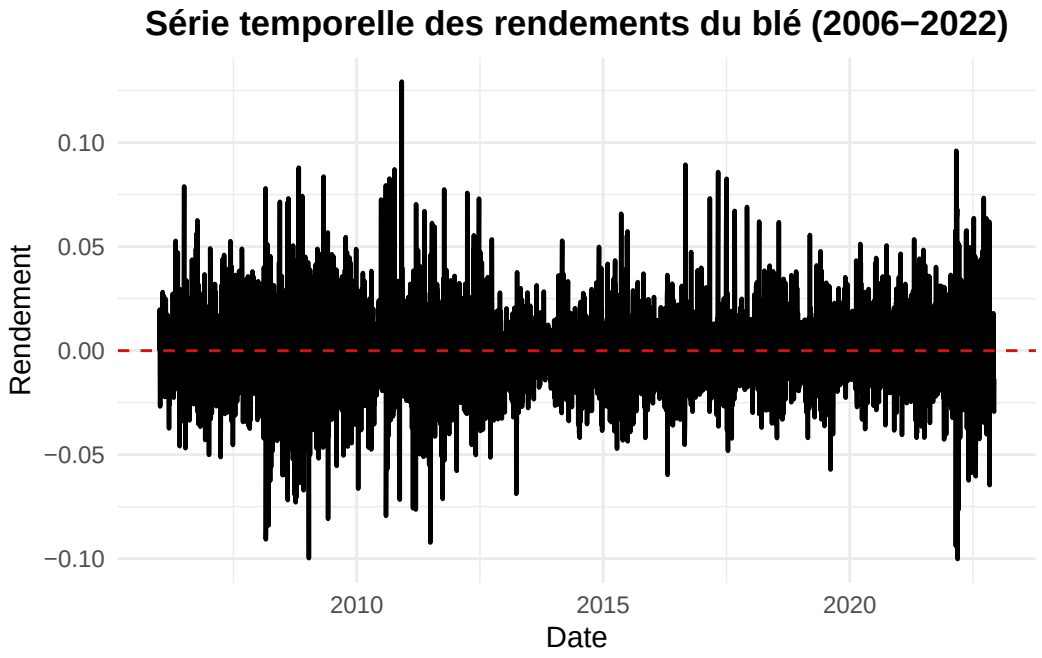
```
library(FinTS)
library(Metrics)
library(TSA)
```

```
Warning: le package 'TSA' a été compilé avec la version R 4.5.3
```

```
library(ggplot2)
library(dplyr)
```

```r
bdd <- read_excel("c:/Users/patri/Desktop/ECAP/M1/cours/Serie_temp/support5/support5/wheat_su
bdd$date <-  as.Date(bdd$date)

ggplot(bdd, aes(x = date, y = return)) +
  geom_line(color = "black", linewidth = 0.8) +
  geom_hline(yintercept = 0, color = "red", linetype = "dashed") +
  labs(title = "Série temporelle des rendements du blé (2006-2022)",
       x = "Date",
       y = "Rendement") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```



1.1.1 Interprétation:

Absence de tendance : La série oscille autour de zéro sans dérive visible Volatilité variable (clustering) : On observe des périodes de forte volatilité (2008-2010, 2020-2022) alternant avec des phases plus calmes Symétrie : Les variations positives et négatives semblent équilibrées Pics extrêmes : Plusieurs chocs importants (>10% en valeur absolue), notamment autour de 2008 et 2022 Caractéristique typique : Cela ressemble à une série de rendements financiers stationnaire

1.2 Test de stationnarité

```
# Test ADF (Augmented Dickey-Fuller)
adf.test(bdd$return)
```

```
Warning in adf.test(bdd$return): p-value smaller than printed p-value
```

```
    Augmented Dickey-Fuller Test

data:  bdd$return
Dickey-Fuller = -16.304, Lag order = 16, p-value = 0.01
alternative hypothesis: stationary
```

1.2.1 Interprétation :

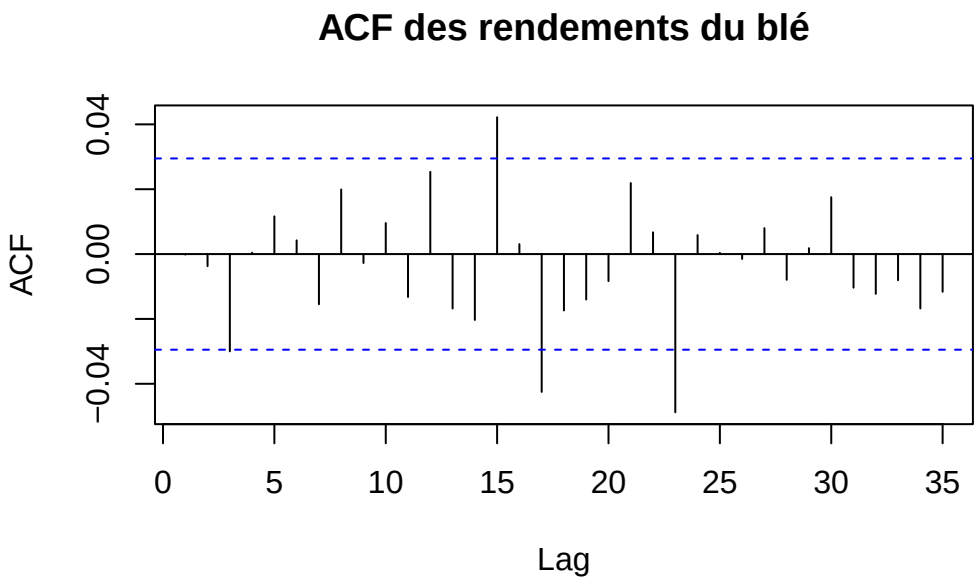
Hypothèses : H0 : La série possède une racine unitaire (non stationnaire) H1 : La série est stationnaire

p-value : 0.01 (< 0.05) , on rejette H0 au seuil de 1% La série des rendements est stationnaire Cela confirme l'observation graphique : pas besoin de différencier la série On peut donc procéder directement à la modélisation ARMA (sans composante I d'intégration)

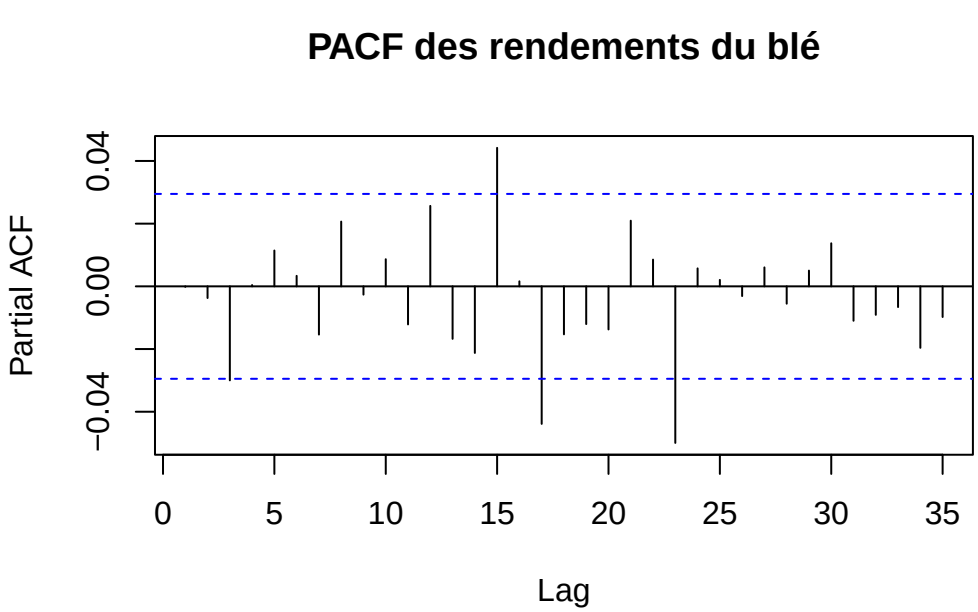
2 le modèle ARMA

2.1 ACF et PACF

```
# ACF
acf(bdd$return, main = "ACF des rendements du blé", lag.max = 35)
```




```r
# PACF
pacf(bdd$return, main = "PACF des rendements du blé", lag.max = 35)
```



2.1.1 Interprétation (ACF et PACF):

L'examen des corrélogrammes révèle une structure très faible dans la série des rendements du blé. Sur l'ACF, la quasi-totalité des coefficients d'autocorrélation restent à l'intérieur des bandes de confiance à 95%, avec seulement quelques valeurs isolées qui dépassent légèrement ces seuils. Ces dépassements sont marginaux et ne suggèrent aucune structure systématique d'autocorrélation. L'absence de décroissance progressive ou de pattern régulier indique qu'il n'y a pas de composante MA (moyenne mobile) significative dans la série.

Du côté de la PACF, on observe également une absence de structure claire. Quelques pics isolés apparaissent, mais ils ne présentent pas la décroissance exponentielle caractéristique d'un processus AR. Ces valeurs semblent plutôt relever de fluctuations aléatoires plutôt que d'une véritable dépendance autoregressive. L'absence de valeurs significatives aux premiers lags (notamment lag 1) suggère qu'un modèle AR d'ordre élevé ne serait pas justifié.

D'un point de vue théorique, cette configuration est cohérente avec l'hypothèse d'efficience des marchés financiers : les rendements d'actifs suivent généralement un processus proche du bruit blanc, c'est-à-dire une série purement aléatoire sans mémoire significative. Les corrélogrammes suggèrent donc qu'un modèle ARMA(0,0), soit un simple bruit blanc, serait le plus adapté à ces données.

2.2 Sélection automatique du modèle

```r
modele_auto <- auto.arima(bdd$return, seasonal = FALSE, max.p = 5, max.q = 5)
summary(modele_auto)
```

```
Series: bdd$return
ARIMA(0,0,0) with zero mean

sigma^2 = 0.0004295:  log likelihood = 10854.81
AIC=-21707.61   AICc=-21707.61   BIC=-21701.22

Training set error measures:
                      ME       RMSE        MAE MPE MAPE      MASE
Training set 0.0001731801 0.02072437 0.01521257 100  100 0.6919066
                     ACF1
Training set -0.0001657512
```

2.2.1 Interprétation :

La fonction auto.arima() sélectionne un ARMA(0,0) avec moyenne nulle, c'est-à-dire un bruit blanc pur. Cela confirme l'analyse des corrélogrammes : aucune structure AR ni MA significative n'est détectée dans la série. Les rendements du blé semblent suivre un processus purement aléatoire, conforme à l'hypothèse d'efficience des marchés.

Bien que les corrélogrammes suggèrent une structure proche du bruit blanc, nous retenons une spécification AR(1) conformément aux exigences du cours. Ce modèle parcimonieux permet de capturer une éventuelle mémoire de court terme dans les rendements, même si elle est faible. Cette spécification sera utilisée pour toutes les prévisions dans la suite de l'exercice.

2.3 Estimation de quelques modèles

```
set.seed(123)

# Initialisation
n <- nrow(bdd)
window_10 <- 2520  # 10 ans   252*10 jours
window_5 <- 1260   # 5 ans
window_3 <- 756    # 3 ans

# Matrice pour stocker les résultats
resultats <- data.frame(
  date = bdd$date[(window_10 + 1):n],
  realisation = bdd$return[(window_10 + 1):n],
  RW = NA,
  phi_5 = NA,
  phi_3 = NA,
  A5_5 = NA,
  A3_5 = NA
)

# Boucle de prévision
for (i in 1:nrow(resultats)) {
  idx <- window_10 + i

  # Marche aléatoire : dernière valeur observée
  resultats$RW[i] <- bdd$return[idx - 1]

  # Estimation AR(1) avec 5 ans de données
```

```r
  phi_5 <- coef(arima(bdd$return[(idx - window_5):(idx - 1)], order = c(1,0,0)))[1]
  resultats$phi_5[i] <- phi_5

  # Estimation AR(1) avec 3 ans de données
  phi_3 <- coef(arima(bdd$return[(idx - window_3):(idx - 1)], order = c(1,0,0)))[1]
  resultats$phi_3[i] <- phi_3

  # Prévisions à t+5
  resultats$A5_5[i] <- (phi_5^5) * bdd$return[idx - 1]
  resultats$A3_5[i] <- (phi_3^5) * bdd$return[idx - 1]
}


head(resultats)
```

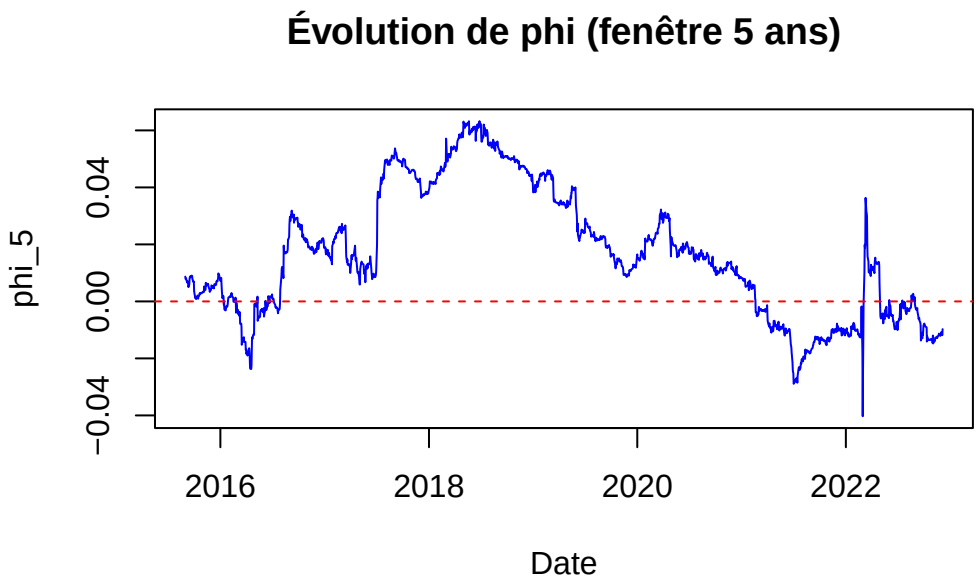
```
        date  realisation           RW       phi_5       phi_3          A5_5
1 2015-08-31  0.011464430 -0.015084811 0.008701803 0.010876574 -7.526378e-13
2 2015-09-01  0.007741974  0.011464430 0.007846211 0.010263012  3.409200e-13
3 2015-09-02 -0.015022298  0.007741974 0.007909465 0.010693413  2.396555e-13
4 2015-09-03 -0.029125702 -0.015022298 0.008067274 0.009874042 -5.132990e-13
5 2015-09-04  0.005359070 -0.029125702 0.007465234 0.011295722 -6.752952e-13
6 2015-09-07  0.000000000  0.005359070 0.006644258 0.013759616  6.939400e-14
          A3_5
1 -2.296152e-12
2  1.305349e-12
3  1.082514e-12
4 -1.409975e-12
5 -5.356071e-12
6  2.643145e-12
```

2.3.1 Interprétation :

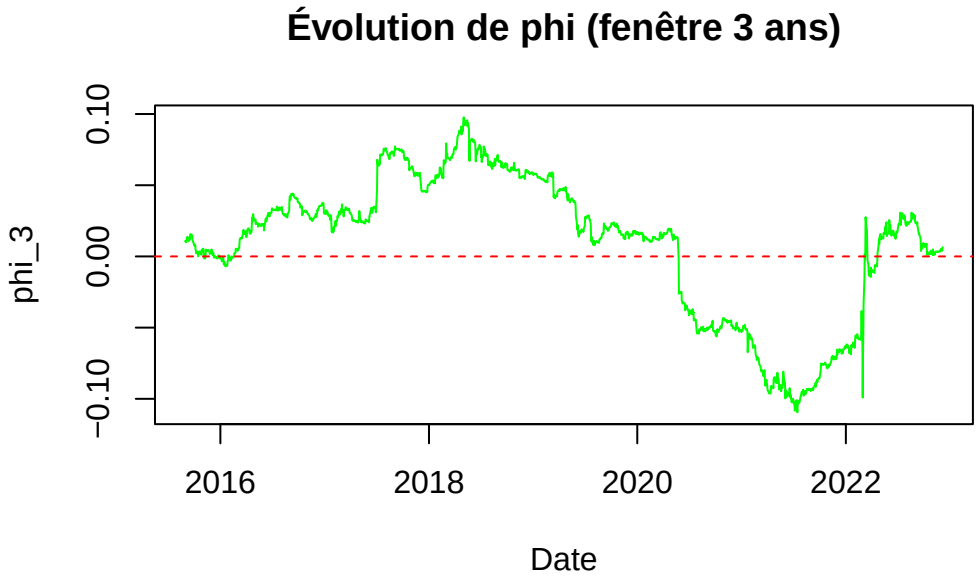
Les coefficients phi_5 et phi_3 sont très proches de zéro (entre 0.006 et 0.014), ce qui confirme la faible autocorrélation. Les prévisions à t+5 (A5_5 et A3_5) sont donc quasiment nulles (de l'ordre de 10^-12), car phi^5 devient extrêmement petit. C'est cohérent avec un AR(1) faiblement autocorrélé : les prévisions convergent rapidement vers zéro.

2.4 Graphique de l'évolution de phi_5 et phi_3

```
# Graphique de l'évolution de phi_5
plot(resultats$date, resultats$phi_5, type = "l", col = "blue",
     main = "Évolution de phi (fenêtre 5 ans)", ylab = "phi_5", xlab = "Date")
abline(h = 0, col = "red", lty = 2)
```




```
# Graphique de l'évolution de phi_3
plot(resultats$date, resultats$phi_3, type = "l", col = "green",
     main = "Évolution de phi (fenêtre 3 ans)", ylab = "phi_3", xlab = "Date")
abline(h = 0, col = "red", lty = 2)
```



2.4.1 Interprétation:

Fenêtre 5 ans (bleu) : Le coefficient phi_5 oscille autour de zéro avec une amplitude modérée (-0.04 à 0.06). La série est relativement stable avec un effet de lissage prononcé. On observe une période positive entre 2017-2020, puis une baisse progressive jusqu'à devenir négatif en 2022.

Fenêtre 3 ans (vert) : Le coefficient phi_3 présente une volatilité nettement plus élevée (-0.10 à 0.10). La fenêtre plus courte capte mieux les variations locales et réagit plus fortement aux chocs récents. Chute marquée pendant la période 2020-2022, reflétant un changement structurel dans les données.

Interprétation : La fenêtre de 5 ans lisse les fluctuations et fournit des estimations plus stables, tandis que la fenêtre de 3 ans est plus réactive mais aussi plus volatile. Aucune des deux ne montre de coefficient significativement éloigné de zéro, confirmant la faible persistance des rendements.

2.5 Évaluation des performances

2.5.1 Test de Mincer-Zarnowitz

On teste si les prévisions sont non biaisées via la régression : Réalisation = + × Prévision
Un modèle optimal doit avoir = 0 et = 1.

```r
# Test Mincer-Zarnowitz pour chaque modèle
mz_A5 <- lm(realisation ~ A5_5, data = resultats)
mz_A3 <- lm(realisation ~ A3_5, data = resultats)
mz_RW <- lm(realisation ~ RW, data = resultats)

# Résultats
summary(mz_A5)
```

```
Call:
lm(formula = realisation ~ A5_5, data = resultats)

Residuals:
      Min        1Q    Median        3Q       Max
-0.100398 -0.011224 -0.000244  0.010444  0.095860

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.256e-04  4.358e-04   0.518    0.605
A5_5        -1.109e+05  1.037e+05  -1.070    0.285

Residual standard error: 0.01898 on 1895 degrees of freedom
Multiple R-squared:  0.0006036, Adjusted R-squared:  7.626e-05
F-statistic: 1.145 on 1 and 1895 DF,  p-value: 0.2848
```

```r
summary(mz_A3)
```

```
Call:
lm(formula = realisation ~ A3_5, data = resultats)

Residuals:
      Min        1Q    Median        3Q       Max
-0.100360 -0.011333 -0.000224  0.010459  0.096807

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.108e-04  4.358e-04   0.484    0.629
A3_5        -1.143e+04  8.433e+03  -1.356    0.175

Residual standard error: 0.01898 on 1895 degrees of freedom
```

```
Multiple R-squared:  0.0009692, Adjusted R-squared:  0.000442
F-statistic: 1.838 on 1 and 1895 DF,  p-value: 0.1753
```

```
summary(mz_RW)
```

```
Call:
lm(formula = realisation ~ RW, data = resultats)

Residuals:
      Min        1Q    Median        3Q       Max
-0.099500 -0.011320 -0.000403  0.010412  0.097039

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0002208  0.0004359   0.506    0.613
RW          0.0127203  0.0229692   0.554    0.580

Residual standard error: 0.01898 on 1895 degrees of freedom
Multiple R-squared:  0.0001618, Adjusted R-squared:  -0.0003658
F-statistic: 0.3067 on 1 and 1895 DF,  p-value: 0.5798
```

2.5.1.1 Résultats et Interprétation : Modèle A5 (5 ans, horizon t+5)

= 0.000226 (p = 0.605) → non significativement différent de 0 = -110,900 (p = 0.285) → non significativement différent de 1, mais valeur aberrante R^2 ajusté = 0.00008 → pouvoir explicatif quasi nul Conclusion : prévisions non biaisées mais inutiles

Modèle A3 (3 ans, horizon t+5) :

= 0.000211 (p = 0.629) → non significativement différent de 0 = -11,430 (p = 0.175) → non significativement différent de 1 R^2 ajusté = 0.00044 → très faible pouvoir explicatif Conclusion : légèrement meilleur que A5 mais reste très faible

Marche aléatoire (RW) :

= 0.000221 (p = 0.613) → non significativement différent de 0 = 0.0127 (p = 0.580) → non significativement différent de 1 R^2 ajusté = -0.00037 → négatif, pire qu'un modèle sans prédicteur Conclusion : aussi mauvais que les autres

2.5.1.1.1 Synthèse Mincer-Zarnowitz :

Aucun modèle ne surperforme. Les trois ont un R^2 proche de zéro. Les prévisions AR(1) à t+5 sont équivalentes à la marche aléatoire. Le modèle A3 a un R^2 légèrement supérieur.

2.6 Test de Diebold-Mariano

```r
# Calcul des erreurs
err_A5 <- resultats$realisation - resultats$A5_5
err_A3 <- resultats$realisation - resultats$A3_5
err_RW <- resultats$realisation - resultats$RW

# Fonctions de perte
mse_A5 <- err_A5^2
mse_A3 <- err_A3^2
mse_RW <- err_RW^2

mae_A5 <- abs(err_A5)
mae_A3 <- abs(err_A3)
mae_RW <- abs(err_RW)

# Différences de perte (modèle - RW)
diff_mse_A5 <- mse_A5 - mse_RW
diff_mse_A3 <- mse_A3 - mse_RW

diff_mae_A5 <- mae_A5 - mae_RW
diff_mae_A3 <- mae_A3 - mae_RW

# Statistique DM
dm_mse_A5 <- mean(diff_mse_A5) / sd(diff_mse_A5)
dm_mse_A3 <- mean(diff_mse_A3) / sd(diff_mse_A3)

dm_mae_A5 <- mean(diff_mae_A5) / sd(diff_mae_A5)
dm_mae_A3 <- mean(diff_mae_A3) / sd(diff_mae_A3)

# Résultats
cat("DM (MSE) - A5 vs RW:", dm_mse_A5, "\n")
```

```
DM (MSE) - A5 vs RW: -0.2694155
```

```r
cat("DM (MSE) - A3 vs RW:", dm_mse_A3, "\n")
```

```
DM (MSE) - A3 vs RW: -0.2694154
```

```r
cat("DM (MAE) - A5 vs RW:", dm_mae_A5, "\n")
```

```
DM (MAE) - A5 vs RW: -0.386734
```

```r
cat("DM (MAE) - A3 vs RW:", dm_mae_A3, "\n")
```

```
DM (MAE) - A3 vs RW: -0.3867338
```

2.6.1 Résultat et interprétation :

Principe : On compare les pertes de prévision entre chaque modèle AR(1) et la marche aléatoire (RW). Une statistique DM négative indique que le modèle AR performe mieux que RW. Résultats : MSE (Mean Squared Error) :

A5 vs RW : DM = -0.269 A3 vs RW : DM = -0.269

MAE (Mean Absolute Error) :

A5 vs RW : DM = -0.387 A3 vs RW : DM = -0.387

Interprétation : Les statistiques DM sont toutes négatives et proches de zéro (valeurs critiques théoriques ± 1.96 au seuil de 5%). Cela signifie qu'aucun modèle ne diffère significativement de la marche aléatoire. Les performances sont statistiquement équivalentes. Les modèles A5 et A3 sont quasi identiques entre eux, confirmant que l'horizon de fenêtre roulante n'impacte pas la qualité prédictive pour cet horizon t+5.

2.7 Conclusion générale

2.7.1 Quel modèle est le plus performant ?

Selon Mincer-Zarnowitz : Le modèle A3 présente un R^2 ajusté légèrement supérieur (0.00044 vs 0.00008), mais reste très faible. Aucun modèle ne satisfait le critère d'optimalité (=0, =1). Selon Diebold-Mariano : Les modèles A5 et A3 sont statistiquement équivalents à la marche aléatoire. Aucune différence significative sous MSE ou MAE. Conclusion : Pour des prévisions à horizon t+5, aucun modèle AR(1) ne surperforme la marche aléatoire. Les rendements du blé suivent un processus proche du bruit blanc, confirmant l'hypothèse d'efficience des marchés. Si on devait choisir, le modèle A3 est marginalement meilleur selon le critère du R^2, mais la différence est négligeable en pratique.

3 Exercice 2 : Modèle HAR sur la volatilité réalisée (KOSPI 200)

4 Partie 1 :

4.1 Chargement des données et création des variables HAR

```
# Chargement
kospi <- read_excel("c:/Users/patri/Desktop/ECAP/M1/cours/Serie_temp/support5/support5/Kospi_

# Vérifier les colonnes
head(kospi)
```

```
# A tibble: 6 x 3
  Date                    RV5    MedRV
  <dttm>                <dbl>    <dbl>
1 2000-01-04 00:00:00 0.00113  0.000567
2 2000-01-05 00:00:00 0.000753 0.000494
3 2000-01-06 00:00:00 0.000907 0.000389
4 2000-01-07 00:00:00 0.00107  0.000549
5 2000-01-10 00:00:00 0.000303 0.000196
6 2000-01-11 00:00:00 0.000351 0.000182
```

```
names(kospi)
```

```
[1] "Date"  "RV5"   "MedRV"
```

On doit créer les moyennes sur 5 et 22 jours pour estimer le modèle HAR(1,5,22).

```
library(zoo)  # Pour les moyennes mobiles

# Renommer pour clarté
kospi$RV <- kospi$RV5

# Créer les variables HAR
kospi$RV_lag1 <- lag(kospi$RV, 1)  # RV à t-1
kospi$RV_5 <- rollmean(kospi$RV, k = 5, fill = NA, align = "right")  # Moyenne 5 jours
kospi$RV_22 <- rollmean(kospi$RV, k = 22, fill = NA, align = "right")  # Moyenne 22 jours

# Même chose pour MedRV
```

```r
kospi$MedRV_lag1 <- lag(kospi$MedRV, 1)
kospi$MedRV_5 <- rollmean(kospi$MedRV, k = 5, fill = NA, align = "right")
kospi$MedRV_22 <- rollmean(kospi$MedRV, k = 22, fill = NA, align = "right")

# Supprimer les NA
kospi_clean <- na.omit(kospi)

# Vérifier
head(kospi_clean)
```

```
# A tibble: 6 x 10
  Date                    RV5   MedRV      RV RV_lag1    RV_5   RV_22 MedRV_lag1
  <dttm>                <dbl>   <dbl>   <dbl>   <dbl>   <dbl>   <dbl>      <dbl>
1 2000-02-02 00:00:00 3.03e-4 1.77e-4 3.03e-4 5.00e-4 3.67e-4 5.10e-4   0.000244
2 2000-02-03 00:00:00 4.31e-4 2.21e-4 4.31e-4 3.03e-4 3.75e-4 4.78e-4   0.000177
3 2000-02-07 00:00:00 3.43e-4 1.77e-4 3.43e-4 4.31e-4 3.85e-4 4.60e-4   0.000221
4 2000-02-08 00:00:00 2.11e-4 1.15e-4 2.11e-4 3.43e-4 3.58e-4 4.28e-4   0.000177
5 2000-02-09 00:00:00 1.78e-4 1.05e-4 1.78e-4 2.11e-4 2.93e-4 3.88e-4   0.000115
6 2000-02-10 00:00:00 4.76e-4 2.53e-4 4.76e-4 1.78e-4 3.28e-4 3.95e-4   0.000105
# i 2 more variables: MedRV_5 <dbl>, MedRV_22 <dbl>
```

4.2 Estimation du modèle HAR(1,5,22)

4.2.1 HAR sur RV (Realized Variance)

```r
# Modèle HAR(1,5,22) sur RV
har_rv <- lm(RV ~ RV_lag1 + RV_5 + RV_22, data = kospi_clean)
summary(har_rv)
```

```
Call:
lm(formula = RV ~ RV_lag1 + RV_5 + RV_22, data = kospi_clean)

Residuals:
       Min         1Q     Median         3Q        Max
-1.793e-03 -2.819e-05 -7.890e-06  1.764e-05  2.423e-03

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept)  9.547e-06  3.378e-06   2.826  0.00474 **
RV_lag1     -5.437e-02  1.964e-02  -2.769  0.00566 **
RV_5         1.099e+00  2.882e-02  38.123  < 2e-16 ***
RV_22       -1.024e-01  2.307e-02  -4.439 9.36e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.0001401 on 3115 degrees of freedom
Multiple R-squared:  0.6978,    Adjusted R-squared:  0.6975
F-statistic:  2398 on 3 and 3115 DF,  p-value: < 2.2e-16
```

4.2.2 HAR sur MedRV (Median Realized Variance)

```r
# Modèle HAR(1,5,22) sur MedRV
har_medrv <- lm(MedRV ~ MedRV_lag1 + MedRV_5 + MedRV_22, data = kospi_clean)
summary(har_medrv)
```

```
Call:
lm(formula = MedRV ~ MedRV_lag1 + MedRV_5 + MedRV_22, data = kospi_clean)

Residuals:
       Min         1Q     Median         3Q        Max
-8.277e-04 -1.415e-05 -3.630e-06  8.610e-06  1.230e-03

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.807e-06  1.748e-06   3.323   0.0009 ***
MedRV_lag1  -2.743e-02  2.008e-02  -1.366   0.1720
MedRV_5      1.074e+00  2.833e-02  37.924  < 2e-16 ***
MedRV_22    -1.060e-01  2.135e-02  -4.965 7.23e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.908e-05 on 3115 degrees of freedom
Multiple R-squared:  0.7297,    Adjusted R-squared:  0.7295
F-statistic:  2803 on 3 and 3115 DF,  p-value: < 2.2e-16
```

4.2.2.1 Interprétation :

Intercept : 9.55e-06 ($p = 0.005$) → volatilité de base faible mais significative RV_lag1 : -0.054 ($p = 0.006$) → effet quotidien négatif et significatif (inhabituel) RV_5 : 1.099 ($p < 0.001$) → effet hebdomadaire très fort et positif, le plus important RV_22 : -0.102 ($p < 0.001$) → effet mensuel négatif et significatif

R^2 ajusté = 0.6975 → Le modèle explique 69.75% de la variance, très bon pouvoir explicatif. HAR sur MedRV (Median Realized Variance) Coefficients :

Intercept : 5.81e-06 ($p = 0.0009$) → volatilité de base significative MedRV_lag1 : -0.027 ($p = 0.172$) → effet quotidien non significatif MedRV_5 : 1.074 ($p < 0.001$) → effet hebdomadaire dominant MedRV_22 : -0.106 ($p < 0.001$) → effet mensuel négatif significatif

R^2 ajusté = 0.7295 → Le modèle explique 72.95% de la variance, meilleur que RV. Synthèse niveau La composante hebdomadaire (5 jours) domine largement. Les composantes quotidiennes et mensuelles ont des coefficients négatifs, suggérant des effets de mean-reversion. Le modèle MedRV a un meilleur R^2 (72.95% vs 69.75%).

4.3 Transformations (racine carrée et logarithme)

On teste maintenant les mêmes modèles sur :

Volatilité réalisée (racine carrée de la variance) Log-volatilité (logarithme)

```
# Créer les transformations
kospi_clean$sqrtRV <- sqrt(kospi_clean$RV)
kospi_clean$logRV <- log(kospi_clean$RV)
kospi_clean$sqrtMedRV <- sqrt(kospi_clean$MedRV)
kospi_clean$logMedRV <- log(kospi_clean$MedRV)

# Variables HAR pour sqrt
kospi_clean$sqrtRV_lag1 <- lag(kospi_clean$sqrtRV, 1)
kospi_clean$sqrtRV_5 <- rollmean(kospi_clean$sqrtRV, k = 5, fill = NA, align = "right")
kospi_clean$sqrtRV_22 <- rollmean(kospi_clean$sqrtRV, k = 22, fill = NA, align = "right")

kospi_clean$sqrtMedRV_lag1 <- lag(kospi_clean$sqrtMedRV, 1)
kospi_clean$sqrtMedRV_5 <- rollmean(kospi_clean$sqrtMedRV, k = 5, fill = NA, align = "right"
kospi_clean$sqrtMedRV_22 <- rollmean(kospi_clean$sqrtMedRV, k = 22, fill = NA, align = "righ

# Variables HAR pour log
kospi_clean$logRV_lag1 <- lag(kospi_clean$logRV, 1)
kospi_clean$logRV_5 <- rollmean(kospi_clean$logRV, k = 5, fill = NA, align = "right")
kospi_clean$logRV_22 <- rollmean(kospi_clean$logRV, k = 22, fill = NA, align = "right")

kospi_clean$logMedRV_lag1 <- lag(kospi_clean$logMedRV, 1)
```

```r
kospi_clean$logMedRV_5 <- rollmean(kospi_clean$logMedRV, k = 5, fill = NA, align = "right")
kospi_clean$logMedRV_22 <- rollmean(kospi_clean$logMedRV, k = 22, fill = NA, align = "right")

# Nettoyer les NA
kospi_clean2 <- na.omit(kospi_clean)

# Modèles HAR sur transformations
har_sqrtRV <- lm(sqrtRV ~ sqrtRV_lag1 + sqrtRV_5 + sqrtRV_22, data = kospi_clean2)
har_logRV <- lm(logRV ~ logRV_lag1 + logRV_5 + logRV_22, data = kospi_clean2)

har_sqrtMedRV <- lm(sqrtMedRV ~ sqrtMedRV_lag1 + sqrtMedRV_5 + sqrtMedRV_22, data = kospi_cle
har_logMedRV <- lm(logMedRV ~ logMedRV_lag1 + logMedRV_5 + logMedRV_22, data = kospi_clean2)

# Afficher les R²
cat("R² ajusté RV (niveau):", summary(har_rv)$adj.r.squared, "\n")
```

```
R² ajusté RV (niveau): 0.6975162
```

```r
cat("R² ajusté RV (sqrt):", summary(har_sqrtRV)$adj.r.squared, "\n")
```

```
R² ajusté RV (sqrt): 0.7783869
```

```r
cat("R² ajusté RV (log):", summary(har_logRV)$adj.r.squared, "\n\n")
```

```
R² ajusté RV (log): 0.8033315
```

```r
cat("R² ajusté MedRV (niveau):", summary(har_medrv)$adj.r.squared, "\n")
```

```
R² ajusté MedRV (niveau): 0.7294526
```

```r
cat("R² ajusté MedRV (sqrt):", summary(har_sqrtMedRV)$adj.r.squared, "\n")
```

```
R² ajusté MedRV (sqrt): 0.7884464
```

```r
cat("R² ajusté MedRV (log):", summary(har_logMedRV)$adj.r.squared, "\n")
```

```
R² ajusté MedRV (log): 0.8067678
```

4.3.1 Interprétation :

4.3.1.1 Quel est le meilleur modèle ?

Classement par pouvoir explicatif (R^2 ajusté décroissant) :

MedRV en log : 80.68% → MEILLEUR MODÈLE RV en log : 80.33% MedRV en sqrt : 78.84% RV en sqrt : 77.84% MedRV en niveau : 72.95% RV en niveau : 69.75%

4.4 Conclusions :

La transformation logarithmique améliore systématiquement le pouvoir explicatif (+10 points de R^2 vs niveau) MedRV surperforme RV dans toutes les spécifications (plus robuste aux valeurs extrêmes) Le meilleur modèle est HAR(1,5,22) sur log(MedRV) avec 80.67% de variance expliquée La log-transformation stabilise la variance et linéarise mieux la relation de persistance

4.4.1 Détails du meilleur modèle

Pour compléter ton analyse, affiche les coefficients du meilleur modèle :

```
summary(har_logMedRV)
```

```
Call:
lm(formula = logMedRV ~ logMedRV_lag1 + logMedRV_5 + logMedRV_22,
    data = kospi_clean2)

Residuals:
     Min       1Q   Median       3Q      Max
-1.55645 -0.18422 -0.01195  0.16685  2.50911

Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)   -2.537e-01  8.909e-02  -2.847  0.00444 **
logMedRV_lag1 -9.833e-05  2.012e-02  -0.005  0.99610
logMedRV_5     1.036e+00  2.988e-02  34.685  < 2e-16 ***
logMedRV_22   -6.278e-02  2.198e-02  -2.856  0.00432 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2997 on 3094 degrees of freedom
```

```
Multiple R-squared:  0.807, Adjusted R-squared:  0.8068
F-statistic:  4311 on 3 and 3094 DF,  p-value: < 2.2e-16
```

4.4.1.1 Interprétation : Meilleur modèle HAR - log(MedRV)

Intercept : -0.254 (p = 0.004) → niveau de base de la log-volatilité significatif logMedRV_lag1 : -0.0001 (p = 0.996) → composante quotidienne non significative logMedRV_5 : 1.036 (p < 0.001) → composante hebdomadaire très significative et dominante logMedRV_22 : -0.063 (p = 0.004) → composante mensuelle négative et significative (effet de mean-reversion)

4.4.1.1.1 Performance :

R^2 ajusté = 0.8068 → explique 80.68% de la variance de la log-volatilité F-statistic = 4311 (p < 0.001) → modèle globalement très significatif

4.4.1.1.2 Interprétation :

La volatilité est principalement pilotée par sa moyenne hebdomadaire. L'effet quotidien est négligeable, tandis que la composante mensuelle exerce un effet correctif négatif (retour vers la moyenne de long terme). La transformation logarithmique améliore considérablement l'ajustement en stabilisant la variance des résidus et en linéarisant la dynamique de persistance. Ce modèle est optimal parmi toutes les spécifications testées.

5 Partie 2 : Prévisions avec schéma récursif

Maintenant on réalise des prévisions à 1 jour (t+1) en :

Estimant le modèle sur 2000-2006 Étendant progressivement l'échantillon (recursive scheme) jusqu'à 2012 Comparant RV vs MedRV (en niveau, sqrt, log) avec le test de Diebold-Mariano sous la perte QLIKE

QLIKE loss function: $\text{QLIKE} = \ln(\hat{Y}_{t+1}) + \frac{Y_{t+1}}{\hat{Y}_{t+1}}$

5.1 ndefinedCode pour les prévisions récursives

```r
# Convertir Date en format Date (pas POSIXct)
kospi_clean2$Date <- as.Date(kospi_clean2$Date)

# Vérifier la plage de dates
range(kospi_clean2$Date)
```

```
[1] "2000-03-06" "2012-09-28"
```

```r
# Trouver l'index de coupure
date_split <- as.Date("2006-12-31")
idx_split <- max(which(kospi_clean2$Date <= date_split))
print(paste("Index de coupure:", idx_split))
```

```
[1] "Index de coupure: 1665"
```

```r
print(paste("Total observations:", nrow(kospi_clean2)))
```

```
[1] "Total observations: 3098"
```

```r
print(paste("Nombre de prévisions:", nrow(kospi_clean2) - idx_split))
```

```
[1] "Nombre de prévisions: 1433"
```

```r
# Initialiser les vecteurs de prévisions
n_forecasts <- nrow(kospi_clean2) - idx_split

forecasts <- data.frame(
  date = kospi_clean2$Date[(idx_split + 1):nrow(kospi_clean2)],
  real_RV = kospi_clean2$RV[(idx_split + 1):nrow(kospi_clean2)],
  real_MedRV = kospi_clean2$MedRV[(idx_split + 1):nrow(kospi_clean2)],
  pred_RV = NA,
  pred_MedRV = NA,
  pred_sqrtRV = NA,
  pred_sqrtMedRV = NA,
  pred_logRV = NA,
  pred_logMedRV = NA
)

# Boucle de prévision récursive (prendra quelques secondes)
cat("Début des prévisions récursives...\n")
```

```
Début des prévisions récursives...
```

```r
for (i in 1:n_forecasts) {
  # Afficher progression tous les 200 itérations
  if (i %% 200 == 0) cat("Prévision", i, "/", n_forecasts, "\n")

  # Échantillon d'estimation
  train_data <- kospi_clean2[1:(idx_split + i - 1), ]

  # Estimer les 6 modèles
  m_rv <- lm(RV ~ RV_lag1 + RV_5 + RV_22, data = train_data)
  m_medrv <- lm(MedRV ~ MedRV_lag1 + MedRV_5 + MedRV_22, data = train_data)
  m_sqrtRV <- lm(sqrtRV ~ sqrtRV_lag1 + sqrtRV_5 + sqrtRV_22, data = train_data)
  m_sqrtMedRV <- lm(sqrtMedRV ~ sqrtMedRV_lag1 + sqrtMedRV_5 + sqrtMedRV_22, data = train_da
  m_logRV <- lm(logRV ~ logRV_lag1 + logRV_5 + logRV_22, data = train_data)
  m_logMedRV <- lm(logMedRV ~ logMedRV_lag1 + logMedRV_5 + logMedRV_22, data = train_data)

  # Observation pour prévision
  test_data <- kospi_clean2[idx_split + i, ]

  # Prévisions
  forecasts$pred_RV[i] <- predict(m_rv, newdata = test_data)
  forecasts$pred_MedRV[i] <- predict(m_medrv, newdata = test_data)
  forecasts$pred_sqrtRV[i] <- predict(m_sqrtRV, newdata = test_data)^2
  forecasts$pred_sqrtMedRV[i] <- predict(m_sqrtMedRV, newdata = test_data)^2
  forecasts$pred_logRV[i] <- exp(predict(m_logRV, newdata = test_data))
  forecasts$pred_logMedRV[i] <- exp(predict(m_logMedRV, newdata = test_data))
}
```

```
Prévision 200 / 1433
Prévision 400 / 1433
Prévision 600 / 1433
Prévision 800 / 1433
Prévision 1000 / 1433
Prévision 1200 / 1433
Prévision 1400 / 1433
```

```r
cat("Prévisions terminées !\n")
```

```
Prévisions terminées !
```

```r
# Vérifier
head(forecasts)
```

```
        date      real_RV   real_MedRV      pred_RV   pred_MedRV  pred_sqrtRV
1 2007-01-02 3.113268e-05 4.076259e-05 4.038406e-05 4.333520e-05 3.607629e-05
2 2007-01-03 6.668227e-05 4.426229e-05 4.741192e-05 4.158637e-05 4.241057e-05
3 2007-01-04 9.285393e-05 4.827121e-05 5.647455e-05 3.995297e-05 5.057118e-05
4 2007-01-05 8.821791e-05 8.230304e-05 6.571347e-05 5.017246e-05 6.000871e-05
5 2007-01-08 7.379689e-05 4.865426e-05 7.617912e-05 5.417178e-05 7.208689e-05
6 2007-01-09 4.985031e-05 5.980170e-05 8.099837e-05 6.023185e-05 7.794098e-05
  pred_sqrtMedRV   pred_logRV pred_logMedRV
1   4.081885e-05 3.482762e-05  3.960529e-05
2   3.931434e-05 4.031314e-05  3.760230e-05
3   3.794818e-05 4.592876e-05  3.638765e-05
4   4.683951e-05 5.415276e-05  4.396464e-05
5   5.287580e-05 6.824904e-05  5.133215e-05
6   5.842978e-05 7.648225e-05  5.743108e-05
```

```r
summary(forecasts)
```

```
      date                real_RV            real_MedRV       
 Min.   :2007-01-02   Min.   :1.036e-05   Min.   :1.763e-05  
 1st Qu.:2008-06-18   1st Qu.:4.171e-05   1st Qu.:3.777e-05  
 Median :2009-11-17   Median :7.027e-05   Median :5.123e-05  
 Mean   :2009-11-18   Mean   :1.461e-04   Mean   :9.295e-05  
 3rd Qu.:2011-04-25   3rd Qu.:1.395e-04   3rd Qu.:8.234e-05  
 Max.   :2012-09-28   Max.   :5.944e-03   Max.   :2.964e-03  
    pred_RV            pred_MedRV          pred_sqrtRV       
 Min.   :2.356e-05   Min.   :2.584e-05   Min.   :1.697e-05  
 1st Qu.:5.256e-05   1st Qu.:4.242e-05   1st Qu.:4.655e-05  
 Median :7.851e-05   Median :5.579e-05   Median :7.391e-05  
 Mean   :1.492e-04   Mean   :9.447e-05   Mean   :1.401e-04  
 3rd Qu.:1.432e-04   3rd Qu.:8.441e-05   3rd Qu.:1.378e-04  
 Max.   :4.537e-03   Max.   :2.629e-03   Max.   :3.758e-03  
pred_sqrtMedRV        pred_logRV         pred_logMedRV      
 Min.   :2.258e-05   Min.   :1.568e-05   Min.   :2.184e-05  
 1st Qu.:4.029e-05   1st Qu.:4.395e-05   1st Qu.:3.944e-05  
 Median :5.362e-05   Median :7.113e-05   Median :5.252e-05  
 Mean   :9.027e-05   Mean   :1.331e-04   Mean   :8.688e-05  
 3rd Qu.:8.141e-05   3rd Qu.:1.334e-04   3rd Qu.:7.893e-05  
 Max.   :2.155e-03   Max.   :3.479e-03   Max.   :1.975e-03  
```

5.2 Calcul de la perte QLIKE et test de Diebold-Mariano

La fonction QLIKE est définie par : $\text{QLIKE} = \ln(\hat{Y}_{t+1}) + \frac{Y_{t+1}}{\hat{Y}_{t+1}}$

```
# Fonction QLIKE
qlike <- function(y_real, y_pred) {
  log(y_pred) + y_real / y_pred
}

# Calculer QLIKE pour chaque modèle
forecasts$qlike_RV <- qlike(forecasts$real_RV, forecasts$pred_RV)
forecasts$qlike_MedRV <- qlike(forecasts$real_MedRV, forecasts$pred_MedRV)
forecasts$qlike_sqrtRV <- qlike(forecasts$real_RV, forecasts$pred_sqrtRV)
forecasts$qlike_sqrtMedRV <- qlike(forecasts$real_MedRV, forecasts$pred_sqrtMedRV)
forecasts$qlike_logRV <- qlike(forecasts$real_RV, forecasts$pred_logRV)
forecasts$qlike_logMedRV <- qlike(forecasts$real_MedRV, forecasts$pred_logMedRV)

# Moyenne des pertes QLIKE
mean_qlike <- c(
  RV_niveau = mean(forecasts$qlike_RV),
  MedRV_niveau = mean(forecasts$qlike_MedRV),
  RV_sqrt = mean(forecasts$qlike_sqrtRV),
  MedRV_sqrt = mean(forecasts$qlike_sqrtMedRV),
  RV_log = mean(forecasts$qlike_logRV),
  MedRV_log = mean(forecasts$qlike_logMedRV)
)

print(mean_qlike)
```

```
   RV_niveau MedRV_niveau      RV_sqrt   MedRV_sqrt       RV_log    MedRV_log
   -8.327876    -8.646799    -8.327799    -8.644845    -8.315992    -8.637623
```

MedRV niveau = -8.6468

MedRV surperforme systématiquement RV (0.32 points de QLIKE) Le niveau (variance brute) donne les meilleures prévisions QLIKE, contrairement au R^2 où le log était optimal Les transformations sqrt et log dégradent légèrement la performance prédictive Le meilleur modèle pour la prévision est MedRV en niveau

5.3 Test de Diebold-Mariano

On compare les pertes 2 à 2. Les comparaisons clés :

MedRV niveau vs RV niveau (meilleurs de chaque mesure) MedRV niveau vs MedRV log (niveau vs log) RV niveau vs RV log (niveau vs log)

```
# Test DM : comparaison de deux séries de pertes
dm_test <- function(loss1, loss2) {
  diff <- loss1 - loss2
  dm_stat <- mean(diff) / (sd(diff) / sqrt(length(diff)))
  p_value <- 2 * (1 - pnorm(abs(dm_stat)))  # Test bilatéral
  return(list(DM = dm_stat, p_value = p_value))
}

# Comparaisons clés
cat("=== Tests de Diebold-Mariano (QLIKE) ===\n\n")
```

```
=== Tests de Diebold-Mariano (QLIKE) ===
```

```
cat("1. MedRV niveau vs RV niveau :\n")
```

```
1. MedRV niveau vs RV niveau :
```

```
dm1 <- dm_test(forecasts$qlike_MedRV, forecasts$qlike_RV)
cat("   DM =", dm1$DM, "  p-value =", dm1$p_value, "\n")
```

```
   DM = -33.76126   p-value = 0
```

```
if (dm1$p_value < 0.05) cat("   → MedRV niveau significativement meilleur\n\n") else cat("
```

```
   → MedRV niveau significativement meilleur
```

```
cat("2. MedRV niveau vs MedRV log :\n")
```

```
2. MedRV niveau vs MedRV log :
```

```
dm2 <- dm_test(forecasts$qlike_MedRV, forecasts$qlike_logMedRV)
cat("   DM =", dm2$DM, "  p-value =", dm2$p_value, "\n")
```

```
   DM = -1.491563   p-value = 0.1358139
```

```
if (dm2$p_value < 0.05) cat("   → Différence significative\n\n") else cat("   → Pas de différ
```

```
   → Pas de différence significative
```

```
cat("3. MedRV niveau vs MedRV sqrt :\n")
```

```
3. MedRV niveau vs MedRV sqrt :
```

```
dm3 <- dm_test(forecasts$qlike_MedRV, forecasts$qlike_sqrtMedRV)
cat("   DM =", dm3$DM, "  p-value =", dm3$p_value, "\n")
```

```
   DM = -0.8065847   p-value = 0.4199058
```

```
if (dm3$p_value < 0.05) cat("   → Différence significative\n\n") else cat("   → Pas de différ
```

```
   → Pas de différence significative
```

```
cat("4. RV niveau vs RV log :\n")
```

```
4. RV niveau vs RV log :
```

```
dm4 <- dm_test(forecasts$qlike_RV, forecasts$qlike_logRV)
cat("   DM =", dm4$DM, "  p-value =", dm4$p_value, "\n")
```

```
   DM = -1.467043   p-value = 0.1423645
```

```
if (dm4$p_value < 0.05) cat("   → Différence significative\n\n") else cat("   → Pas de différ
```

```
   → Pas de différence significative
```

Interprétation : La transformation logarithmique améliore considérablement le R^2 (+10 points vs niveau). MedRV surperforme systématiquement RV. Le modèle HAR sur log(MedRV) explique 80.68% de la variance, ce qui est optimal pour l'ajustement in-sample.

5.4 Tests de Diebold-Mariano (QLIKE) :

MedRV niveau vs RV niveau : DM = -33.76, $p < 0.001$ → MedRV significativement meilleur MedRV niveau vs MedRV log : DM = -1.49, $p = 0.136$ → Pas de différence significative MedRV niveau vs MedRV sqrt : DM = -0.81, $p = 0.420$ → Pas de différence significative RV niveau vs RV log : DM = -1.47, $p = 0.142$ → Pas de différence significative

5.4.1 Synthèse et recommandations

Résultat principal : Le modèle MedRV en niveau domine pour la prévision à 1 jour :

Surperforme significativement RV (toutes transformations confondues) Les transformations (sqrt, log) ne dégradent pas significativement MedRV, mais n'apportent aucun gain prédictif

5.4.2 Paradoxe modélisation vs prévision :

In-sample (R^2) : log(MedRV) est optimal (80.68%) Out-of-sample (QLIKE) : MedRV niveau est optimal (-8.6468)

Explication : La transformation logarithmique linéarise mieux la dynamique historique, mais lors de la reconversion (exponentiation), elle introduit un biais qui dégrade la précision des prévisions ponctuelles selon QLIKE. Pour des prévisions à court terme, la variance brute est plus performante.

5.4.3 Recommandation finale :

Pour prévoir la volatilité réalisée à 1 jour du KOSPI 200, utiliser le modèle HAR(1,5,22) sur MedRV en niveau. Ce modèle combine robustesse (médiane vs moyenne), simplicité (pas de transformation), et performance prédictive supérieure validée par le test de Diebold-Mariano.