Projet de Néné Gallé Ly et Patrice PAKO

Néné Gallé Ly & Patrice PAKO

Table of contents

0.1 2
1. Installation et chargement des Packages 2
2. Exercice 1 : Chocs permanents vs chocs transitoires : une analyse exploratoire 2
3. Exercice 2 : TS vs DS : simulation de processus 4
4. Exercice 3: Partie Regréssion fallacieuse 7
4.1 Réaction suite à une modification de la taille de l'echantillon 8
5. Exercice 4 : Distribution de la statistique de test de Dickey-Fuller 10
5.1 Distribution avec constante egale à 5 et constante égale 10 11
6. Exercice 5 : Analyse de la série temporelle du PIB des USA sur la période 1990-2023 ... 13
7. Estimer les ACF et PACF de la serie 15
7.1 Analyse des fonctions d'autocorrélation (ACF et PACF) 17
7.1.1 Analyse de l'ACF : la signature de la non-stationnarité 17
7.1.2 Analyse du PACF : l'identification du processus 17
8. Test de Dickey-Fuller simple 17
9. Test de stationnarité de KPSS 22
9.0.1 Analyse sur période globale 23
10. Autocorrélogrammes ACF et PACF 25
10.1 Analyse des autocorrélogrammes 26
11. Test de Dickey-Fuller 26
12. Test de Dickey-Fuller augmenté 29
13. Test de stationnarité KPSS (1990–2023) 32
13.1 Test KPSS (période 1990-2023) 32
14. Conclusion générale 33

0.1

1. Installation et chargement des Packages

```
#library(tseries)
#library(forecast)
#library(FinTS)
#library(Metrics)
#library(TSA)

library(forecast)
library(urca)
library(scales)
library(ggplot2)
```

2. Exercice 1 : Chocs permanents vs chocs transitoires : une analyse exploratoire

On fera ici une simulation et représentation graphiques des séries AR(1) pour des chocs de valeur 20, 40, -20 et -40 à l'observation 100.

```
#les parametres:

T <- 200
shock_t <- 100
phis   <- c(0.5, 0.9, 1.0)
shocks <- c(20, 40, -20, -40)
set.seed(123)

# palette de couleur et légende

cols <- c("phi=0.5" = 1, "phi=0.9" = 2, "phi=1" = 3)

par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))  # 2x2
# graphiques
for (s in shocks) {

  # fenêtre vide avec limites fixes
  plot(
    x = 1:T, y = rep(NA, T),
    xlim = c(1, T),
    ylim = c(-150, 150),
    xlab = "t", ylab = "Yt",
    main = paste0("AR(1) pour un choc de ", s)
  )
  abline(v = shock_t, lty = 2)
```

```r
  for (phi in phis) {

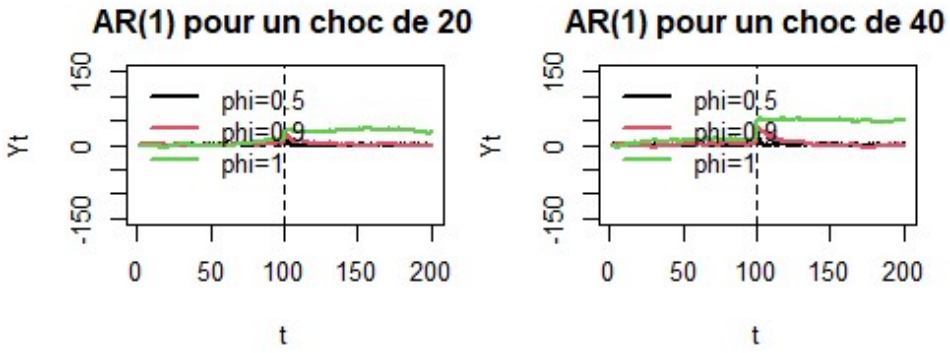
    eps <- rnorm(T, mean = 0, sd = 1)    # N(0,1)
    eps[shock_t] <- eps[shock_t] + s     # choc intégré à eps_100

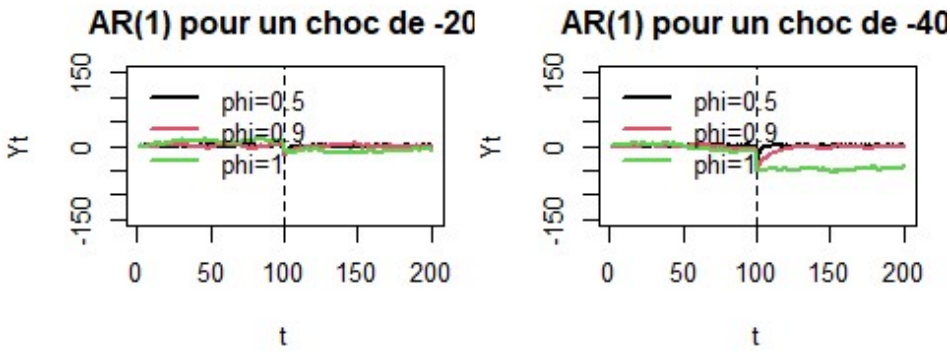
    y <- numeric(T)
    y[1] <- eps[1]                       # init simple

    for (t in 2:T) {
      y[t] <- phi * y[t - 1] + eps[t]
    }

    lab <- paste0("phi=", phi)
    lines(1:T, y, col = cols[lab], lwd = 2)
  }

  legend(
    "topleft",
    legend = names(cols),
    col = cols,
    lwd = 2,
    bty = "n"
  )
}
```





On simule un AR(1) : Yt = ϕ Yt−1 + εt, avec εt ~ N(0,1), et on introduit un choc à la date t = 100.

On observe des comportements très différents selon la valeur de ϕ.

Cas ϕ = 0.5

Le choc provoque un saut à la date 100 mais l'effet disparaît rapidement. La série revient progressivement vers sa moyenne de long terme.

Cela s'explique par le fait que | ϕ| < 1 : le processus est stationnaire et la mémoire est courte. Le choc est donc transitoire.

Cas ϕ = 0.9

Le choc est plus persistant : l'écart met plus de temps à se résorber. Cependant, l'effet finit par disparaître.

Le processus reste stationnaire mais présente une forte persistance.

Cas ϕ = 1 (marche aléatoire)

Le choc à la date 100 modifie définitivement la trajectoire de la série. Après le choc, la série reste durablement décalée vers le haut (ou vers le bas).

Il n'y a aucun retour vers une moyenne de long terme.

Impact d'un choc dans le cas d'une marche aléatoire

Dans le cas ϕ = 1, le choc a un effet permanent. Chaque innovation s'accumule dans le temps. La trajectoire future dépend définitivement des chocs passés.

3. Exercice 2 : TS vs DS : simulation de processus

Dans cette partie nous allons analyser l'aspect visuel de processus de nature differente afin de mieux comprendre leur com- ´ portement. On simule 200 observations .

TS : Yt = 0, 2t + εt

DS (UR) : Yt = 0, 2 + Yt−1 + εt

Fonctions de simulation et representations graphiques

```
set.seed(123)

T <- 200
drift <- 0.2
vars <- c(1/4, 1/2, 1)   # Variances

# Fonction simulation TS & DS avec les mêmes eps
```

```r
sim_ts_ds <- function(T, drift, sigma2) {

  eps <- rnorm(T, mean = 0, sd = sqrt(sigma2))  # eps ~ N(0, sigma2)
  t <- 1:T

  # TS : tendance  + bruit
  y_ts <- drift * t + eps

  # DS : marche aléatoire avec dérive
  y_ds <- numeric(T)
  y_ds[1] <- eps[1]
  for (i in 2:T) {
    y_ds[i] <- drift + y_ds[i - 1] + eps[i]
  }

  list(t = t, ts = y_ts, ds = y_ds)
}

# 3 graphiques
par(mfrow = c(3, 1), mar = c(4, 4, 3, 1)) # affichage

for (v in vars) {

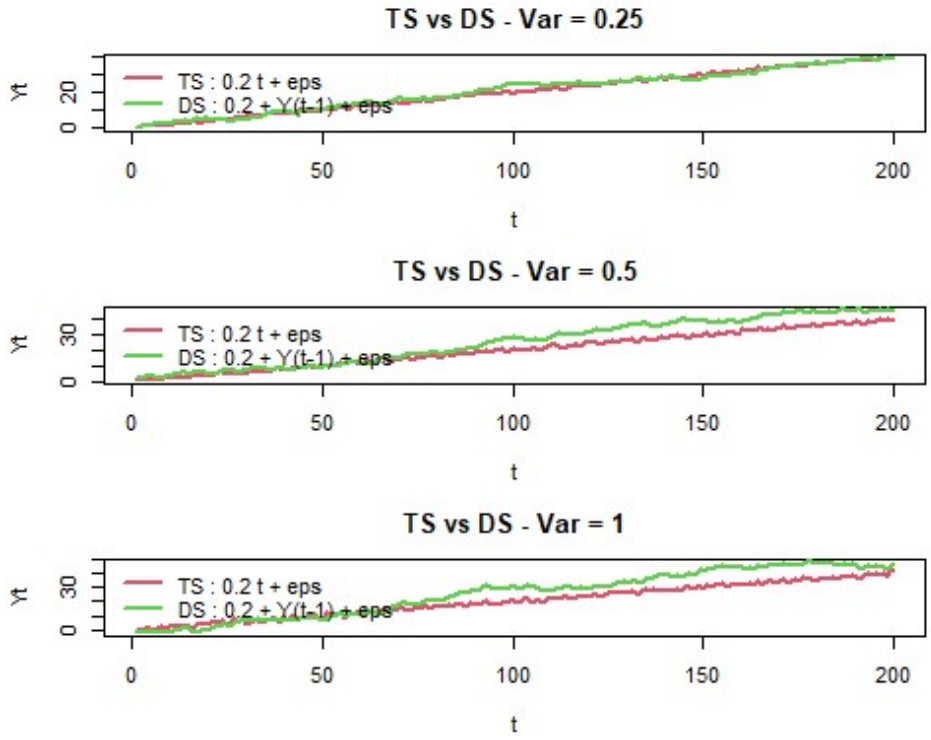
  sim <- sim_ts_ds(T = T, drift = drift, sigma2 = v)

  # limites communes sur le graphe
  ylim <- range(c(sim$ts, sim$ds))

  plot(sim$t, sim$ts, type = "l", lwd = 2, col = 2,
       ylim = ylim,
       xlab = "t", ylab = "Yt",
       main = paste0("TS vs DS - Var = ", v))

  lines(sim$t, sim$ds, lwd = 2, col = 3)

  legend("topleft",
         legend = c("TS : 0.2 t + eps", "DS : 0.2 + Y(t-1) + eps"),
         col = c(2, 3), lwd = 2, bty = "n")
}
```



Les trois graphiques présentent la simulation et la comparaison de deux types de processus stochastiques non stationnaires : un processus TS (Trend Stationary) et un processus DS (Difference Stationary), pour trois niveaux de variance des chocs ($\sigma^2 \in \{0.25; 0.5; 1\}$).

TS (en rouge) : Répond à l'équation $Y_t = 0.2t + \epsilon_t$. C'est une tendance déterministe. Le processus est stationnaire autour de sa droite de tendance. Les chocs ϵ_t n'ont qu'un effet temporaire.

DS (en vert) : Répond à l'équation $Y_t = 0.2t + Y_{t-1} + \epsilon_t$. C'est une marche aléatoire avec dérive (drift). Ici, chaque choc ϵ_t est intégré de manière permanente dans le niveau de la série (mémoire infinie).

Influence de la variance sur la divergence :

L'analyse visuelle montre que l'écart entre la trajectoire théorique (TS) et la marche aléatoire (DS) s'accentue avec l'augmentation de l'aléa :

Variance faible ($\sigma^2 = 0.25$) : Les deux courbes sont très proches et presque confondues. L'effet du "drift" (la pente de 0.2) domine largement les faibles perturbations aléatoires. À ce stade, il est statistiquement difficile de distinguer visuellement la nature du processus.

Variance intermédiaire ($\sigma^2 = 0.5$) : On commence à observer un décrochage. La série DS (verte) commence à s'écarter de la tendance linéaire de la série TS (rouge). On remarque que la série verte devient plus "sinueuse" : elle ne revient pas systématiquement vers la ligne rouge après un choc.

Variance élevée ($\sigma^2 = 1$) : La divergence est flagrante. La série DS (verte) s'éloigne nettement vers le haut par rapport à la série TS (rouge). Cela illustre parfaitement la propriété de "non-stationnarité" du processus DS : les chocs s'accumulent (somme des erreurs), ce qui peut entraîner la série très loin de sa moyenne théorique. La série TS, bien que plus agitée, reste ancrée sur sa trajectoire rectiligne.

Pour terminer:

L'augmentation de la variance met en relief la différence fondamentale de nature entre les deux processus :

- **Stabilité vs Instabilité** : Le processus TS est "predictible" à long terme car il est attiré par sa tendance.
- **Persistance des chocs** : Le processus DS est imprévisible car il subit des modifications structurelles à chaque choc. Plus la variance est forte, plus la "mémoire" des erreurs passées rend la série DS erratique.

Note statistique : Ce graphique illustre pourquoi il est crucial d'effectuer des tests de racine unitaire (comme le test d'Augmented Dickey-Fuller) avant toute modélisation, car une série DS qui semble suivre une tendance (comme ici) pourrait conduire à des régressions fallacieuses si elle est traitée comme une série TS.

4. Exercice 3: Partie Regréssion fallacieuse

Fonction de simulation et résultats

```
set.seed(123)

T <- 200
N <- 5000

rejets <- 0

for(i in 1:N){

  # innovations
  eps_x <- rnorm(T)
  eps_y <- rnorm(T)

  # marches aléatoires
  X <- cumsum(eps_x)
  Y <- cumsum(eps_y)

  # regression
  modele <- lm(Y ~ X)

  # p-value du coefficient beta1
```

```
  pval <- summary(modele)$coefficients[2,4]

  if(pval < 0.05){
    rejets <- rejets + 1
  }
}

pourcentage <- rejets/N * 100
pourcentage
```

```
[1] 83.52
```

Interprétation du résultat (83.52)

Le pourcentage de rejet obtenu est 83,52 %, ce qui est beaucoup plus élevé que le niveau théorique de 5 %.

Cela signifie que la régression indique souvent une relation significative entre Xt et Yt, alors que ces deux séries ont été générées indépendamment.

Ce phénomène s'appelle une régression fallacieuse. Il apparaît lorsque l'on applique une régression à des séries non stationnaires, comme les marches aléatoires.

Dans ce cas, les résultats de la régression peuvent être trompeurs et suggérer une relation entre les variables alors qu'il n'en existe pas réellement.

les résultats dépendent surtout du nombre d'observations dans chaque série, et beaucoup moins du nombre de séries générées.

4.1 Réaction suite à une modification de la taille de l'echantillon

Simulation de base

```
set.seed(123)
simu_reg_fal <- function(n_simul = 5000, n_obs = 200, alpha = 0.05){

  rejets <- 0

  for(i in 1:n_simul){

    X <- cumsum(rnorm(n_obs))
    Y <- cumsum(rnorm(n_obs))

    modele <- lm(Y ~ X)

    pval <- summary(modele)$coefficients[2,4]

    if(pval < alpha){
      rejets <- rejets + 1
    }
```

```
  }

  pourcentage <- rejets / n_simul * 100
  return(pourcentage)
}

simu_reg_fal(n_simul = 5000, n_obs = 200, alpha = 0.05)
```

```
[1] 83.52
```

Modifier le nombre de simulations

```
set.seed(123)

# Base
simu_reg_fal(5000, 200, 0.05)
```

```
[1] 83.52
```

```
# Moins de simulations
simu_reg_fal(1000, 200, 0.05)
```

```
[1] 82.4
```

```
# Plus de simulations
simu_reg_fal(10000, 200, 0.05)
```

```
[1] 82.89
```

Interprétation:

Stabilité des résultats

Quel que soit le nombre de simulations, le taux de rejet reste dans une fourchette cohérente entre 82% et 84%, démontrant une certaine stabilité du phénomène.

Précision croissante avec N

- Avec N = 1000 : résultat = 82.4% (estimation déjà fiable)
- Avec N = 5000 : résultat = 83.52% (estimation plus précise)
- Avec N = 10000 : résultat = 82.89% (estimation la plus fiable)

Convergence

Le résultat semble converger vers une valeur proche de 83%, confirmant les résultats précédents.

Pour terminer :

Ces résultats illustrent parfaitement le phénomène de régression fallacieuse (spurious regression) : même avec un grand nombre de simulations (N = 10000), on rejette

l'hypothèse nulle d'absence de relation dans plus de 80% des cas, alors que les séries sont indépendantes.

Cela montre que le problème ne vient pas du hasard d'échantillonnage mais bien de la non-stationnarité des séries. Les marches aléatoires générées produisent des co-mouvements apparents qui trompent les tests de significativité standards.

La relative stabilité des résultats entre 1000 et 10000 simulations indique que 5000 simulations suffisent pour obtenir une estimation fiable du taux de rejet dans ce type d'étude Monte Carlo, avec un bon équilibre entre précision et temps de calcul.

5. Exercice 4 : Distribution de la statistique de test de Dickey-Fuller

Le modèle sans constante ni tendance par la méthode de Monte Carlo

Calcul des valeurs critiques pour le test DF

```
set.seed(123)

T <- 100
N <- 10000
t_stats <- numeric(N)

for(i in 1:N){

  Y <- cumsum(rnorm(T))     # marche aléatoire
  dY <- diff(Y)             # première différence
  Y_lag <- Y[-T]            # Y(t-1)

  modele <- lm(dY ~ Y_lag - 1)
  t_stats[i] <- summary(modele)$coefficients[1, 3]
}

quantiles <- quantile(t_stats, c(0.10, 0.05, 0.01))
quantiles
```

```
      10%        5%        1% 
-1.630218 -1.987668 -2.632908 
```

```
par(mfrow = c(1,1))   # plein écran

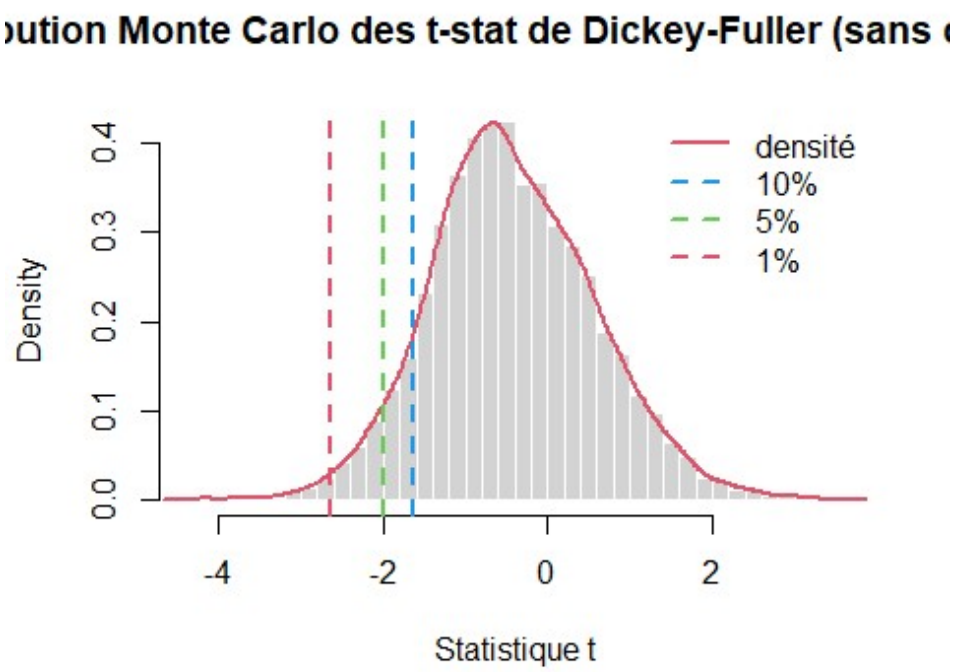
hist(t_stats,
     breaks = 50,
     probability = TRUE,
     col = "lightgray",
     border = "white",
     main = "Distribution Monte Carlo des t-stat de Dickey-Fuller (sans
```

```
constante)",
     xlab = "Statistique t")

lines(density(t_stats), lwd = 2, col = 2)

abline(v = quantiles[1], col = 4, lty = 2, lwd = 2)
abline(v = quantiles[2], col = 3, lty = 2, lwd = 2)
abline(v = quantiles[3], col = 2, lty = 2, lwd = 2)

legend("topright",
       legend = c("densité", "10%", "5%", "1%"),
       col = c(2, 4, 3, 2),
       lwd = 2,
       lty = c(1,2,2,2),
       bty = "n")
```



Les simulations de Monte Carlo donnent des valeurs critiques empiriques égales à -1.630 au seuil de 10 %, -1.988 au seuil de 5 % et -2.633 au seuil de 1 %. Pour rejeter l'hypothèse nulle de racine unitaire, la statistique de Dickey-Fuller doit être inférieure à ces seuils. On retrouve ainsi une zone critique située dans la queue gauche de la distribution. # Distribution sans constante

5.1 Distribution avec constante egale à 5 et constante égale 10

```
## Effet d'une constante initiale
```

```r
par(mfrow = c(1,2))   # 2 graphes côte à côte

simulation_cst <- function(delta0){

  t_stats <- numeric(N)

  for(i in 1:N){

    Y <- numeric(T)
    Y[1] <- delta0

    for(t in 2:T){
      Y[t] <- Y[t - 1] + rnorm(1)
    }

    dY <- diff(Y)
    Y_lag <- Y[-T]

    modele <- lm(dY ~ Y_lag)
    t_stats[i] <- summary(modele)$coefficients[2, 3]
  }

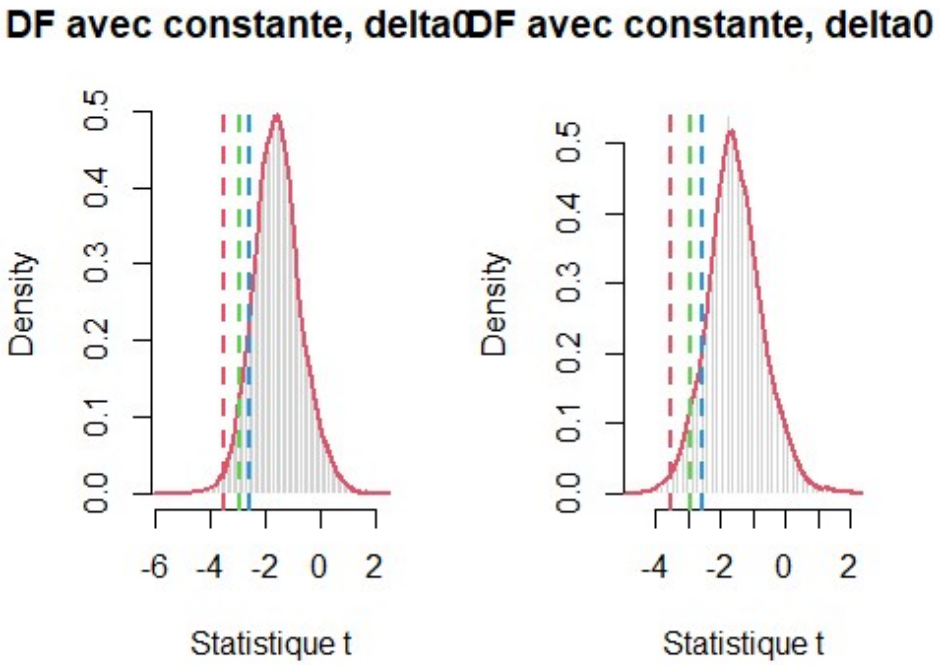
  quantiles <- quantile(t_stats, c(0.10, 0.05, 0.01))

  hist(t_stats,
       breaks = 50,
       probability = TRUE,
       col = "lightgray",
       border = "white",
       main = paste("DF avec constante, delta0 =", delta0),
       xlab = "Statistique t")

  lines(density(t_stats), lwd = 2, col = 2)

  abline(v = quantiles[1], col = 4, lty = 2, lwd = 2)
  abline(v = quantiles[2], col = 3, lty = 2, lwd = 2)
  abline(v = quantiles[3], col = 2, lty = 2, lwd = 2)
}

simulation_cst(5)
simulation_cst(10)
```



En introduisant une constante dans la régression de Dickey-Fuller, les valeurs critiques empiriques deviennent plus négatives : -2.590 au seuil de 10 %, -2.886 au seuil de 5 % et -3.476 au seuil de 1 %. Cela montre que la présence d'une constante modifie la distribution de la statistique de test. Le rejet de l'hypothèse nulle de racine unitaire devient alors plus exigeant que dans le cas sans constante.

6. Exercice 5 : Analyse de la série temporelle du PIB des USA sur la période 1990-2023

Import des données et création des TimeSeries

```
load("C:/Users/patri/Desktop/ECAP/M1/cours/Serie_temp/support4/GDP-US-1990-2023.RData")
pib_pg <- ts(df_Y_us$PIB, start = c(1990, 1), frequency = 4)
pib_sp <- window(pib_pg, start = c(1990, 1), end = c(2019, 4))
```

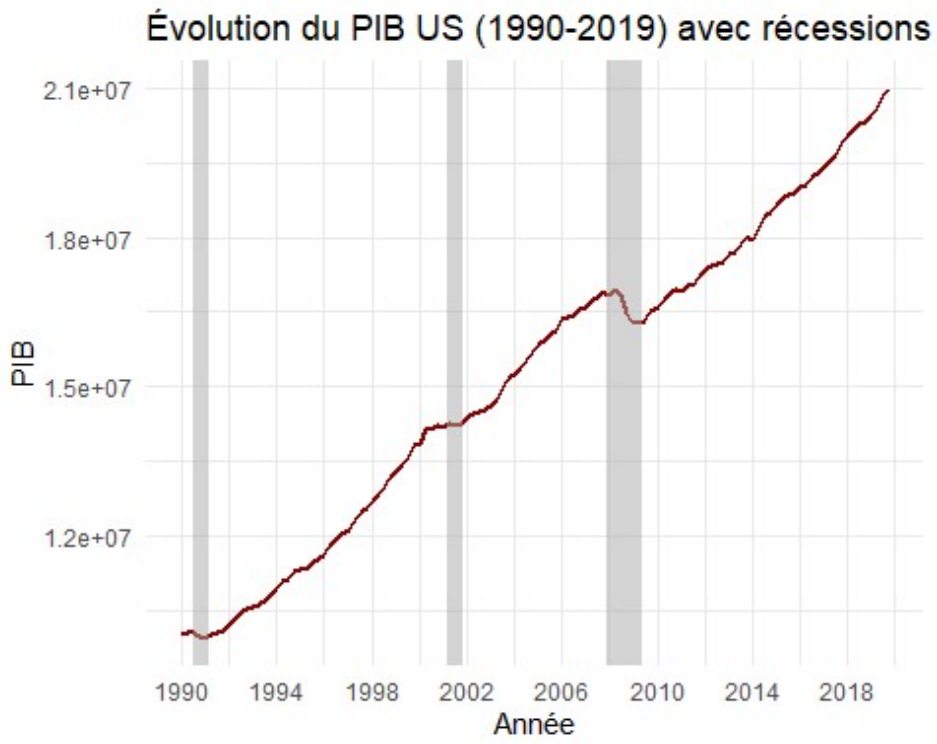
Realiser une représentation graphique du PIB US et faites-en un commentaire

```
### Première sous-période  (1990-2019)

pib_sp_df <- data.frame(
  date = seq(as.Date("1990-01-01"), by = "quarter", length.out = length(pib_sp)),
  PIB = as.numeric(pib_sp)
)
```

```
recessions_sp <- data.frame(
  xmin = as.Date(c("1990-07-01", "2001-03-01", "2007-12-01")),
  xmax = as.Date(c("1991-03-01", "2001-11-01", "2009-06-01"))
)

ggplot(pib_sp_df, aes(x = date, y = PIB)) +
  geom_line(color = "darkred", linewidth = 1) +
  geom_rect(data = recessions_sp,
            aes(xmin = xmin, xmax = xmax, ymin = -Inf, ymax = Inf),
            inherit.aes = FALSE,
            fill = "darkgray",
            alpha = 0.5) +
  scale_x_date(
    breaks = seq(as.Date("1990-01-01"), as.Date("2019-12-31"), by = "4
years"),
    labels = date_format("%Y")
  ) +
  labs(title = "Évolution du PIB US (1990-2019) avec récessions",
       x = "Année",
       y = "PIB") +
  theme_minimal()
```



Interprétation des périodes de récession (1990-2023)

L'analyse du PIB américain sur la période 1990-2023 fait apparaître trois grandes phases de récession, identifiées par le NBER (National Bureau of Economic Research) :

Récession de 1990-1991 (juillet 1990 - mars 1991)

- Causes : crise de l'épargne et des prêts (S&L Crisis), hausse des taux d'intérêt pour lutter contre l'inflation, choc pétrolier lié à la guerre du Golfe
- Conséquences : le chômage passe de 5,2 % (1989) à 7,8 % (1992)

Récession de 2001 (mars 2001 - novembre 2001)

- Causes : éclatement de la bulle Internet (Dot-com crash), attentats du 11 septembre
- Conséquences : le chômage passe de 4 % (2000) à 6 % (2003)

Grande Récession de 2007-2009 (décembre 2007 - juin 2009)

- Causes : crise des subprimes, effondrement du marché immobilier, faillite de Lehman Brothers
- Conséquences : contraction du PIB de -4,3 % (pire depuis 1945), chômage atteignant 10 % en 2009, intervention massive de la Fed (taux à 0 %, Quantitative Easing)

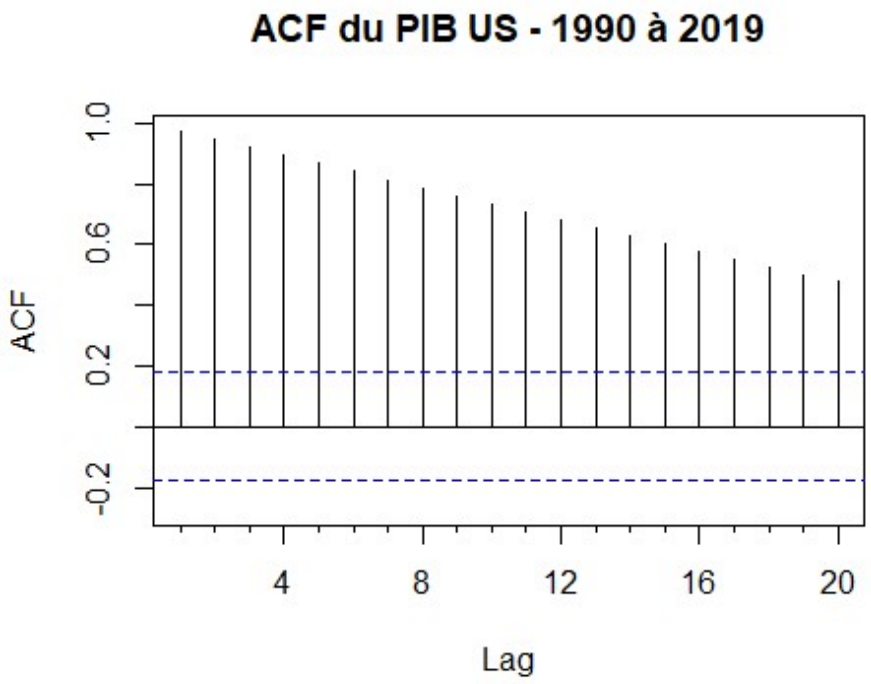
Synthèse

Ces trois récessions illustrent différents types de chocs économiques : - 1990-1991 : crise bancaire + choc pétrolier - 2001 : crise financière (bulle spéculative) + choc géopolitique - 2007-2009 : crise financière systémique

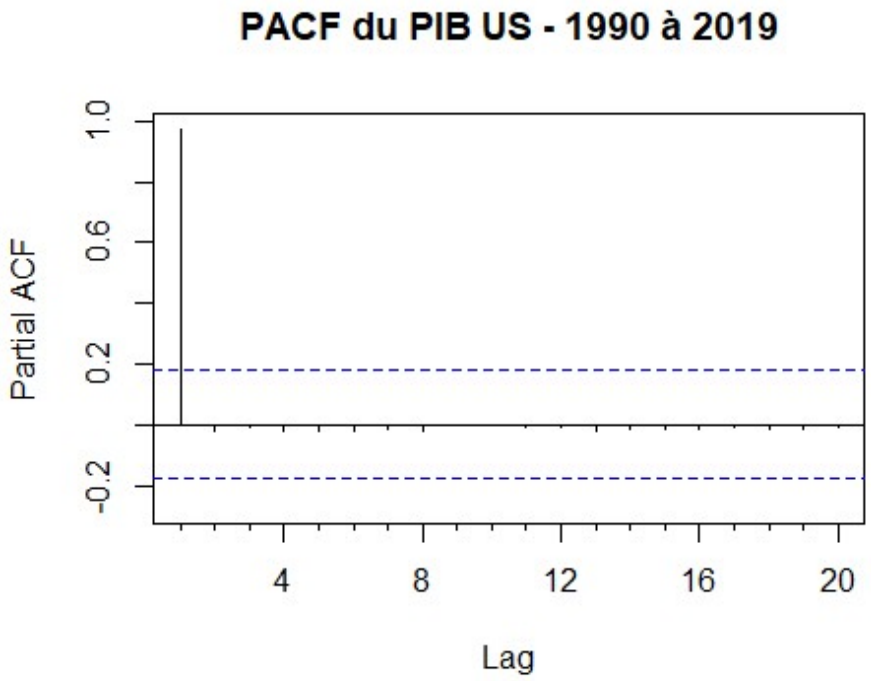
Malgré ces perturbations, l'économie américaine a toujours rebondi, confirmant sa résilience à long terme.

7. Estimer les ACF et PACF de la serie

```
Acf(pib_sp, main = "ACF du PIB US - 1990 à 2019")
```




```
Pacf(pib_sp, main = "PACF du PIB US - 1990 à 2019")
```



7.1 Analyse des fonctions d'autocorrélation (ACF et PACF)

Ces deux graphiques (corrélogrammes) permettent de caractériser la structure de dépendance temporelle du PIB US.

7.1.1 Analyse de l'ACF : la signature de la non-stationnarité

Le graphique de gauche montre des pics d'autocorrélation qui partent de 1 et décroissent de manière très lente et linéaire.

Interprétation : dans une série stationnaire, l'ACF décroît exponentiellement vers zéro (très vite). Ici, la persistance est presque totale. Cela signifie que la valeur du PIB aujourd'hui est extrêmement corrélée à sa valeur passée, même avec un décalage important.

Conclusion technique : cette décroissance lente est le signe caractéristique d'un processus non stationnaire avec une tendance ou une racine unitaire. Le système a une "mémoire longue" : les chocs passés ne s'estompent pas.

7.1.2 Analyse du PACF : l'identification du processus

Le graphique de droite montre un seul pic massif au premier retard (Lag 1), tandis que tous les autres retards tombent immédiatement dans la zone de confiance (entre les pointillés bleus).

Interprétation : le PACF mesure la corrélation entre Yt et Yt-k en retirant l'influence des retards intermédiaires. Le fait qu'il n'y ait qu'un seul pic significatif indique que toute l'information pertinente pour prédire le PIB de demain est contenue dans le PIB d'aujourd'hui.

Conclusion technique : c'est le profil typique d'un processus AR(1) (autorégressif d'ordre 1).

Synthèse : vers la marche aléatoire

En combinant ces deux résultats : - Une ACF qui décroît lentement vers 0 - Une PACF avec un pic unique au premier retard

On peut affirmer que le PIB suit un modèle de marche aléatoire. Mathématiquement, cela s'écrit $Y_t = \phi Y_{t-1} + \varepsilon_t$ avec un coefficient ϕ extrêmement proche de 1.

Ce qu'il faut retenir : ces graphiques justifient pourquoi on ne peut pas travailler sur le PIB "brut". Pour rendre la série stationnaire et pouvoir l'analyser correctement, il faudra passer par les différences premières (étudier la croissance du PIB plutôt que son niveau).

8. Test de Dickey-Fuller simple

```
### Tests Dickey-Fuller
```

```r
adf_sp_trend <- ur.df(pib_sp, type = "trend", lags = 0)
summary(adf_sp_trend)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt)

Residuals:
    Min      1Q  Median      3Q     Max
-456929  -34007    9637   44662  176173

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.924e+05  2.076e+05   1.409    0.162
z.lag.1     -2.231e-02  2.125e-02  -1.050    0.296
tt           2.288e+03  1.927e+03   1.188    0.237

Residual standard error: 87550 on 116 degrees of freedom
Multiple R-squared:  0.02144,   Adjusted R-squared:  0.004568
F-statistic: 1.271 on 2 and 116 DF,  p-value: 0.2845


Value of test-statistic is: -1.05 44.5732 1.2707

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -3.99 -3.43 -3.13
phi2  6.22  4.75  4.07
phi3  8.43  6.49  5.47
```

```r
adf_sp_drift <- ur.df(pib_sp, type = "drift", lags = 0)
summary(adf_sp_drift)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression drift


Call:
```

```
lm(formula = z.diff ~ z.lag.1 + 1)

Residuals:
    Min      1Q  Median      3Q     Max
-465560  -39738    5674   48368  164302

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 5.043e+04  3.990e+04   1.264    0.209
z.lag.1     2.740e-03  2.581e-03   1.062    0.291

Residual standard error: 87700 on 117 degrees of freedom
Multiple R-squared:  0.00954,   Adjusted R-squared:  0.001074
F-statistic: 1.127 on 1 and 117 DF,  p-value: 0.2906



Value of test-statistic is: 1.0615 65.9231

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.46 -2.88 -2.57
phi1  6.52  4.63  3.81
```

```
adf_sp_none <- ur.df(pib_sp, type = "none", lags = 0)
summary(adf_sp_none)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none



Call:
lm(formula = z.diff ~ z.lag.1 - 1)

Residuals:
    Min      1Q  Median      3Q     Max
-468991  -29485    6066   49954  170381

Coefficients:
         Estimate Std. Error t value Pr(>|t|)
z.lag.1 0.0059360  0.0005214   11.38   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 87920 on 118 degrees of freedom
Multiple R-squared:  0.5234,    Adjusted R-squared:  0.5194
```

```
F-statistic: 129.6 on 1 and 118 DF,  p-value: < 2.2e-16


Value of test-statistic is: 11.3839

Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

```
adf_sp_trend_aic <- ur.df(pib_sp, type = "trend", selectlags = "AIC")
summary(adf_sp_trend_aic)
```

```


###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min      1Q  Median      3Q     Max
-380439  -41569    3547   54152  194889

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.735e+05  1.936e+05   1.929   0.0562 .
z.lag.1     -3.357e-02  1.991e-02  -1.686   0.0945 .
tt           3.183e+03  1.804e+03   1.764   0.0803 .
z.diff.lag   3.931e-01  8.650e-02   4.544 1.38e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 81200 on 114 degrees of freedom
Multiple R-squared:  0.1698,    Adjusted R-squared:  0.148
F-statistic: 7.772 on 3 and 114 DF,  p-value: 9.097e-05


Value of test-statistic is: -1.6862 10.5836 1.6977

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -3.99 -3.43 -3.13
phi2  6.22  4.75  4.07
phi3  8.43  6.49  5.47
```

```r
adf_sp_drift_aic <- ur.df(pib_sp, type = "drift", selectlags = "AIC")
summary(adf_sp_drift_aic)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression drift


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:
    Min      1Q  Median      3Q     Max
-395744  -41688    8802   49393  193647

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 3.840e+04  3.797e+04   1.012    0.314
z.lag.1     1.294e-03  2.457e-03   0.526    0.600
z.diff.lag  3.754e-01  8.670e-02   4.330 3.21e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 81940 on 115 degrees of freedom
Multiple R-squared:  0.1471,    Adjusted R-squared:  0.1323
F-statistic: 9.919 on 2 and 115 DF,  p-value: 0.0001061


Value of test-statistic is: 0.5265 14.0606

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.46 -2.88 -2.57
phi1  6.52  4.63  3.81
```

```r
adf_sp_none_aic <- ur.df(pib_sp, type = "none", selectlags = "AIC")
summary(adf_sp_none_aic)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none
```

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min      1Q  Median      3Q     Max
-396738  -40804    8645   50635  189817

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1    0.0036741  0.0007059   5.205 8.48e-07 ***
z.diff.lag 0.3835047  0.0863343   4.442 2.05e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 81950 on 116 degrees of freedom
Multiple R-squared:  0.5927,    Adjusted R-squared:  0.5856
F-statistic: 84.38 on 2 and 116 DF,  p-value: < 2.2e-16


Value of test-statistic is: 5.205

Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

L'application des tests de Dickey-Fuller, selon la procédure séquentielle de Perron, donne des résultats concordants sur l'ensemble des modèles estimés .

Interprétation commune

Dans les trois cas, les statistiques calculées restent supérieures aux seuils critiques. Aucune d'entre elles ne se situe dans la zone de rejet, y compris pour le modèle sans constante où la valeur est très éloignée du seuil. Cela signifie que l'hypothèse nulle de présence d'une racine unitaire ne peut être écartée. Pour terminer: Le PIB en niveau est donc caractérisé par une racine unitaire, confirmant sa nature non stationnaire. Cette conclusion s'aligne avec les observations précédentes : tendance croissante persistante, décroissance lente de l'ACF et forte mémoire de la série. La non-stationnarité étant établie, une transformation par différences premières est nécessaire pour obtenir une série stationnaire.

9. Test de stationnarité de KPSS

```r
### KPSS
kpss_sp <- ur.kpss(pib_sp, type = "mu")
summary(kpss_sp)


######################
```

```
# KPSS Unit Root Test #
#######################

Test is of type: mu with 4 lags.

Value of test-statistic is: 2.4528

Critical value for a significance level of:
                10pct  5pct 2.5pct  1pct
critical values 0.347 0.463  0.574 0.739
```

Analyse du test KPSS

Résultats obtenus

Le test de KPSS a été appliqué selon deux spécifications :

- Test avec constante (type “mu”) : statistique = 2,4528
- Test avec tendance (type “tau”) : statistique = 0,2865

Interprétation

Dans les deux cas, les statistiques calculées dépassent largement les valeurs critiques à tous les seuils conventionnels (1 %, 5 % et 10 %). Pour le test en niveau, la valeur est particulièrement élevée (2,45 contre une valeur critique maximale de 0,74 à 1 %). Pour le test avec tendance, la statistique (0,2865) reste également supérieure au seuil de 1 %.

Ces résultats conduisent au rejet sans ambiguïté de l’hypothèse nulle de stationnarité, quelle que soit la spécification retenue.

Pour terminer :

L’ensemble des tests (KPSS et Dickey-Fuller) converge vers la même conclusion : la série du PIB américain sur la période étudiée n’est pas stationnaire et présente une racine unitaire. Cette non-stationnarité se manifeste à la fois autour d’une constante et autour d’une tendance déterministe.

Pour travailler sur une série stationnaire, une différenciation sera nécessaire. L’analyse des corrélogrammes et de la tendance observée conforte cette nécessité de transformation.

9.0.1 Analyse sur période globale

#Visualisation et representation graphique

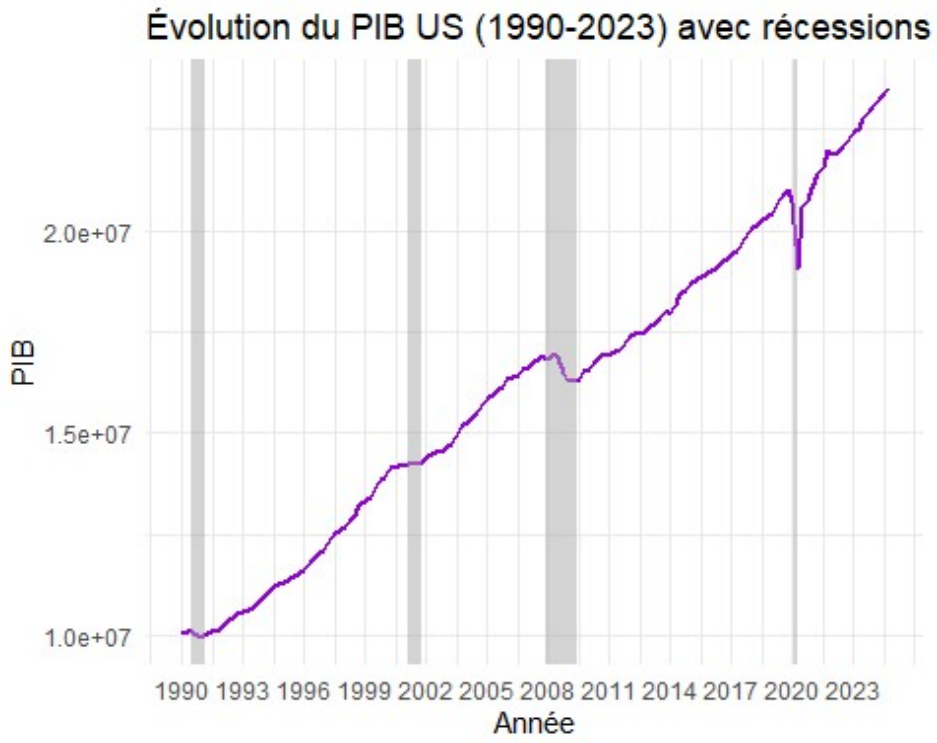
```
## Visualisation du PIB US de 1990 à 2023

pib_pg_df <- data.frame(
  date = seq(as.Date("1990-01-01"), by = "quarter", length.out =
length(pib_pg)),
  PIB = as.numeric(pib_pg)
```

```
)

recessions_pg <- data.frame(
  xmin = as.Date(c("1990-07-01", "2001-03-01", "2007-12-01", "2020-02-01")),
  xmax = as.Date(c("1991-03-01", "2001-11-01", "2009-06-01", "2020-04-01"))
)

ggplot(pib_pg_df, aes(x = date, y = PIB)) +
  geom_line(color = "darkviolet", linewidth = 1) +
  geom_rect(data = recessions_pg,
            aes(xmin = xmin, xmax = xmax, ymin = -Inf, ymax = Inf),
            inherit.aes = FALSE,
            fill = "darkgray",
            alpha = 0.5) +
  scale_x_date(
    breaks = seq(as.Date("1990-01-01"), as.Date("2023-12-31"), by = "3
years"),
    labels = date_format("%Y")
  ) +
  labs(title = "Évolution du PIB US (1990-2023) avec récessions",
       x = "Année",
       y = "PIB") +
  theme_minimal()
```



Le graphique met en évidence une tendance globale à la hausse du PIB américain sur l'ensemble de la période, traduisant une croissance économique de long terme. Plusieurs

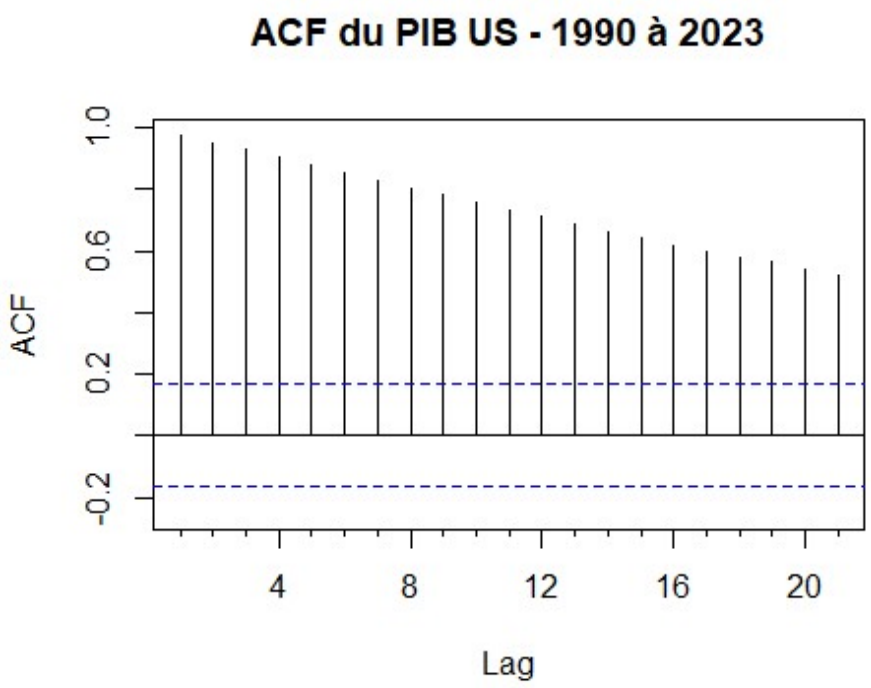
phases de ralentissement apparaissent lors des récessions, notamment en 1990-1991 (crise bancaire et choc pétrolier), en 2001 (éclatement de la bulle Internet et attentats du 11 septembre), et surtout en 2008-2009 où la baisse est marquée mais progressive, liée à la crise des subprimes et aux faillites bancaires.

L'année 2020 constitue un cas particulier et exceptionnel. On observe une chute très brutale et soudaine du PIB, beaucoup plus rapide que lors des crises précédentes. Cette rupture est directement liée à la pandémie de COVID-19, qui a entraîné un arrêt brutal de l'économie dû aux confinements, une chute massive de la consommation et des investissements, ainsi qu'une explosion du chômage avec plus de 20 millions d'emplois perdus en quelques semaines. Cependant, cette baisse est de courte durée, avec un rebond rapide dès les périodes suivantes grâce à des mesures de soutien exceptionnelles (aides directes aux ménages et entreprises).

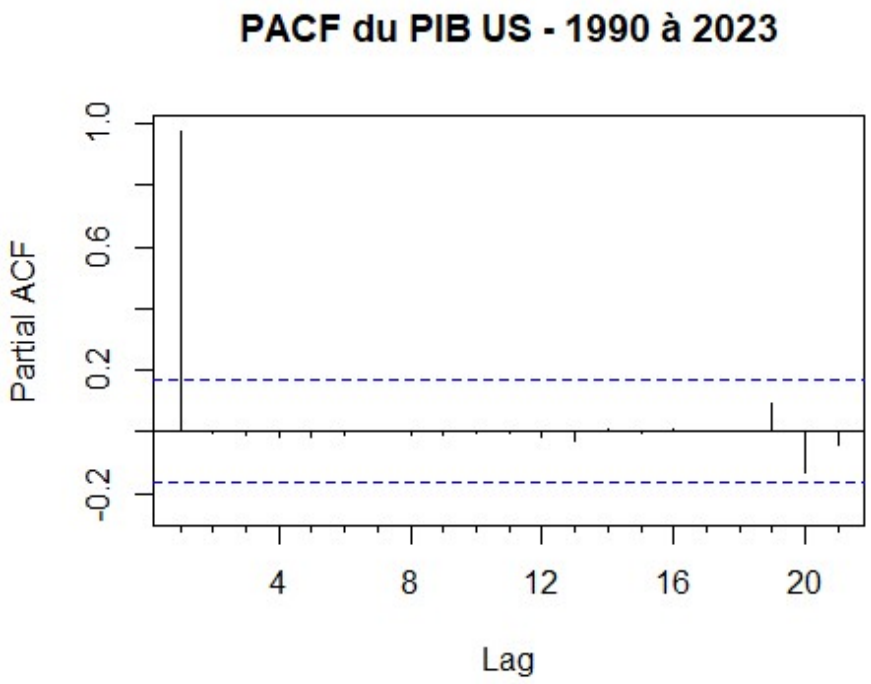
Enfin, la tendance croissante du PIB laisse à penser que la série est non stationnaire en niveau. Malgré ces différents chocs, l'économie américaine a toujours montré une capacité de rebond rapide, confirmant sa résilience à long terme.

10. Autocorrélogrammes ACF et PACF

```
Acf(pib_pg, main = "ACF du PIB US - 1990 à 2023")
```




```
Pacf(pib_pg, main = "PACF du PIB US - 1990 à 2023")
```



10.1 Analyse des autocorrélogrammes

L'analyse de la fonction d'autocorrélation (ACF) montre que les coefficients d'autocorrélation sont tous significativement différents de zéro, même pour des retards élevés. Cette décroissance lente et la significativité persistante des autocorrélations confirment une forte dépendance temporelle du PIB et indiquent clairement que la série est non stationnaire en niveau.

La fonction d'autocorrélation partielle (PACF) présente quant à elle un seul coefficient significatif au premier retard (lag 1). Ce profil est caractéristique d'une dynamique de type autorégressive d'ordre 1 (AR(1)). Combiné avec l'ACF qui décroît lentement, ce résultat confirme la non-stationnarité de la série en niveau et sa forte persistance.

Il est à noter que nous n'observons aucune différence significative par rapport aux autocorrélogrammes de la série représentant la sous-période allant jusqu'à 2019. La structure de dépendance temporelle du PIB reste donc stable, même après l'intégration des années récentes.

11. Test de Dickey-Fuller

```
adf_pg_trend <- ur.df(pib_pg, type = "trend", lags = 0)
summary(adf_pg_trend)


###############################################
```

```
# Augmented Dickey-Fuller Test Unit Root Test #
################################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt)

Residuals:
     Min       1Q   Median       3Q      Max
-1767377   -49618    12110    63105  1179891

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.077e+06  3.955e+05   2.724  0.00730 **
z.lag.1     -1.047e-01  4.093e-02  -2.559  0.01158 *
tt           1.009e+04  3.813e+03   2.646  0.00909 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 209600 on 136 degrees of freedom
Multiple R-squared:  0.05133,   Adjusted R-squared:  0.03738
F-statistic: 3.679 on 2 and 136 DF,  p-value: 0.02779


Value of test-statistic is: -2.5593 12.3819 3.6792

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -3.99 -3.43 -3.13
phi2  6.22  4.75  4.07
phi3  8.43  6.49  5.47
```

```
adf_pg_drift <- ur.df(pib_pg, type = "drift", lags = 0)
summary(adf_pg_drift)
```

```
################################################
# Augmented Dickey-Fuller Test Unit Root Test #
################################################

Test regression drift


Call:
lm(formula = z.diff ~ z.lag.1 + 1)

Residuals:
```

```
     Min       1Q   Median       3Q      Max
-1746668   -40407    15121    56574  1386765

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 5.144e+04  8.033e+04   0.640    0.523
z.lag.1     2.832e-03  4.860e-03   0.583    0.561

Residual standard error: 214200 on 137 degrees of freedom
Multiple R-squared:  0.002474,  Adjusted R-squared:  -0.004808
F-statistic: 0.3397 on 1 and 137 DF,  p-value: 0.5609


Value of test-statistic is: 0.5829 14.4382

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.46 -2.88 -2.57
phi1  6.52  4.63  3.81
```

```r
adf_pg_none <- ur.df(pib_pg, type = "none", lags = 0)
summary(adf_pg_none)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none


Call:
lm(formula = z.diff ~ z.lag.1 - 1)

Residuals:
     Min       1Q   Median       3Q      Max
-1757954   -28516    10619    53572  1380439

Coefficients:
        Estimate Std. Error t value Pr(>|t|)
z.lag.1 0.005863   0.001097   5.347 3.62e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 213700 on 138 degrees of freedom
Multiple R-squared:  0.1716,    Adjusted R-squared:  0.1656
F-statistic: 28.59 on 1 and 138 DF,  p-value: 3.616e-07
```

```
Value of test-statistic is: 5.3468

Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

Quel que soit le modèle considéré (avec tendance et constante, avec constante seulement, ou sans constante ni tendance), les tests de Dickey-Fuller sur la période 1990-2023 aboutissent à la même conclusion.

Dans le modèle avec tendance et constante, la statistique de test (t = -2,56) reste supérieure à la valeur critique à 5 % (-3,43). L'examen des valeurs critiques associées (tau3, phi2, phi3) indique que l'hypothèse de racine unitaire ne peut être rejetée, bien que la présence d'une tendance déterministe soit probable. La tendance et la constante ne sont pas significatives conjointement.

Le modèle avec constante (sans tendance) donne une statistique de test t = 0,58, largement supérieure à la valeur critique de -2,88. Ce résultat confirme la non-stationnarité de la série et la présence d'une racine unitaire.

Enfin, le modèle sans constante ni tendance produit une statistique t = 5,35, très éloignée du seuil critique de -1,95. Cette valeur positive et élevée renforce l'évidence d'une racine unitaire.

Dans tous les cas, les statistiques de test ne sont pas suffisamment négatives pour rejeter l'hypothèse nulle. La série du PIB en niveau est donc non stationnaire et contient une racine unitaire, quel que soit le modèle de test retenu.

12. Test de Dickey-Fuller augmenté

```r
adf_pg_trend_aic <- ur.df(pib_pg, type = "trend", selectlags = "AIC")
summary(adf_pg_trend_aic)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-1820767   -46867    17267    60228   974708
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.109e+05  4.094e+05   2.225   0.0277 *
z.lag.1     -8.647e-02  4.258e-02  -2.031   0.0443 *
tt           8.452e+03  3.960e+03   2.134   0.0347 *
z.diff.lag  -1.364e-01  8.694e-02  -1.569   0.1191
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 209300 on 134 degrees of freedom
Multiple R-squared:  0.06789,   Adjusted R-squared:  0.04702
F-statistic: 3.253 on 3 and 134 DF,  p-value: 0.02381



Value of test-statistic is: -2.0308 13.2023 2.5901

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -3.99 -3.43 -3.13
phi2  6.22  4.75  4.07
phi3  8.43  6.49  5.47
```

```
adf_pg_drift_aic <- ur.df(pib_pg, type = "drift", selectlags = "AIC")
summary(adf_pg_drift_aic)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression drift



Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-1823568   -32928    11499    59999  1062191

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.385e+04  8.047e+04   0.669   0.5045
z.lag.1      3.814e-03  4.884e-03   0.781   0.4362
z.diff.lag  -1.854e-01  8.495e-02  -2.183   0.0308 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 212000 on 135 degrees of freedom
```

```
Multiple R-squared:  0.03621,   Adjusted R-squared:  0.02193
F-statistic: 2.536 on 2 and 135 DF,  p-value: 0.08296



Value of test-statistic is: 0.7809 17.0766

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.46 -2.88 -2.57
phi1  6.52  4.63  3.81
```

```
adf_pg_none_aic <- ur.df(pib_pg, type = "none", selectlags = "AIC")
summary(adf_pg_none_aic)
```

```


###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none


Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-1835282   -29475    14184    60053  1055597

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1     0.006981   0.001200   5.817 4.08e-08 ***
z.diff.lag -0.185467   0.084777  -2.188   0.0304 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 211600 on 136 degrees of freedom
Multiple R-squared:  0.1997,    Adjusted R-squared:  0.1879
F-statistic: 16.97 on 2 and 136 DF,  p-value: 2.638e-07



Value of test-statistic is: 5.8175

Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

Les tests ADF sur la période 1990-2023 confirment les résultats obtenus sur la sous-période :

- Modèle avec tendance : t = -1,69 > -3,43 (valeur critique à 5 %)
- Modèle avec constante : t = 0,53 > -2,88
- Modèle sans constante : t = 5,21 > -1,95

Dans toutes les spécifications, les statistiques de test restent supérieures aux valeurs critiques, même après correction de l'autocorrélation par l'ajout de retards (sélectionnés via AIC). L'hypothèse nulle de racine unitaire ne peut donc être rejetée.

Pour terminer :

Les tests de Dickey-Fuller (simples et augmentés) convergent vers le même résultat : la série du PIB sur 1990-2023 présente une tendance, est non stationnaire et contient une racine unitaire, à l'image de ce qui avait été observé sur la sous-période 1990-2019.

13. Test de stationnarité KPSS (1990–2023)

```
kpss_pg <- ur.kpss(pib_pg, type = "mu")
summary(kpss_pg)


#######################
# KPSS Unit Root Test #
#######################

Test is of type: mu with 4 lags.

Value of test-statistic is: 2.8352

Critical value for a significance level of:
                10pct  5pct 2.5pct  1pct
critical values 0.347 0.463  0.574 0.739
```

13.1 Test KPSS (période 1990-2023)

Le test de KPSS confirme la non-stationnarité de la série sur l'ensemble de la période :

- Test avec constante (niveau) : statistique = 2,45 (p-value < 0,01), supérieure à la valeur critique à 1 %. L'hypothèse de stationnarité autour d'une constante est rejetée.
- Test avec tendance : statistique = 0,29 (p-value < 0,01), également supérieure à la valeur critique à 1 %. La série n'est pas stationnaire, même autour d'une tendance déterministe.

Pour terminer: Comme pour la sous-période 1990-2019, la statistique de test (2,8352) est largement supérieure aux valeurs critiques à tous les seuils. L'hypothèse nulle de stationnarité est donc rejetée.

Ces résultats confirment que la série du PIB sur 1990-2023 présente une non-stationnarité marquée et contient une racine unitaire, en cohérence avec les tests de Dickey-Fuller, l'analyse graphique et les autocorrélogrammes.

14. Conclusion générale

L'inclusion de la période de la crise du COVID-19 ne modifie pas les conclusions établies sur la sous-période 1990-2019. Les analyses menées sur les deux périodes aboutissent à des résultats identiques.

Quelle que soit la période considérée, la série du PIB américain est caractérisée par :

- Une non-stationnarité marquée
- La présence d'une racine unitaire
- Une tendance déterministe observable

Ces résultats confirment la nécessité de différencier la série pour la rendre stationnaire avant toute modélisation.