IAE Nantes
Économie & Management
Pôle Sociétés

Nantes Université

Master 1 Econométrie & Statistique,
Parcours Econométrie Appliquée

Dossier de Technique de Prévision et conjoncture

Production industrielle de gaz et électricité de 2003 à 2022

Dossier Réalisé par

ANATO Diane

KOLIE Patrice

Année académique 2025-2026

Sommaire

Introduction 3
I. Analyse exploratoire 4
A. Présentation et caractérisation de la série étudiée 4
B. Détection et explications économiques des points atypiques 5
C. Statistiques descriptives sur la série corrigée 8
D. Détection de la saisonnalité 10
E. Désaisonnalisation et décomposition de la série corrigée 11
II. Prévision de la série saisonnière sur une année 13
A. Estimations et prévisions des modèles 13
B. Tableau récapitulatif et comparaison des modèles basées sur l'AIC et l'AICc 21
III. Évolution des prévisions des différents modèles graphique 21
IV. Qualité de prévision : MSE, R2OOS et graphique des CSPE 22
V. Test de précision de Diebold-Mariano 25
VI. Conclusion 27
VII. Annexe 29

Introduction

Prévoir l'évolution d'une série temporelle est essentiel dans de nombreux domaines économiques et industriels. Cela permet de prévoir les évolutions à venir à partir des observations passées, et ainsi d'aider à prendre des décisions et à planifier des actions. Dans le secteur de l'énergie, il est essentiel de prévoir efficacement la production et la consommation d'électricité et de gaz. Cela permet d'équilibrer l'offre et la demande, de mieux gérer les infrastructures et d'anticiper les futurs investissements.

Cette étude se concentre sur l'analyse et la prévision de la production industrielle du secteur des services publics (électricité et gaz) aux États-Unis. Les données proviennent du Federal Reserve System et couvrent la période de janvier 2003 à décembre 2022. Cette série a des caractéristiques typiques des données énergétiques : une forte saisonnalité liée aux variations climatiques, une tendance de long terme relativement stable, et quelques perturbations ponctuelles dues à des événements exceptionnels.

L'objectif de ce travail est double. D'abord, nous présentons la structure de la série en identifiant ses principales composantes et leur évolution dans le temps. Ensuite, nous comparons plusieurs méthodes de prévision pour trouver celle qui est la plus adaptée à cette série.

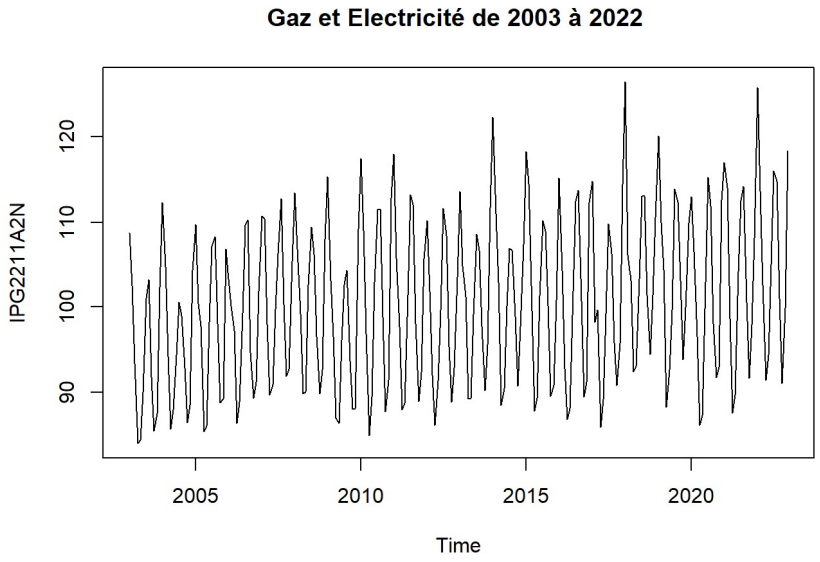
Pour cela, nous utilisons différentes techniques statistiques et économétriques. Une analyse exploratoire permet d'abord d'identifier les points inhabituels et de comprendre leurs causes économiques ou climatiques. Ensuite, la méthode de désaisonnalisation X13-SARIMA-SEATS permet d'isoler les différentes composantes de la série. Enfin, nous estimons plusieurs modèles de prévision et nous les comparons à l'aide de critères statistiques précis : critères d'information (AIC, AICc), mesures d'erreur (MSE, ROOS), et test de Diebold-Mariano.

I. Analyse exploratoire

Cette première phase consiste en une analyse exploratoire de la série temporelle afin d'en comprendre la structure et la qualité statistique. Elle permet notamment d'identifier les points atypiques et de préparer une modélisation fiable de la dynamique étudiée.

A. Présentation et caractérisation de la série étudiée

Cette étude repose sur l'analyse d'une série mensuelle relative à la production industrielle du secteur des services publics (électricité et gaz) aux États-Unis. Les données sont issues du Federal Reserve System et mises à disposition via la plateforme Federal Reserve Bank of St. Louis[1]. La période d'observation s'étend de janvier 2003 à décembre 2022, soit 240 observations. L'indice, exprimé en base 100 en 2017, retrace les variations de la production physique d'énergie, un secteur dont l'activité dépend à la fois des conditions climatiques et du niveau d'activité économique.



Le premier aperçu de notre série montre des composantes relativement stables dans le temps, notamment la saisonnalité et la tendance. Nous sommes donc face à une série stationnaire sur la période étudiée.

Nous remarquons deux phases de forte consommation d'énergie pour chaque année (comme le confirme le seasonal plot en annexe 1). La première apparaît en hiver due la demande accrue

[1] Industrial Production: Utilities: Electric and Gas Utilities (NAICS = 2211,2) (IPG2211A2N) | FRED | St. Louis Fed

de chauffage, tandis que la seconde se manifeste durant les mois d'été, notamment sous l'effet de l'augmentation de la consommation liée à la climatisation. Entre ces deux périodes, la production diminue régulièrement pendant les saisons intermédiaires (printemps et automne), ce qui donne à la série un profil cyclique annuel stable.

Au-delà de cette composante saisonnière, la série ne présente pas de changement important sur le long terme. Le niveau de production fluctue autour d'une moyenne relativement constante, avec une légère hausse observable sur l'ensemble de la période.

L'écart entre les points hauts et les points bas reste important sur toute la période, ce qui traduit une forte sensibilité de la production à certains facteurs extérieurs.

Certaines périodes se distinguent par des variations plus brutales que d'habitude, avec des pentes presque verticales. Ces phases peuvent être liées à des événements spécifiques, comme des vagues de froid, des épisodes de forte chaleur ou encore des perturbations économiques pouvant affecter temporairement la demande énergétique.

B. Détection et explications économiques des points atypiques

L'analyse des points atypiques détectés met en évidence plusieurs perturbations significatives dans la dynamique de la production d'électricité et de gaz. Ces anomalies traduisent des écarts ponctuels par rapport au comportement habituel de la série et peuvent être associées à des événements économiques ou climatiques spécifiques.

Tableau : Résumé des points atypiques

Type	individu	time	coefhat	tstat
TC	37	2006:01:00	-8.031	-3.505
AO	170	2017:02:00	-7.620	-3.584
AO	181	2018:01:00	8.015	3.820
AO	228	2021:12:00	-8.248	-3.670

Le premier point atypique identifié correspond à un changement temporaire (TC) observé en janvier 2006, caractérisé par un coefficient négatif significatif. Contrairement à un choc ponctuel et isolé, cet événement traduit une baisse de la production qui s'est prolongée sur plusieurs mois.

D'un point de vue économique et climatique, janvier 2006 a été l'un des mois les plus doux jamais enregistrés aux États-Unis, selon la National Centers for Environmental Information[2]. Plus précisément, il s'agit du mois de janvier le plus chaud observé depuis le début des relevés en 1895, avec une température moyenne de 39,5°F, soit environ 4,7°C au-dessus de la normale. Or, dans le secteur des « utilities », la production d'énergie est directement déterminée par la demande finale. Ainsi, des températures exceptionnellement douces ont entraîné une baisse importante des besoins en chauffage, aussi bien dans les logements que dans les activités industrielles.

Cette situation explique la détection d'un changement temporaire par le modèle : la baisse de la demande ne s'est pas limitée à une période très courte, mais s'est étendue sur l'ensemble du mois, voire au début du mois suivant. Il en résulte une rupture transitoire dans la dynamique saisonnière habituelle, généralement caractérisée par une forte consommation hivernale.

Par ailleurs, cette anomalie climatique a également eu des répercussions sur les marchés énergétiques. La diminution de la demande a conduit à une chute significative des prix du gaz naturel, les stocks constitués en anticipation de l'hiver n'ayant pas été mobilisés comme prévu. Cela confirme que ce point atypique ne relève pas d'une erreur de mesure, mais bien d'un choc exogène réel ayant affecté l'équilibre entre l'offre et la demande.

Le deuxième point correspond à un outlier additif (AO) observé en février 2017, caractérisé par un effet négatif marqué et significatif. Ce type de point traduit un choc brutal mais non persistant.

L'explication réside, là encore, dans une anomalie thermique majeure : février 2017 a été marqué par des températures exceptionnellement élevées sur une grande partie du territoire américain. La Réserve fédérale des États-Unis a d'ailleurs souligné dans ses rapports que la production du secteur des « utilities » avait diminué, en raison de besoins de chauffage inférieurs aux normales saisonnières[3]. En moyenne, la température aux États-Unis a atteint 41,2°F, soit 7,3°F au-dessus de la moyenne du XXe siècle. Cet épisode se classe ainsi comme le deuxième mois de février le plus chaud depuis le début des relevés climatiques sur plus d'un

[2] Rapports mensuels sur le climat | Rapport national sur le climat | Janvier 2006 | Centres nationaux d'information environnementale (NCEI)

[3] Évaluation du climat américain en février 2017 | Actualités | Centres nationaux d'information environnementale (NCEI)

siècle. De plus, près d'un quart du territoire a enregistré des niveaux de chaleur record, entraînant une baisse significative de la production d'énergie destinée au chauffage.

À l'inverse, le point atypique observé en janvier 2018 correspond à un outlier additif (AO) positif, indiquant une hausse exceptionnelle de la production. Ce type de point reflète un choc brutal et ponctuel.

L'explication repose sur un événement climatique : le phénomène de « Bomb Cyclone », une vague de froid polaire intense qui a frappé l'Est des États-Unis au début de l'année 2018. Selon la Energy Information Administration (EIA)[4], cet épisode a entraîné une demande record de gaz naturel et d'électricité, en raison de besoins de chauffage exceptionnellement élevés.

Cette situation a été amplifiée par des contraintes sur les infrastructures de transport du gaz naturel, notamment dans des régions comme la Nouvelle-Angleterre et New York. En conséquence, la production d'électricité a fortement augmenté, notamment via des sources alternatives telles que le pétrole ou les systèmes à double combustible. Par ailleurs, les prix de gros de l'électricité ont connu une hausse spectaculaire : ils ont atteint environ 247 dollars par mégawattheure en Nouvelle-Angleterre et à New York, et 262 dollars/MWh dans la région Mid-Atlantic, contre seulement 30 à 50 dollars/MWh au cours des semaines précédentes.

Dans ce contexte, les températures extrêmement basses ont généré une demande historique en énergie pour le chauffage. Le coefficient positif estimé (8,015) traduit ainsi une augmentation brutale de la production afin de répondre à cette situation exceptionnelle. La qualification en « outlier additif » est donc cohérente : il s'agit d'un pic de consommation intense mais temporaire, dont les effets se sont dissipés rapidement une fois l'épisode climatique terminé.

Enfin, l'anomalie détectée en décembre 2021 correspond à un outlier additif (AO) négatif, traduisant une baisse ponctuelle de la production. Deux facteurs principaux permettent d'expliquer ce phénomène.

D'une part, le mois de décembre 2021 a été exceptionnellement chaud aux États-Unis. Selon la National Centers for Environmental Information, la température moyenne s'est établie à 39,3°F, soit 6,7°F au-dessus de la moyenne du XXe siècle, ce qui en fait le mois de décembre le plus

[4] January's cold weather affects electricity generation mix in Northeast, Mid-Atlantic - U.S. Energy Information Administration (EIA)

chaud depuis le début des relevés climatiques sur 127 ans[5]. Cette douceur inhabituelle a fortement réduit les besoins en chauffage, entraînant mécaniquement une baisse de la production dans le secteur des « utilities ». La Réserve fédérale des États-Unis souligne d'ailleurs, dans son rapport G.17, un recul de la production énergétique imputable à cette diminution de la demande.

D'autre part, cette période coïncide avec la propagation rapide du variant Omicron de la COVID-19. Bien que l'activité économique ne se soit pas totalement arrêtée, cet épisode a pu engendrer des perturbations logistiques et des ajustements temporaires dans les chaînes d'approvisionnement énergétique. Combinés à des conditions climatiques particulièrement clémentes, ces éléments contribuent à expliquer le creux de production observé avant la reprise en 2022. La qualification en « additive outlier » est donc cohérente : il s'agit d'un choc ponctuel, lié à des facteurs exogènes, dont les effets se sont rapidement dissipés.

Par ailleurs, les statistiques associées à chaque outlier vérifient la condition |t-stat|>2,58. Ainsi, tous les outliers détectés sont statistiquement significatifs au seuil de risque de 1%. Cela confirme que ces événements ne sont pas du simple "bruit" statistique mais des ruptures réelles dans la dynamique de production.

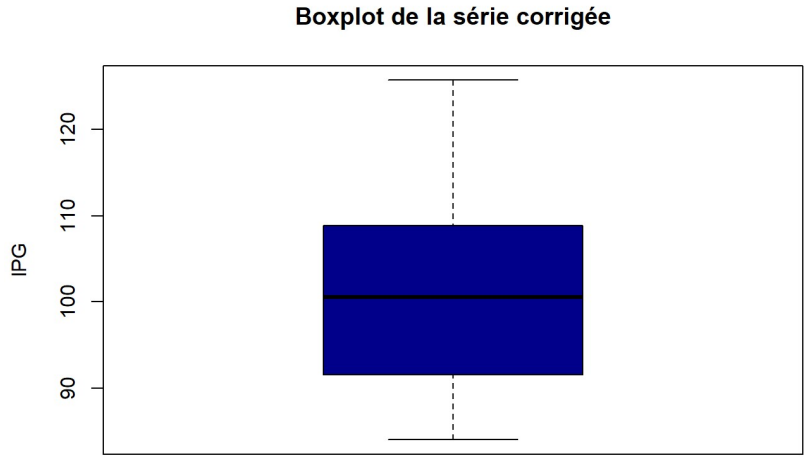
C. Statistiques descriptives sur la série corrigée

Une fois ces anomalies détectées, la série a été corrigée afin de neutraliser leur influence et d'obtenir une nouvelle série ajustée. Cette série corrigée conserve la dynamique générale de la série initiale tout en supprimant les perturbations exceptionnelles.

Tableau : Résumé des statistiques descriptives

N	240	**min**	84.04
moyenne	100.6	**max**	125.7
Ecart type	9.61	**Etendue**	41.66
median	100.49	**skew**	0.17
trimmed	100.36	**kurtosis**	-1.04
mad	12.93	**Erreur standard**	0.62

[5] Rapports mensuels sur le climat | Rapport national sur le climat | Décembre 2021 | Centres nationaux d'information environnementale (NCEI)



La série corrigée comporte 240 observations, avec une moyenne et une médiane très proche (100.6 vs 100.49). Cette proximité indique une distribution globalement symétrique, ce qui est confirmé par le coefficient d'asymétrie (skewness) légèrement positif. Cela signifie que la distribution est très légèrement étirée vers les valeurs élevées, mais reste globalement équilibrée.

La dispersion des données est modérée, comme en témoigne un écart-type de 9.61. Cela suggère que les valeurs de la série sont relativement concentrées autour de la moyenne. La moyenne tronquée, très proche de la moyenne classique, indique que les valeurs extrêmes n'influencent plus significativement la distribution.

En ce qui concerne la forme de la distribution, un kurtosis négatif indique une distribution plus aplatie que la loi normale, avec des queues plus fines et une présence moins importante de valeurs extrêmes. L'erreur standard relativement faible montre que la moyenne est estimée avec une bonne précision.

Le boxplot ne met en évidence aucune valeur atypique, aucune correction supplémentaire n'est donc nécessaire.

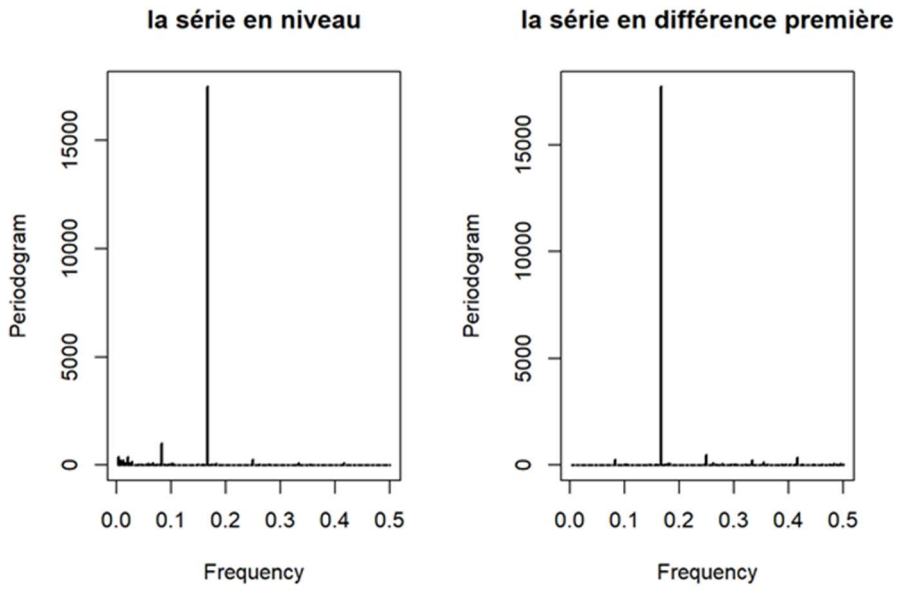
D. Détection de la saisonnalité

Tableau : récapitulatif des tests de saisonnalité

Test de saisonnalité			
Webel- Ollech		Seasonnal dummies	
stat	p-value	stat	p-value
1	0 6.43e-15	319,04	0.00

Les tests de saisonnalité appliqués à la série, à savoir le test de Webel-Ollech et celui basé sur les variables indicatrices saisonnières (seasonal dummies), convergent vers une même conclusion. D'une part, le test de Webel-Ollech donne une statistique de 1 avec une p-value faible, strictement inférieure au seuil de risque 5 %. D'autre part, le test des variables saisonnières fournit une statistique élevée associée à une p-value nulle.

Ces résultats conduisent à rejeter l'hypothèse nulle d'absence de saisonnalité dans les deux cas. La série présente donc une saisonnalité significative.



Le périodogramme de la série en niveau montre un pic très marqué à une fréquence précise. Cela correspond à un cycle d'environ six mois, ce qui indique que certaines variations se répètent régulièrement. La série présente donc une saisonnalité ou une composante cyclique.

Après une différenciation première, utilisée pour supprimer la tendance et stabiliser la moyenne, ce pic reste visible. Cela signifie que la composante périodique principale persiste et qu'elle ne provient pas seulement de la tendance, mais d'une vraie saisonnalité.

Une simple différenciation n'est donc pas suffisante. Il faut appliquer une différenciation saisonnière pour corriger cette structure et rendre la série stationnaire, condition nécessaire pour utiliser un modèle SARIMA.

E. Désaisonnalisation et décomposition de la série corrigée

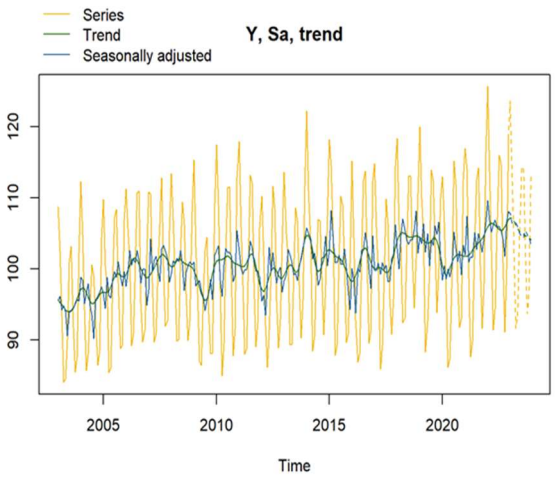
Le traitement des séries a été réalisé selon l'approche X-13ARIMA-SEATS. Une première étape de modélisation RegARIMA a permis de corriger les effets calendaires et les valeurs aberrantes. Ensuite, une décomposition complète a été effectuée afin d'obtenir la série désaisonnalisée.

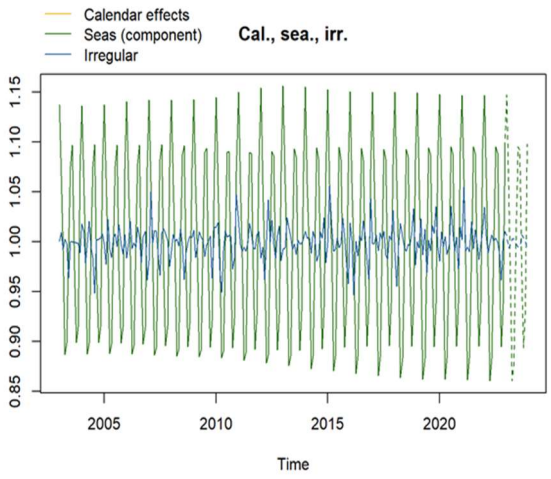
En utilisant la méthode de désaisonnalisation X13-SARIMA-SEATS, la structure du modèle ressortant est : y = regression model + arima (2, 0, 0, 0, 1, 1)

Cela nous indique alors que le modèle utilise une différenciation saisonnière et une composante MA saisonnière.

- Interprétation du schéma de décomposition

Le modèle a retenu une transformation logarithmique de la série. Ce choix implique l'adoption d'un schéma de décomposition multiplicative. Dans ce cadre, l'amplitude des fluctuations saisonnières dépend du niveau de la série : plus le niveau de la série est élevé, plus les variations saisonnières sont importantes.





Le premier graphique présente conjointement la série brute, la série désaisonnalisée et la tendance-cycle. La série brute met en évidence de fortes oscillations saisonnières caractérisées par des pics récurrents au cours de l'année. Après correction de la saisonnalité, la série désaisonnalisée apparaît plus lisse, ce qui indique que la méthode a correctement extrait la composante saisonnière. Cette série corrigée suit l'évolution centrale de la série initiale sans reproduire les fluctuations périodiques.

La composante tendance-cycle révèle l'évolution de long terme de la série. Celle-ci présente une dynamique globalement stable, avec certaines variations correspondant à des périodes de ralentissement ou de choc économique. La tendance permet ainsi d'isoler les mouvements structurels indépendamment des variations saisonnières.

Le second graphique isole les différentes composantes estimées par X13-SARIMA-SEATS. La composante saisonnière apparaît particulièrement régulière au cours du temps, traduisant la présence d'un schéma saisonnier stable. Les fluctuations observées se répètent selon une périodicité annuelle relativement constante. Cette stabilité confirme l'importance de la saisonnalité dans la dynamique de la série.

La composante irrégulière regroupe les fluctuations non expliquées par la tendance, la saisonnalité ou les effets déterministes. Certains pics observés dans cette composante correspondent à des perturbations ponctuelles ou à des valeurs atypiques déjà détectées précédemment lors de l'analyse des outliers.

- **Effets déterministes**

L'estimation du modèle ne retient pas d'effets calendaires significatifs tels que les jours ouvrables ou l'effet de Pâques. Cela signifie que les variations de la série sont principalement expliquées par la saisonnalité intrinsèque et la dynamique propre de la série plutôt que par la structure du calendrier.

La moyenne estimée est positive et significative, ce qui traduit l'existence d'une légère tendance haussière sur l'ensemble de la période étudiée.

- **Les résidus**

Les graphiques de diagnostic des résidus (en annexe 1) montrent que les résidus du modèle X13-SARIMA-SEATS se comportent globalement comme un bruit blanc, avec des autocorrélations faibles, une variance stable et une moyenne proche de zéro, ce qui indique que le modèle capture correctement la dynamique de la série. De plus, l'histogramme et le graphique Q-Q suggèrent une distribution approximativement normale des résidus, validant ainsi la qualité et la fiabilité de l'estimation du modèle.

II. Prévision de la série saisonnière sur une année

Afin de prévoir la série saisonnière corrigée des points atypiques sur un horizon d'un an, plusieurs méthodes de prévision ont été estimées et comparées. L'objectif est d'identifier la méthode la plus adaptée à la structure de la série et offrant les meilleures performances de prévision.

A. Estimations et prévisions des modèles

- **Modèle X13-SARIMA-SEATS**

La méthode X13-SARIMA-SEATS appliquée à la série retient un modèle ARIMA(2,0,1)(0,1,1)_12. La partie non saisonnière comprend deux termes autorégressifs et un terme moyenne mobile. La partie saisonnière contient une différenciation d'ordre 1 et un terme moyenne mobile saisonnière de période 12. Cela montre que la série dépend de ses valeurs passées et présente une saisonnalité annuelle.

La méthode a retenu une transformation logarithmique plutôt qu'en niveau, ce qui correspond à une structure multiplicative.

Concernant la partie régressive, seul un terme constant a été conservé. Aucun effet de jours ouvrables, d'année bissextile, de fêtes mobiles ou de points atypiques n'a été détecté. La dynamique de la série s'explique donc principalement par sa structure interne.

Tableau : récapitulatifs des coefficients estimés du X13-SARIMA-SEATS

	Estimate	Std. Error	T-stat	Pr(>|t|)
Phi(1)	0.37028	0.12732	2.908	0.004 **
Phi(2)	-0.52154	0.07068	-7.379	2.96e-12 ***
Theta(1)	0.88549	0.12805	6.915	4.66e-11 ***
BTheta(1)	-0.94334	0.03839	-24.571	< 2e-16 ***

Tous les coefficients estimés sont tous significatifs au seuil de 1 %, ce qui confirme la pertinence du modèle retenu.

- **Modèle STS**

Tableau : résumé de l'estimation du modèle STS

level	slope	seas	epsilon
4.904081	0.005222	3.005325	0.000000

Le modèle STS considère que la série observée est composée de plusieurs éléments cachés : la tendance, la saisonnalité et le bruit. Contrairement au modèle ARIMA, qui utilise surtout les valeurs passées, le modèle STS explique la série par plusieurs composantes évoluant dans le temps.

Le modèle estimé met en évidence quatre composantes : le niveau (level), la pente (slope), la saisonnalité (seas) et l'erreur irrégulière (epsilon).

La variance élevée du niveau indique que le niveau général de la série varie beaucoup au cours du temps. En revanche, la faible variance de la pente montre que le rythme d'évolution reste relativement stable, sans changements brusques de tendance. La variance de la composante saisonnière révèle également la présence de fluctuations périodiques importantes dans la série. Enfin, l'absence de bruit résiduel signifie que le modèle explique presque entièrement les variations observées. Ainsi, la dynamique de la série est principalement influencée par les variations du niveau et de la saisonnalité, tandis que la tendance demeure stable.

- **Modèle Holt-Winters**

La méthode Holt-Winters est une extension du lissage exponentiel qui prend en compte le niveau de la série, la tendance et la saisonnalité. Elle est adaptée aux séries présentant des variations saisonnières régulières. Ici, la version retenue est multiplicative, ce qui signifie que l'effet de la saisonnalité varie avec le niveau de la série.

Le modèle repose sur trois composantes : le niveau, la tendance et les coefficients saisonniers. Pour une série mensuelle, la prévision utilise les coefficients des 12 mois de l'année.

Tableau : résumé de l'estimation du Holt Winters

alpha:	beta	gamma:	a	b	s1	s2	s3
0.39123	0	0.31431	107.150	0.09457	1.13831	1.05521	0.96265

s4	s5	s6	s7	s8	s9	s10	s11	s12
0.8561	0.88169	0.99323	1.09932	1.08801	0.96771	0.88695	0.93743	1.08596

Les paramètres estimés montrent que le niveau réagit modérément aux nouvelles observations (α=0.3912). La tendance n'est pas actualisée au fil du temps (β=0), ce qui traduit une évolution relativement stable de la série. En revanche, la composante saisonnière est ajustée progressivement (γ=0.3143), permettant au modèle de prendre en compte les fluctuations périodiques de manière modérée.

Le niveau final est estimé à 107,15 et la tendance à 0,0946, ce qui traduit une légère hausse de la série sur le long terme. Les coefficients saisonniers mettent en évidence des variations selon les mois : janvier apparaît comme le mois le plus élevé, avec un niveau supérieur à la moyenne d'environ 13,8 %. Les mois de juillet et de décembre présentent également des valeurs au-dessus de la moyenne. À l'inverse, avril constitue le mois le plus faible, avec un niveau inférieur à la moyenne d'environ 14,4 %, ce qui confirme l'existence d'une saisonnalité marquée dans la série.

- **Modèle ETS**

La méthode ETS est une version moderne du lissage exponentiel. Elle permet de modéliser l'erreur, la tendance et la saisonnalité d'une série temporelle. Le modèle est choisi automatiquement selon des critères comme l'AIC ou l'AICc. Et le modèle retenu est

ETS(M,Ad,M) correspond à un modèle avec une erreur multiplicative (M), une tendance additive amortie (Ad) et une saisonnalité multiplicative (M).

Les paramètres estimés indiquent que le niveau réagit de manière modérée aux nouvelles observations (α= 0.4626), tandis que la tendance (β = 0.0001) et la saisonnalité (γ = 0.0001) évoluent très peu au cours du temps, traduisant une structure relativement stable de la série. Le paramètre d'amortissement (φ = 0.9785) montre que la tendance se prolonge dans le temps, mais avec un ralentissement progressif. Par ailleurs, le niveau initial est estimé à 94.6669 et la pente initiale à 0.1308, ce qui suggère une légère hausse de long terme. Les coefficients saisonniers révèlent également des différences selon les mois : décembre et janvier présentent des niveaux supérieurs à la moyenne, tandis qu'août et septembre enregistrent des niveaux plus faibles. Enfin, le faible écart-type résiduel (0.0257) indique que les erreurs du modèle restent limitées, ce qui traduit une bonne qualité d'ajustement.

Ainsi, le modèle ETS(M,Ad,M) est adapté à cette série, car il capte la saisonnalité, une légère tendance et des variations liées au niveau de la série.

- **Modèle TBATS**

La méthode TBATS est un modèle avancé de prévision, adapté aux séries complexes avec saisonnalité marquée, cycles longs ou comportements non linéaires. Elle combine plusieurs éléments : transformation Box-Cox, tendance amortie, saisonnalité trigonométrique et erreurs ARMA si nécessaire.

Le modèle retenu ici est TBATS(0,{0,0},0.8,{<12,5>}), il ne nécessite aucune transformation Box-Cox (λ = 0), ce qui signifie que la série est analysée dans sa forme originale. L'absence de composante ARMA ({0,0}) montre que la tendance et la saisonnalité suffisent à expliquer l'essentiel de la dynamique de la série, sans dépendance résiduelle supplémentaire. Par ailleurs, le paramètre d'amortissement de 0,8 indique que la tendance se prolonge tout en ralentissant progressivement au fil du temps, ce qui permet d'obtenir des prévisions plus réalistes à long terme. Enfin, la composante saisonnière (12,5) traduit une saisonnalité mensuelle de période 12 modélisée à l'aide de cinq harmoniques trigonométriques, offrant ainsi une représentation souple et adaptée des variations saisonnières complexes de la série.

Les paramètres estimés montrent que le niveau réagit fortement aux nouvelles observations (α = 0.6087), ce qui traduit une adaptation rapide du modèle aux variations récentes de la série. La

tendance est quant à elle révisée légèrement à la baisse (β = -0.1205), tandis que les paramètres saisonniers très faibles indiquent une saisonnalité relativement stable au cours du temps. Enfin, le faible écart-type résiduel (σ = 0.0240) témoigne d'erreurs limitées et d'une bonne qualité d'ajustement du modèle.

- **Modèle ADAM ETS**

La méthode ADAM (Augmented Dynamic Adaptive Model) constitue une extension moderne des modèles ETS, en combinant les composantes de lissage exponentiel avec la dynamique autorégressive des modèles ARIMA.

Le modèle retenu automatiquement est un ETS(ANM)+SARIMA(1,0,0)(_{12}), ce qui traduit une structure avec erreur additive, absence de tendance et saisonnalité multiplicative. La saisonnalité apparaît donc comme un élément majeur de la série. En complément, la composante SARIMA permet de prendre en compte l'autocorrélation résiduelle, notamment l'influence des valeurs passées observées aux mêmes périodes des années précédentes. L'estimation du modèle repose enfin sur une initialisation par backcasting, permettant d'améliorer l'évaluation des composantes internes du modèle.

Tableau : récapitulatif de l'estimation

alpha	gamma
0.1457	0.0434

	Lag 1	Lag12
AR(1)	0.3592	0.1102
AR(2)	NA	-0.2972

Les paramètres de persistance (alpha et gamma) estimés montrent que le modèle accorde davantage d'importance à la structure passée de la série qu'aux observations récentes. Ainsi, le niveau et la composante saisonnière évoluent de façon progressive, traduisant une dynamique relativement stable au cours du temps.

Les paramètres autorégressifs estimés sont également instructifs. Le coefficient AR(1) = 0.3592 traduit une dépendance positive de court terme entre les observations successives. Les coefficients saisonniers 0.1102 et -0.2972 montrent qu'il subsiste également une mémoire saisonnière annuelle, avec des effets différenciés selon les retards considérés.

- **Modèle ADAM ETS + ARIMA**

La méthode ADAM ETS + ARIMA est une approche hybride qui combine le lissage exponentiel et les modèles autorégressifs afin de mieux capturer la dynamique de la série. Le modèle retenu est un ETS(MAN) associé à un ARIMA (2,0,0).

La partie ETS signifie que la série est modélisée avec une erreur multiplicative (M), une tendance additive (A) et sans saisonnalité (N). L'erreur multiplicative indique que l'amplitude des fluctuations dépend du niveau de la série. La présence d'une tendance additive montre que la série suit une évolution progressive de long terme, tandis que l'absence de saisonnalité signifie qu'aucune structure saisonnière significative n'a été retenue par la procédure automatique.

La seconde partie du modèle ajoute une structure ARIMA (2,0,0), c'est-à-dire un processus autorégressif d'ordre 2 sans différenciation ni moyenne mobile. Cela signifie que les valeurs présentes de la série dépendent significativement des deux périodes passées. Cette composante permet de capter la mémoire de court terme non entièrement expliquée par le bloc ETS.

La distribution supposée pour les erreurs est une loi normale, hypothèse classique lorsque les résidus apparaissent symétriques et relativement stables. L'estimation repose sur la maximisation de la vraisemblance, avec une valeur de fonction de perte égale à 695.1628.

Les paramètres de persistance estimés (α =0.0081 et β =0.0010) indiquent que le niveau et la tendance sont très peu réactualisés au fil du temps. Le modèle privilégie donc la structure historique de long terme plutôt que les fluctuations récentes. Cela suggère une série relativement stable, dont les changements sont progressifs.

Les paramètres autorégressifs montrent une forte dépendance temporelle, avec un effet positif à court terme (AR(1) = 0.9224) et un effet correcteur négatif à deux retards (AR(2) = -0.8463). Ensemble, ils traduisent un comportement oscillatoire de la série.

- **Modèle SARIMA**

Le modèle SARIMA retenu est une extension de l'ARIMA qui permet de prendre en compte la saisonnalité des données, ce qui le rend adapté aux séries présentant des variations régulières dans le temps.

Le modèle retenu automatiquement est : ARIMA (2,0,1)(2,1,1)[12] with drift

La partie non saisonnière du modèle ARIMA (2,0,1) montre une dépendance aux valeurs passées et aux erreurs récentes, sans nécessiter de différenciation supplémentaire. Cela indique que la série est déjà globalement stationnaire après ajustement.

La composante saisonnière indique une périodicité annuelle (12 mois) avec une différenciation saisonnière d'ordre 1. Elle intègre des effets autorégressifs et de moyenne mobile saisonniers, montrant que les observations des mêmes périodes d'années précédentes influencent encore la dynamique actuelle.

La présence de drift (0.0328) indique une légère tendance moyenne positive au cours du temps, traduisant une progression globale modérée de la série une fois les effets saisonniers pris en compte.

Les coefficients estimés apportent plusieurs informations importantes. Le coefficient ar1 = -0.4394 traduit un effet correcteur de la période précédente, tandis que ar2 = 0.4953 montre une dépendance positive à deux retards. Le terme moyenne mobile ma1 = 0.9264 est élevé, ce qui souligne l'importance des chocs récents dans l'évolution de la série.

Concernant la partie saisonnière, les coefficients sar1 = 0.0866 et sar2 = -0.2941 indiquent des influences modérées des valeurs observées un et deux ans auparavant (avec décalage mensuel). Le coefficient sma1 = -0.8530 révèle quant à lui un effet saisonnier des erreurs passées, ce qui confirme l'existence d'une structure saisonnière significative.

La variance résiduelle estimée (6.142) mesure la dispersion des erreurs autour des valeurs ajustées. Une valeur relativement faible indique que le modèle explique correctement l'essentiel de la dynamique observée.

- **Modèle SSARIMA**

La méthode SSARIMA est une reformulation du modèle SARIMA dans un cadre en espace d'état, tout en conservant la prise en compte de la dépendance temporelle et de la saisonnalité. Elle offre une approche plus flexible, avec une estimation efficace et une mise à jour récursive des prévisions, facilitant ainsi la modélisation des séries temporelles.

Le modèle retenu automatiquement ici est SSARIMA(3,0,3)[1](3,0,0)[12]

La composante non saisonnière contient trois termes autorégressifs et trois termes moyenne mobile, ce qui traduit une dynamique de court terme relativement riche. L'absence de

différenciation suggère que la série est jugée suffisamment stationnaire sans transformation supplémentaire.

La partie saisonnière indique la présence de trois termes autorégressifs saisonniers de périodicité mensuelle. Cela signifie que les observations passées du même mois, observées un, deux ou trois ans auparavant, continuent d'exercer une influence sur la valeur actuelle. La mémoire saisonnière apparaît donc particulièrement importante dans cette série.

Le modèle inclut une constante (-0.5953.) qui représente le niveau moyen de long terme de la série après prise en compte des effets autorégressifs et saisonniers. Sa valeur négative traduit une légère correction à la baisse dans la dynamique moyenne du processus.

L'estimation utilise une initialisation par backcasting, méthode consistant à reconstruire les états initiaux à partir des données observées. Cette procédure améliore généralement la stabilité et la qualité de l'estimation.

Les coefficients autorégressifs non saisonniers (AR (1) = 0.2434, AR (2) = -0.1607, AR (3) = -0.0074) montrent une dépendance modérée aux trois périodes passées, avec des effets alternant entre influence positive et négative. Le troisième terme est très faible, ce qui suggère un impact limité du troisième retard.

Les coefficients autorégressifs saisonniers (AR (1) = 0.5518, AR (2) = 0.2857, AR (3) =0.1770) traduisent une persistance des effets d'une année sur l'autre. La série dépend ainsi des observations passées aux mêmes périodes, ce qui confirme la présence d'une structure saisonnière importante.

Les coefficients moyenne mobile (MA (1) = -0.0736, MA (2) = 0.0687, MA (3) = -0.0804) restent relativement faibles, ce qui signifie que les chocs passés influencent la série, mais de manière plus modérée que les composantes autorégressives.

B. Tableau récapitulatif et comparaison des modèles basées sur l'AIC et l'AICc

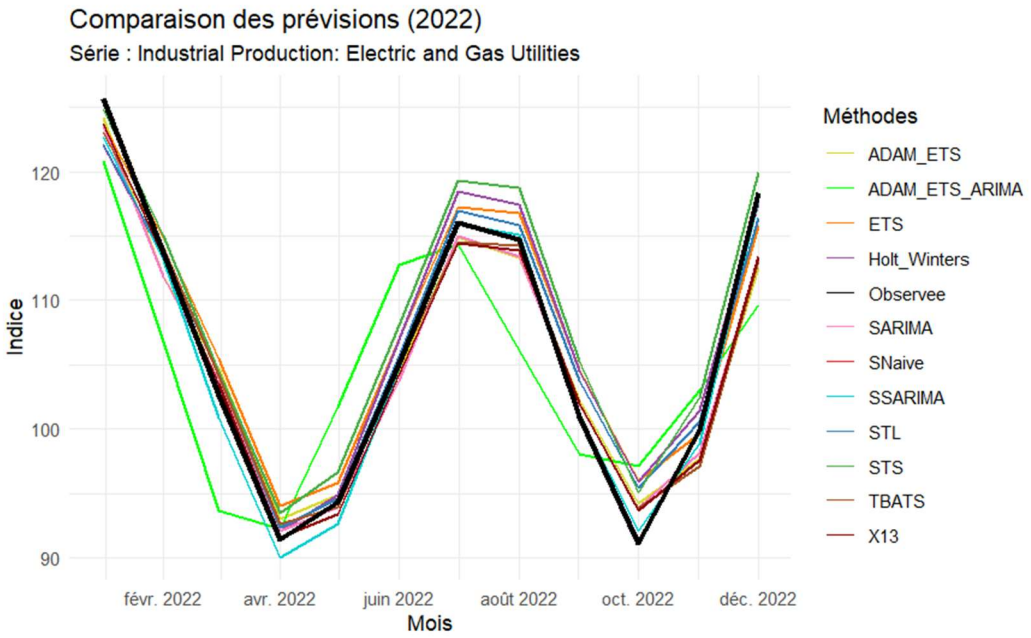
Modèles	ETS(M,Ad,M)	TBATS(0,{0,0},0.8,{<12,5>})	ETS(MNM)+SARIMA (1,0,0)1(2,0,0)12	ETS(MAN) + ARIMA(2,0,0)	ARIMA(2,0,1)(2,1,1)12	SSARIMA(3,0,3)1 (3,0,0)12
alpha	0.4626	0.6087333	0.1457	0.0081		
beta	0.0004	-0.1205263		0.0010		
gamma1	0.0004	0.000113209	0.0434			
gamma2		0.0009939364				
phi1	0.9785					
phi2						
theta						
bthteta						
lambda						
ar1			0.3592	0.9224	-0.4395	0.2434
ar2			na	-0.8463	0.4953	-0.1607
ar3						-0.0074
sar1					0.0866	
sar2					-0.2941	
sar3						
ma1					0.9265	-0.0736
ma2						0.0687
ma3						-0.0804
sma1					-0.8530	
sma2						
Distribution	Normale	Normale	Normale	Normale	Normale	Normale
AIC	1787.458	1772.383	1096.699	1400.326	1090.44	1420.229
AICc	1790.553	-	1097.060	1400.582	1091.1	1421.387

Le choix du meilleur modèle repose sur les critères AIC et AICc, qui évaluent la qualité d'ajustement tout en pénalisant les modèles trop complexes. L'AICc est particulièrement adapté aux échantillons de taille limitée. Dans les deux cas, un modèle est d'autant plus performant que ces valeurs sont faibles.

Les résultats montrent que le modèle SARIMA(2,0,1)(2,1,1)_12 présente les meilleures performances selon les critères AIC et AICc, avec des valeurs plus faibles que celles du modèle ADAM ETS + SARIMA. Le modèle SARIMA(2,0,1)(2,1,1)_12 est donc retenu comme le plus pertinent pour la série. Ce modèle combine une dynamique de court terme à travers sa partie ARIMA non saisonnière et une structure saisonnière qui capte les répétitions annuelles. La différenciation saisonnière permet en outre d'améliorer la stationnarité de la série, ce qui renforce la qualité des prévisions.

III. Évolution des prévisions des différents modèles graphique

Le graphique de comparaison des prévisions permet d'évaluer visuellement la capacité des différents modèles estimés à reproduire l'évolution réelle de la série au cours de l'année 2022.



Dans l'ensemble, tous les modèles parviennent à capter la structure saisonnière de la série (été et hiver). Cependant, des différences importantes apparaissent dans la précision des ajustements. La plupart des modèles ont tendance à surestimer le niveau de la série au moment du pic estival, ce qui suggère que les valeurs observées en 2022 ont été plus faibles que celles anticipées à partir des dynamiques historiques.

Le modèle SARIMA paraît le plus proche de la série observée au cours du premier semestre, tandis que le modèle SSARIMA semble fournir les prévisions les plus proches durant le second semestre, ces constats sont cohérents avec les visualisations fournies en annexe2.

À l'inverse, certains modèles comme SNaive ou ADAM ETS+ARIMA s'éloignent davantage des valeurs observées, notamment en fin de période. Cela traduit une moins bonne capacité d'adaptation aux changements récents de la dynamique de la série.

Enfin, on observe qu'à la fin de l'année 2022, la majorité des modèles anticipent une hausse plus marquée que celle réellement observée. Ce décalage suggère l'existence d'une volatilité inhabituelle ou d'un choc conjoncturel ayant rendu les prévisions plus difficiles sur cette période.

IV. Qualité de prévision : MSE, R2OOS et graphique des CSPE

Afin d'évaluer la qualité des prévisions des modèles, nous avons réestimé ces derniers sur une période allant de janvier 2003 à décembre 2021, puis effectué les prévisions sur l'année 2022.

Tableau : synthèse des indicateurs MSE et R^2OOS

Modèles	MSE	R2OOS
ETS	4.998542	0.5969449
SARIMA	6.489821	0.4766963
STL	6.834617	0.4488938
Holt-Winters	7.133198	0.4248179
STS	7.469897	0.3976683
X13-SARIMA-SEATS	7.511940	0.3942782
ADAM ETS	7.719449	0.3775459
TBATS	9.901930	0.2015625
SNaive	12.401634	0.0000000
SSARIMA	19.867490	-0.6020058
ADAM ETS+ARIMA	29.452480	-1.3748870

Le tableau présente les performances des différents modèles de prévision à partir de deux indicateurs : le MSE (*Mean Squared Error*) et le coefficient de détermination hors échantillon R2OOS (*Out-of-Sample R^2*).

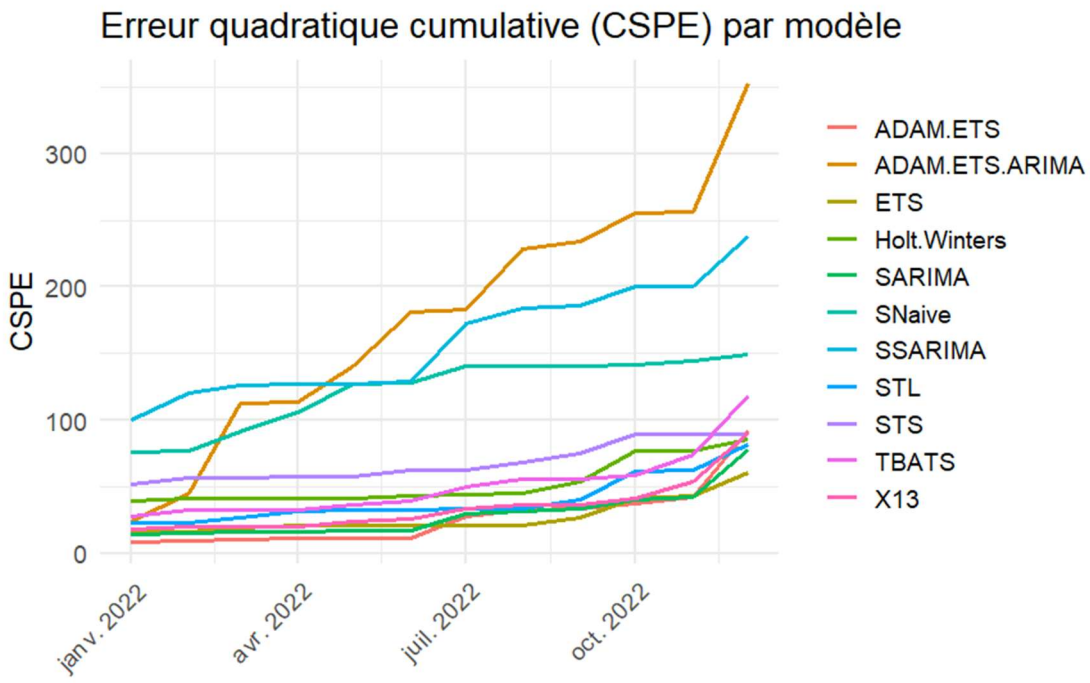
Le MSE mesure l'erreur moyenne de prévision : plus il est faible, meilleure est la précision du modèle. Le R2OOS mesure la capacité du modèle à améliorer les prévisions par rapport à un modèle de référence naïf saisonnier. Une valeur proche de 1 indique une forte capacité prédictive, tandis qu'une valeur négative signifie que le modèle est moins performant que le benchmark.

Le modèle ETS apparaît comme le modèle le plus performant parmi l'ensemble des méthodes testées. Il présente le MSE le plus faible ainsi que le R2OOS le plus élevé. Cela signifie qu'il réduit considérablement l'erreur de prévision par rapport au benchmark saisonnier et qu'il capte efficacement la dynamique de la série. La bonne performance du modèle ETS suggère que la série possède une structure dominée par des composantes de niveau, de tendance et de saisonnalité relativement stables.

Le modèle SARIMA présente de bonnes performances après ETS, indiquant que la structure autorégressive de la série est importante. Les modèles STL et Holt-Winters donnent également des résultats satisfaisants, confirmant la présence d'une saisonnalité marquée.

Les modèles STS, X13-SARIMA-SEATS et ADAM ETS obtiennent des performances intermédiaires, tandis que TBATS semble souffrir d'un surajustement. Enfin, les modèles SSARIMA et ADAM ETS+ARIMA affichent des performances inférieures au benchmark SNaive, traduisant une mauvaise adaptation à la série étudiée.

- **Erreur quadratique cumulative CSPE**



Le graphique de la CSPE (*Cumulative Squared Prediction Error*) permet d'analyser l'évolution cumulée des erreurs de prévision au cours du temps. Contrairement au MSE, qui fournit une mesure globale de l'erreur, la CSPE met en évidence les périodes durant lesquelles les modèles perdent en précision.

Les résultats montrent que les modèles ETS, ADAM ETS et SARIMA présentent les meilleures performances. Leurs courbes restent relativement faibles et stables sur l'ensemble de la période, ce qui traduit une bonne capacité prédictive et une accumulation limitée des erreurs.

À l'inverse, les modèles ADAM ETS+ARIMA et SSARIMA affichent une forte hausse de la CSPE. Leurs courbes augmentent rapidement, indiquant une accumulation importante des

erreurs de prévision et une moins bonne adaptation à la dynamique de la série. Ces constats sont cohérents avec les visualisations fournies en annexe 3.

La pente des courbes fournit également des informations importantes. Une évolution progressive traduit des erreurs faibles et relativement stables, tandis que des hausses brusques signalent des erreurs importantes à certaines périodes. On observe notamment une augmentation plus marquée des erreurs vers la fin de l'année 2022 pour la plupart des modèles, ce qui suggère un changement de dynamique ou un choc ayant rendu la série plus difficile à prévoir.

Enfin, la comparaison avec le benchmark SNaive montre que les modèles dont la courbe reste en dessous de celle du benchmark améliorent effectivement les prévisions. À l'inverse, les modèles situés au-dessus du benchmark présentent des performances inférieures à une méthode naïve saisonnière.

V. Test de précision de Diebold-Mariano

Afin d'évaluer la qualité des prévisions, nous avons constitué un échantillon d'apprentissage (train) en retirant la dernière année de la base initiale, soit 2022. Cette année a été conservée comme période de test. Les modèles ont ensuite été estimés sur l'échantillon train, puis utilisés pour prévoir les douze mois de l'année 2022. Les prévisions obtenues ont été comparées aux valeurs réellement observées afin d'évaluer leur performance.

Pour identifier les modèles les plus performants, nous avons appliqué le test de Diebold-Mariano en version unilatérale (option *"less"*). Ce test permet de vérifier si un modèle produit des erreurs de prévision significativement plus faibles que celles du modèle de référence AR(1). L'hypothèse nulle suppose une précision équivalente entre les modèles, tandis que l'hypothèse alternative considère que le modèle testé est meilleur que le benchmark.

Tableau : résumé du test de Diebold Mariano

Modèles	Statistique_DM	p-value
ETS	-3.357	0.0032
HW	-3.337	0.0033
STS	-3.336	0.0033
TBATS	-3.398	0.0030
SARIMA	-3.457	0.0027
SSARIMA	-3.431	0.0028
STL	-3.331	0.0033
SNaive	-3.242	0.0039
X13-SARIMA-SEATS	-3.402	0.0030
ADAM_ETS	-3.472	0.0026
ADAM_ETS_ARIMA	-2.681	0.0107

Les p-values obtenues indiquent que l'ensemble des modèles avancés surperforment significativement le modèle de référence AR(1) ($p < 0,05$). Cela met en évidence les limites d'un modèle autorégressif simple pour la prévision d'une série mensuelle à forte composante saisonnière. Parmi les méthodes testées, les modèles les plus performants sont ceux présentant les p-values les plus faibles et des statistiques de Diebold-Mariano les plus négatives.

En particulier, le modèle ADAM_ETS_SARIMA, bien qu'améliorant déjà nettement le benchmark AR(1), affiche une performance plus modérée comparativement aux meilleurs modèles (DM = -2.6813, p = 0.01068).

Globalement, les résultats montrent que toutes les approches avancées apportent une amélioration significative des performances de prévision, avec une supériorité notable du modèle ADAM_ETS selon le test de Diebold-Mariano (p-value = 0.002617), suivi de près par les modèles SARIMA et SSARIMA. Ce résultat confirme la pertinence des méthodes avancées pour la modélisation de cette série temporelle saisonnière.

Conclusion

L'objectif de cette étude était double : analyser la structure de la production industrielle d'électricité et de gaz aux États-Unis, à partir de données mensuelles allant de janvier 2003 à décembre 2022, et identifier la meilleure méthode de prévision pour cette série.

L'analyse exploratoire a mis en évidence une forte saisonnalité, avec deux pics de consommation chaque année : un en hiver et un en été. Quatre valeurs atypiques ont également été détectées : en janvier 2006, février 2017, janvier 2018 et décembre 2021. Ces anomalies semblent liées à des événements climatiques exceptionnels. Cela montre que la production d'énergie dépend fortement des conditions météorologiques, ce qui peut compliquer les prévisions à court terme.

La méthode X13-SARIMA-SEATS a permis de séparer les différentes composantes de la série. Le modèle retenu est un ARIMA(2,0,1)(0,1,1)(_{12}). Ce résultat montre la présence d'une dynamique de court terme ainsi qu'une forte composante saisonnière. La transformation logarithmique indique aussi que la saisonnalité est multiplicative : les variations saisonnières augmentent avec le niveau de la série.

La comparaison des différentes méthodes de prévision sur l'année 2022 montre que les résultats changent selon le critère utilisé. D'après les critères d'information AIC et AICc, le meilleur modèle est SARIMA(2,0,1)(2,1,1)(_{12}), suivi du modèle ADAM ETS + SARIMA. En revanche, selon les erreurs de prévision hors échantillon (MSE et R2OOS), c'est le modèle ETS(M,Ad,M) qui obtient les meilleurs résultats. Ce modèle semble bien adapté à la stabilité générale de la série tout en restant réactif aux évolutions récentes.

Le test de Diebold-Mariano confirme que les méthodes avancées sont globalement meilleures qu'un simple modèle AR(1). Cela souligne les limites d'un modèle autorégressif basique face à une série fortement saisonnière. Selon ce test, le modèle ADAM_ETS apparaît comme le plus performant, devant SARIMA et SSARIMA.

L'analyse de l'erreur quadratique cumulée (CSPE) montre cependant que plusieurs modèles ont rencontré des difficultés en fin d'année 2022. Les erreurs augmentent sur cette période, ce qui peut s'expliquer par une volatilité inhabituelle ou un choc imprévu.

Cette étude permet de retenir plusieurs enseignements. Les méthodes de lissage exponentiel, comme ETS et ADAM ETS, ainsi que les modèles SARIMA, sont particulièrement adaptées

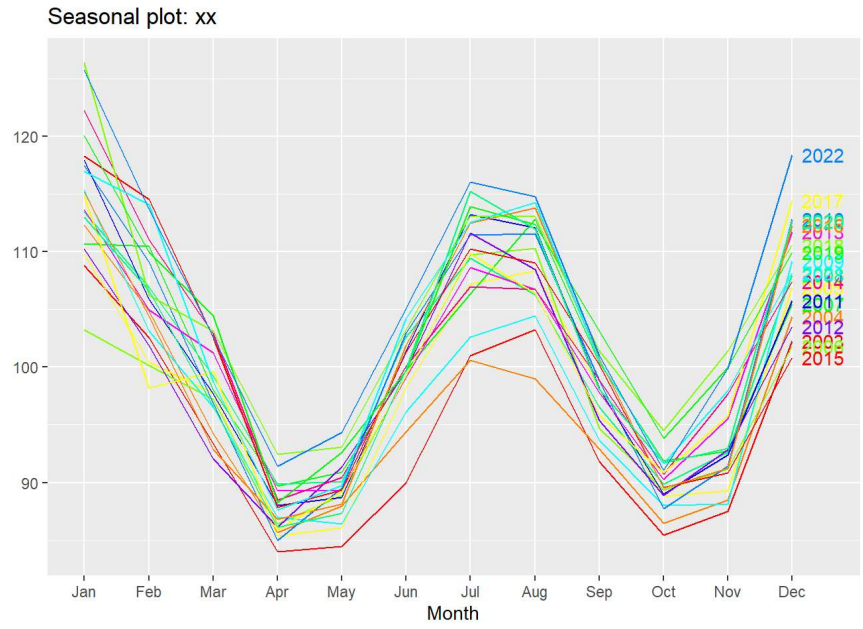
aux séries énergétiques saisonnières. Elle montre aussi qu'il est préférable d'utiliser plusieurs critères de comparaison, car le classement des modèles varie selon l'indicateur retenu.

Enfin, plusieurs pistes d'amélioration peuvent être envisagées. L'ajout de variables externes, comme la météo ou l'activité économique, pourrait améliorer la précision des prévisions. Il serait aussi possible d'utiliser des combinaisons de modèles afin de rendre les résultats plus robustes. Enfin, prolonger l'étude sur des horizons de deux ou trois ans permettrait d'évaluer la performance des modèles à moyen terme.

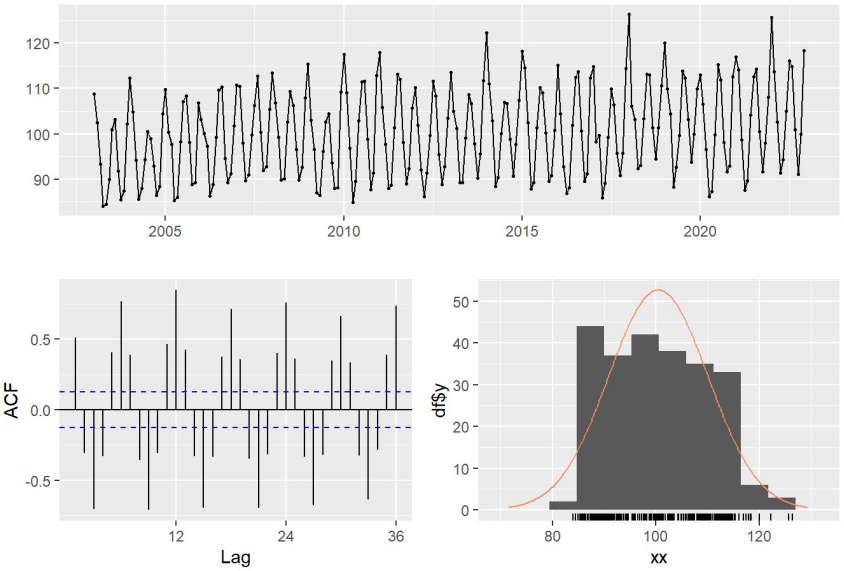
VI. Annexe

Annexe 1 : Analyse exploratoire

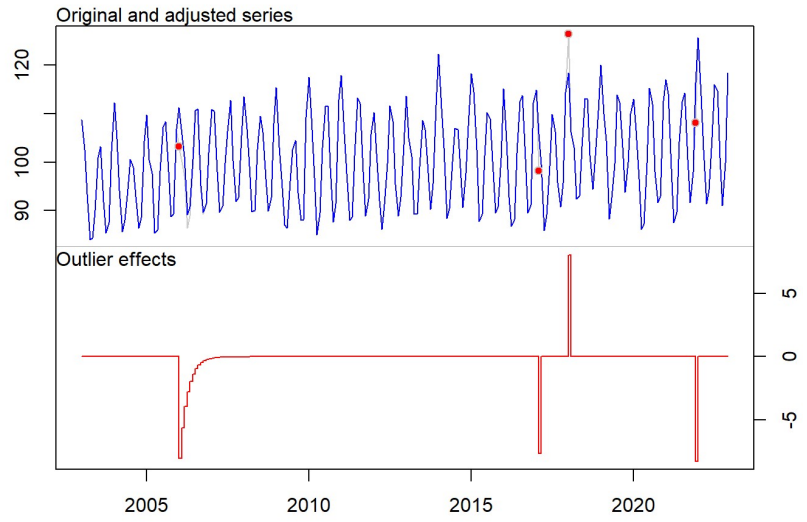
Graphique : seasonal plot



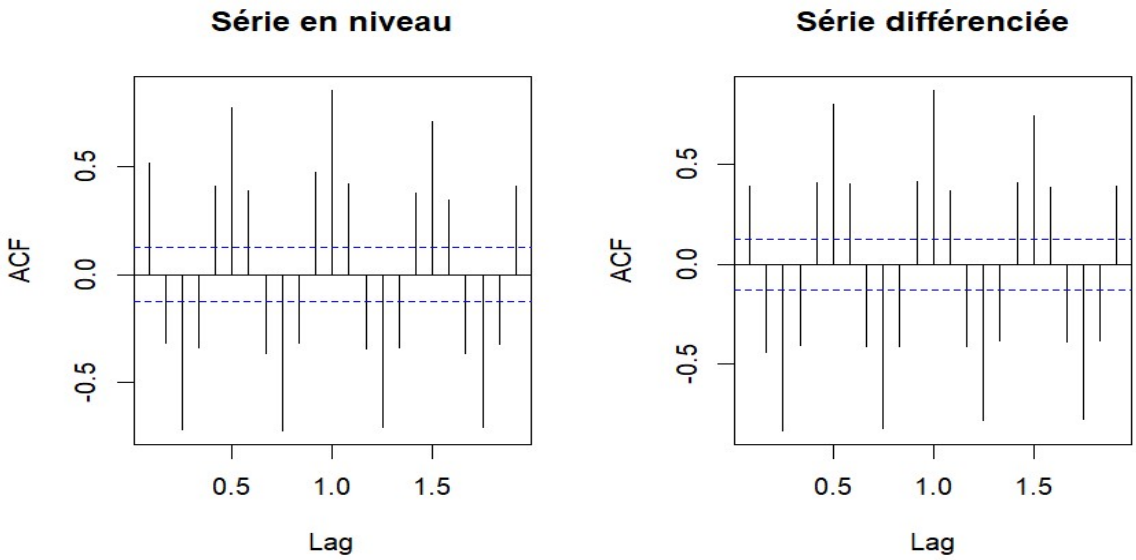
Graphique : Série de la production industrielle et son ACF



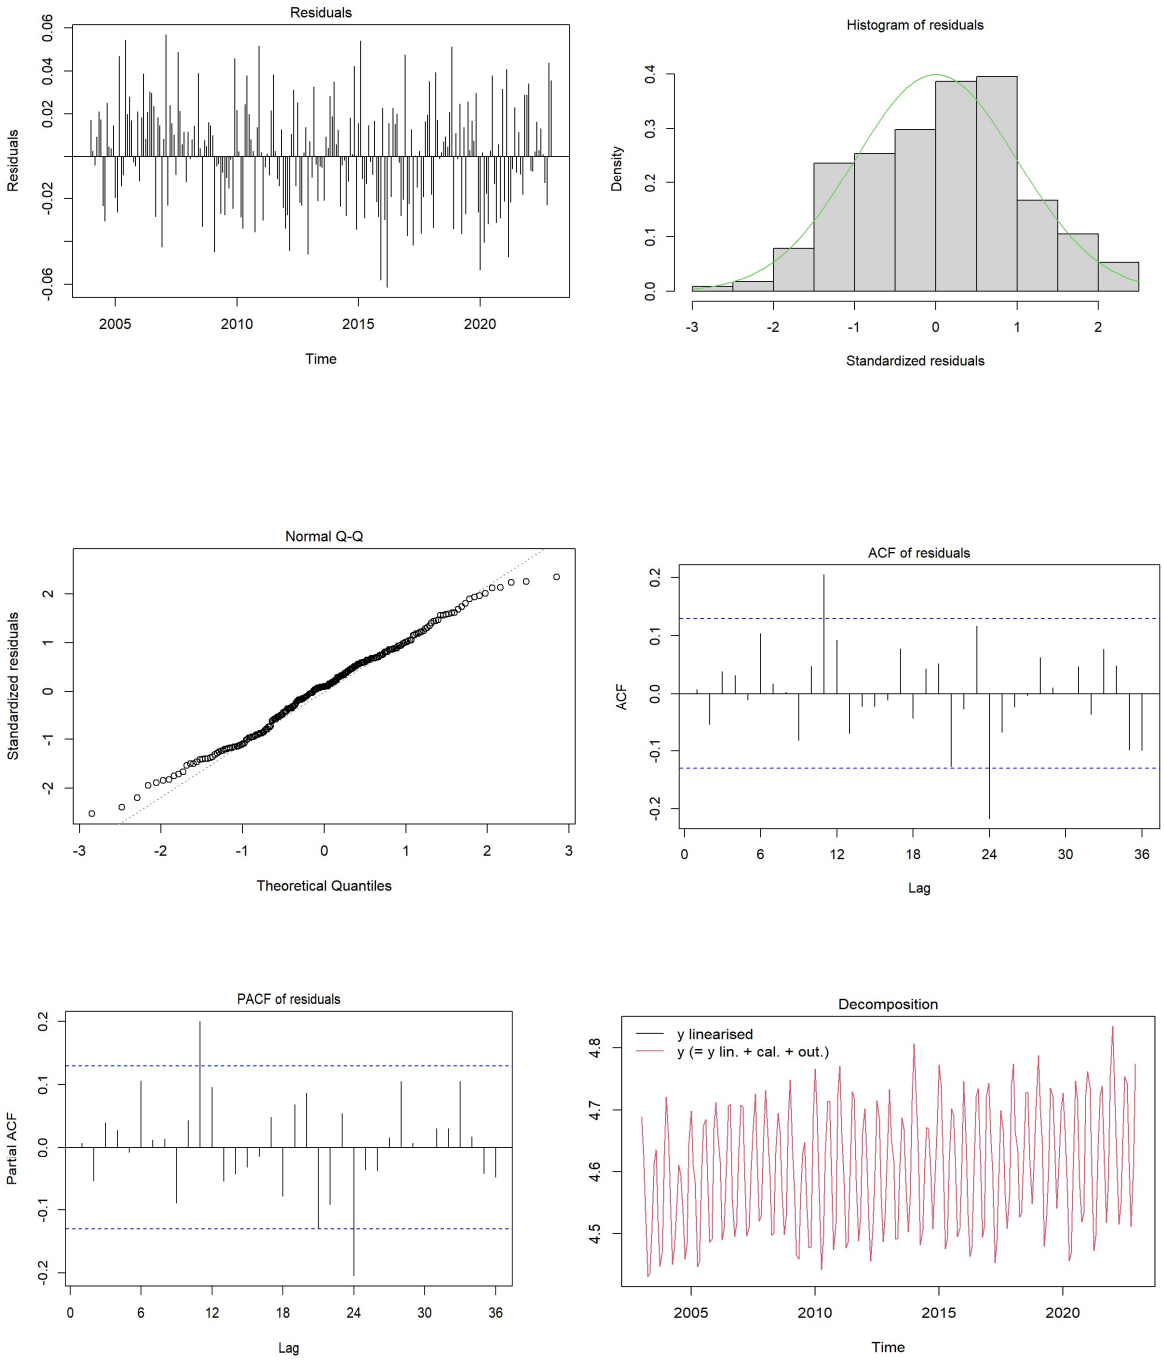
Représentation graphique des points atypiques



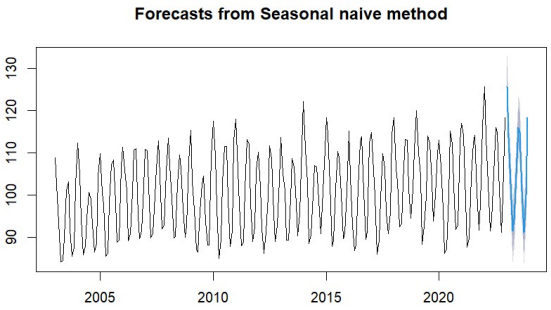
Graphique de l'ACF de la série corigée en niveau et en différence première

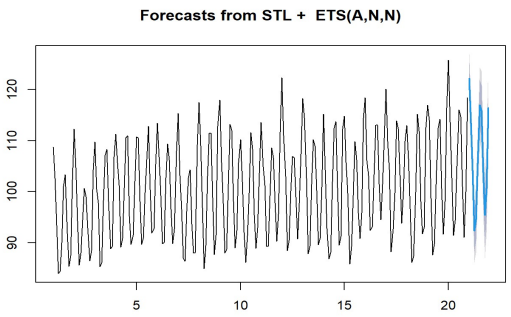


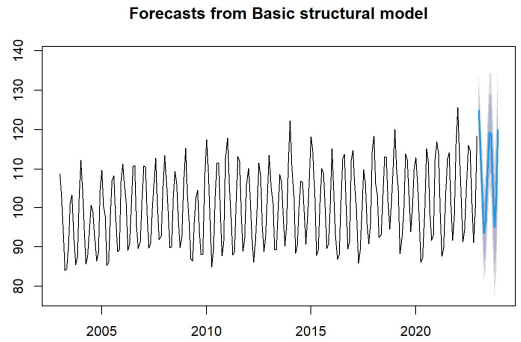
Résultats du X13-SARIMA- SATS

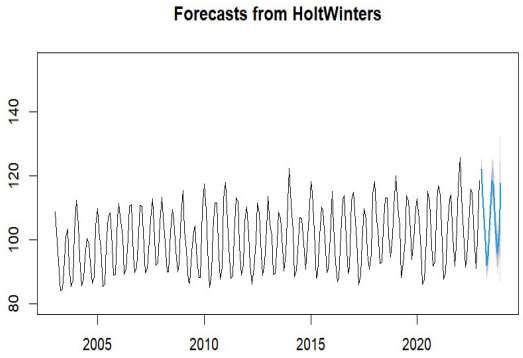


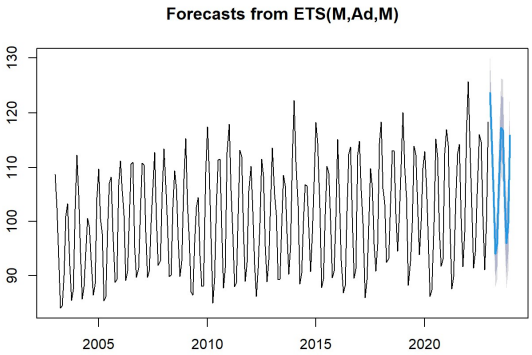
Annexe 2 : Prévision de la série saisonnière corrigée des points atypiques sur une année

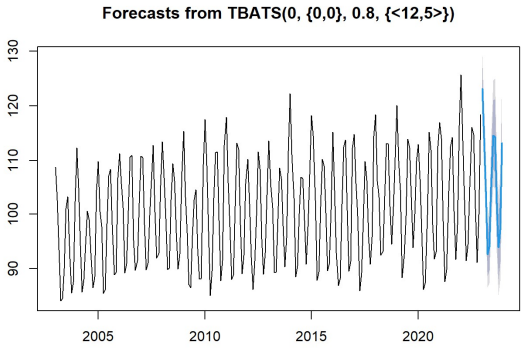

Forecasts from Seasonal naive method
90
100
110
120
130
2005
2010
2015
2020

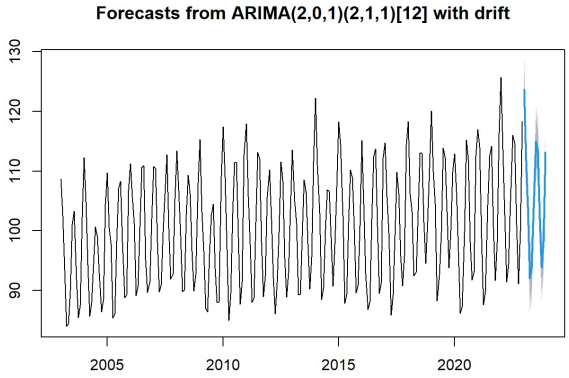

Forecasts from STL + ETS(A,N,N)
90
100
110
120
5
10
15
20

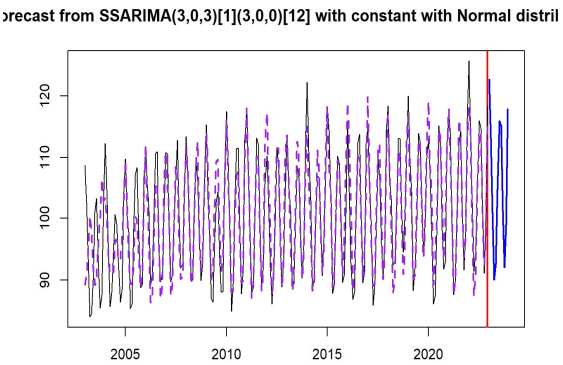

Forecasts from Basic structural model
80
90
100
110
120
130
140
2005
2010
2015
2020


Forecasts from HoltWinters
80
100
120
140
2005
2010
2015
2020

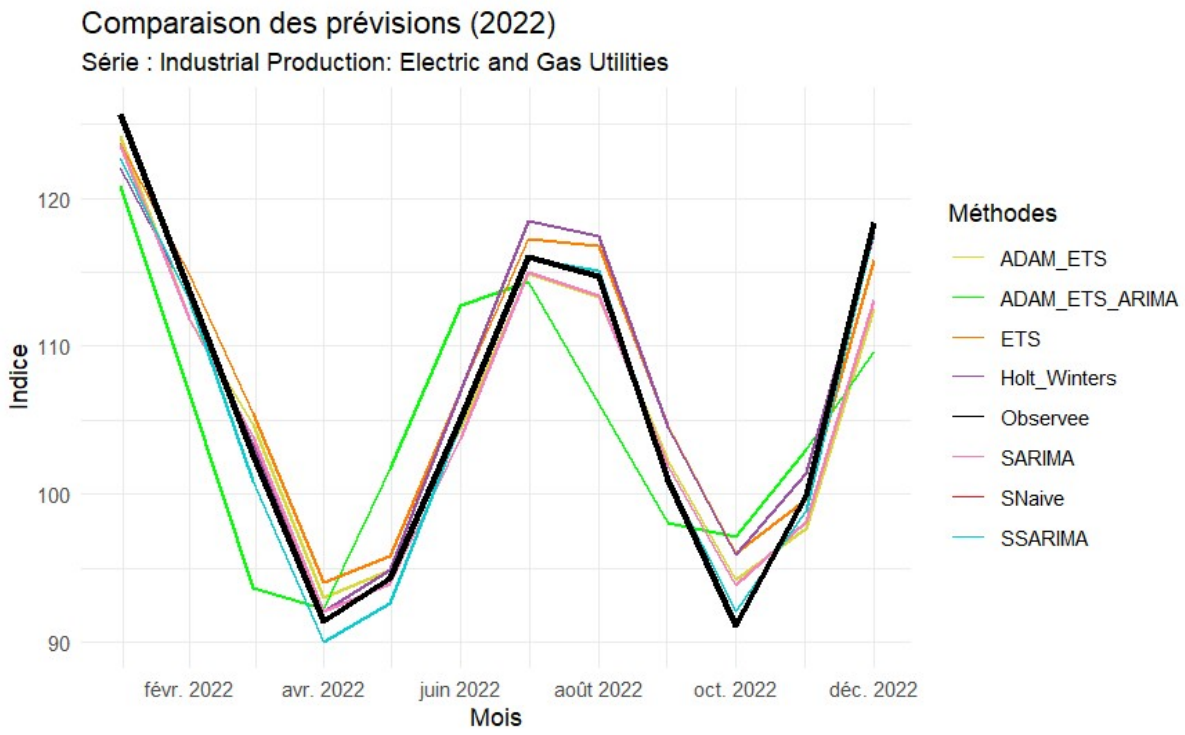

Forecasts from ETS(M,Ad,M)
90
100
110
120
130
2005
2010
2015
2020


Forecasts from TBATS(0, {0,0}, 0.8, {<12,5>})
90
100
110
120
130
2005
2010
2015
2020


Forecasts from ARIMA(2,0,1)(2,1,1)[12] with drift
90
100
110
120
130
2005
2010
2015
2020


orecast from SSARIMA(3,0,3)[1](3,0,0)[12] with constant with Normal distril
90
100
110
120
2005
2010
2015
2020

Graphique de prévision de 2022 de quelques modèles



Annexe3 : Qualité de prévision

Graphique du CSPE avec quelques modèles :

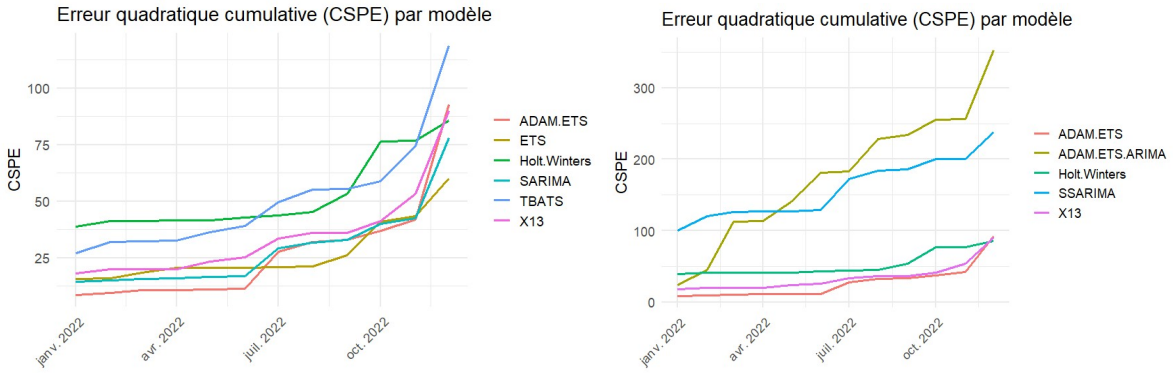


Table des matières

Introduction 3
I. Analyse exploratoire 4
A. Présentation et caractérisation de la série étudiée 4
B. Détection et explications économiques des points atypiques 5
C. Statistiques descriptives sur la série corrigée 8
D. Détection de la saisonnalité 10
E. Désaisonnalisation et décomposition de la série corrigée 11
II. Prévision de la série saisonnière sur une année 13
A. Estimations et prévisions des modèles 13
- X13-SARIMA-SEATS 13
- Modèle STS 14
- Holt-Winters 15
- ETS 15
- TBATS 16
- ADAM ETS 17
- ADAM ETS + ARIMA 18
- SARIMA 18
- SSARIMA 19
B. Tableau récapitulatif et comparaison des modèles basées sur l'AIC et l'AICc 21
III. Évolution des prévisions des différents modèles graphique 21
IV. Qualité de prévision : MSE, R2OOS et graphique des CSPE 22
V. Test de précision de Diebold-Mariano 25
VI. Conclusion 27
VII. Annexe 29